Evaluación Psicológica I

Procesos, garantías y métodos · Temario SAIMAP

16 unidades sobre cómo se evalúa en psicología: concepto, historia y modelos, el proceso de evaluación y el juicio clínico, el informe, la ética y la protección de datos, la fiabilidad, la validez y la calidad de los tests, y los grandes métodos de recogida de información: entrevista, observación y autoinforme. Con recuadros de consenso y debate, mitos, claves PIR y autoevaluación.

Grado · 2.º | 16 unidades | Ampliación PIR

SAIMAP PSICOLOGÍA

Índice

Presentación **3**
Cómo está organizado 3
Criterios de rigor 3
Aviso 4

Capítulo 1 · Concepto, historia y modelos de la evaluación psicológica **5**
Unidad 1 · Qué es evaluar en psicología 5
Unidad 2 · Historia de la evaluación psicológica 12
Unidad 3 · Modelos de evaluación psicológica 19
Unidad 4 · Disyuntivas clásicas y evaluación conductual 25

Capítulo 2 · El proceso de evaluación y el informe **33**
Unidad 5 · El proceso de evaluación psicológica 33
Unidad 6 · Juicio clínico, sesgos y evaluación basada en la evidencia 40
Unidad 7 · El informe psicológico 47

Capítulo 3 · Garantías éticas y científicas **53**
Unidad 8 · Ética y deontología en la evaluación 53
Unidad 9 · Fiabilidad, error de medida y puntuaciones 60
Unidad 10 · Validez y calidad de los tests 67

Capítulo 4 · La entrevista **74**
Unidad 11 · La entrevista: concepto, clasificación y habilidades 74
Unidad 12 · El proceso y los tipos de entrevista 81

Capítulo 5 · La observación **88**
Unidad 13 · Unidades y técnicas de registro 88
Unidad 14 · Muestreo, garantías y planificación de la observación 94

Capítulo 6 · El autoinforme **101**
Unidad 15 · Fundamentos del autoinforme 101
Unidad 16 · Tipos de autoinforme 108

Apéndices **114**
Estudios y datos clave 114
Mitos y correcciones 115
Bibliografía 116
Créditos de las ilustraciones 118

Presentación

Versión 1.0 · noviembre de 2026

Este temario forma parte de **SAIMAP Psicología**, una plataforma de estudio para estudiantes de Psicología y para cualquier persona interesada en la disciplina. Cubre los contenidos de la asignatura de segundo curso *Evaluación Psicológica I* (en otros planes de estudio, *Evaluación Psicológica* o *Fundamentos de la Evaluación Psicológica*) y sirve de base a las unidades de la aplicación. Tiene un libro hermano, *Evaluación Psicológica II. Tests e instrumentos de evaluación*, dedicado a los instrumentos concretos: técnicas proyectivas, tests de inteligencia y de personalidad, evaluación neuropsicológica, intereses, actitudes y salud.

El texto es original y responde a tres preguntas:

- **Cómo se evalúa:** qué es la evaluación psicológica, de dónde viene, qué modelos la orientan, qué pasos sigue el proceso y cómo se comunica en un informe.
- **Con qué garantías:** las éticas, recogidas en el Código Deontológico y en la protección de datos, y las científicas: fiabilidad, validez, baremos y calidad de los tests.
- **Con qué métodos generales:** la entrevista, la observación y el autoinforme.

Se ha actualizado con la investigación reciente que matiza varias ideas muy repetidas. Tres ejemplos:

- La ventaja de la entrevista estructurada es real, aunque las cifras clásicas se han revisado a la baja.
- El diagnóstico clínico rutinario coincide poco con el de las entrevistas estandarizadas.
- El pensamiento en voz alta bien instruido apenas altera el proceso que se estudia.

Cómo está organizado

El temario tiene **6 capítulos y 16 unidades**. Cada unidad se divide en **4 apartados**, que corresponden a los 4 módulos de la unidad en la aplicación; el quinto módulo de la aplicación es el repaso.

Cada unidad incluye además:

- **Consenso y debate**: qué está establecido y qué sigue discutiéndose en la investigación actual.
- **Mito frecuente**: una idea popular errónea y su corrección.
- **Conceptos clave**: los términos que hay que dominar, con una definición breve.
- **Clave PIR**: qué contenidos suelen preguntarse en el examen de Psicólogo Interno Residente y qué trampas conviene evitar.
- **Autoevaluación**: cinco preguntas de tres opciones, con sus soluciones comentadas.

Criterios de rigor

- El contenido refleja el **consenso académico actual**. Cuando la ciencia no tiene una respuesta cerrada, se dice, y se presentan las posturas.
- Los estudios clásicos se presentan junto con sus **réplicas, metaanálisis y revisiones** más recientes.
- La normativa se describe según su estado a noviembre de 2026. El Código Deontológico del Psicólogo de 1987 (con sus modificaciones) sigue vigente, y el nuevo Código se presenta como lo que es: un proyecto en tramitación.

- Las cifras de los estudios son las publicadas por sus autores y se dan como aproximadas cuando así se citan en la literatura. Las figuras marcadas como esquema son ilustrativas.
- Los gráficos y esquemas son de elaboración propia. Las fotografías y grabados históricos proceden de Wikimedia Commons y llevan su atribución.
- Las fuentes principales están en la bibliografía final. No se incluye ninguna referencia que no se haya podido verificar.

Aviso

Este material tiene una finalidad exclusivamente educativa. No sustituye la evaluación ni el consejo de un profesional. SAIMAP Psicología es un proyecto independiente y no está vinculado a ninguna universidad.

Capítulo 1 · Concepto, historia y modelos de la evaluación psicológica

Antes de aprender a entrevistar, observar o interpretar una puntuación hay que saber qué significa evaluar en psicología, para qué sirve y de dónde vienen sus herramientas. Este capítulo define la disciplina y la distingue de términos cercanos, recorre su historia desde los primeros exámenes hasta las guías actuales y presenta los grandes modelos que orientan qué se evalúa y cómo.

Unidad 1 · Qué es evaluar en psicología

Objetivos: definir la evaluación psicológica y enumerar sus objetivos clásicos; distinguirla de términos afines como psicodiagnóstico, *testing*, *assessment* o evaluación de programas; reconocer sus ámbitos de aplicación y los tipos de demanda; justificar la necesidad de una evaluación multimétodo y multiinformante.

1.1 Concepto y objetivos de la evaluación psicológica

En la línea de Fernández-Ballesteros, la **evaluación psicológica** es la disciplina que explora y analiza el comportamiento de una persona o de un grupo con fines de descripción, clasificación o diagnóstico, predicción, explicación, cambio y valoración. Lo hace mediante un **proceso de toma de decisiones** que se apoya en instrumentos científicos.

La definición tiene cuatro piezas que conviene separar:

- **Qué se evalúa:** el comportamiento en sentido amplio. Incluye lo que una persona hace, piensa y siente, sus respuestas fisiológicas y sus características más estables, como las aptitudes o los rasgos.
- **A quién:** a un sujeto concreto, pero también a una pareja, una familia, un aula o un equipo de trabajo.
- **Para qué:** para responder a una pregunta y tomar una decisión. No se evalúa por evaluar.
- **Cómo:** con un procedimiento científico, que formula hipótesis, las contrasta con datos y usa instrumentos cuyas garantías se pueden comprobar.

La evaluación es a la vez una **actividad profesional** y un **campo de investigación**. El profesional la aplica para resolver casos; la investigación estudia cómo construir instrumentos, cómo combinar datos y qué errores comete quien evalúa (Unidad 6).

Los **objetivos clásicos** son seis:

Objetivo	Pregunta a la que responde	Ejemplo
Describir	¿Cómo es o qué le pasa?	Perfil de fortalezas y dificultades de un alumno
Clasificar o diagnosticar	¿A qué categoría corresponde?	Decidir si se cumplen los criterios de un trastorno
Predecir	¿Qué es probable que ocurra?	Estimar el rendimiento de un candidato en un puesto
Explicar	¿Por qué ocurre?	Identificar qué mantiene una conducta de evitación
Orientar el cambio	¿Qué conviene hacer?	Elegir los objetivos y las técnicas de una intervención

Objetivo	Pregunta a la que responde	Ejemplo
Valorar	¿Ha funcionado lo que se hizo?	Comparar las medidas antes y después del tratamiento

Los cuatro primeros pueden cerrar una evaluación por sí solos: una selección de personal termina con una predicción y una decisión. Los dos últimos aparecen cuando hay **intervención**, y convierten la evaluación en algo que acompaña todo el trabajo, desde la primera entrevista hasta el seguimiento. Esta doble vía, descriptivo-predictiva e interventivo-valorativa, organiza el proceso que se estudia en la Unidad 5.

La idea central de la definición es que evaluar es **contrastar hipótesis**. El evaluador no se limita a reunir datos: parte de una pregunta, propone explicaciones posibles y elige las técnicas que permiten ponerlas a prueba. Un minicaso lo muestra. Unos padres consultan porque su hija de nueve años «no se concentra en los deberes». Caben varias hipótesis: una dificultad de lectura que hace la tarea pesada, un problema de atención, preocupaciones por un cambio familiar o, simplemente, unos deberes demasiado largos para su edad. Cada hipótesis pide datos distintos, y sin ellas la evaluación sería una colección de pruebas sin dirección.

Por eso la evaluación no termina con una puntuación, sino con una **respuesta razonada** a la demanda, comunicada de forma comprensible (Unidad 7) y respetando las normas éticas (Unidad 8). Un error frecuente es reducir la evaluación a aplicar tests. Los tests son una herramienta dentro de un proceso que incluye entrevista, observación, formulación de hipótesis e informe, y que exige integrar información, no solo medirla.

1.2 Evaluación y términos afines

La expresión «evaluación psicológica» es relativamente reciente, y a lo largo de la historia se han usado otros nombres que se solapan con ella. Algunos se emplean a veces como sinónimos, pero cada uno tiene un origen y un alcance propios. Como muestra la figura 1.1, todos ellos ocupan una parte del territorio de la evaluación.

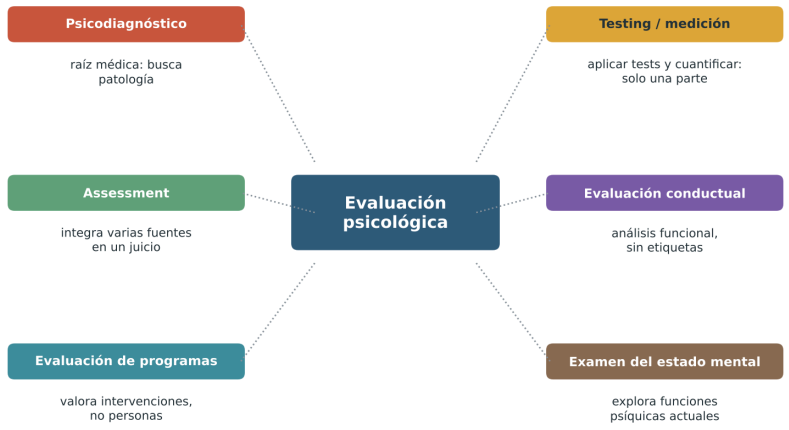


Figura 1.1. **Evaluación psicológica y términos afines.** En el centro, la evaluación psicológica; alrededor, psicodiagnóstico, *testing* o medición, *assessment*, evaluación conductual, evaluación de programas y examen del estado mental, cada uno con el rasgo que lo diferencia. Elaboración propia.

- **Psicodiagnóstico.** Tiene raíz médica y proyectiva: el término se popularizó con la obra de Rorschach (1921), que llevaba ese título. Se centra en la **patología** y en asignar una etiqueta. Es el uso más cercano a la clínica tradicional.
- **Diagnóstico psicológico.** Se usa a menudo como equivalente del anterior. Subraya el objetivo de identificar y clasificar un problema, que es solo uno de los seis objetivos vistos en el apartado 1.1.
- **Testing o medición psicológica.** Consiste en aplicar tests y cuantificar sus resultados. Es solo una parte del proceso: un test bien aplicado proporciona datos, pero no responde por sí solo a la pregunta del caso.

- **Assessment.** Término inglés para el proceso integrador que combina varias fuentes de información, interpreta los datos en su contexto y llega a conclusiones. Meyer et al. (2001) insistieron en esta diferencia: el *testing* produce puntuaciones; el *assessment* las integra con la historia, la entrevista y la observación. Es el término más próximo a «evaluación psicológica».
- **Evaluación conductual.** Procede de la terapia de conducta. Busca las relaciones funcionales entre la conducta y sus antecedentes y consecuencias, sin necesidad de etiquetas diagnósticas. Su herramienta central es el **análisis funcional** (Unidad 4). El **análisis de conducta** es su versión más estrictamente operante.
- **Evaluación de programas.** Valora **intervenciones**, no personas: si un programa de prevención del acoso escolar consigue sus objetivos o si un taller de habilidades sociales cambia algo. Comparte métodos con la evaluación psicológica, pero su objeto es distinto.
- **Valoración psicológica.** Término usado sobre todo en contextos administrativos y legales, por ejemplo para valorar la dependencia o el daño psíquico.
- **Examen psíquico o del estado mental.** Exploración clínica estructurada del estado actual de la persona: conciencia, orientación, atención, lenguaje, pensamiento, percepción, ánimo. Es una parte de la entrevista clínica y se estudia con detalle en Psicopatología.

Término	Objeto principal	Qué lo diferencia
Psicodiagnóstico	Patología	Raíz médica; busca la etiqueta
Testing o medición	Puntuaciones	Solo una fase del proceso
Assessment	Persona en su contexto	Integra varias fuentes
Evaluación conductual	Relaciones funcionales	Sin etiquetas; análisis funcional
Evaluación de programas	Intervenciones	No evalúa personas
Examen del estado mental	Estado clínico actual	Parte de la entrevista clínica

La diferencia entre estos términos no es un capricho de vocabulario. Quien entiende la evaluación como *testing* tenderá a pasar pruebas y copiar puntuaciones; quien la entiende como psicodiagnóstico, a buscar la etiqueta y detenerse ahí. La evaluación psicológica en sentido pleno incluye la medición y el diagnóstico cuando hacen falta, pero va más allá: formula hipótesis, integra fuentes y orienta decisiones.

Un ejemplo cotidiano ayuda a fijar la idea. Pesar a alguien en una báscula es medir; decir que tiene sobrepeso es clasificar; averiguar por qué ha ganado peso, qué hábitos lo mantienen y qué cambio es viable en su vida es evaluar. Las tres actividades se apoyan unas en otras, pero solo la última responde a la pregunta «¿qué hacemos?».

1.3 Ámbitos y tipos de demanda

La evaluación psicológica está presente en todos los campos profesionales de la psicología. Los principales son estos:

Ámbito	Preguntas habituales	Ejemplo
Clínico y de la salud	Diagnóstico, formulación del caso, planificación y valoración del tratamiento	Adulto con ataques de pánico que pide ayuda
Educativo	Necesidades educativas, dificultades de aprendizaje, orientación académica	Alumna con bajo rendimiento en lectura
Trabajo y organizaciones	Selección, promoción, clima laboral, orientación profesional	Proceso de selección para un puesto de atención al cliente

Ámbito	Preguntas habituales	Ejemplo
Forense	Peritajes en procesos civiles, penales, de familia o laborales	Valoración de la custodia de un menor
Neuropsicológico	Estado de las funciones cognitivas tras una lesión o en un proceso degenerativo	Quejas de memoria en una persona mayor
Social y comunitario	Necesidades de grupos y comunidades, evaluación de programas sociales	Programa municipal de apoyo a cuidadores
Deportivo	Variables psicológicas del rendimiento	Gestión de la presión en competición
Investigación	Medición de variables en estudios científicos	Ensayo que compara dos tratamientos

Cada ámbito tiene sus propios instrumentos, normas legales y estilos de informe, y varias asignaturas los tratan en profundidad: Psicología Jurídica (peritaje), Psicología del Trabajo (selección), Psicopatología (diagnóstico). Lo común a todos es la lógica del proceso: una pregunta, unas hipótesis, unos datos y una decisión.

La demanda. Toda evaluación empieza con una **demanda**: una petición, explícita o no, que alguien formula al psicólogo. Analizarla bien es el primer paso del proceso (Unidad 5), y conviene hacerse varias preguntas:

1. **Quién pide la evaluación.** Puede ser la propia persona, un familiar, un profesor, un médico, una empresa, un juzgado o una aseguradora.
2. **A quién se evalúa.** No siempre coincide con quien pide. Los padres que consultan por un hijo o la empresa que encarga una selección son **clientes**, pero la persona evaluada es otra.
3. **Qué se pregunta.** Un diagnóstico, una orientación, una predicción, un peritaje o la valoración de un cambio.
4. **Qué decisión depende del resultado.** Un tratamiento, una adaptación escolar, una contratación, una sentencia.
5. **Con qué grado de voluntariedad** acude la persona evaluada.

Estas preguntas permiten distinguir tipos de demanda. En una **demanda voluntaria**, la persona pide ayuda para sí misma y suele colaborar. En una **demanda de terceros**, la persona evaluada no ha elegido estar allí, y puede tener motivos para mostrarse mejor o peor de lo que está: un candidato quiere el puesto; una de las partes en un juicio quiere un resultado concreto. La evaluación forense y la de selección exigen, por eso, prestar especial atención a la **distorsión intencionada** de las respuestas, un tema que se retoma en el autoinforme (Unidad 15) y en las escalas de validez (Evaluación Psicológica II).

La demanda también cambia los deberes del evaluador. Quién recibe el informe, quién da el consentimiento y qué información puede comunicarse a cada parte depende de quién pide y de quién es evaluado. Si unos padres separados discrepan sobre la evaluación de su hijo, no basta con la voluntad del que llama primero. Estas cuestiones éticas se desarrollan en la Unidad 8.

Por último, la demanda inicial no siempre es la verdadera pregunta. Un profesor que deriva a un alumno «por hiperactivo» ya trae una etiqueta, y quizá lo que ocurre es que el alumno se aburre porque va por delante del resto. Reformular la demanda en términos evaluables, sin aceptar sin más la hipótesis de quien la trae, forma parte del trabajo.

1.4 Una evaluación multimétodo y multiinformante

Hay amplio consenso en que una buena evaluación debe ser **multimétodo** y **multiinformante**. Ningún método ni ninguna fuente bastan por sí solos, porque cada uno capta una parte del comportamiento y tiene sus propios errores.

Varios métodos. Las técnicas básicas de la asignatura son la **entrevista** (Unidades 11 y 12), la **observación** (Unidades 13 y 14) y el **autoinforme** (Unidades 15 y 16). A ellas se suman los **tests** de rendimiento y

personalidad (Evaluación Psicológica II), los **registros psicofisiológicos** y los **registros de productos** de la conducta, como las notas escolares o los partes de baja. Cada método tiene ventajas y sesgos característicos:

Método	Qué capta mejor	Riesgo típico
Entrevista	Historia, contexto, significado	Depende de la habilidad del entrevistador
Observación	Conducta motora en su contexto	Reactividad y errores del observador
Autoinforme	Pensamientos, emociones, experiencias privadas	Deseabilidad social y estilos de respuesta
Tests de rendimiento	Aptitudes en condiciones controladas	Situación artificial, motivación variable
Registros fisiológicos	Activación corporal	Difícil interpretación fuera del laboratorio

Usar varios métodos tiene una razón teórica además de práctica. Como se verá con el **triple sistema de respuesta** (Lang, 1968; Unidad 4), la conducta motora, la cognitiva y la fisiológica no siempre van juntas: alguien puede decir que ya no tiene miedo a volar y seguir con el corazón acelerado en el despegue.

Varios informantes. El comportamiento de una persona cambia según el contexto, y cada informante la ve en contextos diferentes. El metaanálisis de Achenbach, McConaughy y Howell (1987), con 119 estudios sobre problemas emocionales y de conducta en niños y adolescentes, encontró estos acuerdos medios:

- r = 0,60 entre **informantes similares**, por ejemplo, el padre y la madre.
- r = 0,28 entre **informantes de distinto tipo**, por ejemplo, un progenitor y un profesor.
- r = 0,22 entre el **propio sujeto** y los demás.

Estas cifras no significan que alguien mienta o se equivoque. Un niño puede ser inquieto en clase y tranquilo en casa, y un adolescente puede sentir una tristeza que no muestra a nadie. El desacuerdo es **información**: indica en qué situaciones aparece el problema y qué parte de él es visible para los demás.

Un minicaso: Pablo, de doce años, es derivado por «problemas de conducta». La tutora describe interrupciones constantes en clase; los padres no ven nada parecido en casa; el propio Pablo dice que se aburre en matemáticas porque «no se entera de nada». La observación en el aula muestra que las interrupciones se concentran en esa asignatura. Ninguna fuente por separado daba la imagen completa; juntas sugieren una hipótesis sobre una dificultad de aprendizaje que conviene contrastar.

Una evaluación multimétodo no consiste en acumular pruebas, sino en elegir las que añaden información útil a la pregunta del caso. Cada técnica nueva debería aportar algo que las anteriores no daban, una idea que la evaluación basada en la evidencia llama **validez incremental** (Hunsley y Mash; Unidad 6). Integrar datos discrepantes exige juicio, y ese juicio tiene sus propios sesgos, que se estudian en la Unidad 6.

Consenso y debate

Consenso: la evaluación psicológica es un proceso científico de contraste de hipótesis orientado a tomar decisiones, con instrumentos cuyas garantías se pueden verificar. No se reduce a aplicar tests. Debe ser multimétodo y multiinformante, porque los distintos métodos y fuentes captan facetas diferentes y el acuerdo entre informantes es solo moderado (Achenbach, McConaughy y Howell, 1987).

Debate: cómo integrar la información cuando las fuentes discrepan. No hay una regla única para decidir cuánto peso dar a cada informante, y el resultado puede depender del ámbito y de la pregunta. También persisten diferencias de uso entre «evaluación», «psicodiagnóstico» y «diagnóstico psicológico», que algunos autores tratan como sinónimos y otros distinguen con claridad.

Mito frecuente

Mito: «Evaluar en psicología es pasar tests».

Realidad: el *testing* es solo una parte del proceso. Evaluar es formular hipótesis sobre una demanda y contrastarlas integrando entrevista, observación, autoinformes, tests e información de varios informantes (Meyer et al., 2001). Una puntuación sin contexto no responde a ninguna pregunta práctica.

Conceptos clave

Concepto	Definición
Evaluación psicológica	Análisis científico del comportamiento para describir, clasificar, predecir, explicar, cambiar o valorar
Psicodiagnóstico	Término de raíz médica y proyectiva centrado en la patología y en la etiqueta diagnóstica
Testing	Aplicación de tests y cuantificación de sus resultados; una parte del proceso evaluativo
Assessment	Proceso integrador que combina varias fuentes e interpreta los datos en su contexto
Evaluación de programas	Valoración de intervenciones o programas, no de personas
Demanda	Petición que origina la evaluación; puede proceder del propio sujeto o de terceros
Evaluación multimétodo	Uso combinado de varias técnicas para compensar los sesgos de cada una
Evaluación multiinformante	Recogida de información de varias personas que ven al sujeto en contextos distintos

Clave PIR

Prioridad baja. Cuando aparece, se pregunta por los objetivos de la evaluación, la diferencia entre evaluación y *testing* o psicodiagnóstico y el principio multimétodo. Trampas típicas: tratar como sinónimos evaluación y medición, olvidar que la evaluación de programas no evalúa personas e interpretar el bajo acuerdo entre informantes como prueba de que alguno miente.

Autoevaluación

1. ¿Cuál de estos NO es uno de los objetivos clásicos de la evaluación psicológica?
a) Predecir el comportamiento futuro
b) Valorar los efectos de una intervención
c) Prescribir un tratamiento farmacológico

2. ¿Qué término se refiere a valorar intervenciones y no personas?
a) Assessment
b) Evaluación de programas
c) Psicodiagnóstico

3. El término «psicodiagnóstico» se asocia históricamente con…
a) la obra de Rorschach (1921)
b) la escala de Binet y Simon (1905)
c) el análisis conductual de Kanfer y Saslow (1965)

4. En el metaanálisis de Achenbach et al. (1987), el acuerdo medio más alto se dio entre…
a) informantes similares, como padre y madre
b) el propio sujeto y otros informantes
c) informantes de distinto tipo, como padres y profesores

5. ¿Qué relación hay entre el *testing* y la evaluación psicológica?
a) Son sinónimos en la literatura actual
b) El *testing* es solo una parte del proceso evaluativo
c) La evaluación se limita a interpretar tests

Soluciones

1 c. Prescribir fármacos no es un objetivo de la evaluación psicológica; sí lo son describir, clasificar, predecir, explicar, orientar el cambio y valorarlo. **2 b.** La evaluación de programas comparte métodos, pero su objeto son las intervenciones. **3 a.** La obra de Rorschach llevaba ese título y marcó su uso clínico y proyectivo. **4 a.** r = 0,60 entre informantes similares, frente a 0,28 entre informantes de distinto tipo y 0,22 con el propio sujeto. **5 b.** Aplicar tests produce datos que la evaluación integra con otras fuentes para responder a una demanda.

Unidad 2 · Historia de la evaluación psicológica

Objetivos: identificar los precursores precientíficos y del siglo XIX de la evaluación psicológica; explicar las aportaciones de Galton, Cattell, Binet, Stern y Terman y atribuir correctamente el CI; describir la expansión de los tests en el siglo XX, su crisis y su renovación; conocer los hitos de la evaluación psicológica en España.

2.1 Precursores: de los exámenes imperiales a Wundt

El interés por saber en qué se diferencian las personas es muy antiguo; lo reciente es estudiarlo con procedimientos sistemáticos y comprobables. Aquí se trazan solo las líneas principales; la historia general de la disciplina corresponde a Historia de la Psicología.

La Antigüedad. El antecedente más citado es el sistema de **exámenes de la China imperial** para seleccionar funcionarios. Los candidatos hacían pruebas escritas largas y exigentes. Las fuentes sitúan su origen y su consolidación en distintas dinastías, entre la Han y la Sui–Tang, por lo que no conviene dar un año único. Lo importante es la idea: decidir quién ocupa un puesto a partir de una prueba común, y no del linaje. En la Grecia clásica ya aparece la idea de que no todos sirven para lo mismo: en *La República*, Platón reparte las funciones de la ciudad según las aptitudes de cada cual. La medicina hipocrática, por su parte, explicaba el temperamento por el predominio de uno de los cuatro **humores**, una tipología que hoy carece de base fisiológica.

Huarte de San Juan. En 1575 se publicó en Baeza el *Examen de ingenios para las ciencias*, del médico Juan Huarte de San Juan. Su tesis es que cada persona tiene un **«ingenio»** particular y que conviene ajustar los estudios y la profesión a ese ingenio. Por eso se le considera precursor de la **orientación profesional** y de la **psicología diferencial**. La obra tuvo gran difusión en Europa, y Huarte es hoy el patrón de la psicología en España.

El siglo XIX. Varias líneas preparan el terreno de la evaluación científica:

- **La psiquiatría.** Esquirol (1838) distinguió la demencia, una pérdida de capacidades que se tenían, de la «idiocia», un desarrollo insuficiente desde el principio, y usó el **lenguaje** como criterio para graduar los niveles de deficiencia. Séguin, que trabajó en la educación de niños con discapacidad intelectual, ideó el **tablero de formas** (*form board*), antecedente de las pruebas manipulativas.
- **La frenología.** Para Gall, cada capacidad psíquica tenía su «órgano» en una parte del cerebro, y su desarrollo podía leerse palpando los relieves del cráneo. Era falsa, pero anticipaba la idea de inferir características psicológicas de indicadores observables.
- **La psicología experimental.** Wundt fundó en **Leipzig, en 1879**, el laboratorio que se toma como inicio de la psicología científica. Su aportación a la evaluación fue el **control riguroso de la situación de medida**: instrucciones fijas, aparatos precisos como el cronoscopio, condiciones repetibles. Pero Wundt buscaba **leyes generales** de la mente y trataba las diferencias entre personas como error. Le interesaba qué tienen en común los sujetos, no en qué se distinguen.
- **Las primeras pruebas mentales con pacientes.** Kraepelin, discípulo de Wundt y figura clave de la clasificación psiquiátrica, aplicó a pacientes pruebas de **asociación** de palabras y de **cálculo continuado**. Ebbinghaus, conocido por sus estudios de memoria, propuso una tarea de **completar frases** para evaluar a escolares.

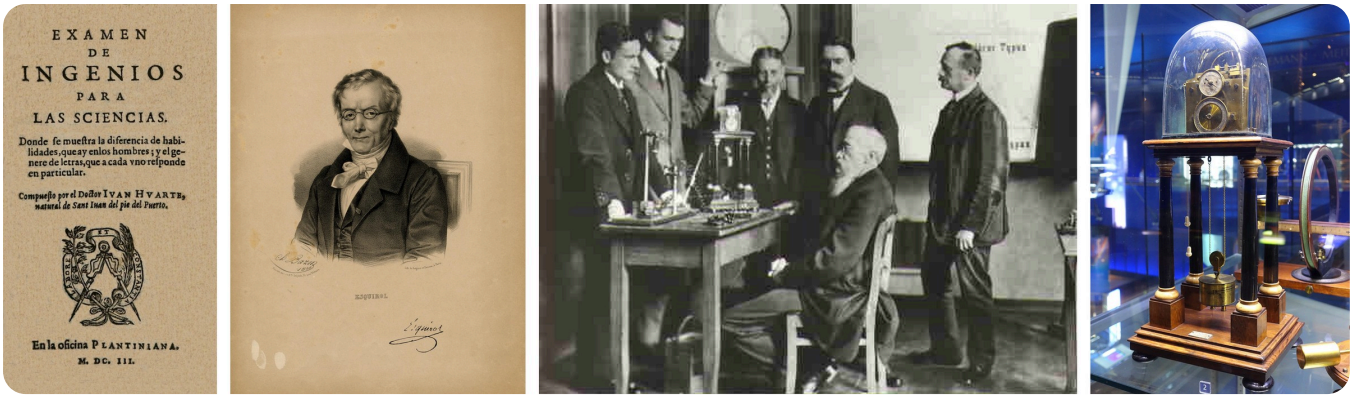


Figura 2.1. **Precursores de la evaluación psicológica.** De izquierda a derecha: portada del *Examen de ingenios para las ciencias* de Huarte de San Juan (edición de 1603); Jean-Étienne Esquirol (grabado de 1838); Wilhelm Wundt con su grupo de investigación en Leipzig (hacia 1880), y un cronoscopio de Hipp (hacia 1890), aparato usado para medir tiempos de reacción. Fuente: Wikimedia Commons; dominio público, salvo el cronoscopio (Daderot, CC0).

La figura 2.1 reúne algunos de estos antecedentes. En conjunto, cada línea aporta una pieza: la prueba común (China), el ajuste entre persona y tarea (Huarte), la gradación de capacidades (Esquirol), la situación de medida controlada (Wundt) y las primeras tareas mentales con individuos (Kraepelin, Ebbinghaus). Falta el ingrediente decisivo, el interés por las **diferencias individuales**, que llegará con Galton.

2.2 La etapa fundacional: de Galton a Terman

Entre finales del siglo XIX y comienzos del XX, la evaluación se convierte en una disciplina con métodos propios. Se suele hablar de tres «padres»: Galton aporta el método, Cattell la tecnología y el nombre, y Binet el concepto.



Figura 2.2. **Pioneros de la medición de las diferencias individuales.** Francis Galton (hacia 1890), James McKeen Cattell, Alfred Binet, William Stern y Lewis M. Terman (1923). Fuente: Wikimedia Commons; dominio público.

Francis Galton. Influido por la teoría de la evolución de Darwin, pariente suyo, Galton quiso medir en qué varían las personas y cuánto de esa variación se hereda. En **1884** abrió en Londres un **laboratorio antropométrico** donde cualquiera podía medirse estatura, peso, agudeza visual y auditiva, fuerza o tiempo de reacción. Suponía que la agudeza sensorial reflejaba la capacidad intelectual. Además, desarrolló procedimientos estadísticos para estudiar cómo varían juntas dos medidas, el germen de la correlación. Su programa estaba unido a la **eugenesia**, que él mismo promovió y que tuvo consecuencias sociales muy graves.

James McKeen Cattell. Se doctoró con Wundt en Leipzig, pero se interesó, como Galton, por las diferencias entre personas. En **1890** acuñó la expresión **«mental test»** para designar una serie de pruebas breves, sobre todo sensoriales y motoras, que aplicaba a estudiantes universitarios. El intento fracasó en lo esencial: Wissler (1901) comprobó que esas pruebas apenas se relacionaban entre sí ni con las calificaciones académicas. Las funciones simples no servían para predecir el rendimiento intelectual.

Alfred Binet. Binet sostuvo que había que medir **funciones superiores**, como la memoria, la comprensión, el juicio o el razonamiento, y no la agudeza sensorial. El Ministerio de Instrucción Pública francés necesitaba identificar a los escolares que precisaban una enseñanza especial, y Binet y su colaborador Théodore Simon

publicaron en **1905** la **escala Binet-Simon**, la primera escala práctica de inteligencia. Tenía una treintena de tareas ordenadas por dificultad, con instrucciones fijas. En las revisiones siguientes (1908 y 1911) las tareas se agruparon por edades, y el resultado se expresaba como **edad mental**: la edad cuyos niños típicos resuelven lo mismo que el evaluado.

William Stern. En **1912** propuso dividir la edad mental entre la edad cronológica. Así nació el **cociente intelectual** (CI = EM / EC), que permite comparar a niños de edades diferentes: dos años de retraso no significan lo mismo a los cinco que a los doce.

Lewis M. Terman. En **1916** publicó en la Universidad de Stanford la adaptación estadounidense de la escala, el **Stanford-Binet**, y **multiplicó el cociente por 100** para evitar decimales. Un niño de 10 años con una edad mental de 12 obtiene 12 / 10 = 1,2, es decir, un CI de 120.

Autor	Fecha	Aportación
Galton	1884	Laboratorio antropométrico; estudio cuantitativo de las diferencias individuales
Cattell	1890	Acuña «mental test»; pruebas sensoriales y motoras
Binet y Simon	1905	Primera escala práctica de inteligencia; edad mental
Stern	1912	Cociente intelectual (EM / EC)
Terman	1916	Stanford-Binet; CI multiplicado por 100

La atribución del CI es una trampa clásica. **Binet no inventó el CI**: usó la edad mental. El cociente es de Stern, y el ×100, de Terman.

En paralelo nace la aplicación clínica: Witmer abrió en **1896**, en la Universidad de Pensilvania, la primera **clínica psicológica**, dedicada a niños con problemas escolares, y acuñó la expresión «psicología clínica».

2.3 Expansión, crisis y renovación en el siglo XX

La expansión. La entrada de Estados Unidos en la Primera Guerra Mundial exigió clasificar con rapidez a cientos de miles de reclutas. Un grupo de psicólogos dirigido por Robert Yerkes elaboró en **1917** dos pruebas **colectivas**: el **Army Alpha**, verbal, para quienes sabían leer inglés, y el **Army Beta**, no verbal, para analfabetos y personas que no dominaban el idioma.



Figura 2.3. **Evaluación colectiva en el ejército de EE. UU.** Soldados estadounidenses realizando un precursor del Army Alpha en noviembre de 1917. Fuente: Departamento de Guerra de EE. UU., Wikimedia Commons; dominio público.

Como muestra la figura 2.3, la aplicación colectiva permitía evaluar a muchas personas a la vez, y tras la guerra pasó a la escuela y a la empresa. En las décadas siguientes aparecieron instrumentos que siguen siendo referencia:

- **Técnicas proyectivas:** las manchas de tinta de **Rorschach (1921)** y el **TAT** de Morgan y Murray (1935), que presentan estímulos ambiguos para que la persona proyecte en su respuesta aspectos de su personalidad.
- **Escalas de Wechsler:** el **Wechsler-Bellevue (1939)** sustituyó el cociente de edades por el **CI de desviación**, que expresa la posición de la persona respecto a su grupo de edad (media 100, desviación típica 15). Resolvía un problema del CI de cociente: en adultos, la edad mental deja de crecer y el cociente pierde sentido.
- **Inventarios de personalidad:** el **MMPI** de Hathaway y McKinley, publicado en 1943, seleccionó sus ítems por su capacidad para diferenciar grupos clínicos de personas sin trastorno.

Estos instrumentos se estudian en Evaluación Psicológica II.

La crisis. Entre los años cincuenta y setenta se acumularon críticas:

1. **Meehl (1954)**, en *Clinical versus Statistical Prediction*, mostró que la combinación estadística de datos predecía igual o mejor que el juicio de los clínicos (Unidad 6).
2. Las **técnicas proyectivas** recibieron críticas por su escasa fiabilidad y validez, y los estudios de Chapman y Chapman sobre la **correlación ilusoria** mostraron que los clínicos «veían» relaciones entre signos y diagnósticos que no existían en los datos.
3. **Mischel (1968)** cuestionó que los rasgos predijeran bien la conducta en situaciones concretas y abrió el debate persona-situación (Unidad 4).
4. **Kanfer y Saslow (1965)** propusieron el **análisis conductual** como alternativa a la clasificación diagnóstica. Nacía la **evaluación conductual**, centrada en la conducta y en sus determinantes actuales.

La renovación. La evaluación no desapareció: cambió. Ganaron peso los enfoques interactivos, que combinan persona y situación, y la evaluación cognitivo-conductual. Los tests mejoraron sus garantías con nuevos modelos psicométricos, como la teoría de respuesta al ítem, que permite los tests adaptativos informatizados. Se formalizó el propio proceso de evaluación con las **Guías para el Proceso de Evaluación (GAP)** (Fernández-Ballesteros et al., 2001), y los **Standards** de AERA, APA y NCME (2014) fijaron que lo que se valida es la interpretación de las puntuaciones para un uso concreto (Unidad 10).

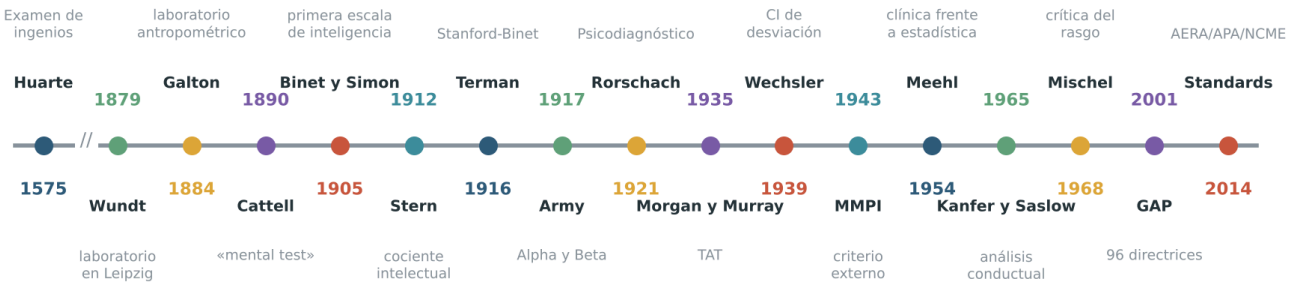


Figura 2.4. **Línea de tiempo de la evaluación psicológica.** Desde Huarte (1575) y Wundt (1879), pasando por Galton (1884), Cattell (1890), Binet-Simon (1905), Stern (1912), Terman (1916), Army Alpha y Beta (1917), Rorschach (1921), TAT (1935), Wechsler-Bellevue (1939), MMPI (1943), Meehl (1954), Kanfer y Saslow (1965) y Mischel (1968), hasta las GAP (2001) y los Standards (2014). Elaboración propia.

La figura 2.4 resume el recorrido: construcción de instrumentos, crisis de sus fundamentos y renovación centrada en las garantías y el proceso.

2.4 La evaluación psicológica en España

España aporta uno de los precursores más citados, **Huarte de San Juan (1575)**, pero la evaluación científica llegó a comienzos del siglo XX a través de la **psicotecnia**, la aplicación de la psicología a la orientación y la selección profesional.

Las primeras instituciones. En **1918–1919** se creó en Barcelona el **Institut d'Orientació Professional**. **Emili Mira i López** fue jefe de su laboratorio desde 1919 y su director desde 1927. En **1922**, Mira estudió la selección de conductores de la Compañía General de Autobuses de Barcelona, considerada el inicio de la evaluación empírica de aptitudes profesionales en España. Entre 1920 y 1928 se pusieron en marcha institutos psicotécnicos en Madrid, con **José Germain**, y en Barcelona, aunque las fuentes discrepan sobre sus fechas exactas y sus denominaciones. La Guerra Civil interrumpió este desarrollo, y Mira marchó al exilio.

La reconstrucción. Tras la guerra, Germain dirigió el **Departamento de Psicología Experimental del CSIC**, en el Instituto Luis Vives, creado en 1943 o en 1948 según la fuente. En él se formaron, entre otros, Yela, Pinillos, Siguán, Secadas, Úbeda y Forteza. En **1952** se fundó la Sociedad Española de Psicología.

La institucionalización académica y profesional:

Fecha	Hito
1953	Se crea la Escuela de Psicología y Psicotecnia de la Universidad de Madrid (BOE de 14-6-1953), que abre en el curso 1954-55
1957	Mariano Yela obtiene la cátedra de Psicología General
1957	Roberto Cuñat funda TEA Ediciones; desde 1958 su departamento de Psicología adapta tests con Yela
1968-69	Se crea la Sección de Psicología en Filosofía y Letras
1971	Primera promoción de licenciados en Psicología
1979–80	La Ley 43/1979 (BOE de 8-1-1980) crea el Colegio Oficial de Psicólogos
1987	El 22 de mayo se aprueba el Código Deontológico del Psicólogo

Un matiz sobre Yela: fue el primer catedrático de la nueva etapa, no el primero de la historia, porque a comienzos del siglo XX ya existía la cátedra de Psicología Experimental de Simarro.

La consolidación. Rocío Fernández-Ballesteros es la autora de referencia de la evaluación psicológica en España. Publicó *Psicodiagnóstico* (1980), dirigió *Introducción a la evaluación psicológica* (1992) y *Evaluación psicológica: conceptos, métodos y estudio de casos* (2004; 2.ª ed. 2011), y coordinó las GAP (2001). Su modelo del proceso de evaluación se estudia en la Unidad 5.

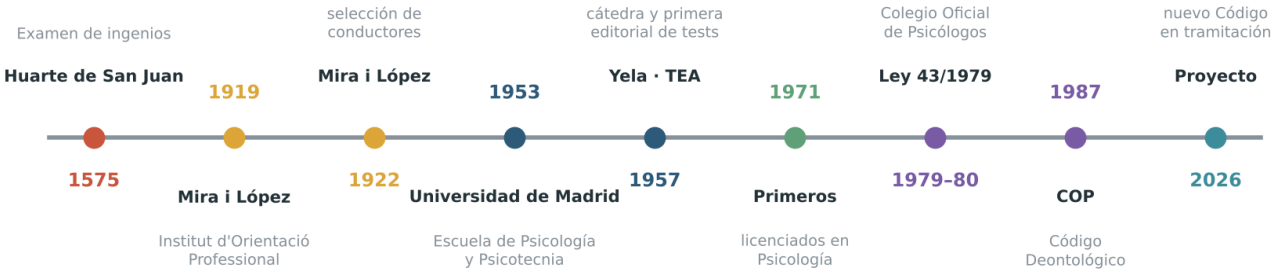


Figura 2.5. **Hitos de la evaluación psicológica en España.** Huarte (1575), Mira i López en el Institut d'Orientació Professional (1919), selección de conductores (1922), Escuela de Psicología y Psicotecnia (1953), cátedra de Yela y fundación de TEA (1957), primeros licenciados (1971), Colegio Oficial de Psicólogos (1979–80), Código Deontológico (1987) y nuevo Código en tramitación (2026). Elaboración propia.

Como recoge la figura 2.5, la evaluación sigue cambiando. En febrero de 2026 la Junta de Gobierno del Consejo General de la Psicología aprobó un proyecto de **nuevo Código Deontológico**, que ha pasado por audiencia pública y por un informe de la CNMC. En noviembre de 2026 no consta su aprobación definitiva, así que debe considerarse **en tramitación** (Unidad 8).

Consenso y debate

Consenso: la evaluación psicológica moderna nace de la línea de las diferencias individuales de Galton, Cattell y Binet, no del laboratorio de Wundt, que aportó sobre todo el control de la situación de medida. La escala de Binet y Simon (1905) fue la primera escala práctica de inteligencia; el cociente es de Stern (1912) y el ×100, de Terman (1916). La crisis de los años cincuenta a setenta (Meehl, 1954; Mischel, 1968) dio paso a una evaluación más preocupada por las garantías y por el proceso.

Debate: algunas fechas no son seguras: la dinastía de los exámenes imperiales chinos, la creación de los institutos psicotécnicos españoles o si el departamento del CSIC data de 1943 o de 1948. También se discute hasta qué punto es legítimo llamar «precursores» a autores como Huarte, con fines y métodos muy distintos de los actuales.

Mito frecuente

Mito: «Wundt fundó la evaluación psicológica».

Realidad: Wundt (Leipzig, 1879) fundó el laboratorio que inicia la psicología experimental y aportó el control de la situación de medida, pero buscaba leyes generales de la mente y trataba las diferencias individuales como error. La línea propiamente evaluativa, centrada en las diferencias entre personas, viene de Galton (1884), Cattell (1890) y Binet y Simon (1905).

Conceptos clave

Concepto	Definición
Examen de ingenios	Obra de Huarte (1575) que propone ajustar estudios y oficio al ingenio de cada persona

Concepto	Definición
Laboratorio antropométrico	Laboratorio de Galton (Londres, 1884) que medía rasgos físicos, sensoriales y motores
Mental test	Expresión acuñada por Cattell (1890) para sus pruebas breves sensoriales y motoras
Edad mental	Edad cuyos niños típicos resuelven las mismas tareas que el evaluado (escala Binet-Simon)
Cociente intelectual	Edad mental dividida por edad cronológica (Stern, 1912), multiplicada por 100 (Terman, 1916)
CI de desviación	Posición respecto al propio grupo de edad, con media 100 (Wechsler-Bellevue, 1939)
Test colectivo	Prueba aplicable a muchas personas a la vez, como el Army Alpha y el Army Beta (1917)
Psicotecnia	Aplicación de la psicología a la orientación y la selección profesional

Clave PIR

Prioridad media. Se pregunta a quién corresponde cada aportación fundacional (edad mental, CI, ×100, CI de desviación, *mental test*) y el orden cronológico de los grandes instrumentos. Trampas típicas: atribuir el CI a Binet, presentar a Wundt como fundador de la evaluación de las diferencias individuales y confundir el Army Alpha, verbal, con el Army Beta, no verbal.

Autoevaluación

1. ¿Quién acuñó la expresión «mental test» en 1890?
a) Francis Galton
b) James McKeen Cattell
c) Wilhelm Wundt

2. El cociente intelectual entendido como edad mental dividida por edad cronológica fue propuesto por…
a) Alfred Binet
b) Lewis M. Terman
c) William Stern

3. ¿Qué instrumento introdujo el CI de desviación?
a) El Wechsler-Bellevue (1939)
b) El Stanford-Binet (1916)
c) El Army Alpha (1917)

4. El *Examen de ingenios para las ciencias* (1575) de Huarte se considera precursor de…
a) la frenología
b) la psicofísica
c) la orientación profesional

5. La Escuela de Psicología y Psicotecnia de la Universidad de Madrid se creó en…
a) 1971
b) 1953
c) 1987

Soluciones

1 b. Cattell, discípulo de Wundt, acuñó la expresión; Galton había abierto su laboratorio antropométrico en 1884. **2 c.** Binet usó la edad mental; Stern propuso el cociente y Terman lo multiplicó por 100. **3 a.** Wechsler sustituyó el cociente de edades por la posición respecto al grupo de edad. **4 c.** Huarte proponía ajustar estudios y profesión al ingenio de cada persona. **5 b.** Se creó por BOE de 14-6-1953; 1971 es la primera promoción de licenciados y 1987, el Código Deontológico.

Unidad 3 · Modelos de evaluación psicológica

Objetivos: identificar qué supone cada modelo sobre los determinantes de la conducta y qué propone medir; relacionar cada modelo con sus métodos preferentes y su nivel de inferencia; distinguir la evaluación tradicional de la evaluación conductual; valorar los modelos como enfoques complementarios al servicio de la pregunta de evaluación.

3.1 El modelo psicométrico o del atributo

Toda evaluación parte de una idea, explícita o no, sobre qué causa la conducta. Esa idea decide qué variables se miden, con qué técnicas, cómo se interpretan los datos y para qué se usan. A ese conjunto de supuestos se le llama **modelo de evaluación**. Los manuales de referencia (Fernández-Ballesteros, dir., 2011) describen varios. Esta unidad presenta seis: psicométrico, médico, dinámico, fenomenológico, conductual y cognitivo-conductual, además de algunos enfoques complementarios.

El **modelo psicométrico**, también llamado **del atributo** o **correlacional**, procede de la psicología diferencial que iniciaron Galton, J. McKeen Cattell y Binet (Unidad 2). Sus supuestos básicos son tres:

1. La conducta depende sobre todo de **variables internas** del sujeto: **rasgos** de personalidad, **aptitudes** o capacidades.
2. Esos atributos son **relativamente estables** a lo largo del tiempo y de las situaciones.
3. No se pueden observar directamente, así que se **infieren** a partir de sus manifestaciones: las respuestas a un test se tratan como **signos** del atributo (apartado 4.2).

Un rasgo es, por tanto, un **constructo hipotético**: una etiqueta teórica para un patrón de conductas que tienden a aparecer juntas. Si alguien suele llegar puntual, planificar sus tareas y revisar su trabajo, se le atribuye un nivel alto de responsabilidad. El rasgo no se ve; se deduce de esa regularidad.

El método característico es el **correlacional**. Se aplican pruebas estandarizadas a muestras amplias, se estudia cómo se relacionan las puntuaciones entre sí y con criterios externos, y se construyen **baremos**. La puntuación de una persona se interpreta comparándola con la de su **grupo normativo** (interpretación **normativa**). Por eso la **fiabilidad** y la **validez** de los tests son las garantías centrales de este modelo (Unidades 9 y 10).

Sus objetivos son **describir**, **clasificar** y, sobre todo, **predecir**. Un ejemplo: un aspirante a conductor obtiene un percentil 85 en una prueba de atención sostenida; rinde mejor que el 85 % de su grupo de referencia. Si la prueba se relaciona con la siniestralidad, esa puntuación ayuda a predecir su desempeño.

Donde más pesa es en los contextos **educativo** (orientación escolar) y **organizacional** (selección de personal), aunque también es habitual en clínica y neuropsicología. Su nivel de **inferencia es alto**: del dato (respuestas a unos ítems) se salta a un atributo interno y, a menudo, a una predicción.

Puntos fuertes. Ofrece procedimientos estandarizados y replicables, comparaciones con normas poblacionales y garantías cuantificables. Es el modelo con más desarrollo técnico, y en España los tests más usados por los psicólogos son psicométricos (Muñiz, Hernández y Fernández-Hermida, 2020).

Críticas. La más influyente fue la de Mischel (1968): la conducta es menos **consistente entre situaciones** de lo que el modelo suponía, y los rasgos predicen peor la conducta concreta en una situación concreta. Esta crítica abrió el llamado **debate persona-situación** e impulsó la evaluación conductual. Además, conocer el nivel de un rasgo dice poco sobre **cómo intervenir**.

La teoría formal de los tests corresponde a Psicometría, y los tests concretos de inteligencia y personalidad, a Evaluación Psicológica II.

3.2 Los modelos médico y dinámico

Los modelos médico y dinámico comparten con el psicométrico un supuesto: las causas de la conducta están **dentro** del organismo. Difieren en qué tipo de causa interna buscan y en cómo la evalúan.

El modelo médico. Nace de la psiquiatría y traslada a la psicología la lógica de la consulta médica: detrás de lo que la persona muestra o cuenta habría un **trastorno**, a menudo con base orgánica, que hay que identificar. Lo que se recoge son **síntomas**, y lo que interesa es qué cuadro forman juntos: un **síndrome** o entidad nosológica. Cada síntoma funciona como una pista que remite a ese trastorno de fondo.

Evaluar sirve aquí para llegar a un **diagnóstico** que oriente qué tratamiento aplicar. Para ello se apoya en la **entrevista clínica** y el **examen del estado mental**, completados con escalas de síntomas y observación, y sus referencias de clasificación son el DSM y la CIE (en la actualidad, DSM-5-TR y CIE-11). El nivel de inferencia es **medio-alto**: se parte de conductas observables o referidas, pero se concluye una categoría diagnóstica.

El modelo médico aporta un **lenguaje común** entre profesionales y da acceso a tratamientos y prestaciones. Sus límites también son conocidos: dos personas con el mismo diagnóstico pueden necesitar intervenciones distintas, la etiqueta no explica por qué se mantiene un problema y puede tener efectos estigmatizantes. El Código Deontológico pide cautela con etiquetas como «normal/anormal» o «adaptado/inadaptado» (art. 12; Unidad 8). Además, la concordancia entre el diagnóstico clínico rutinario y el obtenido con entrevistas estandarizadas es baja (Rettew et al., 2009), una cuestión que se retoma en la Unidad 12. La psicopatología descriptiva y los sistemas de clasificación se estudian en Psicopatología.

El modelo dinámico. Deriva del **psicoanálisis**. La conducta se explica por el funcionamiento **intrapsíquico**: impulsos, conflictos inconscientes, mecanismos de defensa y estructura de la personalidad, con un peso especial de las experiencias infantiles. Su objeto de estudio no es la conducta en sí, sino lo que esta **expresa** de esa vida mental inconsciente.

Como lo que busca no es accesible a la conciencia, prefiere situaciones abiertas en las que la persona responda sin pautas: la conversación libre, la asociación libre y, sobre todo, las **técnicas proyectivas**, como el test de Rorschach (1921) o el TAT de Morgan y Murray (1935). La idea es que, ante un estímulo ambiguo, la persona proyecta su organización psíquica. El nivel de inferencia es **muy alto**: de la descripción de una lámina se pasa a hipótesis sobre conflictos que la persona no conoce. En la práctica psicoanalítica no hay una fase de evaluación separada del tratamiento: comprender al paciente y ayudarle a cambiar ocurren en las mismas sesiones. Por eso apenas se usa fuera de la clínica.

Sus problemas son la dificultad para someter a prueba sus inferencias y las garantías débiles de muchas interpretaciones proyectivas: los estudios sobre **correlación ilusoria** mostraron que los clínicos pueden «ver» en estas pruebas relaciones que no existen (Unidad 6). En España, ninguna técnica proyectiva figura entre los 25 tests más usados por los psicólogos (Muñiz, Hernández y Fernández-Hermida, 2020). Las técnicas proyectivas se estudian en Evaluación Psicológica II.

3.3 Los modelos fenomenológico y constructivista

Los modelos anteriores sitúan al evaluador como experto que interpreta signos. Los modelos **fenomenológico** y **constructivista** cambian el punto de partida: lo que más importa es cómo la persona **vive** e **interpreta** su propia experiencia, y nadie tiene mejor acceso a ella que la propia persona.

El modelo fenomenológico o humanista. Se apoya en la psicología humanista y, sobre todo, en la obra de Carl Rogers. Su objeto es la **experiencia subjetiva**: el autoconcepto, los valores, el significado que la persona da a lo que le ocurre. La conducta se entiende desde el marco de referencia del propio sujeto, no desde categorías externas. Por eso desconfía de las etiquetas diagnósticas y de las comparaciones con normas.

Sus técnicas buscan que la persona exprese su punto de vista con la menor distorsión posible:

- la **entrevista centrada en el cliente**, con las actitudes de empatía, aceptación y autenticidad (Unidad 11);
- los **autoinformes** sobre autoconcepto y autoestima;

- el **Q-sort** (Stephenson, 1953): la persona ordena un conjunto de frases según lo bien que la describen, de forma que se ajuste a una distribución fija. En la tradición rogeriana se usa para comparar cómo se ve la persona («yo real») con cómo le gustaría ser («yo ideal»).

El nivel de inferencia es **medio**: el evaluador interpreta poco y recoge mucho de lo que la persona dice de sí misma. El riesgo está en el otro extremo: depender casi por completo del autoinforme, con sus fuentes de error (Unidad 15).

El modelo constructivista. Su referente es la **teoría de los constructos personales** de George Kelly (1955). Kelly propuso ver a cada persona como un científico que elabora hipótesis sobre el mundo y las pone a prueba. Para anticipar los acontecimientos, cada persona usa un sistema propio de **constructos**: dimensiones bipolares con las que organiza su experiencia, como «cercano–distante» o «fiable–interesado». Dos personas pueden vivir la misma situación de forma muy distinta porque la construyen con dimensiones distintas.

La técnica característica es la **rejilla de constructos personales** (*repertory grid*). Un ejemplo simplificado: una persona escribe los nombres de figuras importantes de su vida (su madre, su pareja, un amigo, «yo actual», «yo ideal»). Se le pide que compare grupos de tres y diga en qué se parecen dos y se diferencian del tercero. Así surgen sus constructos («me escucha–va a lo suyo»). Después puntúa a cada figura en cada constructo. El resultado es una matriz que puede analizarse cuantitativamente y que muestra el **sistema de significados** de esa persona.

La rejilla ilustra que lo idiográfico no está reñido con lo cuantitativo: el contenido lo aporta la persona y el análisis puede ser numérico (apartado 4.1).

Otros enfoques. El **modelo de la psicología soviética** (Vygotsky, Luria) sostiene que las capacidades se construyen en la relación con otros y con instrumentos como el lenguaje. De ahí sale la **evaluación dinámica**: el evaluador enseña, da pistas o modela la tarea y observa cuánto mejora la persona, es decir, la distancia entre lo que resuelve sin ayuda y lo que resuelve con ella (**zona de desarrollo próximo**), que se toma como indicador de su **potencial de aprendizaje**. Pese al nombre, no tiene relación con el modelo dinámico o psicoanalítico del apartado 3.2. Sus usos más frecuentes están en la escuela y en la rehabilitación neuropsicológica.

Estos modelos recuerdan algo que vale para cualquier evaluación: el significado que la persona da a su problema forma parte del problema. Las técnicas subjetivas, como la rejilla o el Q-sort, se estudian en Evaluación Psicológica II.

3.4 Los modelos conductual y cognitivo-conductual

El modelo conductual. Surge en los años sesenta como reacción a los modelos centrados en determinantes internos. La crítica de Mischel (1968) al modelo de rasgos y la propuesta de **análisis conductual** de Kanfer y Saslow (1965) como alternativa a la clasificación diagnóstica son sus hitos de referencia. Sus supuestos cambian la pregunta de la evaluación: ya no se trata de saber **qué tiene** la persona, sino **qué hace**, **en qué situaciones** y **qué lo mantiene**.

- El objeto de evaluación es la **conducta** misma y sus **determinantes ambientales actuales**: los antecedentes que la desencadenan y las consecuencias que la mantienen.
- La respuesta se trata como **muestra** de la conducta de interés, no como signo de un atributo oculto (apartado 4.2).
- El nivel de inferencia es **bajo**: se procura describir conductas definidas operativamente y relaciones observables.
- La metodología es de inspiración **experimental**: se formulan hipótesis sobre qué controla la conducta y se comprueban, a menudo con diseños de caso único y medidas repetidas.
- La técnica preferente es la **observación directa**, junto con el **análisis funcional** (Unidad 4).
- La evaluación está unida a la **intervención**: se evalúa para decidir qué cambiar y para comprobar si el cambio se produce.

El modelo cognitivo-conductual. A partir de los años setenta, la evaluación conductual incorporó los **procesos cognitivos** (pensamientos, expectativas, atribuciones) y las **emociones** como variables que también hay que evaluar y que pueden formar parte de la cadena que mantiene un problema. Para acceder a ellas recurre a los **autorregistros**, a autoinformes de cogniciones como el ATQ (Hollon y Kendall, 1980) y a la observación. El nivel de inferencia pasa a ser **bajo-medio**, porque los pensamientos solo son accesibles a través de lo que la persona informa.

Ambos modelos usan autoinformes, pero no como indicadores de rasgos. Cuando una persona con fobia a volar responde «evito los aviones siempre que puedo», esa respuesta se toma como una **muestra** de su conducta de evitación, no como signo de un rasgo de neuroticismo. El ámbito de aplicación de estos modelos es prácticamente universal: clínico, educativo, laboral, de la salud o comunitario.

La comparación entre la **evaluación tradicional** (psicométrica, médica y dinámica) y la **evaluación conductual** es una de las disyuntivas clásicas de la disciplina:

Rasgo	Evaluación tradicional	Evaluación conductual
Determinantes	Internos y estables	Ambientales y actuales, en interacción con el organismo
Respuesta del evaluado	Signo de un atributo	Muestra del repertorio
Inferencia	Alta o muy alta	Baja
Comparación	Con un grupo normativo	Con la propia persona a lo largo del tiempo
Momento	Antes de intervenir	Antes, durante y después de intervenir

Modelo	Objeto de evaluación	Método preferente	Inferencia
Psicométrico o del atributo	Rasgos estables e internos	Tests normativos	Alta
Médico	Síntomas → entidad nosológica	Entrevista, criterios DSM/CIE	Media-alta
Dinámico	Estructuras y conflictos inconscientes	Técnicas proyectivas	Muy alta
Fenomenológico	Experiencia subjetiva, autoconcepto	Entrevista centrada en el cliente, Q-sort, autoinformes	Media
Conductual	Conducta y ambiente actual	Observación, análisis funcional	Baja
Cognitivo-conductual	Conducta, cognición y emoción	Autorregistros, autoinformes, observación	Baja-media

Figura 3.1. **Los seis modelos de evaluación.** Tabla que resume, para los modelos psicométrico, médico, dinámico, fenomenológico, conductual y cognitivo-conductual, su objeto de evaluación, su método preferente y su nivel de inferencia, que va de muy alto (dinámico) a bajo (conductual). Elaboración propia.

Como muestra la figura 3.1, los modelos se ordenan casi en un continuo de inferencia, del dinámico al conductual.

Hacia la integración. Hoy los modelos se entienden como **complementarios**. Una misma evaluación puede usar un test normativo para describir el nivel de ansiedad, una entrevista diagnóstica para decidir si hay un trastorno y un análisis funcional para planificar la intervención. El **modelo biopsicosocial** recuerda que en cualquier problema intervienen factores biológicos, psicológicos y sociales. La **evaluación basada en la evidencia** (Hunsley y Mash) pide elegir cada instrumento por su validez para el propósito concreto, su utilidad clínica y su **validez incremental**: lo que añade a la información que ya se tiene (Unidad 6).

Consenso y debate

Consenso: cada modelo parte de supuestos distintos sobre los determinantes de la conducta, y esos supuestos fijan qué se evalúa, con qué técnicas y con qué nivel de inferencia. Hoy se entienden como enfoques complementarios, y la elección de procedimientos debe basarse en su fiabilidad, validez y utilidad para la pregunta concreta, más que en la adscripción a una escuela.

Debate: el valor del diagnóstico categorial. Rettew et al. (2009), con 38 estudios, hallaron una concordancia media baja (κ = 0,27) entre el diagnóstico clínico rutinario y las entrevistas estandarizadas, aunque advierten que esto no demuestra cuál de las dos vías es peor. También sigue abierta la discusión sobre las garantías de las técnicas proyectivas del modelo dinámico.

Mito frecuente

Mito: «La evaluación conductual no usa autoinformes; solo admite la observación directa».

Realidad: la evaluación conductual usa autoinformes, entrevistas y autorregistros, pero interpreta las respuestas como muestras de conducta y no como signos de rasgos. Cone (1978) incluye la entrevista y el autoinforme entre los métodos de su cubo de evaluación conductual, y el autorregistro es una técnica central del enfoque (Korotitsch y Nelson-Gray, 1999).

Conceptos clave

Concepto	Definición
Modelo de evaluación	Conjunto de supuestos sobre qué determina la conducta, qué evaluar y con qué técnicas
Modelo psicométrico	Infiere rasgos y aptitudes estables a partir de tests y los compara con normas
Modelo médico	Evalúa síntomas para diagnosticar un trastorno que oriente el tratamiento
Modelo dinámico	Busca conflictos y estructuras inconscientes, sobre todo con técnicas proyectivas
Modelo fenomenológico	Evalúa la experiencia subjetiva y el autoconcepto desde el marco del propio sujeto
Rejilla de constructos	Técnica de Kelly que obtiene y puntúa los constructos personales de un sujeto
Modelo conductual	Evalúa la conducta y sus determinantes ambientales actuales con baja inferencia
Evaluación dinámica	Evalúa el potencial de aprendizaje con ayuda, dentro de la zona de desarrollo próximo

Clave PIR

Prioridad media. Se pregunta qué modelo corresponde a una descripción (objeto, técnica preferente o nivel de inferencia) y qué diferencia la evaluación tradicional de la conductual. La trampa típica es asociar el modelo conductual a la ausencia de autoinformes o confundir el nivel de inferencia de cada modelo. También conviene no atribuir la rejilla al modelo humanista de Rogers: es de Kelly.

Autoevaluación

1. ¿Qué modelo trata las respuestas a un test como signos de atributos internos estables y las compara con un grupo normativo?
a) El modelo conductual
b) El modelo psicométrico
c) El modelo fenomenológico

2. ¿Qué modelo presenta el nivel de inferencia más alto?
a) El modelo médico
b) El modelo cognitivo-conductual
c) El modelo dinámico

3. La rejilla de constructos personales es la técnica característica del modelo…
a) constructivista de Kelly
b) fenomenológico de Rogers
c) psicométrico de Cattell

4. Una psicóloga conductual pide a un paciente que conteste un cuestionario sobre sus conductas de evitación. Interpretará sus respuestas como…
a) signos de un rasgo de neuroticismo
b) indicadores de un conflicto inconsciente
c) muestras de su repertorio de conducta

5. ¿Qué crítica impulsó la evaluación conductual frente al modelo de rasgos?
a) La baja fiabilidad de las entrevistas libres (Rettew et al., 2009)
b) La escasa consistencia de la conducta entre situaciones (Mischel, 1968)
c) La falta de baremos en las técnicas proyectivas (Rorschach, 1921)

Soluciones

1 b. El modelo psicométrico infiere rasgos y aptitudes y usa interpretación normativa. **2 c.** El modelo dinámico infiere conflictos inconscientes a partir de respuestas a estímulos ambiguos. **3 a.** La rejilla procede de la teoría de los constructos personales de Kelly; el Q-sort es el que se asocia a la tradición rogeriana. **4 c.** La evaluación conductual usa autoinformes, pero como muestra de conducta. **5 b.** Mischel (1968) cuestionó la consistencia transituacional que suponía el modelo de rasgos.

Unidad 4 · Disyuntivas clásicas y evaluación conductual

Objetivos: explicar las principales disyuntivas de la evaluación psicológica y sus consecuencias prácticas; distinguir respuesta como signo y como muestra, y puntuación normativa, criterial e ipsativa; describir el análisis funcional y los elementos de la fórmula E-O-R-K-C; explicar el triple sistema de respuesta, la desincronía y el cubo de Cone.

4.1 Nomotético, idiográfico e idiotético; cuantitativo y cualitativo

A lo largo de su historia, la evaluación psicológica ha discutido sobre varias **disyuntivas**: pares de opciones que parecen excluirse y que, en la práctica, suelen combinarse. Conocerlas ayuda a entender por qué dos evaluadores ante el mismo caso pueden elegir procedimientos muy diferentes.

Nomotético frente a idiográfico. Allport (1937) popularizó en la psicología de la personalidad esta distinción:

- El enfoque **nomotético** estudia a las personas como miembros de una clase. Busca **leyes generales** y dimensiones comunes a todos, trabaja con muestras amplias y métodos correlacionales o experimentales, y sitúa a cada individuo respecto a una **norma** de grupo. Ejemplos de autores nomotéticos son Cattell, Eysenck y Costa y McCrae.
- El enfoque **idiográfico** estudia a la persona como un caso **único**. Le interesa la organización particular de sus características, su historia y su contexto, y trabaja con pocos sujetos estudiados en profundidad. Ejemplos de autores con orientación idiográfica son Freud, Rogers, Kelly y el propio Allport.

Un ejemplo muestra la diferencia. Para evaluar la timidez de Lucía, un enfoque nomotético le aplica un cuestionario de ansiedad social y concluye que su puntuación supera a la del 90 % de las mujeres de su edad. Un enfoque idiográfico explora en qué situaciones concretas se siente cohibida, qué piensa en ellas y qué hace, y construye una descripción que solo vale para Lucía.

El enfoque idiotético. Lamiell (1981, 1997) propuso una tercera vía. El enfoque **idiotético** describe a cada persona de forma idiográfica, **sin transformar sus puntuaciones en normas de grupo**, y a partir de muchas descripciones individuales busca **principios generales**. La propuesta recibió críticas metodológicas, entre ellas las de Paunonen (1986), y no ha desplazado a los enfoques clásicos, pero ilustra que lo general y lo individual pueden articularse.

Conviene no confundir **idiográfico** con **ipsativo**. Lo idiográfico es una orientación general hacia el caso único. Lo ipsativo es un tipo de puntuación que compara a la persona consigo misma (apartado 4.2).

Cuantitativo frente a cualitativo. La evaluación **cuantitativa** se basa en la medición estandarizada y en el análisis estadístico de los datos. La evaluación **cualitativa** busca comprender de forma global el significado que la persona da a su experiencia, con técnicas como la entrevista abierta, el análisis narrativo o la observación no sistematizada. Hay dos ideas importantes:

1. Son **complementarias**. Una entrevista abierta puede generar hipótesis que después se contrastan con medidas cuantitativas, y un dato numérico puede necesitar una explicación cualitativa para tener sentido.
2. La oposición cuantitativo/cualitativo **no coincide** con la oposición objetivo/subjetivo. Una escala de 0 a 10 en la que el paciente puntúa su dolor es cuantitativa y subjetiva a la vez. Un registro narrativo de lo que hace un niño en el recreo es cualitativo y puede hacerse con mucho rigor.

A estas disyuntivas se suma la que enfrenta la **evaluación tradicional** con la **evaluación conductual**, comparada en el apartado 3.4. Las demás se presentan a continuación.

4.2 Signo y muestra, normativo y criterial, rasgo y estado

Disyuntiva	Polo A	Polo B	Referencia
Nomotético / idiográfico	Leyes generales; norma de grupo	Lo singular de cada persona	Allport (1937); Lamiell (1981)
Cuantitativo / cualitativo	Medición y escalas	Significado y narrativa	Complementarios
Signo / muestra	Indicio de un constructo latente	Muestra del repertorio	Goodenough (1949); Mischel (1968)
Normativo / criterial / ipsativo	Comparación con un grupo	Con un estándar o consigo mismo	R. B. Cattell (1944)
Rasgo / estado	Disposición estable	Condición transitoria	Spielberger (STAI, 1970)
Estructura / función	Qué forma tiene la conducta	Para qué sirve	Haynes y O'Brien (1990)
Molar / molecular	Unidades amplias	Unidades finas	Fija la fiabilidad alcanzable
Ancho de banda / fidelidad	Mucha información poco precisa	Poca información muy precisa	Cronbach y Gleser (1957)

Figura 4.1. **Ocho disyuntivas de la evaluación psicológica.** Tabla con cada par de opciones (nomotético/idiográfico, cuantitativo/cualitativo, signo/muestra, normativo/criterial/ipsativo, rasgo/estado, estructura/función, molar/molecular, ancho de banda/fidelidad), sus polos y una referencia o implicación práctica. Elaboración propia.

Como resume la figura 4.1, las disyuntivas afectan a todas las decisiones de la evaluación.

Signo frente a muestra. Es probablemente la distinción con más consecuencias prácticas. La formuló Goodenough (1949) y adquirió fuerza con la crítica de Mischel (1968).

- Una respuesta es un **signo** cuando se interpreta como **indicador** de algo distinto de ella misma, normalmente un atributo interno. Si alguien responde «sí» a «me preocupo por muchas cosas», el evaluador infiere un rasgo de ansiedad.
- Una respuesta es una **muestra** cuando se interpreta como una **parte representativa** del conjunto de conductas que interesa. Si se observa cuántas veces un niño se levanta de su silla durante la clase, ese registro es una muestra de su conducta en clase.

La evaluación de rasgos trata las respuestas como signos; la conductual, como muestras. La diferencia determina el nivel de inferencia y el problema central de cada enfoque: para el signo, demostrar que el indicador refleja el constructo; para la muestra, demostrar que es **representativa** de la conducta en otras situaciones y momentos.

Normativo, criterial e ipsativo. Son tres referencias para interpretar una puntuación:

- **Normativa**: se compara con la de un grupo de referencia. «Su puntuación en comprensión lectora está en el percentil 40 de su curso».
- **Criterial**: se compara con un **criterio** o nivel de dominio fijado de antemano. «Resuelve correctamente 18 de los 20 tipos de problema que el programa exige».
- **Ipsativa**: se compara con las demás puntuaciones de la **misma persona**. Aparece en los formatos de **elección forzada** y en el **Q-sort**: si una persona elige entre «me gusta organizar» y «me gusta crear», sus preferencias quedan ordenadas entre sí, pero no se puede decir que le guste organizar más que a otra persona. Por eso las puntuaciones ipsativas **no permiten comparar directamente a distintos sujetos**.

Rasgo frente a estado. Un **rasgo** es una tendencia estable; un **estado**, una condición transitoria, ligada a la situación. El ejemplo clásico es el **STAI** de Spielberger (1970), con dos escalas: ansiedad estado (A-E: «¿cómo se siente ahora mismo?») y ansiedad rasgo (A-R: «¿cómo se siente en general?»). Una opositora puede puntuar alto en ansiedad estado la mañana del examen y medio en ansiedad rasgo.

Otras tres disyuntivas.

- **Estructura frente a función.** La misma forma o **topografía** de una conducta puede cumplir **funciones** distintas. Un niño que llora en clase puede hacerlo para conseguir la atención de la maestra o para evitar una tarea difícil. Describir la conducta no basta; hay que saber para qué sirve (apartado 4.3).
- **Molar frente a molecular.** Una unidad **molar** es amplia («participa en clase»); una **molecular**, muy concreta («levanta la mano»). La unidad elegida fija también la **fiabilidad** alcanzable: las unidades moleculares facilitan el acuerdo entre observadores, pero pueden perder significado.
- **Ancho de banda frente a fidelidad.** Cronbach y Gleser (1957/1965) señalaron que cuanta más información distinta recoge un instrumento (**ancho de banda**), menos precisión suele tener en cada aspecto (**fidelidad**). La entrevista tiene mucho ancho de banda y fidelidad variable; un test específico de atención tiene poco ancho de banda y mucha fidelidad.

4.3 El análisis funcional y el modelo E-O-R-K-C

El núcleo de la evaluación conductual es el **análisis funcional**: identificar qué variables controlan una conducta problema para poder modificarla. Kanfer y Saslow (1965) lo propusieron como **alternativa a la clasificación diagnóstica**: en lugar de preguntar qué trastorno tiene la persona, se pregunta qué hace, en qué condiciones y qué consecuencias lo mantienen.

En un capítulo posterior (1969), estos autores desarrollaron una guía de evaluación en siete áreas:

1. **Análisis inicial** de la situación problema: **excesos** conductuales (lo que ocurre demasiado), **déficits** (lo que falta) y **recursos** de la persona.
2. **Clarificación** de la situación problema.
3. **Análisis motivacional**: qué funciona como reforzador para esa persona.
4. **Análisis evolutivo** de su historia.
5. **Análisis del autocontrol**.
6. **Análisis de las relaciones sociales**.
7. **Análisis del entorno** sociocultural y físico.

La fórmula E-O-R-K-C. Para describir cada secuencia problema se usa la fórmula **E-O-R-K-C** (en inglés, SORKC). Se desarrolló a partir de la propuesta de Kanfer y Saslow, tomó la K de Lindsley (1964) y quedó sistematizada en Kanfer y Phillips (1970). Sus cinco elementos son:

Elemento	Qué recoge	Pregunta guía
E · Estímulo	Antecedentes que preceden a la conducta	¿Cuándo y dónde ocurre?
O · Organismo	Estado biológico e historia de aprendizaje	¿Qué aporta la persona?
R · Respuesta	Conducta motora, cognitiva y fisiológica	¿Qué hace, piensa y siente?
K · Contingencia	Relación entre respuesta y consecuencia (programa)	¿Con qué regularidad sigue la consecuencia?
C · Consecuencia	Lo que ocurre después de la conducta	¿Qué gana o qué evita?

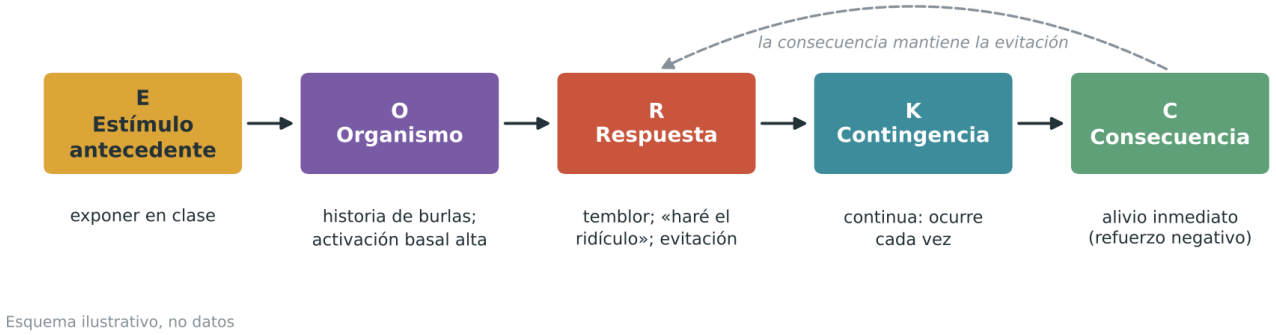


Figura 4.2. **Análisis E-O-R-K-C de un caso de ansiedad social.** El estímulo es tener que exponer en clase; el organismo aporta una historia de burlas y una activación alta; la respuesta incluye temblor, el pensamiento «haré el ridículo» y la evitación; la contingencia es continua, y la consecuencia es un alivio inmediato que actúa como refuerzo negativo. Esquema ilustrativo. Elaboración propia.

La figura 4.2 permite leer el caso como una cadena. Daniel, estudiante universitario, siente que le tiembla la voz cada vez que tiene que exponer en clase, piensa que hará el ridículo y acaba pidiendo que otro compañero presente por él. Cada vez que evita la exposición siente un **alivio inmediato**: la evitación queda **reforzada negativamente**, porque retira el malestar. Como la contingencia es **continua** (siempre que evita, se alivia), la conducta se mantiene con fuerza. El análisis no termina en una etiqueta («fobia social»), sino que señala dónde intervenir: exponerse de forma gradual sin evitar, trabajar el pensamiento anticipatorio o entrenar habilidades de presentación.

Una definición actual. Haynes y O'Brien (1990) definieron el análisis funcional como la identificación de las **relaciones funcionales causales** importantes y **controlables** que se aplican a un conjunto de conductas de un cliente. Tres rasgos de esta definición conviene subrayar:

- Es **idiográfico**: vale para una persona concreta.
- Busca relaciones **controlables**, es decir, variables sobre las que se puede intervenir. Una historia de burlas en la infancia ayuda a entender el caso, pero no se puede cambiar; la evitación actual, sí.
- Es una **hipótesis**: se revisa a medida que llegan datos nuevos, también durante el tratamiento.

Estos autores integraron sus propuestas en el modelo de caso clínico analítico-funcional (FACCM), que recogen en Haynes y O'Brien (2000). La aplicación del análisis funcional al diseño de tratamientos se estudia en Terapia de conducta.

4.4 El triple sistema de respuesta y el cubo de Cone

El triple sistema de respuesta. Lang (1968), a partir de sus estudios sobre el miedo, propuso que las respuestas emocionales se expresan en tres sistemas:

- **motor** o conductual: lo que la persona hace (huir, evitar, acercarse);
- **cognitivo-verbal**: lo que piensa y dice sentir;
- **fisiológico**: la activación del organismo (frecuencia cardiaca, sudoración, tensión muscular).

La aportación clave de Lang es que estos sistemas están **débilmente acoplados**: no siempre cambian a la vez ni en la misma medida. La falta de concordancia entre ellos recibió después el nombre de **desincronía**, un término que introdujeron Rachman y Hodgson (1974).

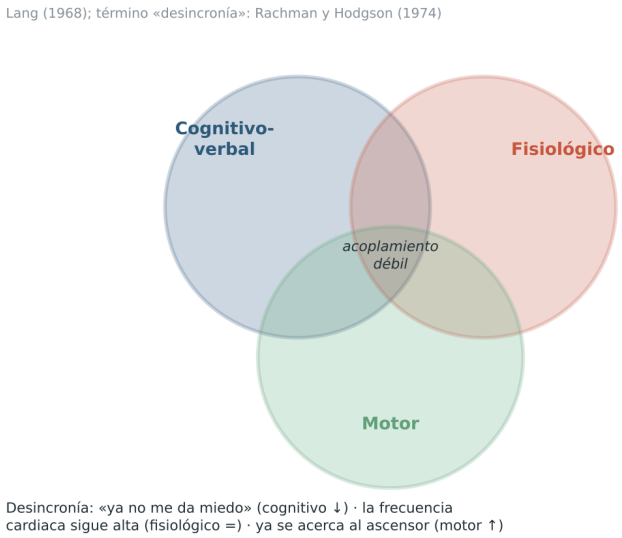


Figura 4.3. **Triple sistema de respuesta y desincronía.** Tres círculos solapados representan los sistemas motor, cognitivo-verbal y fisiológico. En el ejemplo, la persona dice «ya no me da miedo», su frecuencia cardiaca sigue alta y ya se acerca al ascensor. Triple sistema de Lang (1968); término «desincronía» de Rachman y Hodgson (1974). Esquema ilustrativo. Elaboración propia.

Como ilustra la figura 4.3, durante un tratamiento por miedo a los ascensores los tres sistemas pueden avanzar a ritmos distintos. Por eso conviene **medir los tres sistemas**: un solo indicador puede dar una imagen engañosa del cambio. Además, una discrepancia entre ellos **no es necesariamente un error de medida**, sino un dato clínico que puede orientar la intervención.

El cubo de Cone. Cone (1978) propuso una forma de clasificar los procedimientos de evaluación conductual, el *behavioral assessment grid* o **cubo de Cone**, con tres ejes:

1. **Contenidos**: los tres sistemas de respuesta (motor, fisiológico y cognitivo).
2. **Métodos**, ordenados de **más indirecto a más directo**: entrevista, autoinforme, calificación por otros, autoobservación y observación directa. Los métodos indirectos recogen información alejada en el tiempo o en el lugar de la conducta; los directos la registran cuando y donde ocurre.
3. **Universos de generalización**: observador, ítem, tiempo, situación, método y dimensión. Indican hasta qué punto un dato obtenido en unas condiciones se puede generalizar a otras.

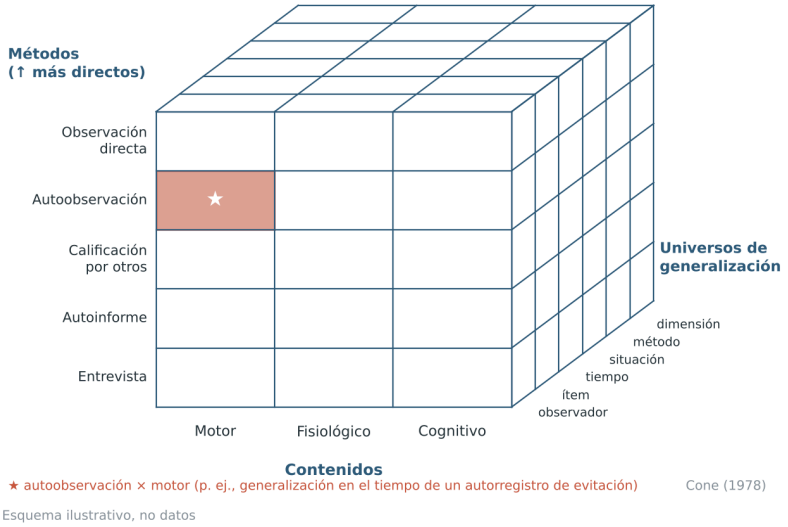


Figura 4.4. **Cubo de evaluación conductual de Cone (1978).** Los tres ejes son los contenidos (motor, fisiológico, cognitivo), los métodos, de indirecto a directo (entrevista, autoinforme, calificación por otros, autoobservación, observación directa), y los universos de generalización. La celda destacada corresponde a la autoobservación de una conducta motora generalizada en el tiempo. Esquema ilustrativo. Elaboración propia.

Cada procedimiento ocupa una celda del cubo, como muestra la figura 4.4. Un autorregistro diario del número de cigarrillos fumados es **autoobservación** de una conducta **motora**, y la pregunta relevante es si los datos de unos días se generalizan a otros (**tiempo**). Cone propuso además reformular la fiabilidad y la validez como cuestiones de **generalizabilidad**, siguiendo la teoría de Cronbach, Gleser, Nanda y Rajaratnam (1972).

La validez en la evaluación conductual. Además de los tipos clásicos de validez (de contenido, de criterio y de constructo), la evaluación conductual destaca tres:

- **validez ecológica**: si lo evaluado representa la conducta en los contextos naturales de la persona;
- **validez de tratamiento** (*treatment utility*): si la evaluación mejora los resultados de la intervención;
- **validez social**: si los objetivos, los procedimientos y los resultados son relevantes y aceptables para la persona y su entorno.

La teoría formal de la generalizabilidad se estudia en Psicometría; los tipos de validez, en la Unidad 10.

Consenso y debate

Consenso: la distinción entre signo y muestra marca una diferencia real en el nivel de inferencia y en el tipo de garantía que necesita cada dato. El análisis funcional es un procedimiento idiográfico, guiado por hipótesis y orientado a variables controlables. Las respuestas en los tres sistemas están débilmente acopladas, así que una evaluación completa debe medir más de uno.

Debate: si el enfoque idiotético de Lamiell (1981, 1997) resuelve de verdad la tensión entre lo nomotético y lo idiográfico, frente a críticas como las de Paunonen (1986). También sigue abierta, tras la crítica de Mischel (1968), la forma de integrar en la evaluación los rasgos estables y la variabilidad de la conducta entre situaciones.

Mito frecuente

Mito: «La desincronía entre los sistemas de respuesta es un concepto de Lang».

Realidad: Lang (1968) propuso el triple sistema de respuesta y describió los tres sistemas como débilmente acoplados. El término «desincronía» para la falta de concordancia entre ellos procede de Rachman y Hodgson (1974).

Conceptos clave

Concepto	Definición
Enfoque idiotético	Describe al individuo sin normas de grupo y busca principios generales (Lamiell, 1981)
Signo	Respuesta interpretada como indicador de un atributo distinto de ella misma
Muestra	Respuesta interpretada como parte representativa de la conducta de interés
Puntuación ipsativa	Compara las puntuaciones de una persona entre sí; no permite comparar sujetos
Ancho de banda	Amplitud de información que recoge un instrumento, a costa de su fidelidad
Análisis funcional	Identificación de relaciones causales importantes y controlables de las conductas de un cliente
E-O-R-K-C	Fórmula de estímulo, organismo, respuesta, contingencia y consecuencia
Desincronía	Falta de concordancia entre los sistemas de respuesta (Rachman y Hodgson, 1974)

Clave PIR

Prioridad alta. Se pregunta la diferencia entre signo y muestra, el significado de cada elemento de la fórmula E-O-R-K-C y el triple sistema de respuesta; con prioridad media, el cubo de Cone y el dilema ancho de banda/fidelidad. Trampas típicas: atribuir la desincronía a Lang en lugar de a Rachman y Hodgson (1974), confundir ipsativo con idiográfico y tomar la K por la consecuencia, cuando es la contingencia o programa.

Autoevaluación

1. Un evaluador registra cuántas veces un alumno interrumpe durante la clase para saber cómo se comporta en ella. Está tratando la conducta como…
a) una muestra
b) un signo
c) un estado

2. Las puntuaciones obtenidas con un formato de elección forzada se caracterizan porque…
a) se comparan con un criterio de dominio fijado de antemano
b) se interpretan siempre respecto a un baremo poblacional
c) no permiten comparar directamente a distintas personas

3. En la fórmula E-O-R-K-C, la K se refiere a…
a) la consecuencia que sigue a la respuesta
b) la contingencia o programa que relaciona respuesta y consecuencia
c) el conocimiento previo del organismo

4. ¿Quién introdujo el término «desincronía» para la falta de concordancia entre sistemas de respuesta?
a) Rachman y Hodgson (1974)
b) Lang (1968)
c) Kanfer y Saslow (1965)

5. En el cubo de Cone, ¿cuál de estos métodos es el más directo?
a) La entrevista
b) La calificación por otros
c) La observación directa

Soluciones

1 a. Se toma la conducta como parte representativa de su comportamiento en clase. **2 c.** Son puntuaciones ipsativas: ordenan las preferencias dentro de la misma persona. **3 b.** La K procede de Lindsley (1964) y describe la regularidad con que sigue la consecuencia. **4 a.** Lang propuso el triple sistema débilmente acoplado; el término es de Rachman y Hodgson. **5 c.** Los métodos van de la entrevista, la más indirecta, a la observación directa.

Capítulo 2 · El proceso de evaluación y el informe

Evaluar no es aplicar una batería de pruebas y leer los resultados: es un proceso de toma de decisiones que parte de una demanda, formula hipótesis y las somete a prueba con instrumentos que tienen garantías. Este capítulo describe ese proceso, los errores de juicio que lo amenazan y las herramientas para corregirlos, y termina con su producto final: el informe psicológico.

Unidad 5 · El proceso de evaluación psicológica

Objetivos: describir la evaluación como un proceso de contraste de hipótesis con fases definidas; distinguir la rama descriptivo-predictiva de la interventivo-valorativa; identificar los tipos de hipótesis y saber traducirlas en enunciados verificables; conocer el origen, el alcance y la utilidad de las Guías para el Proceso de Evaluación (GAP).

5.1 La evaluación como proceso de toma de decisiones

Una evaluación psicológica empieza con una pregunta que alguien formula: un colegio quiere saber por qué un alumno no rinde, una empresa necesita elegir entre varios candidatos, una persona pide ayuda porque no puede subir a un avión. Para responderla, el evaluador no se limita a «medir»: va **tomando decisiones** encadenadas sobre qué información buscar, qué explicaciones considerar, qué técnicas usar y qué concluir. Por eso la evaluación se entiende hoy como un **proceso**, no como un acto aislado.

En la línea de Fernández-Ballesteros, ese proceso sigue la lógica del **método científico**. El evaluador recoge información, plantea **hipótesis** sobre el caso, deduce de ellas consecuencias que se puedan comprobar y las pone a prueba con instrumentos fiables y válidos. Las conclusiones no se apoyan en la intuición ni en la autoridad del profesional, sino en datos que otro evaluador podría revisar.

Según el objetivo, el proceso toma dos caminos que se complementan:

- **Rama descriptivo-predictiva.** Basta con describir, clasificar o predecir: un diagnóstico, una selección de personal, una orientación vocacional. Su lógica es **correlacional**: se comparan las puntuaciones con normas o criterios y se estima qué cabe esperar.
- **Rama interventivo-valorativa.** Además de describir, hay que **cambiar** algo y comprobar si ha cambiado. Su lógica se acerca a la **experimental**: se introduce un tratamiento y se mide su efecto.

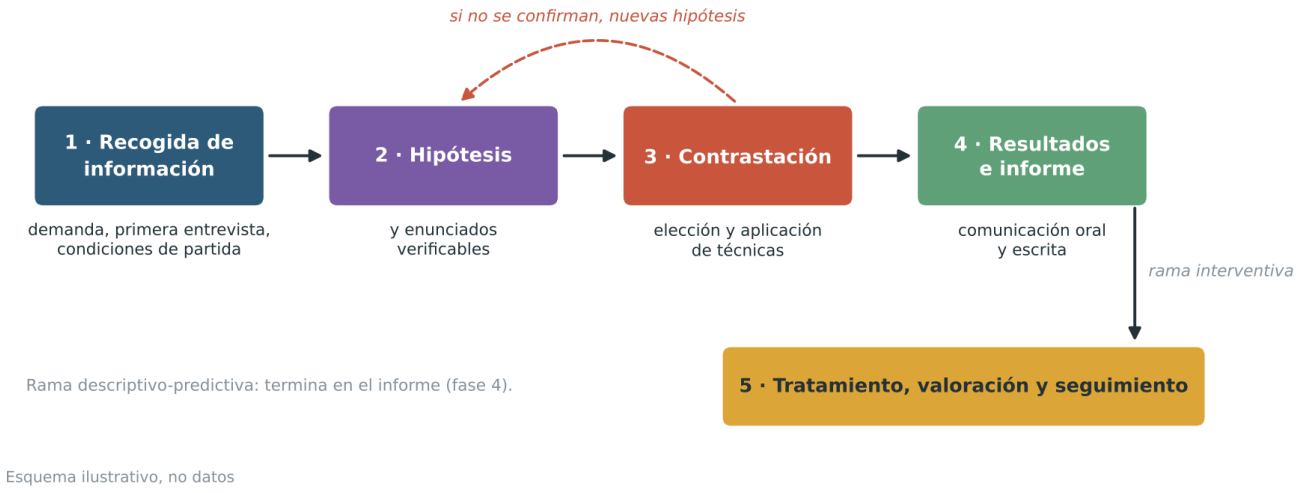


Figura 5.1. **Fases del proceso de evaluación.** De la recogida de información se pasa a las hipótesis y enunciados verificables, a la contrastación y a los resultados e informe; si hay intervención, siguen el tratamiento, la valoración y el seguimiento. La flecha de retorno indica que la contrastación puede obligar a reformular las hipótesis. Elaboración propia.

Como muestra la figura 5.1, las fases básicas son cuatro, y una quinta se añade cuando hay intervención:

Fase	Pregunta que responde	Producto
1. Recogida de información	¿Qué se pide y en qué situación?	Demanda analizada y datos iniciales
2. Hipótesis y enunciados verificables	¿Qué podría explicar el caso y cómo lo comprobaré?	Hipótesis y predicciones concretas
3. Contrastación	¿Apoyan los datos mis hipótesis?	Resultados de las técnicas aplicadas
4. Resultados e informe	¿Qué respondo a la demanda?	Informe oral o escrito
5. Tratamiento, valoración y seguimiento	¿Ha funcionado la intervención y se mantiene?	Datos de cambio y de seguimiento

La flecha de vuelta de la figura es tan importante como las fases. El proceso es **iterativo**: si los datos no apoyan una hipótesis, se vuelve atrás, se plantea otra y se buscan datos nuevos. También puede aparecer información relevante en plena intervención que obligue a revisar lo que se creía saber del caso.

Un ejemplo. Una madre consulta porque su hija de 14 años «ya no quiere ir al instituto». La evaluadora podría quedarse con la primera idea que se le ocurre, por ejemplo acoso escolar. Si trabaja como propone el modelo, la convierte en una hipótesis entre otras (ansiedad social, un problema de aprendizaje no detectado, un conflicto familiar) y decide qué datos permitirían distinguirlas. Si la observación y las entrevistas descartan el acoso, no fuerza los datos para que encajen: vuelve a la fase de hipótesis.

Los objetivos del proceso son los clásicos de la evaluación (Unidad 1): describir, clasificar o diagnosticar, predecir, explicar, orientar el cambio y valorar sus efectos. Los cuatro primeros pueden cerrarse en la rama descriptivo-predictiva; los dos últimos exigen la interventivo-valorativa.

5.2 Recogida de información y formulación de hipótesis

La recogida de información. La primera fase tiene tres tareas. La primera es el **análisis de la demanda**: quién pide la evaluación, qué pide exactamente, para qué la quiere y qué espera obtener. Quien consulta no siempre es quien va a ser evaluado, y lo que se pide no siempre coincide con lo que preocupa: un padre puede pedir «un

test de inteligencia» cuando lo que le inquieta es si su hijo debe repetir curso. Traducir la demanda a términos evaluables es ya una decisión técnica.

La segunda tarea es la **primera entrevista** y la recogida de datos iniciales: el problema actual, su historia, el contexto familiar, escolar o laboral y los recursos de la persona. La tercera es comprobar las **condiciones de partida**: si el evaluador es competente para ese caso, si la demanda es legítima y si la persona está informada del método. El Código Deontológico pide rechazar un encargo cuando se va a usar contra los intereses de las personas (art. 24) e informar del procedimiento (art. 25); estos aspectos se desarrollan en la Unidad 8 y en la asignatura de Deontología.

Desde el principio conviene recoger información **de varias fuentes y con varios métodos** (Unidad 1). Las fuentes no coinciden tanto como se suele suponer. En el metaanálisis de Achenbach, McConaughy y Howell (1987), con 119 estudios sobre problemas infantiles, la correlación media era de 0,60 entre informantes similares (dos profesores), de 0,28 entre informantes de distinto tipo (un profesor y un progenitor) y de 0,22 entre el propio niño y los demás. Cada informante ve una parte de la conducta, en situaciones distintas.

La formulación de hipótesis. Con los datos iniciales, el evaluador plantea explicaciones provisionales. Se distinguen cuatro tipos, que pueden ilustrarse con un caso: Hugo, de 9 años, derivado por su tutora porque «interrumpe la clase continuamente».

Tipo de hipótesis	Qué afirma	Ejemplo en el caso de Hugo
De cuantificación	Cuánto, con qué frecuencia o intensidad se da algo	Hugo se levanta de su sitio muchas veces en cada sesión
De semejanza	Que el sujeto se parece o difiere de otros, o de sí mismo en otras situaciones	Su nivel de atención es inferior al de los niños de su edad
De asociación o predictiva	Que dos variables van juntas, lo que permite predecir	Las interrupciones son más frecuentes en las clases con tareas escritas largas
Funcional o explicativa	Por qué ocurre la conducta: qué la provoca y qué la mantiene	Levantarse le permite escapar de las tareas difíciles (refuerzo negativo)

Las hipótesis funcionales son las que más información dan para intervenir, y enlazan con el análisis funcional (Unidad 4). Pero suelen apoyarse en hipótesis de los otros tipos: antes de explicar por qué Hugo se levanta, hay que saber cuánto lo hace y en qué situaciones.

De la hipótesis al enunciado verificable. Una hipótesis solo es útil si se puede poner a prueba. Para ello se deducen **enunciados verificables**: predicciones concretas que indican qué se debería observar si la hipótesis fuera cierta. «Hugo evita las tareas difíciles» se convierte en «si se le dan fichas de menor dificultad, la frecuencia de levantarse bajará con respecto a la línea base». El enunciado define a la vez qué técnica usar (observación en el aula), qué medir (frecuencia) y en qué condiciones.

La calidad de las hipótesis depende de la calidad de la información de partida. Por eso la entrevista inicial con poca estructura es un punto débil del proceso: Rettew et al. (2009) encontraron una concordancia baja entre el diagnóstico clínico rutinario y el obtenido con entrevistas estandarizadas, una cuestión que se trata en la Unidad 12.

5.3 Contrastación, resultados y seguimiento

La contrastación. En la tercera fase se eligen y aplican las técnicas que permiten comprobar los enunciados. La elección no depende de las pruebas que el evaluador tenga más a mano, sino de cuatro criterios:

1. **Pertinencia:** la técnica debe medir lo que el enunciado predice. Si la hipótesis habla de frecuencia en el aula, un cuestionario de personalidad no sirve.
2. **Garantías:** fiabilidad y validez demostradas para ese uso y esa población (Unidades 9 y 10).

3. **Variedad de métodos y fuentes:** entrevista, observación, autoinforme y tests se complementan.
4. **Coste y carga:** tiempo, dinero y molestias para la persona evaluada.

Aplicadas las técnicas, se corrigen, se interpretan y se comparan los resultados con lo que predecían los enunciados. Hay tres desenlaces posibles. Si los datos apoyan la hipótesis, se avanza. Si la contradicen, se descarta y se vuelve a la fase 2. Si son ambiguos, se buscan datos adicionales. Este retorno no es un fracaso del evaluador: es la manera de evitar que una idea inicial se mantenga sin pruebas.

Los resultados y el informe. En la cuarta fase se integran los datos y se responde a la demanda. Se informa a quien corresponda, de palabra, por escrito o de las dos formas, con recomendaciones y tiempo para preguntas. Cuando no hay intervención prevista, aquí acaba la evaluación. El informe se estudia en la Unidad 7.

La rama interventivo-valorativa. Cuando hay que intervenir, el proceso continúa con un ciclo parecido aplicado al tratamiento:

- se seleccionan las **conductas objetivo** y se formulan hipótesis sobre qué variables hay que modificar para cambiarlas;
- se diseña y aplica el tratamiento, y se **recogen datos** de forma sistemática durante su desarrollo;
- se **valora** el cambio; si es insuficiente, se ajusta la intervención o se replantean las hipótesis;
- se comunican los resultados finales;
- pasado un tiempo, se repiten las medidas (**seguimiento**) para saber si la mejora ha resistido.

Para valorar el cambio en un caso individual se usan **diseños de caso único (N = 1)**. Lo esencial es medir la conducta antes de intervenir (**línea base**) y seguir midiéndola de forma repetida durante y después del tratamiento (**medidas repetidas**). Comparar la tendencia de la línea base con la del tratamiento permite atribuir el cambio con más seguridad que una sola medida antes y otra después. Los diseños se tratan en Métodos de investigación, y la planificación del tratamiento, en Terapia de conducta.

Volviendo al caso de Hugo: durante dos semanas se registra cuántas veces se levanta en cada sesión (línea base). Después se introducen tareas fraccionadas y pausas breves programadas, y se sigue registrando. Si la frecuencia baja y vuelve a subir cuando se retiran los cambios, la hipótesis funcional gana apoyo. Tres meses después, un nuevo registro indica si la mejora se mantiene.

El seguimiento cierra el círculo, pero también puede abrirlo de nuevo: si la conducta reaparece, se recoge información sobre lo que ha cambiado y el proceso vuelve a empezar con hipótesis nuevas.

5.4 Las Guías para el Proceso de Evaluación (GAP)

El modelo de fases no se queda en una propuesta teórica. A finales de los años noventa, un grupo de trabajo de la **European Association of Psychological Assessment (EAPA)**, coordinado por Rocío Fernández-Ballesteros, elaboró las **Guías para el Proceso de Evaluación** (*Guidelines for the Assessment Process*, **GAP**). Se publicaron en Fernández-Ballesteros et al. (2001), en el *European Journal of Psychological Assessment*.

Sus rasgos principales son:

- Son **96 directrices** alcanzadas por **consenso** entre expertos de distintos países.
- Están **organizadas según las fases del proceso**, desde el análisis de la demanda hasta la valoración y el seguimiento.
- Son **generales**: sirven para cualquier ámbito (clínico, educativo, organizacional, forense) y para cualquier enfoque teórico.
- Son **recomendaciones de buena práctica**, no normas legales. Su autoridad procede del consenso profesional, no de una ley.

Las GAP llenan un hueco. Los Standards de la AERA, APA y NCME (2014) y las directrices de la International Test Commission (Unidad 10) se centran sobre todo en los **tests**: cómo construirlos, adaptarlos y usarlos. El

Código Deontológico regula la **conducta ética** del profesional. Las GAP, en cambio, se ocupan del **proceso completo**: qué hacer antes de elegir un test, cómo pasar de los datos a las conclusiones y cómo comunicarlas. Por eso se citan como referencia, junto con el Código, para elaborar informes.

Su utilidad práctica es la de una **lista de comprobación**. La tabla siguiente muestra el tipo de cuestiones que ayudan a revisar en cada fase. Es una ilustración de su lógica, no una transcripción del texto de las directrices.

Fase	Cuestiones de control
Demanda y condiciones previas	¿Está clara la pregunta? ¿Soy competente para responderla? ¿Hay algún conflicto ético?
Hipótesis	¿He considerado explicaciones alternativas? ¿Son contrastables?
Contrastación	¿Las técnicas elegidas tienen garantías para este uso? ¿Uso varios métodos?
Resultados e informe	¿Responde el informe a la demanda? ¿Separa datos de interpretaciones? ¿Es comprensible?
Intervención y seguimiento	¿He medido el cambio con las mismas técnicas? ¿He previsto el seguimiento?

Un ejemplo de su valor. Un psicólogo de una empresa recibe el encargo de evaluar a un empleado por «problemas de actitud». Si sigue el espíritu de las GAP, antes de aplicar ninguna prueba aclara qué conducta concreta preocupa, quién recibirá el informe, si el trabajador ha sido informado y si la demanda es legítima. Muchos problemas de una evaluación se originan en estas primeras decisiones, no en los tests.

Las GAP también encarnan el **consenso** de fondo de esta unidad: la evaluación es un proceso de contraste de hipótesis que usa instrumentos con garantías verificables. Para el PIR conviene recordar su autoría (Fernández-Ballesteros et al., 2001), su origen en la EAPA, el número de directrices (96) y su organización por fases del proceso.

Consenso y debate

Consenso: la evaluación es un proceso de contraste de hipótesis que sigue la lógica del método científico y usa instrumentos con garantías verificables (Fernández-Ballesteros et al., 2001). El proceso es iterativo, no lineal, y debe ser multimétodo y multiinformante (Achenbach, McConaughy y Howell, 1987).

Debate: qué grado de estructura conviene en la recogida inicial de información. Rettew et al. (2009), con 38 estudios y casi 16.000 casos, hallaron un κ medio de 0,27 entre el diagnóstico clínico rutinario y el de entrevistas estandarizadas, con un rango de 0,19 (ansiedad generalizada) a 0,86 (anorexia). Los propios autores advierten que este dato no demuestra cuál de las dos vías es peor.

Mito frecuente

Mito: «Evaluar es una secuencia lineal: se recoge información, se pasa una batería de tests y se redacta el informe».

Realidad: el proceso es cíclico. La contrastación puede obligar a reformular las hipótesis, y la intervención puede aportar información que lleve a revisar fases anteriores. Las GAP (Fernández-Ballesteros et al., 2001) organizan el proceso en fases, pero la elección de técnicas depende de las hipótesis, no de una batería fija.

Conceptos clave

Concepto	Definición
Proceso de evaluación	Secuencia iterativa de decisiones para responder a una demanda contrastando hipótesis
Análisis de la demanda	Aclarar quién pide la evaluación, qué pide, para qué y qué espera obtener
Rama descriptivo-predictiva	Camino del proceso que describe, clasifica o predice, con lógica correlacional
Rama interventivo-valorativa	Camino que añade intervención y valoración del cambio, con lógica experimental
Hipótesis funcional	Explicación de por qué ocurre una conducta: qué la provoca y qué la mantiene
Enunciado verificable	Predicción concreta, deducida de una hipótesis, que indica qué se debería observar
Línea base	Medida de la conducta antes de intervenir, que sirve de referencia para valorar el cambio
GAP	96 directrices consensuadas en la EAPA para todo el proceso (Fernández-Ballesteros et al., 2001)

Clave PIR

Prioridad alta. Se pregunta el orden de las fases, la diferencia entre las dos ramas (correlacional frente a experimental), los tipos de hipótesis a partir de un ejemplo y los datos básicos de las GAP. La trampa típica es presentar el proceso como lineal o confundir una hipótesis de asociación con una funcional: la primera dice que dos cosas van juntas; la segunda, por qué ocurre la conducta. También se confunden las GAP con los Standards (2014), que se centran en los tests.

Autoevaluación

1. En el modelo de Fernández-Ballesteros, si los datos de la contrastación no apoyan una hipótesis, lo indicado es…
a) redactar el informe con los datos disponibles
b) volver a la fase de formulación de hipótesis
c) pasar directamente a la fase de tratamiento

2. «Las rabietas de Leo se mantienen porque así consigue la atención de sus padres» es una hipótesis…
a) de cuantificación
b) de semejanza
c) funcional o explicativa

3. La rama interventivo-valorativa del proceso sigue una lógica…
a) experimental, porque valora el efecto de un tratamiento
b) correlacional, porque compara con normas de grupo
c) idiográfica, porque prescinde de cualquier medida

4. En el metaanálisis de Achenbach, McConaughy y Howell (1987), la concordancia más baja se dio entre…
a) dos informantes del mismo tipo, como dos profesores
b) el propio niño y los demás informantes
c) un profesor y uno de los progenitores

5. Las GAP (Fernández-Ballesteros et al., 2001) son…
a) 96 directrices de consenso aplicables a cualquier ámbito
b) normas legales de obligado cumplimiento en la Unión Europea
c) un listado de los tests recomendados para cada demanda

Soluciones

1 b. El proceso es iterativo: se reformulan las hipótesis y se buscan datos nuevos. **2 c.** Explica por qué se mantiene la conducta a partir de su consecuencia. **3 a.** Introduce un tratamiento y mide el cambio, como en un diseño experimental. **4 b.** La correlación media fue de 0,22, frente a 0,28 entre informantes distintos y 0,60 entre similares. **5 a.** Son recomendaciones de buena práctica elaboradas en la EAPA y organizadas por fases, no normas legales ni listados de tests.

Unidad 6 · Juicio clínico, sesgos y evaluación basada en la evidencia

Objetivos: comparar la predicción clínica y la actuarial y conocer la evidencia de Meehl y de Grove et al.; reconocer los principales sesgos del evaluador y el efecto Barnum; calcular e interpretar valores predictivos en función de la tasa base; describir la evaluación basada en la evidencia y las nuevas formas de evaluación digital.

6.1 Predicción clínica frente a predicción actuarial

Toda evaluación termina en un juicio: este niño necesita apoyo, este candidato rendirá bien, esta persona tiene riesgo de recaída. La pregunta es **cómo se combinan los datos** para llegar a ese juicio. Hay dos formas:

- **Predicción clínica:** el evaluador integra los datos «en su cabeza», con su experiencia y su criterio, y emite un juicio.
- **Predicción actuarial o mecánica:** los datos se combinan con una regla explícita (una fórmula, una tabla, un algoritmo) que da siempre el mismo resultado ante los mismos datos.

Conviene no confundir esta distinción con la del tipo de dato. Una entrevista clínica puede aportar información que después se combina con una fórmula, y las puntuaciones de un test pueden interpretarse de forma intuitiva. Lo que se compara es el **método de combinación**, no el origen de la información.

Paul Meehl abrió el debate con *Clinical versus Statistical Prediction* (Meehl, 1954). Revisó los estudios disponibles en los que se podía comparar el acierto de clínicos y de reglas estadísticas sobre los mismos casos, y concluyó que las reglas igualaban o superaban a los clínicos. El libro provocó una fuerte polémica, porque cuestionaba algo que muchos profesionales daban por hecho: que la experiencia permite integrar los datos mejor que cualquier fórmula.

Medio siglo después, el metaanálisis de **Grove, Zald, Lebow, Snitz y Nelson (2000)** resumió 136 estudios de ámbitos muy diversos (diagnóstico, pronóstico, rendimiento académico o laboral, conducta delictiva, entre otros):

Resultado	Proporción aproximada de estudios
La predicción mecánica es superior	33–47 %
Ambas tienen un acierto similar	En torno a la mitad
La predicción clínica es superior	6–16 %

En promedio, la combinación mecánica fue alrededor de un **10 % más precisa**. La conclusión de consenso es que **la combinación mecánica iguala o supera al juicio clínico** en la gran mayoría de las comparaciones.

Hay que leer bien este resultado. No dice que el clínico nunca acierte: en cerca de la mitad de los estudios ambos métodos empatan. Tampoco dice que el clínico sobre. Sigue siendo necesario para analizar la demanda, decidir qué información recoger, obtener datos en la entrevista y la observación, detectar circunstancias excepcionales que ninguna fórmula contempla y comunicar los resultados. Lo que el metaanálisis muestra es que, una vez reunidos los datos, **sumarlos de forma intuitiva suele ser menos preciso que hacerlo con una regla**.

¿Por qué ocurre? Una fórmula pondera los datos siempre igual, no se cansa, no se deja influir por un detalle llamativo y no olvida variables. El juicio humano, en cambio, es vulnerable a sesgos sistemáticos (apartado 6.2), a la inconsistencia (el mismo caso puede valorarse distinto en dos días diferentes) y a la escasa retroalimentación: el clínico rara vez sabe si su predicción se cumplió.

Un ejemplo cotidiano. Un equipo de orientación decide cada año qué alumnos de primaria necesitan refuerzo lector. Si cada orientadora valora «a ojo» las fichas, unas darán más peso a la caligrafía, otras a la conducta en

clase y otras al informe de la familia. Una regla sencilla y validada, que combine la velocidad lectora, la comprensión y los errores, hará clasificaciones más coherentes. La orientadora sigue siendo imprescindible para revisar los casos dudosos y hablar con las familias.

6.2 Sesgos del evaluador y efecto Barnum

El evaluador es también un instrumento de medida, y como todo instrumento tiene errores. Los **sesgos cognitivos** son errores sistemáticos de juicio: no aparecen al azar, sino en una dirección previsible. La revisión de referencia sobre su papel en la evaluación clínica es la de Garb (2005).



Figura 6.1. **Sesgos del evaluador.** Seis tarjetas con un ejemplo clínico breve de cada sesgo: confirmación, anclaje, disponibilidad, correlación ilusoria, omisión de la tasa base y efecto Barnum. Elaboración propia.

Como muestra la figura 6.1, los más estudiados son estos:

- **Sesgo de confirmación:** buscar, recordar e interpretar la información que confirma la hipótesis inicial y pasar por alto la que la contradice. Un evaluador que sospecha un TDAH desde la primera llamada tiende a preguntar solo por síntomas de inatención.
- **Anclaje:** dar un peso excesivo a la primera información recibida. El diagnóstico que figura en el informe de derivación condiciona toda la evaluación posterior.
- **Disponibilidad:** juzgar la probabilidad de algo por la facilidad con que vienen a la mente casos parecidos. Tras atender un caso grave muy llamativo, se «ve» ese trastorno en los siguientes.
- **Correlación ilusoria:** percibir una relación entre dos variables que no existe en los datos, o que es mucho más débil. Chapman y Chapman (1967, 1969) mostraron que clínicos y estudiantes «encontraban» relaciones entre ciertos rasgos de los dibujos de la figura humana o de las respuestas al Rorschach y determinados problemas, porque parecían lógicas, aunque los datos no las apoyaban.
- **Omisión de la tasa base:** ignorar lo frecuente o infrecuente que es un problema en la población evaluada (apartado 6.3).
- **Efecto halo:** dejar que una impresión global, positiva o negativa, tiña la valoración de rasgos concretos.
- **Exceso de confianza:** creer que los propios juicios son más acertados de lo que son, algo que la experiencia no corrige si no hay retroalimentación.

El efecto Barnum. Forer (1949) dio a sus estudiantes un supuesto perfil de personalidad elaborado a partir de sus respuestas a un test. En realidad, todos recibieron **el mismo texto**, compuesto por frases vagas y aplicables a casi cualquiera, del tipo «a veces dudas de si has tomado la decisión correcta». Los estudiantes valoraron el perfil como muy ajustado a su forma de ser. El término **efecto Barnum** lo popularizó Meehl (1956), y también se conoce como **efecto Forer**.

El efecto tiene dos caras para el evaluador. Por un lado, explica por qué un informe vago puede parecer acertado al evaluado y al propio profesional, sin aportar ninguna información sobre esa persona en concreto. Por otro, obliga a redactar con descripciones **específicas** y apoyadas en datos (Unidad 7). Una frase como «necesita sentirse valorada por los demás» vale para casi todo el mundo; «en las tres situaciones de grupo observadas evitó dar su opinión hasta que se le preguntó directamente» describe a una persona concreta.

Cómo reducir los sesgos. No basta con conocerlos. Las estrategias con más apoyo son estructurales: plantear desde el principio **hipótesis alternativas** y buscar activamente datos que podrían refutarlas; usar entrevistas e instrumentos **estructurados**; consultar las **tasas base** antes de decidir; apoyarse en reglas de decisión explícitas cuando existan, y someter los casos difíciles a la revisión de otro profesional.

6.3 Tasas base y razonamiento probabilístico

La **tasa base** es la frecuencia de un problema en la población a la que pertenece la persona evaluada. Es uno de los conceptos más preguntados y peor entendidos, porque el acierto de una prueba no depende solo de la prueba, sino también de lo frecuente que sea lo que se busca.

Para razonar con tasas base hay que distinguir cuatro índices. Los dos primeros describen la prueba:

- **Sensibilidad:** proporción de personas con el problema que la prueba detecta (verdaderos positivos entre todos los que lo tienen).
- **Especificidad:** proporción de personas sin el problema que la prueba descarta (verdaderos negativos entre todos los que no lo tienen).

Los otros dos responden a la pregunta que interesa al evaluador ante un resultado concreto:

- **Valor predictivo positivo (VPP):** si la prueba da positivo, ¿qué probabilidad hay de que la persona tenga el problema?
- **Valor predictivo negativo (VPN):** si da negativo, ¿qué probabilidad hay de que no lo tenga?

La clave es que la sensibilidad y la especificidad son propiedades bastante estables de la prueba, mientras que **el VPP y el VPN cambian con la tasa base**. Un ejemplo calculado lo muestra.

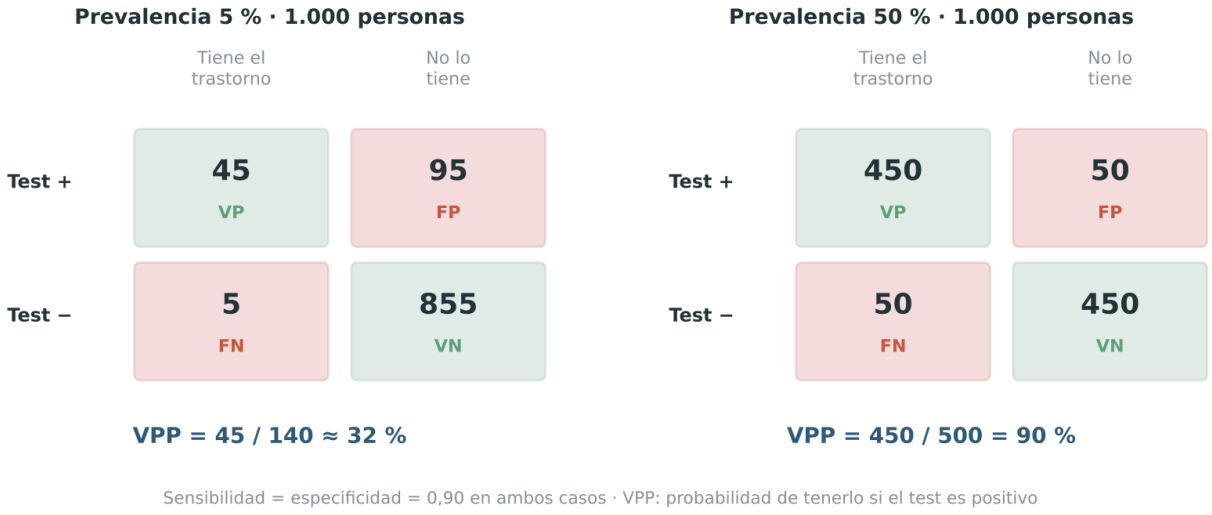


Figura 6.2. **El valor predictivo positivo depende de la tasa base.** Dos tablas de 1.000 personas evaluadas con una prueba de sensibilidad y especificidad de 0,90. Con una prevalencia del 5 %, solo un 32 % de los positivos son verdaderos; con una prevalencia del 50 %, lo son el 90 %. Dato calculado. Elaboración propia.

Como muestra la figura 6.2, se aplica la misma prueba en dos contextos:

	Prevalencia del 5 %	Prevalencia del 50 %
Personas con el problema	50	500
Verdaderos positivos (90 % de ellas)	45	450
Falsos negativos	5	50
Personas sin el problema	950	500
Verdaderos negativos (90 % de ellas)	855	450
Falsos positivos	95	50
VPP = VP / (VP + FP)	45 / 140 ≈ 32 %	450 / 500 = 90 %
VPN = VN / (VN + FN)	855 / 860 ≈ 99,4 %	450 / 500 = 90 %

Con una prevalencia baja, la prueba produce **más falsos positivos que verdaderos positivos**, aunque sea una buena prueba: de cada tres personas que dan positivo, dos no tienen el problema. El motivo es sencillo. El 10 % de error recae sobre un grupo muy grande (950 personas sanas), y ese 10 % supera en número a todos los casos reales. En cambio, el VPN es altísimo: un resultado negativo descarta el problema con mucha seguridad.

Esto tiene consecuencias prácticas:

1. Un **cribado** en la población general (por ejemplo, aplicar un cuestionario de riesgo de suicidio a todos los alumnos de un instituto) generará muchos falsos positivos. Un positivo es una señal para evaluar más a fondo, no un diagnóstico.
2. La misma prueba aplicada en una **consulta especializada**, donde el problema es mucho más frecuente, tendrá un VPP mucho mayor.
3. Cuando la tasa base es muy baja, puede ocurrir que la regla «decir siempre que no» acierte más que la prueba. Por eso hay que valorar si una prueba aporta algo **por encima de la tasa base**.

Omitir la tasa base es el error que consiste en interpretar un positivo como si su probabilidad fuera la sensibilidad («la prueba detecta el 90 % de los casos, luego este positivo es un caso al 90 %»). El razonamiento correcto parte de la tasa base y la actualiza con el resultado de la prueba, que es lo que formaliza el teorema de Bayes. La utilidad diagnóstica, las curvas ROC y la elección de puntos de corte se tratan en la Unidad 10 y en Psicometría.

6.4 Evaluación basada en la evidencia y evaluación digital

Evaluación basada en la evidencia. Igual que la intervención debe apoyarse en tratamientos con eficacia demostrada, la evaluación debe apoyarse en instrumentos y procedimientos con apoyo empírico **para el propósito concreto** para el que se usan. Hunsley y Mash han sistematizado esta idea en tres criterios:

Criterio	Pregunta
Validez para el propósito	¿Hay pruebas de que este instrumento sirve para esta decisión y esta población?
Utilidad clínica	¿Mejora las decisiones o los resultados del caso? ¿Compensa su coste?
Validez incremental	¿Aporta información que no se tenía ya con otros datos más baratos?

La validez incremental es especialmente útil para decidir qué **no** aplicar. Si una entrevista breve y un cuestionario ya permiten tomar la decisión, añadir una prueba larga solo se justifica si mejora el acierto. Este enfoque conecta con la predicción actuarial (6.1) y con las tasas base (6.3): una evaluación basada en la evidencia combina los datos de forma explícita y tiene en cuenta la frecuencia del problema.

Evaluación digital. La tecnología ha abierto vías nuevas para recoger información:

- **Evaluación ecológica momentánea (EMA).** La persona responde a preguntas breves en su móvil varias veces al día, en su entorno habitual (Shiffman, Stone y Hufford, 2008). Reduce el **sesgo de recuerdo**, porque se pregunta por lo que ocurre en el momento, y gana **validez ecológica**. A cambio, supone **carga** para el evaluado y puede ser **reactiva**: registrar el estado de ánimo varias veces al día puede modificarlo. Es la versión digital del autorregistro (Unidad 16).
- **Tests adaptativos informatizados (TAI).** Basados en la teoría de respuesta al ítem, eligen cada ítem según las respuestas anteriores. Logran mediciones precisas con menos ítems. Su fundamento se estudia en Psicometría.
- **Sensorización pasiva.** El móvil o los dispositivos que se llevan puestos (*wearables*) registran datos sin que la persona tenga que responder: actividad física, horas de sueño, desplazamientos, uso del teléfono. Prometen datos continuos y poco reactivos, pero su validez para inferir estados psicológicos está todavía en discusión.

Marco legal. Estos datos son a menudo datos de salud, que el Reglamento General de Protección de Datos considera de categoría especial (Unidad 8). Además, la **Ley de IA de la Unión Europea** (Reglamento 2024/1689) clasifica como de **alto riesgo** ciertos usos de la inteligencia artificial en el empleo y la educación, y **prohíbe**, salvo excepciones, el reconocimiento de emociones en el lugar de trabajo y en los centros educativos. Un sistema que analizara la cara de los candidatos en una videoentrevista para inferir su estado emocional entraría de lleno en estas restricciones.

La tecnología no cambia los principios del proceso. Un dato digital sigue necesitando una hipótesis que le dé sentido, garantías de fiabilidad y validez para el uso previsto, y un evaluador que lo interprete y responda de sus conclusiones.

Consenso y debate

Consenso: la combinación mecánica de los datos iguala o supera al juicio clínico en la gran mayoría de los estudios (Meehl, 1954; Grove et al., 2000). El evaluador está expuesto a sesgos sistemáticos (Garb, 2005), y el valor predictivo de una prueba depende de la tasa base.

Debate: la validez de las métricas pasivas (*wearables*, sensorización del móvil) y de la inteligencia artificial para inferir estados psicológicos sigue en discusión, y la Ley de IA de la UE (Reglamento 2024/1689) restringe algunos de sus usos. También se discute en qué situaciones concretas el juicio clínico añade valor, dado que cerca de la mitad de las comparaciones terminan en empate.

Mito frecuente

Mito: «Un buen evaluador con experiencia no necesita fórmulas: su intuición integra los datos mejor que cualquier regla».

Realidad: desde Meehl (1954), la evidencia apunta en sentido contrario. En el metaanálisis de Grove et al. (2000), con 136 estudios, la combinación mecánica fue en promedio un 10 % más precisa y solo perdió en una minoría de comparaciones. Además, la sensación de acierto puede ser engañosa: los estudiantes de Forer (1949) juzgaron muy preciso un perfil idéntico para todos.

Conceptos clave

Concepto	Definición
Predicción actuarial	Combinación de los datos mediante una regla explícita que da siempre el mismo resultado
Predicción clínica	Combinación de los datos según el juicio y la experiencia del evaluador
Sesgo de confirmación	Tendencia a buscar e interpretar solo la información que apoya la hipótesis inicial
Correlación ilusoria	Percepción de una relación entre variables que no existe en los datos (Chapman y Chapman)
Efecto Barnum	Aceptación como precisa de una descripción vaga válida para casi todos (Forer, 1949)
Tasa base	Frecuencia del problema en la población a la que pertenece la persona evaluada
Valor predictivo positivo	Probabilidad de tener el problema si la prueba da positivo; depende de la tasa base
EMA	Evaluación repetida en el entorno natural mediante el móvil (Shiffman, Stone y Hufford, 2008)

Clave PIR

Prioridad alta. Se pregunta qué concluyeron Meehl (1954) y Grove et al. (2000), en qué consiste el efecto Barnum y quién lo estudió, y se piden cálculos de VPP con distintas prevalencias. La trampa típica es leer a Grove como «el clínico nunca acierta», cuando cerca de la mitad de los estudios son empates, o creer que el VPP es una propiedad fija de la prueba. También se confunde la sensibilidad con el VPP.

Autoevaluación

1. Según el metaanálisis de Grove et al. (2000)…
a) el juicio clínico fue superior en casi la mitad de los estudios
b) ambos métodos empataron en todos los estudios revisados
c) la combinación mecánica igualó o superó al juicio en la mayoría

2. En el estudio de Forer (1949), los estudiantes…
a) recibieron todos el mismo perfil vago y lo juzgaron preciso
b) recibieron perfiles distintos y no los distinguieron entre sí
c) detectaron enseguida que el perfil era el mismo para todos

3. La correlación ilusoria descrita por Chapman y Chapman consiste en…
a) dar más peso a la primera información recibida del caso
b) percibir relaciones entre signos y problemas que los datos no apoyan
c) recordar con más facilidad los casos llamativos o recientes

4. Una prueba tiene sensibilidad y especificidad de 0,90. Con una prevalencia del 5 %, su VPP es aproximadamente…
a) del 90 %
b) del 50 %
c) del 32 %

5. La principal ventaja de la evaluación ecológica momentánea es que…
a) elimina por completo la reactividad de la medida
b) reduce el sesgo de recuerdo y gana validez ecológica
c) no exige ningún esfuerzo por parte del evaluado

Soluciones

1 c. La mecánica fue superior en el 33–47 % de los estudios, la clínica en el 6–16 %, y en torno a la mitad empataron. **2 a.** El perfil era idéntico y estaba hecho de frases aplicables a cualquiera. **3 b.** La relación parece lógica, pero no está en los datos; la opción a es el anclaje y la c, la disponibilidad. **4 c.** Hay 45 verdaderos positivos y 95 falsos positivos: 45/140 ≈ 32 %. **5 b.** A cambio, supone carga y puede ser reactiva.

Unidad 7 · El informe psicológico

Objetivos: describir las funciones del informe y distinguir sus tipos según el canal, la función y el destinatario; conocer su estructura y contenido mínimo y los requisitos del Código Deontológico; aplicar pautas de redacción clara apoyadas en la evidencia; saber organizar una entrevista de devolución y conocer las particularidades del informe pericial.

7.1 Funciones y tipos de informe

El **informe psicológico** cierra el proceso de evaluación (Unidad 5). Su valor no está en listar puntuaciones: **integra** lo que han aportado las distintas técnicas, **responde** a la pregunta que originó la evaluación y **justifica** cada conclusión y recomendación. Cumple varias funciones a la vez:

- **Comunicar** los resultados a quien los necesita, de forma que pueda entenderlos.
- **Fundamentar decisiones**: un tratamiento, una adaptación escolar, una contratación, una resolución judicial.
- **Documentar** lo que se hizo, con qué técnicas y en qué fechas, de modo que otro profesional pueda revisarlo.
- Servir de **documento con efectos legales y profesionales**, del que el psicólogo responde con su firma.

Según el canal, se distingue entre la **entrevista de devolución**, que es oral y la forma más usada en la práctica clínica, y el **informe escrito**. No son excluyentes: la devolución puede acompañarse del informe escrito si la persona lo pide.

Según la función y el destinatario, se distinguen cuatro tipos:

Tipo	Destinatario	Rasgos principales
Técnico	Otros profesionales (psiquiatra, otro psicólogo, equipo de orientación)	Usa terminología especializada; puede incluir puntuaciones y referencias a instrumentos
Personal o para el cliente	La persona evaluada o su familia	Lenguaje llano; se usa como apoyo de la devolución; se entrega por escrito si se pide
Certificado	Quien necesita acreditar algo (la propia persona, una institución)	Breve; para un uso único y predeterminado; solo lo necesario para ese fin
Pericial	Un órgano judicial, dentro de un procedimiento	Responde al objeto de la pericia; separa datos e inferencias; hace constar sus límites

Un mismo proceso puede dar lugar a varios informes. Imagina la evaluación de Clara, una niña de 8 años con dificultades de lectura. La psicóloga puede elaborar un **informe técnico** para el equipo de orientación del colegio, con los resultados de las pruebas y la propuesta de adaptaciones; un **informe personal** para los padres, sin tecnicismos y centrado en qué significan los resultados y cómo ayudar en casa; y un **certificado** breve que acredite que Clara necesita más tiempo en los exámenes, sin más datos que los imprescindibles.

Si quien solicita el certificado es un familiar, hace falta antes la autorización de la persona evaluada. Y cuando la evaluación la solicita un tercero (una empresa, un juzgado, una aseguradora), el evaluado conserva el **derecho a conocer el informe**, salvo que ello suponga un grave perjuicio para él o para el psicólogo (art. 42 del Código Deontológico; Unidad 8).

El informe pericial merece una mención especial por sus exigencias formales y su contexto. Sus particularidades se presentan en el apartado 7.4 y se desarrollan en la asignatura de Psicología Jurídica.

7.2 Estructura y contenido del informe escrito

Cada servicio usa su propia plantilla, pero hay elementos que cualquier informe debería contener (**contenido mínimo**). La figura 7.1 lo organiza en ocho bloques.

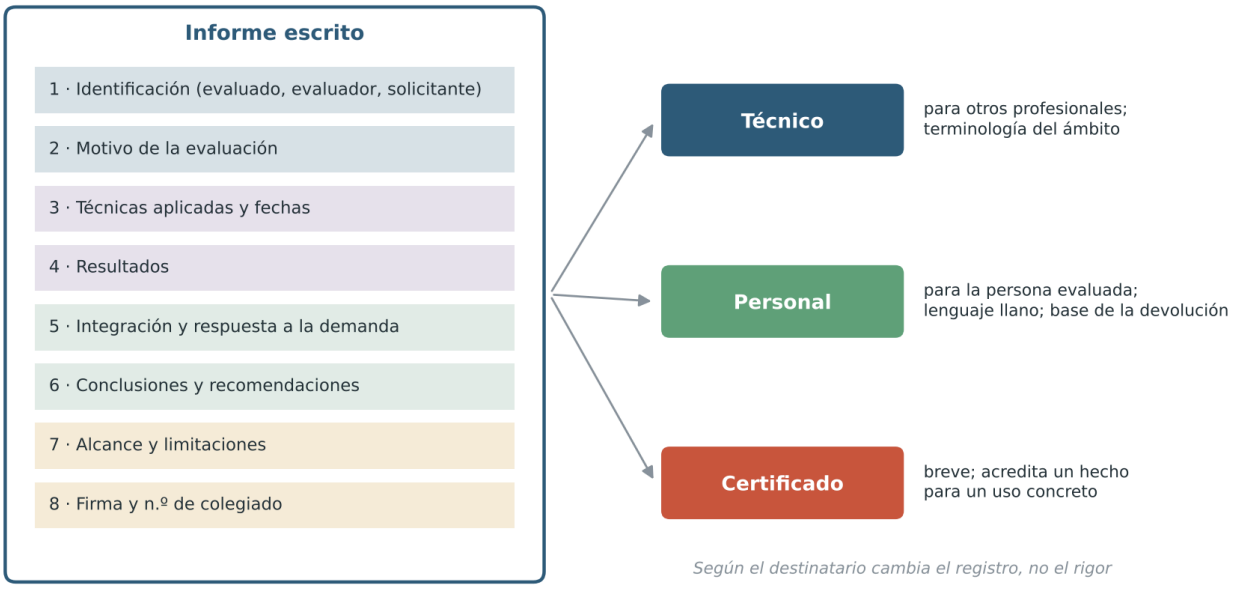


Figura 7.1. **Estructura del informe psicológico.** Plantilla en ocho bloques, desde la identificación hasta la firma con el número de colegiado, y tres versiones según el destinatario: técnico, personal y certificado. Elaboración propia.

Como muestra la figura 7.1, los bloques son:

1. **Identificación.** Datos del evaluado, del evaluador (nombre completo y número de colegiado) y de quien solicita el informe, con la fecha.
2. **Motivo de la evaluación.** La demanda tal como se formuló y el objetivo de la evaluación (diagnóstico, orientación, planificación de una intervención). Conviene anotar la demanda con las palabras de quien la trae, aunque la evaluación acabe mostrando que el problema era otro.
3. **Técnicas y fechas.** Qué se aplicó (entrevistas, observaciones, cuestionarios, tests), cuándo y, si es útil, por qué.
4. **Resultados.** Los datos obtenidos con cada fuente, incluida la conducta durante la evaluación y los antecedentes relevantes.
5. **Integración.** La interpretación conjunta de los datos y la respuesta a la demanda. Es el núcleo del informe.
6. **Conclusiones y recomendaciones.** Lo esencial, en pocas líneas, y las propuestas que se derivan.
7. **Limitaciones.** Hasta dónde llegan las conclusiones y con qué grado de certeza.
8. **Firma** y número de colegiado.

Los requisitos del Código. El artículo 48 del Código Deontológico exige que los informes sean «claros, precisos, rigurosos e inteligibles para su destinatario» y que expresen su **alcance**, sus **limitaciones** y el **grado de certeza** de sus conclusiones. El artículo 12 pide cautela con las etiquetas devaluadoras, como «normal/anormal», «adaptado/inadaptado» o «inteligente/deficiente». Las GAP (Unidad 5) añaden pautas sobre cómo pasar de los datos a las conclusiones.

Datos frente a interpretaciones. Uno de los errores más frecuentes es mezclar lo que se observó con lo que se infiere. «Durante la entrevista lloró dos veces al hablar de su padre» es un dato; «tiene un duelo no resuelto» es una inferencia. Ambas pueden figurar en el informe, pero el lector debe poder distinguirlas, y cada inferencia debe apoyarse en datos que se mencionan.

Integrar, no yuxtaponer. Un informe que presenta los resultados **test por test** («En el test A obtuvo…; en el cuestionario B obtuvo…») obliga al lector a hacer la integración que le correspondía al psicólogo. Es preferible organizar los resultados **por áreas funcionales** (atención, estado de ánimo, relaciones sociales, rendimiento académico) y, dentro de cada área, combinar lo que dicen las distintas fuentes, señalando cuándo coinciden y cuándo no.

Especificidad. El informe debe describir a **esta** persona, no a cualquiera. Las frases vagas que valdrían para casi todo el mundo reproducen el efecto Barnum (Unidad 6) y no aportan información. Cada afirmación importante debería poder responder a la pregunta «¿en qué dato me baso?».

Las limitaciones no son un trámite. Si una prueba no tiene baremos para la población de la persona, si el evaluado estaba muy cansado o si una fuente de información no estuvo disponible, hay que decirlo. Reconocer los límites es parte del rigor, no una debilidad del informe.

7.3 Redactar con claridad

Un informe que el destinatario no entiende no cumple su función, por riguroso que sea. Y los informes psicológicos suelen ser difíciles de leer. Harvey (1997, 2006) analizó su legibilidad y encontró que con frecuencia exigen un **nivel lector universitario o superior**, incluso cuando van dirigidos a padres o profesores. La principal barrera de comprensión es la **jerga** técnica.

Las recomendaciones que se derivan de esta línea de trabajo son concretas:

- **Frases cortas** y estructura sencilla: sujeto, verbo y complemento.
- **Definir los términos técnicos** la primera vez que aparecen, o sustituirlos por expresiones comunes.
- **Organizar por áreas funcionales**, no test por test (apartado 7.2).
- **Explicar las puntuaciones** cuando el destinatario no es técnico. Un percentil 85 dice poco a una familia; «su puntuación es igual o superior a la de 85 de cada 100 niños de su edad» dice mucho más.
- Usar **tablas o esquemas** para los datos numéricos, en lugar de encadenarlos en el texto.
- Evitar **etiquetas** estigmatizantes y describir conductas en lugar de calificar a la persona (art. 12).
- Escribir con **tono respetuoso** y sin juicios de valor.

La diferencia se aprecia mejor con ejemplos:

Redacción poco clara	Redacción clara
Presenta un perfil con elevaciones significativas en las escalas de internalización	Las respuestas de la familia indican más tristeza, preocupación y quejas físicas de lo habitual a su edad
Muestra un déficit en las funciones ejecutivas de inhibición	Le cuesta frenar una respuesta automática: por ejemplo, contesta antes de terminar de leer la pregunta
Es un niño inmaduro y desadaptado	En el recreo suele jugar solo y se enfada cuando pierde, lo que dificulta que lo incluyan en los juegos

Escribir con claridad **no significa perder rigor**. El informe sigue apoyándose en técnicas con garantías y en datos concretos; lo que cambia es la forma de comunicarlos. Para un colega, la terminología técnica ahorra espacio; aun así, un informe técnico también debe poder leerse sin esfuerzo y apoyar cada inferencia en datos.

La investigación sobre informes **accesibles** sigue creciendo. Estudios recientes, como los de Bejnö et al. (2025), exploran cómo adaptar los informes para que las personas evaluadas los comprendan y los usen. Algunos trabajos de 2025 solo están disponibles como prepublicaciones, por lo que deben tomarse como indicios hasta que se confirmen.

Un consejo práctico: antes de entregar un informe personal, conviene releerlo poniéndose en el lugar del destinatario y preguntarse si podría explicarle a otra persona, con sus palabras, qué se ha encontrado y qué se

recomienda. Si la respuesta es no, hay que reescribir.

7.4 La entrevista de devolución y el informe pericial

La entrevista de devolución. Es el momento en que se comunican los resultados, de forma oral, a la persona evaluada o a quien corresponda. En la práctica clínica es la forma de informe más usada, y su calidad influye en que la persona entienda lo que ocurre y se implique en lo que viene después. Una estructura recomendable tiene cinco pasos:

1. **Recordar la demanda**: por qué se hizo la evaluación y qué preguntas se querían responder.
2. **Exponer los hallazgos, empezando por los recursos**: lo que la persona hace bien y los puntos fuertes, antes de las dificultades.
3. **Comprobar la comprensión y la reacción**: preguntar qué ha entendido, cómo se siente y qué dudas tiene.
4. **Dar las recomendaciones**, de forma concreta y viable.
5. **Entregar el informe escrito**, si se pide.

Qué se dice y cómo se dice depende de lo que la persona puede **entender** y **asumir** en ese momento. No se trata de ocultar los aspectos negativos, sino de presentarlos de forma comprensible, con datos y con un plan. Por ejemplo, a los padres de Clara (apartado 7.1) se les puede explicar primero que su hija comprende bien lo que oye y tiene un vocabulario amplio; después, que lee más despacio y con más errores que sus compañeros, con ejemplos de lo observado; a continuación se comprueba qué han entendido y qué les preocupa, y por último se acuerdan las medidas para casa y el colegio.

La devolución también es una ocasión para **contrastar** las conclusiones: la reacción de la persona puede aportar información que matice alguna interpretación, y así el proceso conserva su carácter iterativo (Unidad 5).

El informe pericial. Se elabora dentro de un procedimiento judicial, a petición de un juzgado o de una de las partes, y su destinatario último es el órgano judicial. Tiene tres exigencias específicas:

- **Responde al objeto de la pericia**: a las preguntas concretas que se plantean (por ejemplo, la capacidad de una persona o la situación de unos menores en un proceso de separación), y no a otras.
- **Separa con claridad los datos de las inferencias**, para que el tribunal pueda valorar en qué se apoya cada conclusión.
- **Hace constar sus límites**: qué no se pudo evaluar, qué fuentes faltaron y con qué grado de certeza se formulan las conclusiones.

El perito no decide: aporta conocimiento técnico para que decida el juez. Por eso el informe debe evitar pronunciarse sobre cuestiones que no le corresponden y debe poder defenderse ante preguntas de las partes. El informe pericial, la evaluación de menores en contextos de separación y el papel del psicólogo como perito se estudian en Psicología Jurídica; los aspectos éticos, en la Unidad 8.

Consenso y debate

Consenso: el informe debe responder a la demanda, separar los datos de las interpretaciones, integrar las fuentes y ser «claro, preciso, riguroso e inteligible para su destinatario» (art. 48 del Código Deontológico). Los informes psicológicos suelen ser más difíciles de leer de lo necesario, y la jerga es la principal barrera (Harvey, 1997, 2006).

Debate: cómo hacer accesibles los informes sin perder información relevante, por ejemplo cuántos datos numéricos incluir para un destinatario no técnico. La investigación sobre informes accesibles es reciente (Bejnö et al., 2025), y parte de ella solo está disponible como prepublicación, por lo que aún no permite conclusiones firmes.

Mito frecuente

Mito: «Cuanto más técnico es un informe, más riguroso es».

Realidad: el rigor depende de las técnicas empleadas, de la calidad de los datos y de la justificación de las conclusiones, no del vocabulario. Harvey (1997, 2006) mostró que la jerga es la principal barrera para comprender los informes, y el Código exige que sean inteligibles para su destinatario (art. 48). Un informe que no se entiende no puede cumplir su función.

Conceptos clave

Concepto	Definición
Informe psicológico	Documento que integra los datos de la evaluación, responde a la demanda y justifica conclusiones
Entrevista de devolución	Comunicación oral de los resultados al evaluado; la forma de informe más usada en clínica
Informe técnico	Informe dirigido a otros profesionales, con terminología especializada
Informe personal	Informe para el evaluado o su familia, en lenguaje llano, como apoyo de la devolución
Certificado	Informe breve para un uso único y predeterminado, con solo los datos necesarios
Informe pericial	Informe en un procedimiento judicial que responde al objeto de la pericia y declara sus límites
Integración de resultados	Interpretación conjunta de las fuentes, organizada por áreas y no test por test
Artículo 48	Exige informes claros, precisos, rigurosos e inteligibles, con alcance, límites y grado de certeza

Clave PIR

Prioridad media. Se pregunta la clasificación de los informes (técnico, personal, certificado, pericial), el contenido mínimo y los requisitos del artículo 48. Las trampas típicas son confundir el informe personal con el técnico, atribuir al certificado un contenido amplio cuando es breve y de uso único, y olvidar que el evaluado tiene derecho a conocer el informe aunque lo haya pedido un tercero (art. 42).

Autoevaluación

1. Un informe breve, con un uso único y predeterminado, que solo incluye los datos necesarios para ese fin es un…
a) informe técnico
b) certificado
c) informe pericial

2. Según el artículo 48 del Código Deontológico, los informes deben ser…
a) claros, precisos, rigurosos e inteligibles para su destinatario
b) exhaustivos, con todas las puntuaciones obtenidas en cada prueba
c) técnicos, para garantizar su rigor ante otros profesionales

3. Según Harvey (1997, 2006), la principal barrera para comprender los informes psicológicos es…
a) su excesiva longitud
b) la falta de puntuaciones
c) la jerga técnica

4. En la entrevista de devolución, tras recordar la demanda, se recomienda exponer los hallazgos empezando por…
a) los recursos y puntos fuertes de la persona
b) las puntuaciones más bajas obtenidas
c) el diagnóstico principal y su gravedad

5. Una característica propia del informe pericial es que…
a) se dirige a la persona evaluada en lenguaje llano
b) separa datos de inferencias y hace constar sus límites
c) puede omitir las técnicas usadas si el juez lo permite

Soluciones

1 b. El certificado es breve y sirve para un fin concreto; el técnico y el pericial son más amplios. **2 a.** El artículo añade que deben expresar su alcance, sus limitaciones y el grado de certeza. **3 c.** Los informes suelen exigir un nivel lector universitario o superior, sobre todo por la terminología. **4 a.** Empezar por los recursos facilita que la persona escuche y acepte el resto de la información. **5 b.** También responde al objeto de la pericia; su destinatario último es el órgano judicial.

Capítulo 3 · Garantías éticas y científicas

Una evaluación puede influir en un diagnóstico, en una contratación o en la custodia de un hijo, así que no basta con que el evaluador tenga buena intención. Este capítulo estudia las dos clases de garantías que hacen defendible una evaluación: las éticas, que protegen a la persona evaluada, y las científicas, que aseguran la calidad de los datos. Empieza por el Código Deontológico y sigue con la fiabilidad, las puntuaciones y la validez de los instrumentos.

Unidad 8 · Ética y deontología en la evaluación

Objetivos: identificar los artículos del Código Deontológico del COP que regulan la evaluación psicológica; distinguir intimidad, confidencialidad, secreto profesional y protección de datos; aplicar las normas sobre consentimiento e información a casos con menores y con terceros solicitantes; situar el Código español entre los marcos internacionales y conocer el estado del nuevo Código.

8.1 El Código Deontológico y la evaluación

Las **garantías éticas** regulan cómo se trata a la persona evaluada: qué se le explica, qué se recoge, quién accede a los resultados y para qué se usan. Las **garantías científicas** (Unidades 9 y 10) regulan la calidad de la información. Las dos están más unidas de lo que parece. Aplicar un test sin pruebas de que sirve para el uso que se le da es un problema técnico, pero también ético, porque las decisiones que se tomen con él pueden perjudicar a alguien.

En España, la referencia es el **Código Deontológico del Psicólogo**, aprobado por el Colegio Oficial de Psicólogos el 22 de mayo de 1987. Se modificó en 2010, para adaptarlo a la llamada Ley Ómnibus, y de nuevo en 2014 y 2015. Muchos manuales lo citan como «COP, 2015», que es la versión consolidada. Es el **Código vigente** y obliga a los psicólogos colegiados. Existe un proyecto de nuevo Código que todavía está **en tramitación** (apartado 8.4). El estudio completo del Código corresponde a la asignatura de Deontología; aquí se seleccionan los artículos que afectan directamente a la evaluación.

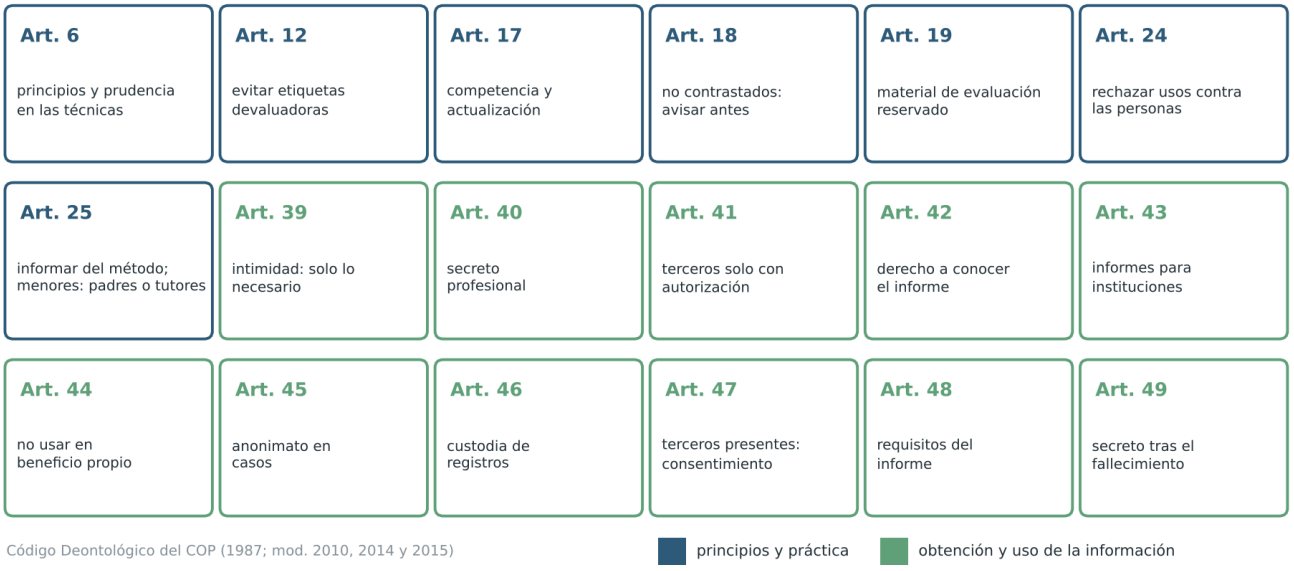


Figura 8.1. **Artículos del Código Deontológico relevantes para la evaluación.** Rejilla con los artículos 6, 12, 17, 18, 19, 24, 25 y 39 a 49, cada uno acompañado de una palabra clave que resume su contenido. Elaboración propia.

Como muestra la figura 8.1, los artículos se agrupan en dos bloques. El primero recoge **principios generales** de la práctica:

Artículo	Idea clave para la evaluación
6	Respeto, responsabilidad y honestidad; «prudencia en la aplicación de instrumentos y técnicas»; fundamentación científica
12	Cautela con etiquetas como «normal/anormal», «adaptado/inadaptado» o «inteligente/deficiente»
17	Competencia profesional y actualización
18	No usar procedimientos no contrastados sin informar antes de su carácter experimental
19	El material de evaluación queda reservado a psicólogos, que deben custodiarlo
24	Rechazar el encargo si se va a usar contra los intereses de las personas
25	Informar del método; con menores, «se hará saber a sus padres o tutores»

El segundo bloque, los **artículos 39 a 49**, trata de la **información**: qué se recoge, cómo se guarda, a quién se comunica y cómo se redacta el informe. Se estudia en el apartado 8.2.

Algunas consecuencias prácticas de estos artículos:

- **Elegir bien el instrumento** es una obligación deontológica. Los artículos 6, 17 y 18 exigen conocer las garantías de lo que se aplica y no presentar como contrastado algo que no lo está. Un cuestionario descargado de una web sin baremos ni estudios de validez no debería sostener una conclusión diagnóstica.
- **Cuidar el lenguaje** de las conclusiones (art. 12). Decir que un niño «es deficiente» etiqueta a la persona; describir su rendimiento en cada área con su margen de error informa sin estigmatizar. El art. 48 añade que los informes deben ser «claros, precisos, rigurosos e inteligibles para su destinatario» (Unidad 7).
- **Proteger el material** (art. 19). Si las láminas o los ítems de un test circulan libremente, la prueba pierde su valor para todos los futuros evaluados.

Un minicaso ayuda a ver cómo se combinan. Una psicóloga de un gabinete recibe a un adolescente derivado por su centro escolar. Antes de empezar debe explicar qué va a hacer y para qué (art. 25), aplicar solo pruebas con

garantías que domine (arts. 6 y 17), evitar etiquetas en el informe (art. 12) y decidir con la familia qué información llegará al centro (art. 41). Cada paso del proceso de evaluación (Unidad 5) tiene así su correlato ético.

8.2 Confidencialidad, secreto profesional y protección de datos

Cuatro conceptos se confunden a menudo:

- La **intimidad** es el derecho de la persona a que no se invada su vida privada. En evaluación implica **recabar solo la información necesaria** para responder a la demanda (art. 39). Preguntar por la vida sexual de alguien en una evaluación para un puesto de administrativo no está justificado.
- La **confidencialidad** es el compromiso de no revelar lo conocido en la relación profesional.
- El **secreto profesional** es la obligación deontológica y legal que concreta ese compromiso (art. 40).
- La **protección de datos** es el marco legal sobre cómo se recogen, guardan, comunican y destruyen los datos personales.

Los artículos 39 a 49 del Código desarrollan estas obligaciones:

Artículo	Contenido resumido
39	Respeto a la intimidad: recabar solo la información necesaria
40	La información obtenida está sujeta a secreto profesional
41	Comunicar a terceros solo con autorización del interesado
42	Si la evaluación la pide un tercero, el evaluado tiene derecho a conocer el informe, salvo grave perjuicio
43	Los informes para instituciones se ajustan a lo acordado
44	No usar la información en beneficio propio
45	Anonimato al exponer casos con fines docentes o científicos
46	Custodia de los registros, también los electrónicos
47	Presencia de terceros solo con consentimiento del evaluado
48	Requisitos del informe: claridad, precisión, rigor, alcance y grado de certeza
49	El secreto persiste tras el fallecimiento de la persona

El **art. 43** es especialmente importante en los contextos organizacionales. Si una empresa encarga la evaluación de candidatos, el informe que recibe se limita a lo acordado para ese fin. El resto de lo que el candidato haya contado no pasa a la empresa ni puede usarse para otros propósitos. El **art. 46** obliga a custodiar los protocolos, las grabaciones y los registros. En la práctica actual esto incluye el ordenador, el correo electrónico, las copias en la nube y las aplicaciones de corrección en línea. Dejar un informe abierto en un ordenador compartido o enviarlo sin protección a una dirección equivocada vulnera el Código, aunque no haya mala fe.

El secreto no es ilimitado. Existen situaciones excepcionales, como un riesgo grave para la persona o para terceros o un requerimiento judicial, cuyos límites se estudian en Deontología y en Psicología Jurídica. Lo relevante aquí es que la excepción debe justificarse y no convertirse en la norma.

El marco legal. Las normas deontológicas conviven con la legislación general:

1. El **Reglamento General de Protección de Datos (RGPD)** de la Unión Europea considera los datos de salud una **categoría especial**, con protección reforzada. Buena parte de la información psicológica entra en ella.
2. La **Ley Orgánica 3/2018** de Protección de Datos Personales y garantía de los derechos digitales (**LOPDGDD**) adapta el RGPD al ordenamiento español.

3. La **Ley 41/2002**, básica reguladora de la autonomía del paciente, regula la información, el consentimiento y la documentación clínica en el ámbito sanitario.

En conjunto, el Código y la ley apuntan en la misma dirección: recoger lo necesario, informar de su uso, guardarlo con seguridad y comunicarlo solo a quien corresponde.

Un ejemplo cotidiano: un psicólogo de un servicio de prevención evalúa el estrés laboral de una trabajadora a petición de la empresa. Durante la entrevista, ella cuenta que atraviesa un divorcio. Ese dato puede ser relevante para entender su malestar, pero el informe para la empresa debe ceñirse a lo acordado (art. 43). Mencionar el divorcio requeriría su autorización (art. 41) y, en cualquier caso, ella tiene derecho a conocer el informe (art. 42).

8.3 Consentimiento y evaluación de menores

Evaluar sin que la persona sepa qué se hace ni para qué vulnera su autonomía. El **art. 25** obliga a informar del método que se va a emplear. En la práctica, un **consentimiento informado** adecuado en evaluación incluye:

- el **objetivo** de la evaluación y quién la solicita;
- las **técnicas** que se van a usar y el tiempo aproximado;
- **quién recibirá** los resultados y en qué forma;
- los **límites** de la confidencialidad;
- el derecho a **preguntar**, a conocer el informe y a retirarse.

El consentimiento es especialmente delicado cuando la evaluación la pide **un tercero**: una empresa, un juzgado, un centro escolar o una aseguradora. El evaluado debe saber que el informe no es para él, aunque conserve el derecho a conocerlo salvo grave perjuicio (art. 42). El psicólogo debe **rechazar el encargo** si sabe que se va a usar contra los intereses de las personas (art. 24). Y si un familiar o un profesional en formación quiere estar presente, hace falta el consentimiento del evaluado (art. 47).

Los menores. El art. 25 establece que, cuando se evalúa a menores, «se hará saber a sus padres o tutores». La fórmula es más débil que «exigir el consentimiento» y ha generado interpretaciones distintas. En 2002, el Consejo General acordó exigir el **consentimiento de ambos progenitores**, o una resolución judicial, para los **tratamientos**. Para la evaluación, los colegios autonómicos interpretan la cuestión de manera diferente. Es un error frecuente citar el art. 25 como si exigiera literalmente el consentimiento de ambos.

¿Qué hacer en la práctica? Ante la falta de un criterio único, la conducta prudente es:

1. **Informar a ambos progenitores** e intentar obtener la conformidad de los dos, sobre todo si están separados.
2. **Documentar** a quién se ha informado, cuándo y con qué respuesta.
3. Si hay un desacuerdo abierto, valorar si procede continuar o si es necesaria una resolución judicial.
4. **Informar también al menor**, con un lenguaje adaptado a su edad, de lo que se va a hacer y por qué.

Un minicaso típico: una madre separada pide evaluar a su hija de nueve años porque cree que tiene problemas de atención. Ella paga las sesiones. El padre no sabe nada. Que la madre pague no le da la decisión en exclusiva: el padre también debe ser informado, y en muchos colegios se exigiría su conformidad. Si, además, la madre quiere usar el informe en un procedimiento de custodia, la evaluación cambia de naturaleza y entra en el terreno pericial (Unidad 7), con exigencias propias que se estudian en Psicología Jurídica.

La evaluación de menores plantea otras cuestiones éticas: quién recibe el informe (la familia, el centro escolar), cuánta información se comparte con el propio menor y cómo se respeta su intimidad cuando ya es adolescente. En todos los casos, el criterio que guía la decisión es el **interés del menor**, no la comodidad de quien encarga la evaluación.

8.4 Marcos internacionales y nuevo Código en tramitación

El Código español no está aislado. Comparte principios con varios marcos internacionales:

- El **Metacódigo de Ética de la EFPA** (Federación Europea de Asociaciones de Psicólogos), aprobado en Atenas en 1995 y revisado en Granada en 2005. No es un código para aplicar directamente, sino una guía para los códigos de las asociaciones nacionales. Se organiza en cuatro principios: **respeto** a los derechos y la dignidad de la persona, **competencia**, **responsabilidad** e **integridad**.
- La **Declaración Universal de Principios Éticos para Psicólogos** (IUPsyS e IAAP, 2008), que busca un marco común para la psicología de todo el mundo.
- Las **directrices de la Comisión Internacional de Tests (ITC)** sobre el uso, la adaptación y la seguridad de los tests, que tienen un fuerte componente ético y se estudian en el apartado 10.4.
- Las **Guías para el Proceso de Evaluación (GAP)** (Fernández-Ballesteros et al., 2001), que traducen las buenas prácticas a directrices concretas para cada fase del proceso (Unidad 5).

Los cuatro principios de la EFPA permiten ordenar los artículos del Código español: el respeto se concreta en la intimidad y el consentimiento (arts. 25 y 39 a 42); la competencia, en la formación y la elección de técnicas (arts. 17 y 18); la responsabilidad, en el rechazo de encargos dañinos y la custodia (arts. 24 y 46); la integridad, en la honestidad y el no beneficio propio (arts. 6 y 44).

Nuevos retos. La evaluación digital plantea problemas que el Código de 1987 no podía prever: corrección automática, tests en línea, datos de sensores del móvil y sistemas de inteligencia artificial (Unidad 6). La **Ley de IA de la UE** (Reglamento 2024/1689) clasifica como de **alto riesgo** ciertos usos en empleo y educación y prohíbe el reconocimiento de emociones en el trabajo y en la escuela, salvo excepciones. Un psicólogo que use una herramienta de este tipo sigue siendo responsable de las conclusiones que firma.

El nuevo Código Deontológico. El Consejo General de la Psicología ha preparado un proyecto de nuevo Código. Su tramitación, hasta noviembre de 2026, es esta:

Fecha	Paso
21-2-2026	La Junta de Gobierno aprueba el proyecto
Hasta el 15-3-2026	Audiencia pública
1-7-2026	Informe de la CNMC (INF/CNMC/130/26)
Pendiente	Aprobación por la Junta General; entraría en vigor 20 días después

No consta su aprobación definitiva, de modo que el temario lo trata como **en tramitación**. Hasta que se apruebe, el Código vigente sigue siendo el de 1987 con sus modificaciones, y es el que hay que citar en un examen o en un informe. Conviene estar atento a su aprobación, porque es previsible que actualice aspectos como la práctica en línea, los registros electrónicos o la evaluación de menores, aunque su contenido final no se conocerá hasta entonces.

Consenso y debate

Consenso: el Código Deontológico de 1987, con sus modificaciones de 2010, 2014 y 2015, es el vigente. La evaluación exige informar a la persona, recabar solo lo necesario, guardar el secreto, custodiar los registros y redactar informes claros y sin etiquetas. Las garantías éticas y científicas son inseparables: usar instrumentos sin garantías es también una falta ética.

Debate: si para evaluar a un menor basta con «hacer saber» a los padres (art. 25) o hace falta el consentimiento de ambos, como acordó el Consejo General en 2002 para los tratamientos; los colegios

autonómicos lo interpretan de forma distinta. También está abierta la aprobación del nuevo Código, todavía en tramitación, y la regulación de la evaluación con inteligencia artificial.

Mito frecuente

Mito: «Si un progenitor paga la evaluación de su hijo, decide él solo».

Realidad: pagar no otorga la decisión. El Código Deontológico (COP, 1987, art. 25) obliga a hacer saber la evaluación a los padres o tutores, y el Consejo General acordó en 2002 exigir el consentimiento de ambos progenitores, o una resolución judicial, para los tratamientos. Lo prudente es informar a los dos, documentarlo y guiarse por el interés del menor.

Conceptos clave

Concepto	Definición
Código Deontológico	Normas éticas del COP (1987; modificado en 2010, 2014 y 2015), vigentes para colegiados
Garantías éticas	Requisitos que protegen los derechos de la persona evaluada durante todo el proceso
Secreto profesional	Obligación de no revelar la información obtenida en la relación profesional (art. 40)
Intimidad	Derecho a la vida privada; obliga a recabar solo la información necesaria (art. 39)
Consentimiento informado	Aceptación de la evaluación tras conocer su objetivo, técnicas, destinatarios y límites
Categoría especial de datos	Datos, como los de salud, que el RGPD protege de forma reforzada
Metacódigo de la EFPA	Guía europea (1995, revisada en 2005): respeto, competencia, responsabilidad, integridad
Art. 42	Si un tercero pide la evaluación, el evaluado puede conocer el informe salvo grave perjuicio

Clave PIR

Prioridad media. Se pregunta qué regula cada artículo clave (6, 12, 18, 19, 25, 40, 42, 43, 46, 48) a partir de un caso práctico y qué principios recoge el Metacódigo de la EFPA. Trampas típicas: atribuir al art. 25 la exigencia literal del consentimiento de ambos progenitores, creer que la empresa que paga la evaluación puede recibir toda la información del candidato y presentar el nuevo Código como ya vigente.

Autoevaluación

1. Una empresa encarga la evaluación de candidatos para un puesto. Según el art. 43, el informe para la empresa…
a) puede incluir toda la información obtenida en la entrevista
b) se ajusta a lo acordado para ese fin concreto
c) solo puede entregarse con orden judicial previa

2. Sobre la evaluación de menores, el art. 25 del Código establece que…
a) se hará saber a sus padres o tutores
b) se exigirá por escrito el consentimiento de ambos progenitores
c) basta con el consentimiento del progenitor que la solicita

3. Un psicólogo usa una técnica novedosa sin estudios que la respalden y no avisa al cliente. Vulnera sobre todo el…
a) art. 49
b) art. 45
c) art. 18

4. ¿Cuál de estos principios NO es uno de los cuatro del Metacódigo de la EFPA?
a) Competencia
b) Eficiencia
c) Integridad

5. En noviembre de 2026, el Código Deontológico que debe citarse como vigente es…
a) el nuevo Código, aprobado por la Junta de Gobierno en 2026
b) el informe de la CNMC sobre el proyecto de Código
c) el de 1987, con sus modificaciones de 2010, 2014 y 2015

Soluciones

1 b. El art. 43 limita los informes para instituciones a lo acordado; el resto queda protegido por el secreto. **2 a.** La fórmula es «hacer saber»; el consentimiento de ambos lo acordó el Consejo General en 2002 para tratamientos. **3 c.** El art. 18 exige informar antes del carácter experimental de los procedimientos no contrastados. **4 b.** Los cuatro principios son respeto, competencia, responsabilidad e integridad. **5 c.** El nuevo Código sigue en tramitación; la Junta de Gobierno solo aprobó el proyecto.

Unidad 9 · Fiabilidad, error de medida y puntuaciones

Objetivos: explicar el modelo de la teoría clásica de los tests y la definición de fiabilidad; distinguir los tipos de fiabilidad y sus coeficientes; calcular e interpretar el error típico de medida y el intervalo de confianza de una puntuación; transformar e interpretar puntuaciones típicas y percentiles.

9.1 Teoría clásica de los tests y concepto de fiabilidad

Ninguna medida es perfecta. Si una persona hace hoy un test de razonamiento y lo repite la semana que viene, es improbable que obtenga exactamente la misma puntuación: habrá dormido distinto, acertará por azar alguna pregunta que antes falló o se distraerá con un ruido. La **fiabilidad** es la **precisión** de una medida, es decir, el grado en que está libre de error aleatorio. Estudiarla permite estimar cuánto error contiene una puntuación y, por tanto, cuánta confianza merece.

El marco tradicional para estudiarla es la **teoría clásica de los tests (TCT)**, que arranca de los trabajos de Spearman (1904). Su modelo es muy sencillo:

X = V + E

- **X** es la puntuación **observada**, la que se obtiene en el test.
- **V** es la puntuación **verdadera**, la que se obtendría sin error. Se define como la media de las puntuaciones que la persona obtendría si pudiera hacer el test infinitas veces en las mismas condiciones.
- **E** es el **error** aleatorio de medida.

El modelo añade tres supuestos: el error medio es cero (los errores se compensan a la larga), el error no se relaciona con la puntuación verdadera (no se equivoca más con quien tiene más capacidad) y los errores de dos aplicaciones distintas no se relacionan entre sí.

A partir de aquí, la **fiabilidad** se define como la **proporción de la varianza de las puntuaciones observadas que se debe a la varianza verdadera**. Se expresa con el **coeficiente de fiabilidad (rxx)**, que va de 0 a 1. Un rxx de 0,90 indica que el 90 % de las diferencias observadas entre las personas refleja diferencias reales y el 10 %, error. En la práctica, rxx se estima como la correlación entre dos medidas equivalentes del mismo atributo.

Varios factores influyen en la fiabilidad que se obtiene:

Factor	Efecto
Longitud del test	Con más ítems equivalentes, los errores se compensan y la fiabilidad sube
Variabilidad de la muestra	En muestras muy homogéneas el coeficiente baja, aunque el test no haya cambiado
Condiciones de aplicación	Instrucciones confusas, ruido o corrección subjetiva añaden error
Intervalo entre aplicaciones	En el test-retest, cuanto más tiempo, más cambio real y menor coeficiente

El efecto de la variabilidad de la muestra tiene una consecuencia importante: **la fiabilidad no es una propiedad fija del test**, sino de las puntuaciones en una muestra y unas condiciones. Un test de vocabulario puede ser muy fiable en una muestra de toda la población y bastante menos en un grupo de licenciados en Filología, que puntúan todos alto.

Dos precisiones evitan confusiones frecuentes. La primera: la fiabilidad trata del error **aleatorio**. Un error **sistemático**, como una báscula que siempre marca dos kilos de más, no reduce la fiabilidad, pero sí afecta a la validez (Unidad 10). La segunda: la fiabilidad es **condición necesaria pero no suficiente** de la validez. Un test que da resultados muy estables puede estar midiendo con precisión algo distinto de lo que pretende.

La TCT no es el único marco. La **teoría de respuesta al ítem (TRI)** estima la precisión para cada nivel del atributo, en lugar de dar un único coeficiente, y es la base de los tests adaptativos informatizados (Unidad 6). La **teoría de la generalizabilidad** (Cronbach, Gleser, Nanda y Rajaratnam, 1972) descompone el error en varias fuentes a la vez (ítems, ocasiones, evaluadores), una idea que retomó Cone al proponer su cubo (Unidad 4). El desarrollo formal de las tres teorías corresponde a Psicometría; aquí interesan como garantías del proceso de evaluación.

9.2 Tipos de fiabilidad

Como el error tiene varias fuentes, hay varias formas de estimar la fiabilidad. Cada una responde a una pregunta distinta.

Test-retest (estabilidad). Se aplica el mismo test dos veces a las mismas personas y se correlacionan las puntuaciones. Responde a la pregunta «¿se mantienen las puntuaciones en el tiempo?». Es adecuada para **rasgos** que se suponen estables, como la inteligencia, y poco útil para **estados**, como la ansiedad del momento, que cambian por naturaleza (Unidad 4). Sus problemas son el aprendizaje y el recuerdo de las respuestas si el intervalo es corto y el cambio real si es largo.

Formas paralelas (equivalencia). Se construyen dos versiones del test con contenidos distintos pero equivalentes y se correlacionan. Evita el recuerdo de los ítems y es útil cuando hay que evaluar varias veces a la misma persona, por ejemplo antes y después de un tratamiento. Su dificultad es construir formas de verdad equivalentes.

Consistencia interna. Se estima con una sola aplicación, a partir de la relación entre los ítems. Responde a la pregunta «¿los ítems miden de forma coherente?».

- **Dos mitades.** Se divide el test en dos partes (por ejemplo, ítems pares e impares) y se correlacionan. Como cada mitad es más corta que el test completo, el coeficiente se corrige con la **fórmula de Spearman-Brown**: $r = 2 \cdot r_{½} / (1 + r_{½})$. Si las mitades correlacionan 0,70, la fiabilidad estimada del test completo es 1,40 / 1,70 ≈ 0,82.
- **KR-20**, para ítems dicotómicos (acierto o error).
- **α de Cronbach** (1951), la generalización para ítems con cualquier formato, como las escalas Likert. Es el coeficiente más usado.
- **ω de McDonald**, que se calcula a partir de un modelo factorial y no exige que todos los ítems pesen igual en el factor, un supuesto del α que rara vez se cumple.

Fiabilidad entre jueces (objetividad). Cuando la puntuación depende del juicio de un evaluador, como en la observación, la entrevista o la corrección de respuestas abiertas, hay que comprobar que distintos evaluadores llegan al mismo resultado. Se usa el **kappa de Cohen** para categorías, que corrige el acuerdo debido al azar, y el **coeficiente de correlación intraclase (CCI)** para puntuaciones cuantitativas. Para kappa se suele usar la interpretación de Landis y Koch (1977): por encima de 0,60, acuerdo sustancial; por encima de 0,80, casi perfecto. El cálculo paso a paso se ve en la Unidad 14.

Tipo	Pregunta	Procedimiento	Coeficiente habitual
Test-retest	¿Es estable en el tiempo?	Dos aplicaciones del mismo test	Correlación de Pearson
Formas paralelas	¿Son equivalentes las versiones?	Dos formas equivalentes	Correlación de Pearson
Consistencia interna	¿Son coherentes los ítems?	Una sola aplicación	Spearman-Brown, KR-20, α, ω
Entre jueces	¿Coinciden los evaluadores?	Dos o más evaluadores	Kappa, CCI

La **longitud** del test se relaciona con la fiabilidad mediante la misma fórmula de Spearman-Brown en su forma general. Si un test con rxx = 0,60 se alarga al doble con ítems equivalentes, su fiabilidad estimada pasa a 1,20 / 1,60 = 0,75. Por eso las escalas muy breves, de tres o cuatro ítems, suelen tener una fiabilidad modesta.

¿Qué tipo de fiabilidad hay que mirar? Depende del uso. Para un test de aptitudes que va a orientar una decisión académica importa la estabilidad y la consistencia interna. Para un sistema de observación en un aula, el acuerdo entre observadores. Para medir el cambio con un tratamiento, las formas paralelas o la estabilidad en ausencia de tratamiento. Además, las decisiones sobre **individuos** exigen coeficientes más altos que las comparaciones entre grupos en investigación, porque el error pesa mucho más cuando la conclusión afecta a una sola persona.

Un error frecuente es interpretar un **α alto** como prueba de que el test mide **una sola cosa**. El α depende del número de ítems y de su correlación media: un test largo que mezcla dos factores distintos puede alcanzar un α elevado. La unidimensionalidad se comprueba con análisis factorial, que es una evidencia de **estructura interna** (Unidad 10).

9.3 Error típico de medida e intervalos de confianza

El coeficiente de fiabilidad describe el test en una muestra. Pero en evaluación lo que interesa casi siempre es una **puntuación individual**: ¿cuánto puede alejarse la puntuación de Marta de su puntuación verdadera? Para responder se usa el **error típico de medida (ETM)**:

ETM = Sx · √(1 − rxx)

donde Sx es la desviación típica de las puntuaciones del test y rxx su coeficiente de fiabilidad. El ETM es la desviación típica de los errores: indica cuánto oscilarían las puntuaciones observadas de una persona alrededor de su puntuación verdadera si pudiera hacer el test muchas veces.

Dos rasgos de la fórmula merecen atención:

- Si la fiabilidad fuera perfecta (rxx = 1), el ETM sería 0. Si fuera nula (rxx = 0), el ETM sería igual a la desviación típica del test: la puntuación no diría nada de la persona.
- La relación no es lineal. En una escala de CI con DT = 15, subir de rxx = 0,50 a 0,62 apenas reduce el ETM (de 10,6 a 9,2 puntos), mientras que pasar de 0,84 a 0,96 lo reduce a la mitad (de 6 a 3): cerca de 1, cada mejora de la fiabilidad recorta mucho el error.

No hay que confundir el ETM con la desviación típica del test. La **DT** describe cuánto difieren las **personas** entre sí; el **ETM** describe cuánto puede variar la puntuación de **una misma persona** por efecto del error.

Con el ETM se construye un **intervalo de confianza** alrededor de la puntuación observada. Si se asume que los errores se distribuyen normalmente:

- intervalo del **68 %**: X ± 1·ETM;
- intervalo del **95 %**: X ± 1,96·ETM.

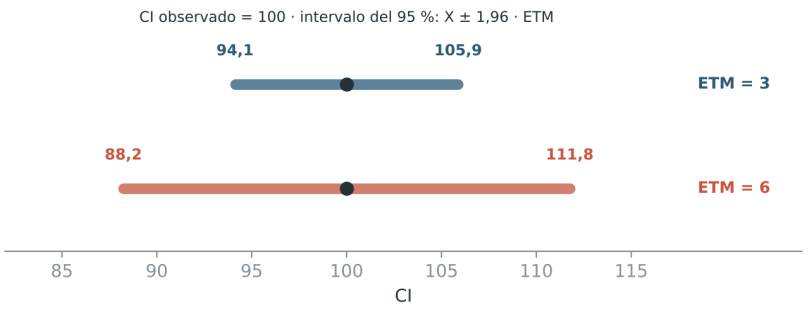


Figura 9.1. **El error típico de medida y la banda de confianza.** Para un CI observado de 100, el intervalo del 95 % va de 94,1 a 105,9 si el ETM es 3, y de 88,2 a 111,8 si el ETM es 6. Elaboración propia.

Como muestra la figura 9.1, con el mismo CI observado de 100, la conclusión cambia mucho según la precisión del test. Con ETM = 3, la puntuación verdadera está, con una confianza del 95 %, entre 94,1 y 105,9 (100 ± 5,88). Con ETM = 6, el intervalo se ensancha hasta 88,2–111,8 (100 ± 11,76), una franja que abarca desde la parte baja hasta la parte alta del promedio.

Las consecuencias prácticas son claras:

1. **Informar con intervalos**, no con puntuaciones aisladas. Escribir «CI = 100» sugiere una precisión que el test no tiene; «CI entre 94 y 106 (95 %)» transmite lo que realmente se sabe. El art. 48 del Código pide expresar el grado de certeza de las conclusiones (Unidad 8).
2. **Prudencia con los puntos de corte.** Si un centro exige un CI de 130 para un programa de altas capacidades, una puntuación de 128 con ETM = 3 no permite afirmar que la persona está por debajo del corte: su intervalo del 95 % llega hasta casi 134.
3. **Prudencia con las diferencias.** Que un niño obtenga 95 en comprensión verbal y 102 en razonamiento perceptivo no implica que tenga un perfil desequilibrado si los intervalos de ambas puntuaciones se solapan ampliamente. La comparación de puntuaciones de un perfil se desarrolla en Psicometría y en Evaluación Psicológica II.
4. **Prudencia con el cambio.** Una mejora de 4 puntos entre dos evaluaciones puede ser solo error si el ETM es de 5 puntos.

El ETM de la TCT es el mismo para todas las puntuaciones del test. La TRI permite estimar un error distinto para cada nivel del atributo: los tests suelen medir con más precisión en la zona central, donde hay más ítems de dificultad adecuada, que en los extremos.

Ejemplo resuelto

Un test de aptitud tiene media 100, DT = 15 y un coeficiente de fiabilidad rxx = 0,91. Un estudiante obtiene una puntuación de 112. ¿Qué se puede afirmar?

Paso 1. Calcular el ETM.
ETM = 15 · √(1 − 0,91) = 15 · √0,09 = 15 · 0,3 = **4,5 puntos**.

Paso 2. Construir el intervalo del 95 %.
1,96 · 4,5 = 8,82. Intervalo: 112 − 8,82 = 103,18 y 112 + 8,82 = 120,82. Redondeando, **entre 103 y 121**.

Paso 3. Construir el intervalo del 68 %.
112 ± 4,5: **entre 107,5 y 116,5**.

Paso 4. Interpretar.
- Con una confianza del 95 %, la puntuación verdadera está por encima de la media (100), porque el límite inferior del intervalo es 103.
- No se puede afirmar que esté por encima de 115 (una desviación típica sobre la media), porque el intervalo incluye valores inferiores y superiores a 115.
- En puntuaciones típicas, 112 equivale a z = (112 − 100) / 15 = 0,8, a T = 50 + 10 · 0,8 = 58 y, en una distribución normal, a un percentil aproximado de 79.

Paso 5. Comparar con un test menos fiable.
Si el test tuviera rxx = 0,75, el ETM sería 15 · √0,25 = 7,5 y el intervalo del 95 % iría de 112 − 14,7 = 97,3 a 112 + 14,7 = 126,7. Con esa precisión ni siquiera podría afirmarse que el estudiante está por encima de la media.

Cómo redactarlo en el informe: «Obtiene una puntuación de 112, situada en la zona media-alta. Teniendo en cuenta el error de medida, su puntuación verdadera se encuentra, con un 95 % de confianza, entre 103 y 121».

9.4 Baremos y puntuaciones típicas

Una puntuación directa, como 34 aciertos, no significa nada por sí sola: depende de cuántos ítems tiene el test y de lo difíciles que son. Para interpretarla hay que compararla con algo.

- En la **interpretación normativa** se compara con un **grupo de referencia**: ¿cuántas personas de su edad obtienen menos? Para ello se usan los **baremos** o normas, tablas que transforman las puntuaciones directas en puntuaciones derivadas a partir de una muestra normativa. Pueden ser generales o específicos por edad, sexo, curso u otras variables.
- En la **interpretación criterial** se compara con un **criterio** de dominio o un punto de corte: ¿domina la persona el 80 % de las operaciones aritméticas del curso? No importa cómo lo hagan los demás.

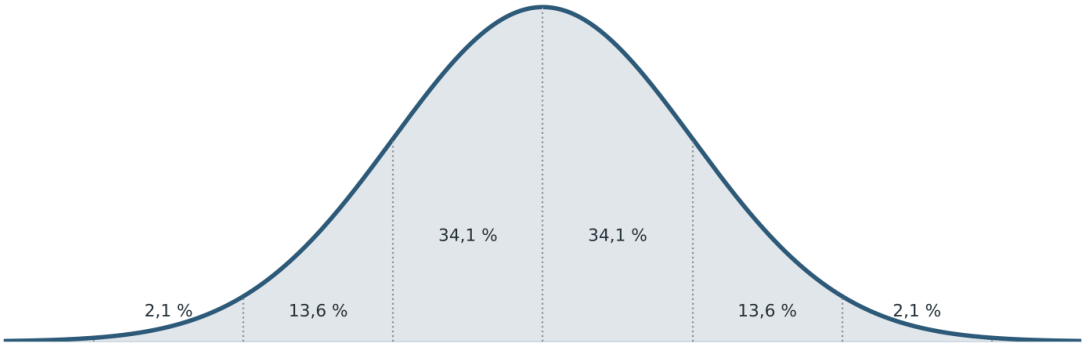
Un baremo solo es útil si la muestra normativa es **representativa** de la población con la que se compara al evaluado, **suficientemente amplia** y **actual**. Comparar a un adolescente español con un baremo antiguo o elaborado en otro país puede dar resultados engañosos.

Puntuaciones típicas. La base de las escalas derivadas es la puntuación **z**, que expresa a cuántas desviaciones típicas está una puntuación de la media del grupo:

z = (X − media) / DT

A partir de z se obtienen las demás escalas con una transformación lineal: nueva puntuación = media de la escala + DT de la escala · z.

Escala	Media	DT	Transformación	Uso típico
z	0	1	—	Base de las demás
T	50	10	50 + 10z	Cuestionarios de personalidad y clínicos
CI de desviación	100	15	100 + 15z	Tests de inteligencia
Escalar Wechsler	10	3	10 + 3z	Subpruebas de las escalas Wechsler
Eneatipo	5	2	5 + 2z	Escala de 1 a 9
Decatipo	5,5	2	5,5 + 2z	Escala de 1 a 10



Puntuación z	-3	-2	-1	0	+1	+2	+3
T (50; 10)	20	30	40	50	60	70	80
CI (100; 15)	55	70	85	100	115	130	145
Escalar (10; 3)	1	4	7	10	13	16	19
Eneatipo (5; 2)	1	1	3	5	7	9	9
Decatipo (5,5; 2)	1	1,5	3,5	5,5	7,5	9,5	10
Percentil	0,1	2	16	50	84	98	99,9

Eneatipo y decatipo se truncan en sus extremos (1–9 y 1–10). Los percentiles son ordinales: no se promedian.

Figura 9.2. **Equivalencias entre escalas en la curva normal.** Ejes paralelos con las puntuaciones z, T, CI, escalares Wechsler, eneatipos, decatipos y percentiles en la media y a ±1, ±2 y ±3 desviaciones típicas. Elaboración propia.

Como muestra la figura 9.2, todas las escalas típicas dicen lo mismo con números distintos. Una persona que está una desviación típica por encima de la media tiene z = 1, T = 60, CI = 115 y escalar 13, y en una distribución normal se sitúa en torno al percentil 84. A dos desviaciones típicas por debajo, z = −2, T = 30, CI = 70 y escalar 4, cerca del percentil 2.

Los percentiles. El **percentil** indica el porcentaje del grupo normativo que obtiene una puntuación igual o inferior. Es la puntuación más fácil de explicar a una familia («ha puntuado mejor que 84 de cada 100 niños de su edad»), pero tiene una limitación importante: es una escala **ordinal**. Las distancias entre percentiles no son iguales en el atributo medido. Como la mayoría de las personas se concentran en el centro de la distribución, en esa zona unos pocos puntos de diferencia real cambian mucho el percentil, y en los extremos ocurre lo contrario:

- de P50 a P60 hay una diferencia de unas 0,25 desviaciones típicas;
- de P90 a P99 hay una diferencia de más de una desviación típica.

Por esta razón **no se pueden promediar percentiles** ni restarlos para medir el cambio. Si un niño está en el percentil 50 en una subprueba y en el 99 en otra, decir que su «percentil medio» es 74,5 no tiene sentido. Para combinar o comparar puntuaciones hay que usar escalas de intervalo, como z o T, y, si se quiere una puntuación compuesta, recurrir al baremo de esa puntuación compuesta.

Dos precauciones más. Las equivalencias exactas entre percentiles y puntuaciones típicas solo valen si la distribución es **normal**; si no lo es, el baremo debe dar los percentiles empíricos. Y toda puntuación derivada hereda el error de la puntuación directa: un percentil 84 también tiene su intervalo de confianza. La construcción de baremos y la normalización de puntuaciones se estudian en Psicometría.

Consenso y debate

Consenso: toda puntuación contiene error y debe interpretarse con su intervalo de confianza, calculado a partir del ETM. La fiabilidad no es una propiedad fija del test, sino de las puntuaciones en una muestra y un uso, y es necesaria pero no suficiente para la validez. Un α alto no demuestra unidimensionalidad. Los percentiles son ordinales y no se promedian.

Debate: si el α de Cronbach debe sustituirse de forma general por el ω de McDonald, dado que el α supone que todos los ítems pesan igual. También se discute cuándo conviene abandonar el error único de la TCT en favor de la precisión variable de la TRI y de los tests adaptativos, y qué fiabilidad mínima es aceptable para decisiones individuales de alto impacto.

Mito frecuente

Mito: «Si un test tiene un α alto, eso demuestra que mide una sola cosa».

Realidad: el α de Cronbach (1951) es un coeficiente de consistencia interna que depende del número de ítems y de su correlación media. Un test largo puede alcanzar un α alto aunque mezcle varios factores. La unidimensionalidad se comprueba con análisis factorial, una evidencia de estructura interna según los Standards (AERA, APA y NCME, 2014).

Conceptos clave

Concepto	Definición
Fiabilidad	Precisión de una medida; proporción de varianza observada que es varianza verdadera

Concepto	Definición
Modelo X = V + E	En la TCT, la puntuación observada es la suma de la verdadera y un error aleatorio
Test-retest	Estabilidad de las puntuaciones al aplicar el mismo test dos veces
Spearman-Brown	Fórmula que estima la fiabilidad de un test al cambiar su longitud
α de Cronbach	Coeficiente de consistencia interna basado en la covariación de los ítems (1951)
Error típico de medida	Desviación típica del error: ETM = Sx·√(1 − rxx)
Puntuación z	Distancia a la media en desviaciones típicas: (X − media) / DT
Percentil	Porcentaje del grupo normativo con puntuación igual o inferior; escala ordinal

Clave PIR

Prioridad alta. Se pide calcular el ETM y un intervalo de confianza, transformar puntuaciones entre escalas (z, T, CI, escalares, eneatipos, decatipos) e identificar el tipo de fiabilidad adecuado para un caso. Trampas típicas: confundir el ETM con la DT, usar 1 en lugar de 1,96 para el intervalo del 95 %, olvidar que el decatipo tiene media 5,5, promediar percentiles y tomar un α alto como prueba de unidimensionalidad.

Autoevaluación

1. Un test tiene DT = 10 y rxx = 0,84. ¿Cuál es su error típico de medida?
a) 1,6
b) 8,4
c) 4

2. Para estimar la fiabilidad de una escala de ansiedad estado, el procedimiento menos adecuado es…
a) el test-retest con un mes de intervalo
b) el α de Cronbach en una sola aplicación
c) el ω de McDonald en una sola aplicación

3. Una puntuación T de 35 equivale a…
a) z = −1,5 y CI = 77,5
b) z = −0,5 y CI = 92,5
c) z = −1,5 y CI = 85

4. Un test largo que mezcla dos factores distintos obtiene α = 0,92. ¿Qué puede concluirse?
a) Que mide un único constructo con mucha precisión
b) Que su consistencia interna es alta, sin probar unidimensionalidad
c) Que su validez de constructo queda demostrada

5. ¿Por qué no deben promediarse percentiles?
a) Porque solo existen para distribuciones no normales
b) Porque siempre sobreestiman la puntuación verdadera
c) Porque son ordinales y sus distancias no son iguales

Soluciones

1 c. ETM = 10·√(1 − 0,84) = 10·√0,16 = 10·0,4 = 4. **2 a.** El estado cambia por naturaleza; un mes después la correlación reflejaría cambios reales, no error. **3 a.** z = (35 − 50) / 10 = −1,5, y CI = 100 + 15·(−1,5) = 77,5. **4 b.** El α depende de la longitud y la correlación media; la unidimensionalidad exige análisis factorial. **5 c.** En el centro de la distribución unos pocos puntos cambian mucho el percentil y en los extremos ocurre lo contrario.

Unidad 10 · Validez y calidad de los tests

Objetivos: explicar la concepción actual de la validez según los Standards (2014) y sus cinco fuentes de evidencia; interpretar las evidencias convergentes, discriminantes y de criterio, y la matriz multirrasgo-multimétodo; calcular e interpretar sensibilidad, especificidad y valores predictivos; conocer los recursos para valorar la calidad de los tests y su uso real en España.

10.1 La validez según los Standards (2014)

Un test puede ser muy fiable y, aun así, no servir para lo que se pretende. Una cinta métrica mide con gran precisión el perímetro craneal, pero no la inteligencia, como creyeron algunos autores del siglo XIX. La **validez** es la garantía más importante de una evaluación porque se refiere a si las conclusiones que se sacan de las puntuaciones están justificadas.

La definición más extendida dice que un test es válido si «mide lo que pretende medir». Es intuitiva, pero incompleta. La concepción actual, recogida en los **Standards for Educational and Psychological Testing** (AERA, APA y NCME, 2014), sostiene que la validez es el **grado en que la evidencia y la teoría apoyan las interpretaciones de las puntuaciones para los usos propuestos**. Tres ideas se siguen de ella:

1. **No se valida el test, sino una interpretación para un uso.** Un cuestionario de ansiedad puede estar bien respaldado para el cribado en atención primaria y no para seleccionar personal en una empresa.
2. **La validez es una cuestión de grado**, no de todo o nada. Se acumula evidencia a favor o en contra.
3. **La validez es unitaria.** No hay «tipos» de validez independientes, sino distintas **fuentes de evidencia** que contribuyen a un mismo argumento.

Esta concepción es el resultado de una evolución. Durante décadas se habló de tres tipos de validez, contenido, criterio y constructo, la llamada visión «trinitaria». Cronbach y Meehl (1955) definieron la validez de constructo, y Messick (1989) defendió que toda la validez es, en el fondo, validez de constructo, e incorporó las consecuencias del uso del test. Los Standards actuales recogen esa visión unificada.

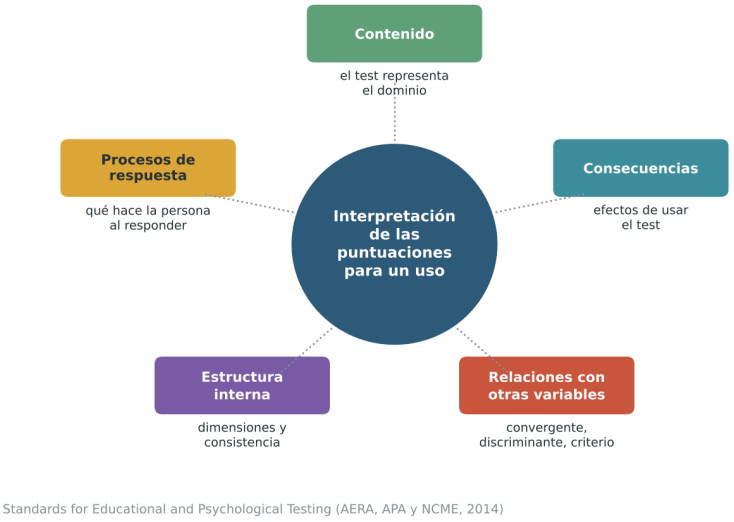


Figura 10.1. **Las cinco fuentes de evidencia de validez.** Contenido, procesos de respuesta, estructura interna, relaciones con otras variables y consecuencias se sitúan alrededor de la interpretación de las puntuaciones para un uso, que es lo que se valida. Elaboración propia.

Como muestra la figura 10.1, los Standards distinguen **cinco fuentes de evidencia**:

Fuente	Pregunta	Ejemplo
Contenido	¿Los ítems representan bien el dominio que se quiere evaluar?	Jueces expertos comprueban que un examen de conducir cubre todas las normas relevantes
Procesos de respuesta	¿Las personas responden usando los procesos que el test supone?	Entrevistas cognitivas para ver cómo se interpreta cada ítem
Estructura interna	¿Las relaciones entre los ítems coinciden con lo que propone la teoría?	Análisis factorial que confirma las dimensiones previstas
Relaciones con otras variables	¿Las puntuaciones se relacionan con otras medidas como se espera?	Correlación con otra escala del mismo constructo o con un criterio externo
Consecuencias	¿Qué efectos, previstos o no, tiene usar el test?	Comprobar si una prueba de selección perjudica sin justificación a un grupo

Muchos manuales siguen usando la terminología clásica, y conviene conocerla. La **validez de contenido** equivale a la primera fuente. La **validez de criterio**, con sus variantes predictiva, concurrente y retrospectiva, forma parte de las relaciones con otras variables (apartado 10.2). La **validez de constructo** abarca hoy todo el argumento.

La **validez aparente** merece una mención aparte. Es el grado en que un test **parece** adecuado a quien lo responde. No es una evidencia técnica de validez: un test puede parecer muy apropiado y no medir bien, o al revés. Pero tiene consecuencias prácticas, porque una persona que percibe el test como absurdo puede colaborar poco o abandonarlo.

Algunos manuales añaden un tercer criterio de calidad junto a la fiabilidad y la validez: la **utilidad**. Un test preciso y bien validado puede no aportar nada a una decisión concreta si la información ya se tenía por otras vías o si su coste no compensa. Esta idea se relaciona con la **validez incremental**, que se estudia en el apartado siguiente, y con la evaluación basada en la evidencia (Unidad 6).

10.2 Evidencias convergentes, discriminantes y de criterio

Las **relaciones con otras variables** son la fuente de evidencia más usada en la práctica. Incluyen tres tipos de datos.

Evidencia convergente. Las puntuaciones deben correlacionar **alto** con otras medidas del **mismo constructo** o de constructos muy próximos. Una nueva escala de depresión debería correlacionar con otras escalas de depresión ya consolidadas.

Evidencia discriminante. Las puntuaciones deben correlacionar **bajo** con medidas de **constructos distintos**. Si la nueva escala de depresión correlacionara tanto con una medida de deseabilidad social como con otra de depresión, cabría sospechar que mide en parte la tendencia a dar una buena imagen.

Evidencia de criterio. Las puntuaciones deben relacionarse con un **criterio externo** relevante para el uso. Según el momento en que se recoge el criterio, se distingue:

- **predictiva**: el criterio se mide **después** (una prueba de selección y el rendimiento en el puesto un año más tarde);
- **concurrente**: el criterio se mide **a la vez** (un cuestionario de cribado y el diagnóstico de una entrevista estructurada ese mismo día);
- **retrospectiva**: el criterio procede del **pasado** (un cuestionario actual y el historial académico previo).

La evidencia de criterio depende de la calidad del propio criterio. Si el criterio es poco fiable, la correlación con el test baja aunque el test sea bueno: el coeficiente de validez no puede superar la raíz cuadrada del producto de las fiabilidades del test y del criterio. Con $r_{xx} = 0{,}81$ y $r_{yy} = 0{,}64$, el máximo posible es $\sqrt{(0{,}81 \cdot 0{,}64)} = 0{,}72$.

También hay que evitar la **contaminación del criterio**: si el supervisor que valora el rendimiento conoce las puntuaciones del test, su juicio puede estar influido por ellas.

La matriz multirrasgo-multimétodo. Campbell y Fiske (1959) propusieron un procedimiento que reúne las evidencias convergentes y discriminantes en una sola tabla. Se miden **varios rasgos** con **varios métodos** y se correlacionan todas las combinaciones.

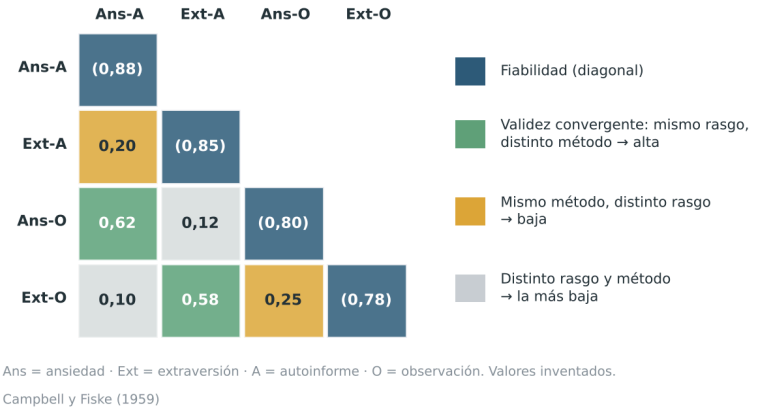


Figura 10.2. **Matriz multirrasgo-multimétodo.** Dos rasgos (ansiedad y extraversión) medidos con dos métodos (autoinforme y observación), con la diagonal de fiabilidad, la de validez convergente y las correlaciones de validez discriminante señaladas. Valores ilustrativos (Campbell y Fiske, 1959). Elaboración propia.

Como muestra la figura 10.2, la matriz se lee comparando bloques de correlaciones:

1. La **diagonal de fiabilidad** (mismo rasgo, mismo método) debe tener los valores más altos.
2. La **diagonal de validez convergente** (mismo rasgo, distinto método) debe ser alta: la ansiedad medida por autoinforme debe correlacionar con la ansiedad observada.
3. Las correlaciones entre **rasgos distintos** deben ser más bajas que las convergentes, tanto si se miden con el mismo método como con métodos distintos.

Si dos rasgos distintos medidos con el mismo método correlacionan más que un mismo rasgo medido con métodos distintos, hay **varianza de método**: parte de lo que se mide se debe al instrumento y no al rasgo. Este razonamiento enlaza con la evaluación multimétodo y multiinformante (Unidad 1).

Validez incremental. Un instrumento tiene validez incremental si **mejora la predicción** respecto a lo que ya se sabía con otras fuentes. Si la entrevista y un cuestionario breve ya predicen bien un resultado, añadir una prueba larga y costosa solo se justifica si aporta información nueva. Es un criterio central de la evaluación basada en la evidencia (Unidad 6).

10.3 Utilidad diagnóstica: sensibilidad, especificidad y curvas ROC

Muchos instrumentos se usan para **clasificar**: tiene o no tiene un trastorno, supera o no un criterio, está o no en riesgo. En estos casos, la validez se expresa con índices de **utilidad diagnóstica**, que comparan la clasificación del test con la de un criterio de referencia.

Un ejemplo hipotético: un cuestionario de cribado de depresión se aplica a 200 personas en atención primaria. Una entrevista estructurada, tomada como criterio, identifica a 40 personas con depresión.

	Con depresión (criterio)	Sin depresión (criterio)	Total
Test positivo	34 (verdaderos positivos)	16 (falsos positivos)	50
Test negativo	6 (falsos negativos)	144 (verdaderos negativos)	150

	Con depresión (criterio)	Sin depresión (criterio)	Total
Total	40	160	200

A partir de la tabla se calculan cuatro índices:

- **Sensibilidad**: proporción de personas con el trastorno que el test detecta. 34 / 40 = **0,85**.
- **Especificidad**: proporción de personas sin el trastorno que el test descarta. 144 / 160 = **0,90**.
- **Valor predictivo positivo (VPP)**: proporción de positivos que realmente tienen el trastorno. 34 / 50 = **0,68**.
- **Valor predictivo negativo (VPN)**: proporción de negativos que realmente no lo tienen. 144 / 150 = **0,96**.

La sensibilidad y la especificidad son propiedades del test en relación con el criterio. Los **valores predictivos**, en cambio, **dependen de la tasa base**: el mismo test aplicado donde el trastorno es raro produce un VPP mucho menor, porque los falsos positivos, procedentes del gran grupo sano, superan a los verdaderos positivos. Este efecto se vio con detalle en la Unidad 6. Para el profesional, los valores predictivos son los que responden a la pregunta práctica: «este paciente ha dado positivo; ¿qué probabilidad hay de que tenga el trastorno?».

El punto de corte. Un cuestionario da una puntuación continua, y hay que decidir a partir de qué valor se considera positivo. Esa decisión implica un **compromiso**:

- Si se **baja** el punto de corte, el test detecta a más personas con el trastorno (sube la sensibilidad), pero también clasifica como positivas a más personas sanas (baja la especificidad).
- Si se **sube**, ocurre lo contrario.

El punto adecuado depende del coste de cada error. En un **cribado**, donde un positivo solo conduce a una evaluación más completa, se prefiere una sensibilidad alta para no dejar casos sin detectar. Cuando un positivo tiene consecuencias graves, como una baja laboral o una medida judicial, se prefiere una especificidad alta.

Las curvas ROC. Para ver todos los puntos de corte a la vez se usa la **curva ROC** (*receiver operating characteristic*). Representa, para cada posible punto de corte, la sensibilidad en el eje vertical frente a 1 − especificidad (la proporción de falsos positivos) en el eje horizontal. Un test sin capacidad discriminativa produce una diagonal; cuanto más se acerca la curva a la esquina superior izquierda, mejor discrimina.

El índice resumen es el **área bajo la curva (AUC)**:

AUC	Interpretación
0,5	El test no discrimina mejor que el azar
Entre 0,5 y 1	Discriminación creciente cuanto más se acerca a 1
1	Discriminación perfecta

El AUC puede interpretarse como la probabilidad de que una persona elegida al azar del grupo con el trastorno obtenga una puntuación más alta que una persona elegida al azar del grupo sin él. Permite comparar instrumentos con independencia del punto de corte, aunque en la práctica clínica siempre habrá que elegir uno.

Una advertencia final: todos estos índices dependen de la calidad del **criterio**. Si la entrevista de referencia también se equivoca, los índices del cuestionario quedarán distorsionados. En psicología rara vez existe un criterio perfecto, y la concordancia entre el diagnóstico clínico rutinario y las entrevistas estandarizadas es modesta (Unidad 12).

10.4 Calidad y uso de los tests: CET-R, directrices ITC y uso en España

Quien evalúa casi nunca ha construido los tests que usa; su papel es el de **usuario** informado, capaz de escoger bien. Para ello necesita información fiable sobre su calidad, y existen varios recursos.

El CET-R. El **Cuestionario para la Evaluación de los Tests** se publicó en una primera versión (Prieto y Muñiz, 2000) y se revisó como **CET-R** (Hernández, Ponsoda, Muñiz, Prieto y Elosua, 2016), siguiendo el modelo europeo de evaluación de tests de la EFPA (Evers et al., 2013). Es una guía estructurada para que revisores expertos valoren un test con criterios explícitos: su fundamentación, la calidad de sus materiales y documentación, las evidencias de fiabilidad y validez y la calidad de sus baremos. La **Comisión de Test del COP** publica revisiones periódicas de tests editados en España desde 2010, que cualquier profesional puede consultar antes de elegir un instrumento.

Las directrices de la ITC. La Comisión Internacional de Tests ha elaborado varias directrices, resumidas en español por Muñiz, Hernández y Ponsoda (2015):

Directriz	Para qué sirve
Uso de los tests	Competencias y buenas prácticas del usuario, desde la elección hasta la comunicación de resultados
Traducción y adaptación (2.ª ed., 2017)	Cómo adaptar un test a otra lengua y cultura con garantías de equivalencia
Seguridad	Protección de los materiales y de los resultados
Control de calidad	Procedimientos para asegurar la calidad en la aplicación, corrección e informe

La directriz de **adaptación** recuerda que traducir un test no basta. Hay que comprobar que los ítems significan lo mismo en la nueva cultura, que la estructura se mantiene y que se dispone de baremos propios. Aplicar en España un cuestionario traducido de manera informal desde otro idioma, sin estudios de equivalencia, es un riesgo técnico y ético (arts. 6 y 18 del Código; Unidad 8).

El uso real de los tests en España. Varias encuestas a profesionales permiten conocer qué tests se usan:

- Muñiz y Fernández-Hermida (2000), con 3.455 psicólogos, encontraron que los **tests de inteligencia** eran los más usados.
- En la encuesta de 2010, los mismos autores situaron el **WISC** en primer lugar y el **MCMI** en segundo.
- Muñiz, Hernández y Fernández-Hermida (2020) comprobaron que los 25 tests más usados son **psicométricos** y que las técnicas proyectivas no aparecen entre ellos. Además, solo el **22,5 %** de los encuestados conocía las revisiones de la Comisión de Test.

El último dato es el más preocupante: la información sobre la calidad de los tests existe, pero buena parte de los profesionales no la consulta. Elegir un instrumento por costumbre, porque se aprendió en la carrera o porque es el que hay en el centro, sin revisar sus evidencias para el uso concreto, contradice todo lo visto en este capítulo.

Una lista de comprobación antes de usar un test:

1. ¿Hay evidencias de validez para **este uso** y **esta población**?
2. ¿Qué **fiabilidad** tiene, y qué ETM resulta para las decisiones que voy a tomar?
3. ¿Los **baremos** son representativos, amplios y actuales?
4. Si es una adaptación, ¿se siguieron las directrices de la ITC?
5. ¿Hay una revisión de la Comisión de Test o una valoración con el CET-R?
6. ¿Tengo la **competencia** para aplicarlo, corregirlo e interpretarlo (art. 17)?

Los tests concretos de inteligencia, personalidad y psicopatología se estudian en Evaluación Psicológica II.

Consenso y debate

Consenso: lo que se valida es la interpretación de las puntuaciones para un uso, no el test (AERA, APA y NCME, 2014). La validez es unitaria, gradual y se apoya en cinco fuentes de evidencia. La fiabilidad es

necesaria pero no suficiente. Los valores predictivos dependen de la tasa base, y la elección del punto de corte depende del coste de cada tipo de error.

Debate: si las consecuencias del uso de un test deben formar parte de la validez o tratarse como una cuestión ética separada. También se discute cómo validar las métricas pasivas (sensores del móvil, *wearables*) y los sistemas de inteligencia artificial, cuyas puntuaciones a menudo no se apoyan en un constructo bien definido, y que la Ley de IA de la UE (Reglamento 2024/1689) considera de alto riesgo en ciertos usos de empleo y educación.

Mito frecuente

Mito: «Este test es válido».

Realidad: la validez no es una propiedad del test, sino de las interpretaciones de sus puntuaciones para un uso concreto (AERA, APA y NCME, 2014). Un mismo cuestionario puede estar bien respaldado para el cribado clínico y carecer de evidencias para la selección de personal. La pregunta correcta es: «¿válido para qué, con quién y para tomar qué decisión?».

Conceptos clave

Concepto	Definición
Validez	Grado en que evidencia y teoría apoyan una interpretación de las puntuaciones para un uso
Evidencia convergente	Correlación alta con otras medidas del mismo constructo
Evidencia discriminante	Correlación baja con medidas de constructos distintos
Validez predictiva	Relación del test con un criterio medido en el futuro
Matriz multirrasgo-multimétodo	Tabla de varios rasgos × varios métodos para evaluar convergencia y discriminación (1959)
Sensibilidad	Proporción de personas con el trastorno que el test clasifica como positivas
Valor predictivo positivo	Proporción de positivos que tienen realmente el trastorno; depende de la tasa base
CET-R	Cuestionario para valorar la calidad de un test, basado en el modelo de la EFPA (2016)

Clave PIR

Prioridad alta. Se pregunta la concepción unitaria de la validez de los Standards, la identificación de cada fuente de evidencia o tipo clásico de validez a partir de un ejemplo, la lectura de la matriz de Campbell y Fiske y el cálculo de sensibilidad, especificidad y valores predictivos desde una tabla 2×2. Trampas típicas: decir que «el test es válido», confundir sensibilidad con VPP, creer que el VPP no cambia con la prevalencia y tratar la validez aparente como una evidencia técnica.

Autoevaluación

1. Según los Standards (2014), lo que se valida es…
a) el test en sí, una vez publicado con sus baremos
b) la interpretación de las puntuaciones para un uso
c) la fiabilidad del test en la muestra normativa

2. Una prueba de selección se aplica hoy y se correlaciona con el rendimiento en el puesto al cabo de un año. Es una evidencia de validez…
a) concurrente
b) de contenido
c) predictiva

3. En una matriz multirrasgo-multimétodo, la ansiedad por autoinforme y la ansiedad observada deben correlacionar alto. Es evidencia…
a) convergente
b) discriminante
c) de fiabilidad

4. Un test detecta a 45 de 50 personas con un trastorno y descarta a 180 de 200 sin él. Su especificidad es…
a) 0,90
b) 0,10
c) 0,69

5. Si un test se aplica en una población donde el trastorno es mucho más raro, manteniendo su sensibilidad y especificidad…
a) su VPP aumenta
b) su VPP disminuye
c) su VPP no cambia

Soluciones

1 b. La validez es de las interpretaciones para un uso, no del test. **2 c.** El criterio se mide después de aplicar el test. **3 a.** Mismo rasgo con distinto método: es la diagonal de validez convergente. **4 a.** Especificidad = 180 / 200 = 0,90; la sensibilidad sería 45 / 50 = 0,90 también, y el VPP, 45 / 65 ≈ 0,69. **5 b.** Con una tasa base baja aumentan los falsos positivos en proporción y baja el VPP.

Capítulo 4 · La entrevista

Casi toda evaluación psicológica empieza con una conversación, y muchas no dejan de apoyarse en ella hasta el final. Este capítulo estudia la entrevista como método de evaluación: qué la distingue de una charla, qué actitudes y técnicas requiere, cómo se desarrolla y qué formas adopta en la clínica, en el juzgado, en la empresa y con niños. El hilo conductor es una idea bien respaldada por la evidencia: cuanto más estructurada está una entrevista, más fiable y válida resulta.

Unidad 11 · La entrevista: concepto, clasificación y habilidades

Objetivos: definir la entrevista psicológica y diferenciarla de otras formas de conversación; valorar sus ventajas y sus limitaciones como método de evaluación; clasificar las entrevistas según su estructura, su objetivo, el número de participantes y el momento del proceso; describir las actitudes del entrevistador; distinguir las principales técnicas de pregunta y de escucha.

11.1 Concepto, ventajas y limitaciones

La **entrevista psicológica** es una conversación dirigida, con un propósito evaluador, en la que una persona obtiene información sobre otra (o sobre un grupo) mediante una interacción cara a cara o a distancia. No basta con que dos personas hablen. Una charla entre amigos no tiene un objetivo fijado de antemano, y un interrogatorio no busca comprender, sino obtener datos aunque sea contra la voluntad del otro. La entrevista se sitúa entre ambos y tiene cuatro rasgos propios:

- **Objetivo previo.** El entrevistador sabe qué necesita averiguar y para qué.
- **Roles diferenciados.** Uno pregunta y dirige; el otro informa. La relación es asimétrica, aunque respetuosa.
- **Interacción en dos sentidos.** Lo que dice el entrevistado modifica la siguiente pregunta, y lo que hace el entrevistador influye en lo que se cuenta.
- **Doble canal.** Se recoge lo que se dice y cómo se dice: el tono, los silencios, la postura.

De ahí una consecuencia importante: el entrevistador es **a la vez el instrumento y una fuente de error**. Sus preguntas, sus expectativas y su forma de reaccionar forman parte de la medida. Por eso la entrevista exige más formación y práctica que aplicar un cuestionario.

En términos de Cronbach y Gleser (1957/1965), la entrevista es el método con **máximo ancho de banda**: abarca muchos temas en poco tiempo. A cambio, su **fidelidad**, la precisión con la que mide cada aspecto, es variable (Unidad 4). En el cubo de Cone, la entrevista ocupa el extremo más indirecto de los métodos: la persona informa de su conducta, pero no se la observa.

Ventajas	Limitaciones
Flexibilidad: se adapta sobre la marcha al caso	Coste en tiempo y, a menudo, varias sesiones
Acceso a la historia personal y a la experiencia subjetiva	Fiabilidad baja cuando no hay estructura

Ventajas	Limitaciones
Observación simultánea de la conducta no verbal	Sesgos del entrevistador: confirmación, halo, primacía y recencia
Construcción de la relación de trabajo	Deseabilidad social y otras distorsiones del entrevistado
Utilidad con quien no sabe o no puede leer	Mucha información difícil de ordenar si la entrevista es abierta

Las limitaciones proceden, sobre todo, de la falta de control. Si dos entrevistadores no preguntan lo mismo ni deciden con los mismos criterios, llegarán a conclusiones distintas sobre la misma persona (apartado 12.2). Los **sesgos** del evaluador actúan con fuerza en una conversación abierta: el **sesgo de confirmación** lleva a preguntar solo lo que encaja con la primera impresión; el **efecto halo** extiende una característica llamativa al juicio global; los efectos de **primacía** y **recencia** dan más peso a lo dicho al principio o al final (Unidad 6). Por parte del entrevistado, la **deseabilidad social** lleva a presentarse de forma favorable.

Un ejemplo: un psicólogo recibe a un joven derivado por «problemas de conducta» y desde el primer minuto lo imagina como un caso de consumo de drogas. Si nada le obliga a explorar otras áreas, preguntará con detalle por el consumo y pasará por encima del acoso que el chico sufre en el instituto. La solución no es renunciar a la entrevista, sino estructurarla y contrastar sus datos con otros métodos e informantes (Unidad 1).

11.2 Clasificación de las entrevistas

Las entrevistas se clasifican según varios criterios que se combinan entre sí. Una misma entrevista puede ser semiestructurada, diagnóstica, individual e inicial a la vez.

Por el grado de estructura. Es el criterio más importante, porque condiciona la fiabilidad.

- **Libre o no estructurada.** No hay guion: el entrevistador sigue el hilo de lo que cuenta la persona. Es útil en los primeros minutos de un contacto o cuando todavía no se sabe qué hay que evaluar. Su fiabilidad es la más baja.
- **Semiestructurada.** Hay una lista de áreas y preguntas básicas, pero el entrevistador puede cambiar el orden, reformular, añadir preguntas de seguimiento y decidir cuándo profundizar. Es la forma más habitual en la práctica clínica, y exige que el entrevistador conozca bien lo que evalúa.
- **Estructurada.** Las preguntas, su orden, su redacción y la forma de codificar las respuestas están fijados. El resultado se obtiene aplicando reglas, no por impresión del entrevistador. Es la más fiable y la más adecuada para investigación, cribados amplios o procesos con muchos candidatos, aunque puede resultar rígida en la clínica.

Más estructura implica más fiabilidad y, en general, más validez. En selección de personal, la entrevista estructurada predice el desempeño con una validez aproximada de $r \approx 0{,}42$, frente a $r \approx 0{,}19$ de la no estructurada (Sackett, Zhang, Berry y Lievens, 2022). Lo que se gana es **comparabilidad**: todas las personas reciben las mismas preguntas y se juzgan con los mismos criterios.

Por el objetivo.

Tipo	Para qué sirve	Ejemplo
Diagnóstica o de evaluación	Describir, clasificar o explicar un problema	Valorar si unos síntomas cumplen criterios de un trastorno
De selección	Predecir el ajuste a un puesto	Entrevista estructurada a candidatos a enfermería
De orientación	Ayudar a decidir un itinerario	Elegir estudios al terminar el bachillerato

Tipo	Para qué sirve	Ejemplo
Terapéutica o de intervención	Evaluar y, a la vez, empezar a promover el cambio	Entrevista motivacional (apartado 12.3)
De investigación	Obtener datos comparables de muchas personas	Encuesta epidemiológica con entrevistadores formados

Por el número de participantes. La **individual** es la más frecuente y la que permite más profundidad. La **conjunta**, con una pareja o una familia, permite ver cómo interactúan, aunque cada uno puede callar cosas delante de los demás. En la **grupal**, cuanto mayor es el grupo, menos detalle se obtiene de cada miembro. Además, puede informar el propio evaluado o **informantes** cercanos (padres, profesores, pareja), que aportan lo que el evaluado no ve o no cuenta (Unidad 1).

Por el momento del proceso.

- **Inicial:** primer contacto; se analiza la demanda, se establece la relación y se informa del proceso.
- **De profundización o complementaria:** se exploran áreas concretas o se contrastan hipótesis.
- **Biográfica o de anamnesis:** se reconstruye la historia vital, a veces con una línea de vida que ordena los acontecimientos importantes.
- **De seguimiento:** se valora la evolución tras una intervención.
- **De devolución:** se comunican los resultados de la evaluación (Unidad 7).

La elección depende del objetivo, del contexto y de la persona. Con una adolescente que viene obligada por su familia, se empezará probablemente de forma abierta, para construir la relación, y se pasará después a un formato semiestructurado.

11.3 Actitudes del entrevistador

Las técnicas sirven de poco si no se apoyan en una actitud adecuada. La tradición humanista de Carl Rogers describió tres actitudes básicas del profesional, que hoy se consideran necesarias en cualquier entrevista de evaluación, sea cual sea el modelo teórico:

- **Empatía.** Capacidad de comprender la experiencia del otro desde su propio marco de referencia, y de **comunicarle** que se le ha comprendido. No consiste en sentir lo mismo ni en darle la razón, sino en entender qué siente y por qué. Es la base del reflejo (apartado 11.4).
- **Aceptación incondicional o calidez.** Respeto por la persona con independencia de lo que cuente. Se acepta a la persona, no necesariamente su conducta. Un entrevistador que muestra rechazo ante un consumo de alcohol elevado conseguirá, sobre todo, que la persona rebaje las cifras en la siguiente pregunta.
- **Autenticidad o congruencia.** Coherencia entre lo que el entrevistador piensa, dice y expresa con el cuerpo. No significa contarlo todo, sino no fingir: un interés impostado se nota.

A estas tres se añade la **escucha activa**, que es la forma práctica de ponerlas en juego: atender sin interrumpir, mostrar con gestos y breves expresiones que se sigue el relato y devolver lo escuchado para comprobar que se ha entendido.

Estas actitudes no son un adorno. Facilitan que la persona hable con franqueza y ayudan a controlar la **deseabilidad social**: quien no se siente juzgado tiene menos motivos para presentarse de forma favorable.

Además de las actitudes, hay una serie de **estrategias generales** que el entrevistador debe cuidar:

1. **Hablar como habla la persona**: vocabulario y ritmo distintos para un niño, una persona mayor o alguien de otra cultura. Evitar tecnicismos y comprobar que las preguntas se entienden.

2. **Garantizar la confidencialidad** y explicar sus límites desde el principio. Por ejemplo, se informa de que el secreto se puede romper si existe un riesgo grave para la persona o para terceros (Unidad 8).
3. **Atender a lo no verbal** sin sobreinterpretarlo. Un gesto no tiene un significado fijo; lo útil es fijarse en las **discrepancias**, como contar una pérdida reciente con una sonrisa.
4. **Tratar las incoherencias y los silencios como pistas** con tacto, como algo que hay que entender y no como una prueba de que la persona miente.
5. **Contrastar** lo que se cuenta con otras fuentes: informantes, registros, pruebas.
6. **Vigilar la propia influencia.** El entrevistador debe ser consciente de sus expectativas, de sus reacciones emocionales y de cómo su estilo puede cambiar las respuestas.

Un error frecuente en estudiantes es confundir empatía con complicidad. Si un paciente explica que deja de ir a trabajar porque su jefe «es insoportable», responder «es normal, yo haría lo mismo» no es empático: es tomar partido y cerrar la exploración. Una respuesta empática sería «parece que ir a trabajar se le ha hecho muy cuesta arriba», que reconoce el malestar y deja abierta la conversación. Las garantías éticas de la entrevista se tratan en la Unidad 8 y en la asignatura de Deontología.

11.4 Técnicas de entrevista

Las técnicas de entrevista son de dos grandes tipos: las que sirven para **obtener información** (preguntas) y las que sirven para **devolverla** y comprobar que se ha entendido (técnicas de escucha).

Preguntas abiertas y cerradas. Las **abiertas** («¿Cómo es un día normal para usted?») permiten que la persona elija qué contar y con qué palabras; dan mucha información, aunque desordenada. Las **cerradas** («¿Se despierta antes de que suene el despertador?») piden un dato concreto, a menudo un sí o un no; son precisas, pero pueden dejar fuera lo importante si se usan demasiado pronto. Entre unas y otras están las preguntas **semiabiertas**, que acotan el tema sin dar la respuesta («¿En qué situaciones le pasa?»).

La secuencia habitual es el **embudo**: empezar con preguntas abiertas y estrechar poco a poco hasta las cerradas. Con personas poco habladoras o muy ansiosas se usa el **embudo invertido**, que empieza por preguntas concretas y fáciles de contestar y se abre a medida que la persona se siente cómoda (apartado 12.1).

Hay preguntas que conviene evitar:

- **Sugestivas**, que contienen la respuesta esperada («Supongo que discuten mucho, ¿no?»).
- **Dobles**, que preguntan dos cosas a la vez («¿Duerme y come bien?»).
- **Encadenadas**, varias seguidas sin dejar responder.

Técnicas de escucha. Sirven para que la persona sienta que se la entiende y para que el entrevistador compruebe su comprensión. Como muestra la figura 11.1, ante una misma frase pueden darse respuestas muy distintas:

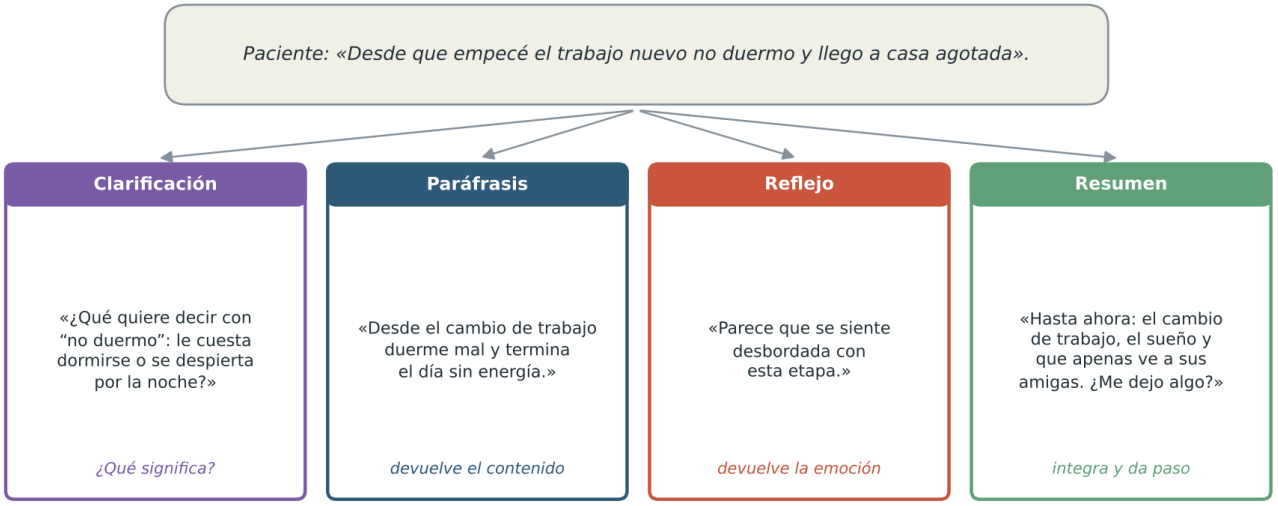


Figura 11.1. **Cuatro formas de responder a una misma frase.** Ante «Desde que empecé el trabajo nuevo no duermo y llego a casa agotada», la clarificación pide precisar, la paráfrasis devuelve el contenido, el reflejo devuelve la emoción y el resumen une varios temas de la sesión. Elaboración propia.

- **Clarificación.** Pregunta que pide precisar algo ambiguo: «¿Qué quiere decir con que no duerme: le cuesta dormirse o se despierta por la noche?».
- **Paráfrasis.** Devuelve, con otras palabras, el **contenido** de lo dicho: «Desde el cambio de trabajo duerme mal y termina el día sin energía».
- **Reflejo.** Devuelve la **emoción** que se percibe, aunque no se haya nombrado: «Parece que se siente desbordada con esta etapa».
- **Resumen.** Recoge varios temas de la sesión y los ordena: «Hasta ahora hemos hablado del cambio de trabajo, del sueño y de que apenas ve a sus amigas. ¿Me dejo algo?».

La paráfrasis se queda en los **hechos**; el reflejo apunta a los **sentimientos**. Ambas se formulan de forma tentativa, para que la persona pueda corregir («no es que esté desbordada, es que estoy enfadada»), y la corrección también informa.

Confrontación o señalamiento de discrepancias. Consiste en poner de manifiesto, sin tono acusador, una contradicción entre dos cosas que ha dicho la persona o entre lo que dice y lo que hace: «Me cuenta que la relación con su hermano va bien, y a la vez que lleva meses sin cogerle el teléfono». Es una técnica potente, pero solo debe usarse cuando la **relación ya está establecida**. Usada en los primeros minutos, suele provocar una actitud defensiva.

También son útiles los **silencios**, que invitan a seguir hablando, y las **facilitaciones** breves («ya», «siga», un gesto de asentimiento). Como habilidades terapéuticas, estas técnicas se estudian en las asignaturas de Intervención.

Consenso y debate

Consenso: la entrevista es un método imprescindible y de enorme ancho de banda, pero su calidad depende de cómo se haga. Más estructura implica más fiabilidad y validez (Sackett et al., 2022), y las actitudes de empatía, aceptación y autenticidad, junto con la escucha activa, mejoran la calidad de la información. El entrevistador es parte del instrumento y una fuente de error que hay que controlar.

Debate: la concordancia entre el diagnóstico clínico rutinario y el obtenido con entrevistas estandarizadas es baja: κ medio de 0,27 en 38 estudios con 15.967 personas, con un rango de 0,19 en el trastorno de ansiedad generalizada a 0,86 en la anorexia (Rettew et al., 2009). Los propios autores advierten que esto

no demuestra cuál de las dos vías es peor, y se discute cuánto pesa la falta de estructura frente a otras causas.

Mito frecuente

Mito: «La entrevista libre es más válida que la estructurada porque es más profunda y se adapta a cada persona».

Realidad: la flexibilidad aumenta el ancho de banda, pero también la variación entre entrevistadores. En selección de personal, la entrevista estructurada predice mejor el desempeño ($r \approx 0{,}42$ frente a $r \approx 0{,}19$; Sackett et al., 2022), y en clínica el diagnóstico rutinario coincide poco con el de las entrevistas estandarizadas (κ medio = 0,27; Rettew et al., 2009). La profundidad no garantiza la exactitud.

Conceptos clave

Concepto	Definición
Entrevista psicológica	Conversación dirigida, con objetivo evaluador y roles diferenciados, para obtener información de otro
Ancho de banda	Amplitud de aspectos que abarca un método; máxima en la entrevista (Cronbach y Gleser)
Entrevista semiestructurada	Guion de áreas y preguntas básicas que el entrevistador adapta en orden y profundidad
Entrevista estructurada	Preguntas, orden y codificación fijados; el resultado se obtiene aplicando reglas
Empatía	Comprender la experiencia del otro desde su marco de referencia y comunicárselo
Paráfrasis	Técnica que devuelve con otras palabras el contenido de lo dicho
Reflejo	Técnica que devuelve la emoción percibida en lo que dice la persona
Embudo	Secuencia de preguntas que va de las abiertas a las cerradas

Clave PIR

Prioridad media. Se pregunta la clasificación por grado de estructura y su relación con la fiabilidad, y se pide identificar técnicas a partir de una respuesta del entrevistador. La trampa típica es confundir paráfrasis (contenido) con reflejo (emoción), o considerar la clarificación una técnica de devolución cuando es una pregunta. También se cae en suponer que la entrevista libre es más válida por ser más profunda.

Autoevaluación

1. Una paciente dice que su madre ha vuelto a ingresar en el hospital. El psicólogo responde: «Parece que esto le tiene muy preocupada». Es un ejemplo de…
a) paráfrasis
b) reflejo
c) clarificación

2. En selección de personal, según Sackett et al. (2022), la entrevista estructurada…
a) predice el desempeño mejor que la no estructurada
b) predice el desempeño igual que la no estructurada
c) predice el desempeño peor que la no estructurada

3. El embudo invertido está especialmente indicado con…
a) personas muy habladoras que se dispersan
b) evaluaciones de investigación con muchos sujetos
c) personas poco comunicativas o muy ansiosas

4. La confrontación o señalamiento de discrepancias debe usarse…
a) en los primeros minutos, para fijar el encuadre
b) cuando la relación con la persona ya está establecida
c) solo en entrevistas estructuradas de diagnóstico

5. Decir que la entrevista tiene mucho ancho de banda significa que…
a) mide cada aspecto con gran precisión
b) se puede aplicar a muchas personas a la vez
c) abarca muchos aspectos distintos en poco tiempo

Soluciones

1 b. Devuelve una emoción que la paciente no ha nombrado; la paráfrasis se quedaría en el hecho del ingreso. **2 a.** La validez aproximada es de 0,42 frente a 0,19. **3 c.** Se empieza por preguntas concretas y fáciles y se abre a medida que la persona se siente cómoda. **4 b.** Sin relación previa, suele provocar una actitud defensiva. **5 c.** El ancho de banda se refiere a la amplitud; la precisión en cada aspecto es la fidelidad, que en la entrevista es variable.

Unidad 12 · El proceso y los tipos de entrevista

Objetivos: describir las fases de una entrevista de evaluación y lo que se hace en cada una; conocer las principales entrevistas estandarizadas para el diagnóstico y valorar su aportación; diferenciar la entrevista clínica, la conductual y la motivacional; explicar la entrevista cognitiva y su evidencia, la entrevista de selección estructurada y las peculiaridades de la entrevista con niños.

12.1 Fases de la entrevista

Una entrevista de evaluación no es una sucesión de preguntas, sino un proceso con una lógica interna. Lo habitual es que no se complete en una sola sesión: la recogida de información se reparte en varios encuentros, intercalados con otras pruebas. Pueden distinguirse cinco fases.

1. Preentrevista. Empieza antes de que la persona entre en el despacho. El entrevistador analiza la **demanda** (quién pide la evaluación, para qué y si el evaluado lo sabe), revisa la información disponible, como informes previos o la hoja de derivación, y prepara un guion. También cuida el **encuadre**: un espacio tranquilo, sin interrupciones, con tiempo suficiente. Aquí se prepara la información para el **consentimiento informado**, que se obtendrá al empezar (Unidad 8).

2. Apertura. Los primeros minutos condicionan el resto. El entrevistador se presenta, explica en qué consistirá la evaluación, cuánto durará y para qué servirán los datos, y aclara la confidencialidad y sus límites. Pregunta por las expectativas de la persona y la invita a exponer el motivo de consulta con sus palabras, sin interrumpirla. El objetivo es crear **rapport**: un clima de confianza y colaboración que facilita que la persona hable con franqueza.

3. Desarrollo. Es la fase central de exploración. El entrevistador sigue un razonamiento **hipotético-deductivo**: a partir de lo que escucha formula hipótesis provisionales y elige las preguntas que permiten contrastarlas (Unidad 5). La secuencia típica es el **embudo**, que va de lo general a lo concreto.

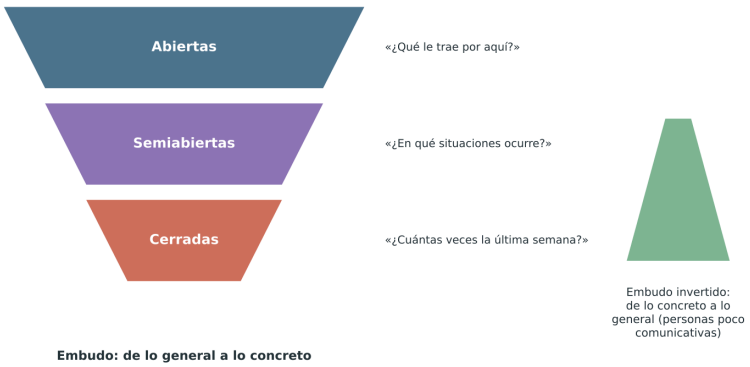


Figura 12.1. **El embudo y el embudo invertido.** A la izquierda, la secuencia habitual: preguntas abiertas («¿Qué le trae por aquí?»), semiabiertas («¿En qué situaciones ocurre?») y cerradas («¿Cuántas veces la última semana?»). A la derecha, el embudo invertido, que empieza por lo concreto y se usa con personas poco comunicativas. Elaboración propia.

Como muestra la figura 12.1, las preguntas abiertas permiten que aparezcan temas que el entrevistador no había previsto, y las cerradas aportan los datos precisos que se necesitan para describir el problema: frecuencia, duración, intensidad, situaciones. Empezar por las cerradas tiene un riesgo: el entrevistador impone su propio mapa y la persona se limita a contestar lo que se le pregunta.

4. Cierre. No se termina de golpe. El entrevistador avisa de que queda poco tiempo, **resume** lo principal y pregunta si la persona quiere añadir algo o tiene dudas. Explica los **siguientes pasos**: otras sesiones, cuestionarios, registros en casa, entrevistas con familiares. Conviene no abrir temas nuevos con carga emocional en los últimos minutos y asegurarse de que la persona se va en condiciones de seguir con su día.

5. Reflexión posterior. Tras la sesión, el entrevistador ordena sus notas, separa lo observado de lo inferido y **revisa sus hipótesis**: cuáles se refuerzan, cuáles se debilitan y qué información falta. También examina su propia actuación: si guio demasiado, si dejó áreas sin explorar, si alguna reacción suya pudo influir en las respuestas.

Fase	Tarea principal	Error típico
Preentrevista	Analizar la demanda y preparar el guion y el encuadre	Llegar sin saber quién pide la evaluación ni para qué
Apertura	Presentarse, informar, crear rapport	Pasar directamente a las preguntas cerradas
Desarrollo	Explorar en embudo y contrastar hipótesis	Quedarse con la primera hipótesis
Cierre	Resumir, resolver dudas, explicar los pasos siguientes	Terminar de forma brusca o abrir temas nuevos
Reflexión posterior	Ordenar los datos y revisar las hipótesis	Mezclar lo observado con lo interpretado

El proceso no es lineal: una respuesta inesperada puede obligar a recordar la confidencialidad o a replantear las hipótesis, igual que en el proceso de evaluación completo (Unidad 5).

12.2 Entrevistas estandarizadas y diagnóstico

Cuando el objetivo es establecer un **diagnóstico** según los sistemas de clasificación (DSM-5-TR o CIE-11), la entrevista libre plantea un problema de fiabilidad. Dos clínicos pueden discrepar por dos motivos: porque **preguntan cosas distintas** y obtienen información diferente, o porque, con la misma información, **deciden con criterios distintos**. Las **entrevistas estandarizadas** reducen ambas fuentes de desacuerdo, ya que fijan qué hay que preguntar y cómo se codifica cada respuesta en relación con los criterios diagnósticos.

Las más conocidas son las siguientes:

Entrevista	Estructura	Quién la aplica	Rasgo principal
SCID-5 (First et al.)	Semiestructurada	Clínicos con formación	Sigue los criterios del DSM-5; el clínico puede reformular y pedir ejemplos
ADIS-5 (Brown y Barlow, 2014)	Semiestructurada	Clínicos con formación	Centrada en los trastornos de ansiedad y relacionados
CIDI	Estructurada	Entrevistadores legos entrenados	Pensada para estudios epidemiológicos amplios
MINI	Estructurada	Clínicos o entrevistadores entrenados	Breve; útil para cribados y como primer paso diagnóstico

La diferencia entre las semiestructuradas y las estructuradas es importante. En las **semiestructuradas**, como la SCID-5, el clínico lee las preguntas, pero puede añadir otras para aclarar y es él quien decide si un criterio se cumple, con su juicio profesional. En las **estructuradas**, como la CIDI, la redacción y el orden son fijos y la decisión se obtiene por reglas, lo que permite que las apliquen entrevistadores sin formación clínica. Es una ventaja en estudios con miles de personas, a costa de perder matices.

El uso de estas entrevistas tiene ventajas claras:

- **Exhaustividad.** Obligan a explorar todas las áreas previstas, lo que evita que la primera hipótesis cierre la exploración y que pasen desapercibidos los trastornos que aparecen junto al principal.
- **Comparabilidad.** Permiten comparar pacientes, centros y estudios.

- **Formación.** Son una buena escuela para aprender a explorar criterios con precisión.

También tienen limitaciones: son largas, pueden resultar mecánicas si se aplican sin habilidad y su calidad depende del entrenamiento de quien las usa. Además, una entrevista estandarizada no sustituye a la evaluación completa del caso: dice si se cumplen unos criterios, pero no explica por qué aparece el problema ni qué lo mantiene.

El dato más citado sobre la distancia entre ambas vías procede del metaanálisis de **Rettew et al. (2009)**. Revisaron 38 estudios, con 15.967 personas, que comparaban el diagnóstico hecho en la práctica clínica habitual con el obtenido mediante entrevistas estandarizadas. La concordancia media fue baja (**κ = 0,27**), con mucha variación entre trastornos: de 0,19 en el trastorno de ansiedad generalizada a 0,86 en la anorexia. Los autores advierten que el dato **no demuestra que el diagnóstico rutinario sea peor**: solo indica que ambas vías no conducen al mismo resultado.

Un ejemplo: dos psicólogas atienden a pacientes con quejas de preocupación y tensión. Una pregunta por la duración de los síntomas y por si la preocupación es difícil de controlar; la otra se centra en los acontecimientos recientes. Ante el mismo paciente, una podría concluir que hay un trastorno de ansiedad generalizada y la otra, un problema de adaptación. Con una entrevista semiestructurada, ambas habrían explorado los mismos criterios. El estudio de los criterios diagnósticos corresponde a Psicopatología.

12.3 Entrevista clínica, conductual y motivacional

La entrevista adopta formas distintas según el modelo de evaluación y el objetivo. En el ámbito clínico destacan tres.

La entrevista clínica y el examen del estado mental. La entrevista clínica general recoge el motivo de consulta, la historia del problema, los antecedentes personales y familiares, el funcionamiento actual y los recursos de la persona. Una parte importante es el **examen del estado mental**, una exploración ordenada de cómo se presenta la persona en el momento de la entrevista. Se basa sobre todo en la observación y en preguntas específicas, y revisa estas áreas:

- **aspecto y conducta** (aseo, vestimenta, actividad motora, colaboración);
- **lenguaje** (velocidad, volumen, coherencia);
- **afecto y humor** (el estado emocional observado y el que la persona describe);
- **pensamiento** (curso y contenido: ideas recurrentes, ideas de muerte);
- **percepción** (alteraciones como alucinaciones);
- **cognición** (orientación, atención, memoria);
- **juicio e insight** (capacidad de valorar la situación y conciencia del problema).

El examen del estado mental procede de la tradición médica y se estudia con más detalle en Psicopatología.

La entrevista conductual. Desde el modelo conductual (Unidades 3 y 4), la entrevista no busca una etiqueta, sino identificar las **conductas problema** y las variables que las controlan. Kanfer y Saslow (1965) propusieron el análisis conductual como alternativa a la clasificación diagnóstica, y en un trabajo posterior ofrecieron una guía con siete áreas: análisis inicial de la situación problema (excesos, déficits y recursos), clarificación, análisis motivacional, análisis evolutivo, análisis del autocontrol, relaciones sociales y entorno sociocultural y físico.

La información se organiza con la fórmula **E-O-R-K-C** (Unidad 4): estímulos antecedentes, variables del organismo, respuesta en sus tres sistemas, contingencia y consecuencias. Las preguntas son concretas y descriptivas: «¿Qué estaba haciendo justo antes?», «¿Qué pensó en ese momento?», «¿Qué pasó después?», «¿Ocurre igual en casa que en el trabajo?». Así, un vago «me pongo fatal en las reuniones» se convierte en una cadena de hechos observables que se puede contrastar después con autorregistros u observación. Las preguntas que más ayudan suelen ser las de qué, cuándo, dónde y cómo.

La entrevista motivacional. Desarrollada por Miller y Rollnick (1991; 3.ª ed., 2013), es un estilo de entrevista orientado a ayudar a la persona a resolver su **ambivalencia** ante el cambio. Se usa mucho con conductas adictivas y de salud, cuando la persona no tiene claro que quiera cambiar. Su estilo básico se resume en las siglas **OARS**:

Siglas	Técnica	Ejemplo
O	Preguntas abiertas	«¿Qué le preocupa de cómo bebe ahora?»
A	Afirmaciones que reconocen esfuerzos y capacidades	«Venir hoy ya ha supuesto un paso»
R	Reflejos	«Por un lado le relaja, y por otro le está costando discusiones en casa»
S	Resúmenes	«Si no me equivoco, lo que más pesa es…»

La entrevista motivacional se sitúa en la frontera entre evaluar e intervenir: mientras recoge información sobre la conducta y sus consecuencias, busca que sea la persona quien formule sus razones para cambiar. Por eso suele clasificarse como entrevista **terapéutica o de intervención** (apartado 11.2). Su aplicación como tratamiento se estudia en las asignaturas de Terapia de conducta e Intervención.

Las tres formas no se excluyen. En una primera consulta por consumo de alcohol, el psicólogo puede explorar el estado mental, describir funcionalmente cuándo y por qué bebe la persona y, a la vez, trabajar con un estilo motivacional para que la evaluación no se viva como un juicio.

12.4 Entrevista forense, de selección y con niños

La entrevista forense y la entrevista cognitiva. En el contexto judicial, la entrevista debe responder a preguntas concretas (qué ocurrió, qué recuerda un testigo, si hay indicios de daño psicológico) y cuidar especialmente la calidad del testimonio. La memoria es reconstructiva, de modo que las preguntas sugestivas pueden añadir detalles falsos. La herramienta mejor estudiada es la **entrevista cognitiva** de Fisher y Geiselman (1984/1992), que combina cuatro técnicas basadas en los principios de la memoria:

1. **Reinstauración del contexto:** pedir que la persona reconstruya mentalmente el lugar, el momento y lo que sentía.
2. **Informar de todo:** animar a contar cualquier detalle, aunque parezca irrelevante o incompleto.
3. **Cambio de orden:** relatar los hechos en otro orden, por ejemplo desde el final.
4. **Cambio de perspectiva:** describir lo ocurrido como lo habría visto otra persona presente.

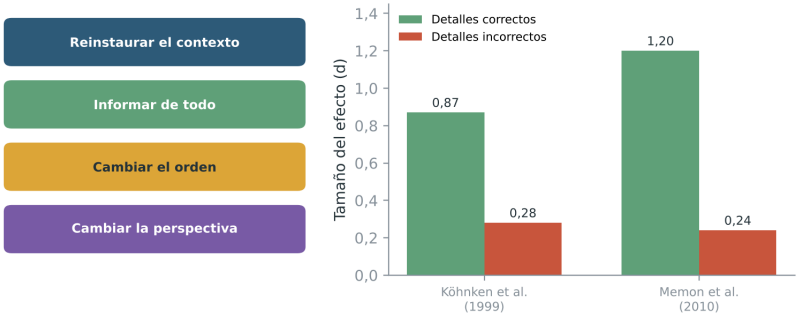


Figura 12.2. **La entrevista cognitiva y su eficacia.** Las cuatro técnicas y los tamaños del efecto frente a la entrevista estándar: d = 0,87 en detalles correctos y 0,28 en incorrectos (Köhnken et al., 1999), y d = 1,20 y ≈ 0,24 (Memon, Meissner y Fraser, 2010). Elaboración propia.

Como muestra la figura 12.2, la evidencia es sólida. El metaanálisis de Köhnken et al. (1999), con unos 2.500 entrevistados, halló un aumento grande de los **detalles correctos** (d = 0,87) y uno pequeño de los incorrectos (d

= 0,28); la exactitud global apenas cambió (85 % con la entrevista cognitiva frente a 82 % con la estándar). Memon, Meissner y Fraser (2010) confirmaron el resultado: d = 1,20 en detalles correctos, ≈ 0,24 en errores y ≈ 0,08 en confabulaciones. El efecto es algo menor en niños (d = 0,91). Una limitación importante es que la entrevista cognitiva **no protege frente a la sugestión posterior**: si el testigo recibe después información engañosa, puede incorporarla. Su aplicación se estudia en Psicología Jurídica, junto con el informe pericial.

La entrevista de selección. En el ámbito organizacional, la entrevista sirve para predecir el desempeño de los candidatos. La versión que mejor funciona es la **entrevista estructurada**: las mismas preguntas para todos, basadas en lo que exige el puesto; **escalas con anclajes** que describen cómo es una respuesta pobre, aceptable o excelente, y **varios evaluadores** que puntúan por separado. Según Sackett et al. (2022), su validez es de r ≈ 0,42, frente a r ≈ 0,19 de la no estructurada. Estas cifras revisan a la baja las de Schmidt y Hunter (1998), que eran de 0,51 y 0,38. Este ámbito se estudia en Psicología del Trabajo.

La entrevista con niños. Entrevistar a un niño exige adaptar casi todo:

- **Lenguaje** acorde con su edad: frases cortas, palabras conocidas, una pregunta cada vez.
- **Preguntas abiertas y no sugestivas.** Los niños pequeños tienden a contestar lo que creen que el adulto espera, y repetir una pregunta puede hacerles pensar que su primera respuesta era errónea.
- **Apoyos** como el dibujo o el juego, sobre todo para establecer la relación.
- **Varios informantes.** Padres y profesores aportan perspectivas distintas. La concordancia entre informantes es modesta: en el metaanálisis de Achenbach, McConaughy y Howell (1987), la correlación media entre el propio niño o adolescente y otros informantes fue de r = 0,22. No significa que alguien mienta, sino que cada uno ve una parte distinta de la conducta.

Además, la evaluación de menores tiene requisitos éticos propios, como informar a los padres o tutores y obtener el consentimiento adecuado (Unidad 8).

Consenso y debate

Consenso: la entrevista cognitiva aumenta mucho los detalles correctos sin un aumento comparable de los errores (Köhnken et al., 1999; Memon et al., 2010), y la entrevista de selección estructurada predice el desempeño mejor que la no estructurada (Sackett et al., 2022). Las entrevistas estandarizadas mejoran la fiabilidad del diagnóstico, y el proceso de entrevista es iterativo y guiado por hipótesis.

Debate: la revisión de Sackett et al. (2022) fue criticada por Oh, Le y Roth (2023), y respondida por Sackett et al. (2023). La dispersión de los resultados entre estudios es grande (DT ≈ 0,19), así que las cifras medias deben tomarse con prudencia. También se discute qué parte del desacuerdo entre diagnóstico rutinario y estandarizado se debe a la estructura y qué parte a otros factores (Rettew et al., 2009).

Mito frecuente

Mito: «La entrevista cognitiva saca más recuerdos, pero a cambio llena el testimonio de errores, así que no compensa».

Realidad: la entrevista cognitiva aumenta mucho los detalles correctos (d = 0,87) y poco los incorrectos (d = 0,28), y la exactitud global se mantiene (85 % frente a 82 %; Köhnken et al., 1999). Las confabulaciones apenas aumentan (d ≈ 0,08; Memon, Meissner y Fraser, 2010). Su límite real es otro: no protege frente a la información engañosa que el testigo reciba después.

Conceptos clave

Concepto	Definición
Rapport	Clima de confianza y colaboración entre entrevistador y entrevistado
Preentrevista	Fase previa de análisis de la demanda, preparación del guion y del encuadre
SCID-5	Entrevista semiestructurada para el diagnóstico según el DSM-5, aplicada por clínicos (First et al.)
CIDI	Entrevista diagnóstica estructurada que pueden aplicar entrevistadores legos entrenados
Examen del estado mental	Exploración ordenada del aspecto, lenguaje, afecto, pensamiento, percepción, cognición y juicio
Entrevista motivacional	Estilo de entrevista para resolver la ambivalencia ante el cambio (Miller y Rollnick, 1991)
OARS	Preguntas abiertas, afirmaciones, reflejos y resúmenes: estilo básico de la entrevista motivacional
Entrevista cognitiva	Entrevista forense con cuatro técnicas basadas en la memoria (Fisher y Geiselman, 1984/1992)

Clave PIR

Prioridad media. Se pregunta por las cuatro técnicas de la entrevista cognitiva y su efecto (muchos más detalles correctos, pocos más errores), por la diferencia entre entrevistas estructuradas y semiestructuradas y por la ventaja predictiva de la entrevista de selección estructurada. Trampas típicas: afirmar que la entrevista cognitiva protege de la sugestión posterior, atribuir a la SCID-5 un formato estructurado para legos (eso es la CIDI) y confundir las fases de apertura y desarrollo.

Autoevaluación

1. ¿Cuál de estas técnicas NO forma parte de la entrevista cognitiva?
a) Cambio de perspectiva
b) Reinstauración del contexto
c) Preguntas cerradas de sí o no

2. Según Köhnken et al. (1999), frente a la entrevista estándar, la entrevista cognitiva…
a) aumenta mucho los detalles correctos y poco los incorrectos
b) aumenta por igual los detalles correctos y los incorrectos
c) reduce los detalles incorrectos sin cambiar los correctos

3. Una entrevista diagnóstica estructurada, pensada para que la apliquen entrevistadores legos en estudios epidemiológicos, es…
a) la SCID-5
b) la CIDI
c) la ADIS-5

4. Revisar las hipótesis y separar lo observado de lo inferido corresponde a la fase de…
a) desarrollo
b) cierre
c) reflexión posterior

5. En el metaanálisis de Rettew et al. (2009), la concordancia media entre el diagnóstico clínico rutinario y el de las entrevistas estandarizadas fue…
a) baja, con un κ medio de 0,27
b) alta, con un κ medio de 0,86
c) moderada, con un κ medio de 0,60

Soluciones

1 c. Las cuatro técnicas son reinstauración del contexto, informar de todo, cambio de orden y cambio de perspectiva. **2 a.** d = 0,87 en correctos y 0,28 en incorrectos, con una exactitud similar. **3 b.** La SCID-5 y la ADIS-5 son semiestructuradas y las aplican clínicos. **4 c.** Tras la sesión se ordenan las notas y se revisan las hipótesis. **5 a.** Con un rango de 0,19 (ansiedad generalizada) a 0,86 (anorexia); 0,86 es el máximo, no la media.

Capítulo 5 · La observación

Observar es la forma más directa de saber qué hace una persona, pero mirar no basta para evaluar. Este capítulo explica cómo se convierte la mirada en un dato: qué unidades se observan, cómo se miden y se registran, y después cómo se muestrea, dónde se observa, qué errores aparecen y cómo se comprueba que el registro es fiable.

Unidad 13 · Unidades y técnicas de registro

Objetivos: distinguir la observación sistemática de la observación cotidiana; ordenar las unidades de análisis según su nivel de inferencia; elegir la unidad de medida adecuada para cada conducta; comparar las técnicas de registro, los sistemas de categorías y los procedimientos automáticos.

13.1 Concepto de observación y unidades de análisis

Toda evaluación incluye algo de observación informal, pero la **observación como técnica** es otra cosa. Es un procedimiento **deliberado y sistemático** para registrar el comportamiento de una o varias personas, con un objetivo previo, unas reglas definidas de antemano (qué, cómo, cuándo y dónde se observa) y un observador entrenado. Lo que la separa de la mirada cotidiana es la **sistematización**: un protocolo que otro profesional podría repetir y obtener lo mismo.

La observación puede hacerla un profesional ajeno a la situación (**no participante**) o alguien que forma parte de ella (**participante**), como una profesora que registra en su propia aula. También puede hacerla la propia persona sobre sí misma: es la **autoobservación**, que se estudia con los autorregistros (Unidad 16).

Antes de observar hay que decidir **qué** se observa, es decir, la **unidad de análisis**. Las unidades se ordenan por el grado de **inferencia** que exigen al observador.

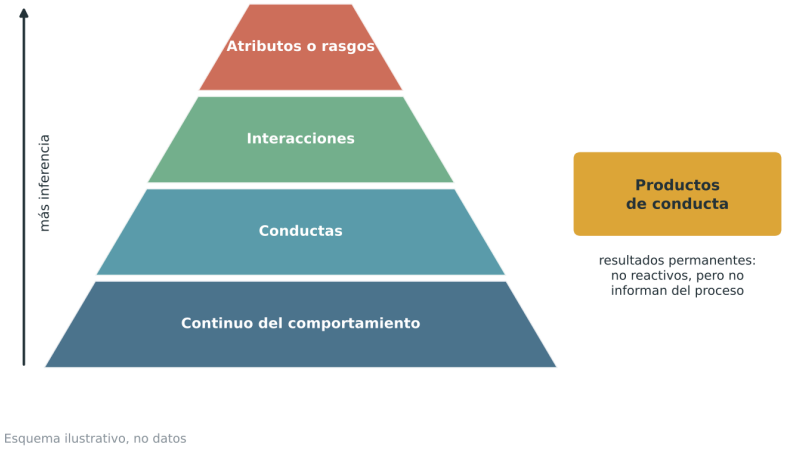


Figura 13.1. **Unidades de análisis y nivel de inferencia.** Pirámide con el continuo del comportamiento en la base, las conductas y las interacciones en los niveles intermedios y los atributos o rasgos en el vértice, donde la inferencia es máxima; los productos de conducta aparecen en un lateral por ser medidas no reactivas. Elaboración propia.

Como muestra la figura 13.1, se distinguen cinco unidades:

- **Continuo del comportamiento.** Se describe lo que ocurre de forma continua, en lenguaje cotidiano y sin decidir antes qué conductas interesan. Es propio de la fase exploratoria y de la perspectiva naturalista: el observador anota todo lo que hace un niño durante el recreo.
- **Conductas.** Se observan respuestas concretas, motoras, verbales o fisiológicas, **definidas operativamente** antes de empezar: «levantarse del asiento sin permiso» en lugar de «estar inquieto». La inferencia es baja.
- **Interacciones.** Se observan **secuencias** entre conductas de varias personas: qué hace el padre después de que el hijo grite y qué hace el hijo después. Es una unidad asociada a los trabajos de Patterson sobre interacción familiar. Obliga a fijar antes de empezar qué conductas de cada persona se van a registrar.
- **Productos de conducta.** Se registra el resultado que deja una conducta: los deberes terminados, las colillas del cenicero, los mensajes enviados. Son **permanentes** y, si se recogen de lo que la persona ya hizo, **no reactivos**, porque nadie cambia su conducta pasada al ser evaluado. Su punto débil es que no informan del proceso y que a veces no se sabe quién es el autor.
- **Atributos o rasgos.** Se infieren características internas a partir de lo observado («es tímida», «muestra baja autoestima»). Es la unidad de **máxima inferencia** y la más expuesta a los sesgos del observador.

La elección de la unidad depende del marco teórico y del objetivo. Una evaluación conductual buscará conductas e interacciones; un enfoque centrado en la personalidad puede interesarse por atributos. La unidad también fija la **fiabilidad alcanzable**: cuanto más molar e inferencial es la unidad, más difícil es que dos observadores coincidan (Unidad 4, disyuntiva molar/molecular).

Un ejemplo muestra la diferencia. Ante un adolescente en clase, «está desmotivado» es un atributo; «mira el móvil bajo la mesa», una conducta; «la profesora le llama la atención y él guarda el móvil durante dos minutos», una interacción; y «entrega tres de diez ejercicios», un producto. Las cuatro descripciones hablan del mismo chico, pero solo las tres últimas pueden contarse sin interpretar.

13.2 Unidades de medida

Una vez definida la conducta, hay que decidir **qué propiedad** de ella se va a cuantificar. Es la **unidad de medida**. La elección no es neutra: una misma conducta puede parecer que mejora o que empeora según lo que se mida.

Medida	Qué responde	Ejemplo
Ocurrencia	¿Aparece o no en el periodo?	Si hubo o no una rabieta en la cena
Frecuencia	¿Cuántas veces ocurre?	Número de preguntas que hace una alumna en clase
Tasa	¿Cuántas veces por unidad de tiempo?	Interrupciones por hora
Duración	¿Cuánto dura cada episodio o el total?	Minutos que dura cada rabieta
Latencia	¿Cuánto tarda en empezar tras el estímulo?	Segundos entre «a la ducha» y que el niño se levanta
Tiempo entre respuestas	¿Cuánto pasa entre dos episodios?	Minutos entre un cigarrillo y el siguiente
Intensidad o magnitud	¿Con qué fuerza ocurre?	Volumen de los gritos en una escala de 1 a 5

Frecuencia y tasa. La frecuencia es útil cuando la conducta tiene un principio y un final claros y episodios de duración parecida: golpes, preguntas, cigarrillos. Si las sesiones no duran lo mismo, la frecuencia bruta engaña y hay que pasar a **tasa**: diez interrupciones en una sesión de una hora no equivalen a diez en una de veinte minutos.

Duración. Conviene cuando lo importante es cuánto tiempo ocupa la conducta y no cuántas veces aparece: estar concentrado en la tarea, llorar, jugar con otros niños. Puede expresarse por episodio o como **porcentaje del tiempo** de observación. Una niña puede tener solo dos rabietas al día, pero si cada una dura cuarenta minutos el problema es otro que si tuviera diez de un minuto.

Latencia y tiempo entre respuestas. La latencia es la medida natural para la obediencia a instrucciones o el tiempo que se tarda en dormirse. El tiempo entre respuestas sirve, por ejemplo, en un programa para dejar de fumar, donde alargar el intervalo entre cigarrillos es un objetivo intermedio.

Intensidad o magnitud. Recoge la fuerza de la conducta. Suele medirse con escalas ordinales, lo que introduce algo de juicio del observador, salvo que se use un aparato (un sonómetro, un dinamómetro). A veces se añade una valoración de la **calidad o adecuación** de la ejecución, por ejemplo aciertos y errores en una tarea.

Tres criterios ayudan a elegir:

1. **La pregunta de evaluación.** Si preocupa que un niño tarde en obedecer, la medida es la latencia, no la frecuencia de órdenes cumplidas.
2. **La forma de la conducta.** Las conductas discretas y breves se cuentan; las continuas se miden por su duración.
3. **El coste.** Medir duraciones exige más atención o un cronómetro; cuando no es posible registrar todo, se recurre al muestreo por intervalos (Unidad 14), que estima estas medidas a cambio de cierto error.

Elegir mal la medida puede llevar a conclusiones falsas sobre un tratamiento. Si un programa reduce el número de discusiones de una pareja de cinco a dos por semana, pero cada discusión pasa de diez minutos a una hora, la frecuencia dice que hay mejoría y la duración dice lo contrario. Registrar más de una propiedad, cuando es posible, protege de este error y forma parte de la lógica multimétodo de la evaluación (Unidad 1).

13.3 Técnicas de registro

La **técnica de registro** es el formato en que se anota lo observado. Va desde la descripción libre hasta la codificación cerrada, y su elección depende de la fase de la evaluación: al principio conviene un registro abierto que permita descubrir qué ocurre; cuando ya se sabe qué interesa, un registro estructurado que permita contar y comparar.

Técnica	Ventaja	Limitación
Registro narrativo (diario, anecdótico)	Exploratorio; ayuda a generar categorías	Selectivo y poco fiable
Escalas de apreciación o estimación	Rápidas; resumen mucho tiempo de observación	Juicio retrospectivo expuesto a varios errores
Catálogos de conducta o listas	Recorren de forma exhaustiva un dominio	Pueden exigir más inferencia
Códigos o sistemas de categorías	Cuantificables; permiten estudiar secuencias	Requieren entrenamiento; más categorías, menos acuerdo
Registro de productos	No reactivo	No informa del proceso; autoría a veces dudosa

Registro narrativo. El observador describe por escrito, o grabando su voz, lo que va ocurriendo, sin un esquema previo. Incluye el **diario** y el **registro anecdótico**, que recoge episodios llamativos. Es flexible y fácil de enseñar a un familiar, pero cada observador elige qué anotar y con qué palabras, así que sirve sobre todo como paso previo para construir categorías.

Escalas de apreciación o estimación. El observador valora, al final de un periodo, en qué grado se da una conducta o un atributo: «Durante la clase de hoy, ¿con qué frecuencia ha interrumpido?» (nunca, a veces, a

menudo, siempre). Son económicas, pero el dato es un **juicio retrospectivo**, no un registro en el momento, y arrastra errores bien conocidos:

- **efecto halo**: una impresión general tiñe la valoración de aspectos concretos («es buen alumno, así que también participará»);
- **lenidad o severidad**: tendencia a puntuar a todos alto o a todos bajo;
- **tendencia central**: evitar los extremos de la escala;
- **error lógico**: dar puntuaciones parecidas a rasgos que el observador cree relacionados.

Muchas escalas de calificación por padres y profesores pertenecen a este grupo; su construcción y su uso como tests se tratan en Evaluación Psicológica II.

Catálogos de conducta o listas. Recogen una serie de conductas definidas de antemano y el observador marca cuáles aparecen. Pueden incluir, o no, sus antecedentes y consecuentes. Formas habituales son las **listas de conductas** adaptadas a un caso, las **matrices de interacción**, que cruzan conductas de dos personas (profesora y alumno, madre e hijo) para ver qué sigue a qué, y los **mapas de conducta**, que sitúan lo observado en el espacio y el tiempo (dónde juega cada niño del patio en cada momento).

Registro de productos. Se anota el resultado material de la conducta: páginas leídas, platos fregados, envoltorios de dulces en la papelera. Es la técnica menos reactiva cuando se usan productos que ya existían, y por eso resulta útil para valorar una intervención. Si se pide a la persona que haga una tarea para observar su producto (un dibujo, una redacción), la medida pasa a ser reactiva, porque sabe que se la evalúa.

Un minicaso: para estudiar las peleas entre dos hermanos, la psicóloga pide primero a la madre un diario de una semana. Del diario salen tres conductas que se repiten (quitar juguetes, insultar, empujar) y el momento crítico, la media hora antes de la cena. Con eso construye una lista simple que la madre marca cada día en esa franja. El registro narrativo ha servido para descubrir; la lista, para contar.

13.4 Sistemas de categorías y registro automático

Un **sistema de categorías** es un instrumento que clasifica cada acontecimiento observado en una categoría de un conjunto cerrado. En la tradición de la metodología observacional, desarrollada en España por Anguera, un buen sistema de categorías cumple dos requisitos:

- **Exhaustividad**: cualquier conducta que aparezca en el ámbito estudiado puede asignarse a alguna categoría.
- **Mutua exclusividad**: cada conducta encaja en una sola categoría, sin solapamientos.

Cuando el fenómeno tiene varias dimensiones a la vez, por ejemplo qué dice un niño, a quién se dirige y con qué tono, un único sistema cerrado se queda corto. Para estos casos se usan los **formatos de campo**, que combinan varios criterios o dimensiones y permiten codificar cada acontecimiento en todos ellos a la vez. El diseño detallado de estos instrumentos y su análisis secuencial pertenecen a Métodos de investigación.

Los sistemas de categorías producen datos **cuantificables** y comparables entre personas y estudios, y permiten analizar **secuencias**: qué categoría tiende a seguir a cuál. A cambio, exigen un **entrenamiento** largo, y su fiabilidad depende del número de categorías: **cuantas más categorías, menor acuerdo** entre observadores. En la práctica clínica rara vez se construye uno para un solo caso; se usan códigos publicados o listas sencillas hechas a medida.

Las definiciones de cada categoría deben incluir **ejemplos y contraejemplos**. «Agresión física: contacto con la mano, el pie o un objeto que puede causar daño. Incluye empujar y pellizcar. No incluye chocar sin querer en la fila.» Sin la última frase, dos observadores registrarán cosas distintas.

Procedimientos automáticos de registro. La tecnología ha ampliado mucho lo que puede registrarse:

- **vídeo** con codificación posterior, que permite revisar las escenas y calcular el acuerdo con calma;

- **actigrafía**, que registra el movimiento con un dispositivo en la muñeca y se usa para estimar el sueño y la actividad;
- **sensores fisiológicos** (frecuencia cardiaca, conductancia de la piel);
- **móviles y dispositivos ponibles (*wearables*)**, que recogen datos pasivos como los desplazamientos o el uso del teléfono.

Estos medios **aumentan la objetividad del registro**, porque el aparato no se cansa ni tiene expectativas. Pero **no resuelven la validez de la inferencia**. Que el actígrafo marque inactividad no dice si la persona dormía, estaba tumbada despierta o se había quitado la pulsera. Que el móvil apenas salga de casa no dice por sí mismo si hay depresión, una baja laboral o una gripe. La validez de estas métricas pasivas está en debate (Unidad 6). Además, son datos personales, a menudo de salud: exigen consentimiento informado y cumplir el **RGPD** y el Código Deontológico (Unidad 8).

Criterios para elegir la técnica. Cuentan el **objetivo** (explorar o medir), la **naturaleza de la conducta**, los **recursos** disponibles y la **precisión** necesaria. Como orientación, para explorar sirven el registro narrativo o una escala sencilla manejable por personas cercanas; para pocas conductas bien definidas, una lista hecha a medida; para interacciones, una matriz de interacción; y para acontecimientos complejos pero bien especificados, un sistema de categorías.

Consenso y debate

Consenso: la observación solo es un método de evaluación cuando es sistemática: objetivo previo, definición operativa de las conductas, entrenamiento de los observadores y control del acuerdo. Cuanto más inferencial es la unidad de análisis, más difícil es el acuerdo. La unidad de medida debe ajustarse a la pregunta de evaluación y a la forma de la conducta.

Debate: la validez de las métricas pasivas obtenidas con móviles y *wearables*: registran con precisión, pero no está claro qué significan en términos psicológicos ni en qué usos son adecuadas. También se discute cuánta estructura conviene en cada fase, porque un código cerrado demasiado pronto puede dejar fuera lo relevante.

Mito frecuente

Mito: «La observación es objetiva por definición: el observador se limita a ver lo que pasa».

Realidad: el observador elige qué mirar, cómo nombrarlo y cuándo anotarlo, y cada decisión introduce juicio. Las expectativas del observador sesgan más las calificaciones globales que los registros por categorías bien definidas (Kent et al., 1974). La objetividad no viene dada por el método: se construye con definiciones operativas, entrenamiento y control continuo del acuerdo (Unidad 14).

Conceptos clave

Concepto	Definición
Observación sistemática	Registro deliberado de la conducta con objetivo, protocolo definido y observador entrenado
Unidad de análisis	Lo que se observa: continuo, conductas, interacciones, productos o atributos
Definición operativa	Descripción de una conducta en términos observables, con ejemplos y contraejemplos

Concepto	Definición
Producto de conducta	Resultado permanente de una conducta; si ya existía, es una medida no reactiva
Latencia	Tiempo que pasa desde que aparece el estímulo hasta que empieza la respuesta
Escala de apreciación	Valoración retrospectiva del grado en que se da una conducta; expuesta a halo y lenidad
Sistema de categorías	Conjunto cerrado de categorías exhaustivas y mutuamente excluyentes para codificar conducta
Formato de campo	Instrumento que codifica cada acontecimiento en varias dimensiones a la vez (Anguera)

Clave PIR

Prioridad media. Se pregunta qué unidad de análisis exige más inferencia, qué medida conviene a una conducta descrita (latencia, duración, frecuencia) y qué errores afectan a las escalas de apreciación. Trampas típicas: confundir producto de conducta con atributo, creer que un registro automático garantiza la validez de la interpretación y olvidar que aumentar el número de categorías reduce el acuerdo entre observadores.

Autoevaluación

1. ¿Qué unidad de análisis exige al observador el mayor nivel de inferencia?
a) Las interacciones entre personas
b) Los atributos o rasgos
c) Las conductas definidas operativamente

2. Interesa saber cuánto tarda un niño en empezar a recoger tras la orden de su madre. La medida adecuada es…
a) la frecuencia
b) la duración
c) la latencia

3. Una profesora puntúa alto en «participación» a un alumno porque es educado y saca buenas notas. Es un ejemplo de…
a) efecto halo
b) tendencia central
c) error de lenidad

4. Que cada conducta pueda asignarse a una sola categoría del sistema es el requisito de…
a) exhaustividad
b) mutua exclusividad
c) formato de campo

5. Respecto a la actigrafía y los sensores del móvil, es correcto afirmar que…
a) eliminan la necesidad de consentimiento al no haber observador
b) garantizan la validez de la inferencia psicológica
c) mejoran la objetividad del registro, pero no su interpretación

Soluciones

1 b. Los atributos se infieren a partir de la conducta y son la unidad de máxima inferencia. **2 c.** La latencia mide cuánto tarda en empezar la respuesta tras la orden; la duración mediría cuánto dura la recogida. **3 a.** Una impresión general positiva se extiende a un aspecto concreto. **4 b.** La exhaustividad exige que toda conducta tenga categoría; la exclusividad, que tenga solo una. **5 c.** El aparato registra con precisión, pero qué significa el dato sigue siendo una inferencia, y los datos exigen consentimiento y RGPD.

Unidad 14 · Muestreo, garantías y planificación de la observación

Objetivos: comparar el registro continuo con el muestreo de intervalo parcial, de intervalo total y momentáneo, y conocer sus sesgos; distinguir la observación natural de la análoga; identificar la reactividad, las expectativas, la deriva y la reactividad del control de fiabilidad; calcular e interpretar el porcentaje de acuerdo y el índice kappa, y planificar una observación.

14.1 Muestreo de tiempo, situaciones y sujetos

Casi nunca es posible observar todo lo que hace una persona. Hay que tomar una **muestra** de su conducta y hacerlo de modo que sea **representativa** de lo que interesa. El muestreo responde a tres preguntas: cuándo se observa, en qué situaciones y a quién.

Muestreo de situaciones. Una conducta puede depender mucho del contexto: un niño puede portarse bien en el colegio y mal en casa, o al revés. Si la pregunta es si el problema es general o específico, hay que observar en **varias situaciones** y comparar. Para ello se hace una lista de las situaciones relevantes y se elige una muestra de ellas.

Muestreo de sujetos. Cuando se evalúa un grupo (una clase, una residencia), se selecciona a algunas personas, al azar o de forma estratificada, y se **rota** a quién se observa en cada periodo.

Muestreo de tiempo. Hay que decidir cuánto dura cada sesión, cuántas sesiones se hacen, en qué momentos del día y cómo se registra dentro de cada sesión. Si no se sabe lo bastante de la conducta para decidirlo, conviene una **preobservación** breve. Dentro de la sesión hay cuatro estrategias principales:

- **Registro continuo.** Se anota cada episodio con su inicio y su final. Da la frecuencia y la duración reales y es el **criterio de comparación** de los demás métodos, pero exige atención plena o vídeo.
- **Intervalo parcial.** La sesión se divide en intervalos iguales y se marca el intervalo si la conducta aparece **en algún momento** de él. **Sobreestima** la duración.
- **Intervalo total.** Se marca el intervalo solo si la conducta ocupa **todo** el intervalo. **Infraestima** la duración.
- **Muestreo momentáneo.** Se mira solo en un **instante** prefijado, por ejemplo al final de cada intervalo, y se anota si la conducta ocurre en ese momento. **Yerra en ambos sentidos**: a veces por exceso y a veces por defecto.

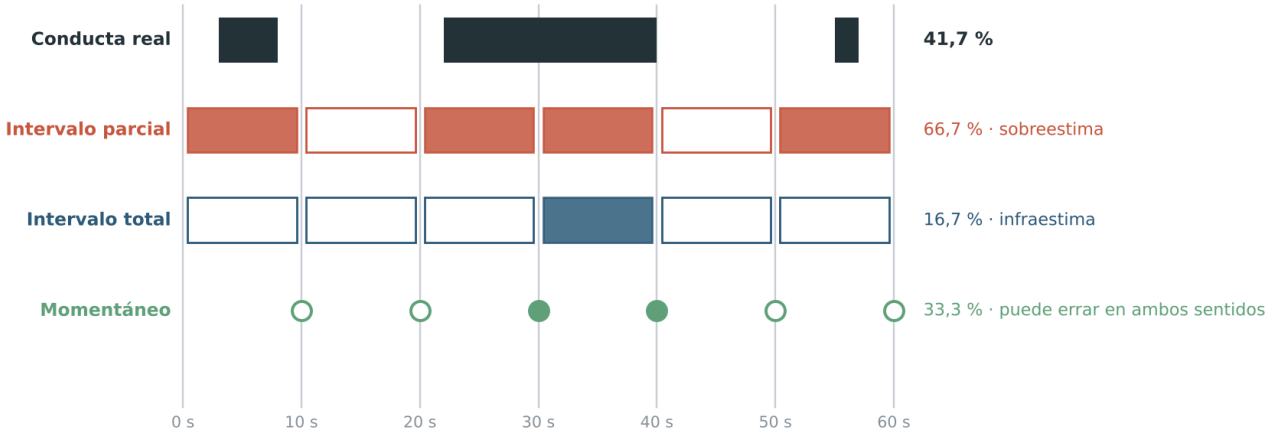


Figura 14.1. **Tres formas de muestrear la misma sesión.** En una sesión hipotética de 60 s dividida en seis intervalos de 10 s, la conducta ocupa 25 s (41,7 %). El intervalo parcial la estima en un 66,7 %, el intervalo total en un 16,7 % y el muestreo momentáneo en un 33,3 %. Caso hipotético; patrón descrito por Powell et al. (1975). Elaboración propia.

Como muestra la figura 14.1, la conducta aparece entre los segundos 3 y 8, entre el 22 y el 40 y entre el 55 y el 57. El **intervalo parcial** marca cuatro de los seis intervalos, porque basta un instante de conducta. El **intervalo total** marca solo uno, del segundo 30 al 40, el único ocupado entero. El **muestreo momentáneo**, que mira en los segundos 10, 20, 30, 40, 50 y 60, registra la conducta en dos de los seis instantes. Ninguno coincide con el 41,7 % real.

Powell, Martindale y Kulp (1975) compararon estas estrategias con el registro continuo y mostraron que el error depende de la **duración de los episodios** y **crece al alargar el intervalo**. El muestreo momentáneo da estimaciones razonables de la duración si los intervalos son cortos; como referencia aproximada, se ha indicado que su error se mantiene por debajo del 20 % con intervalos de hasta unos 240 s, y otro trabajo sitúa el límite en unos 120 s.

Como regla práctica, el intervalo parcial no deja escapar conductas breves, como un tic; el muestreo momentáneo con intervalos cortos estima mejor el **tiempo** que ocupa una conducta continua, como estar concentrado en la tarea. En ningún caso debe tratarse el porcentaje de intervalos como si fuera el porcentaje de tiempo real.

14.2 Observación natural y análoga

El escenario va de la vida diaria de la persona (situación **natural**) a un escenario preparado por el evaluador (situación **análoga** o artificial), con muchos puntos intermedios. Lo que se gana en realismo se pierde en control, y en ningún punto desaparece la reactividad (apartado 14.3).

Observación en situación natural. Se observa a la persona en su medio habitual: la casa, el aula, el patio, el trabajo. Sus ventajas son claras:

- alta **validez ecológica**, porque la conducta es la que realmente ocurre en la vida diaria;
- recoge lo que la persona hace por iniciativa propia, no lo que se le pide;
- permite ver los **antecedentes y consecuentes reales**, imprescindibles para el análisis funcional (Unidad 4);
- facilita seguimientos a lo largo del tiempo.

El precio es el **control**: puede pasar una tarde entera en casa sin que aparezca la rabieta que se quería ver. Hay espacios donde no se puede o no se debe entrar, y cada visita cuesta tiempo; por eso a menudo se delega el registro en padres o docentes, a costa de precisión.

Observación en situación artificial o análoga. Si la conducta es rara, privada o difícil de alcanzar en su medio, el evaluador la **provoca** en un escenario preparado: la consulta, una sala de juego o el laboratorio. Las formas principales son:

- **Pruebas de representación de papeles (*role-playing*)**: se pide a la persona que represente una escena, con frecuencia con el evaluador o un colaborador haciendo de interlocutor. Las **pruebas de rol de habilidades sociales**, en la línea de Bellack, presentan breves situaciones sociales (pedir un favor, rechazar una petición) y se observa la respuesta.
- **Tests situacionales**: el evaluador presenta estímulos o tareas que provocan la conducta, por ejemplo, pedir a una pareja que discuta durante diez minutos un tema en el que no se pone de acuerdo.
- **Test de evitación conductual (BAT)**: se pide a la persona que se acerque paso a paso al estímulo temido (una araña en un terrario, un ascensor) y se registra hasta dónde llega. Permite observar a la vez la conducta motora, la activación fisiológica y lo que la persona dice, es decir, los tres sistemas de respuesta (Unidad 4).

La situación análoga gana **control**: todas las personas se enfrentan a la misma situación, se puede repetir y se provoca justo la conducta que interesa. Gana **validez interna**, pero pierde **validez externa**: nada garantiza que quien rechaza bien una petición en un *role-playing* lo haga con su jefe, ni que el estudiante que se presenta con soltura ante un grupo simulado pregunte de verdad en clase. Para acortar esa distancia, las escenas se construyen a partir de situaciones que la persona vive a menudo y se acercan todo lo posible a las reales. Aun así, sus datos se contrastan siempre con la entrevista, el autoinforme o la observación en el medio natural.

El papel del observador. Cada tipo de observador tiene sus ventajas y sus riesgos:

Observador	Ventaja	Riesgo principal
Profesional no participante	Entrenado, ajeno a la situación	Su presencia puede causar reactividad si es visible
Profesional participante	Accede desde dentro a la situación	Mayor reactividad; implicación que sesga el registro
Persona del entorno (padre, profesora)	Poca reactividad; observa muchas horas	Menor precisión; expectativas sobre la persona

14.3 Fuentes de error del observador

La observación tiene sus propias fuentes de error. Proceden de la persona observada, del observador y del propio sistema de registro.

Reactividad del observado. La persona cambia su conducta porque sabe que la observan. Suele ser mayor al principio, por la novedad, y disminuye con la **habituación**, por lo que conviene descartar las primeras sesiones o prolongar la presencia del observador antes de registrar. También ayudan los observadores discretos y las medidas no reactivas, como los productos de conducta ya existentes. Las grabaciones sin conocimiento de la persona plantean problemas éticos (Unidad 8).

Expectativas del observador. Quien sabe que un niño está diagnosticado de TDAH o que ha empezado un tratamiento puede ver, sin querer, lo que espera. Kent et al. (1974) mostraron que las expectativas sesgan más las **calificaciones globales** que los **registros por categorías** bien definidas. Por eso conviene que los observadores no conozcan las hipótesis ni la fase del tratamiento.

Reactividad del control de fiabilidad. También el observador reacciona a ser observado. Reid (1970) vio que la exactitud de los observadores cae cuando creen que nadie comprueba su trabajo. Romanczyk, Kent, Diament y O'Leary (1973) compararon distintas condiciones de control.

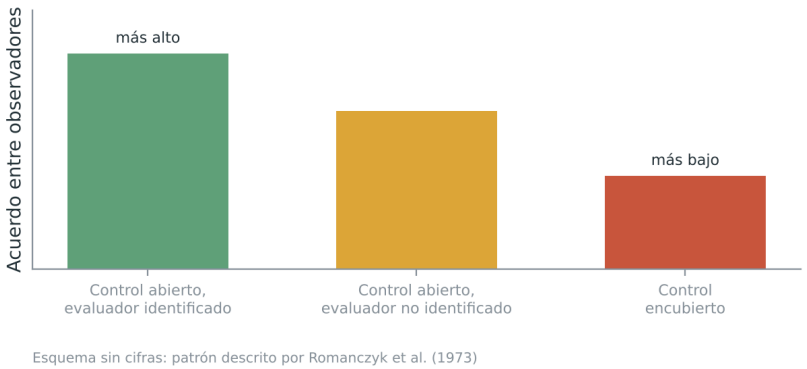


Figura 14.2. **El acuerdo depende de saberse controlado.** Barras conceptuales, sin cifras: el acuerdo es alto con control abierto y evaluador identificado, menor con control abierto y evaluador no identificado, y el más bajo con control encubierto. Patrón descrito por Romanczyk et al. (1973). Elaboración propia.

Como muestra la figura 14.2, cuando el control era **encubierto**, el acuerdo bajaba de forma sustancial y los observadores registraban **menos conducta disruptiva**. La consecuencia práctica es incómoda: el acuerdo medido en las sesiones de control puede ser más alto que el que hay en el resto. Por eso los controles deben ser **periódicos** y, cuando sea posible, **encubiertos** o aleatorios.

Deriva del observador. Con el paso del tiempo, el observador cambia poco a poco su forma de aplicar las definiciones, sin darse cuenta. La deriva es más peligrosa cuando dos observadores se forman y trabajan **juntos**: van redefiniendo el código entre ellos y pueden **coincidir mucho entre sí y ser poco exactos** respecto a la definición original (O'Leary y Kent, 1973; Kent, Kanowitz, O'Leary y Cheiken, 1977). Un acuerdo alto entre ellos no detecta el problema. Las soluciones son reentrenar periódicamente con material de referencia ya codificado, rotar las parejas y comparar con un criterio externo.

Conviene no confundir los conceptos: en la **reactividad** cambia la persona observada; en la **deriva**, el observador.

Complejidad del código y características del observador. Cuantas más categorías, más parecidas entre sí y más rápida la conducta, más errores. También influyen la experiencia, el cansancio o la familiaridad con la persona. Señales de alarma son los cambios bruscos de frecuencia sin cambios en la situación y las discrepancias claras con otras fuentes, como la entrevista o los autoinformes.

14.4 Acuerdo entre observadores, criterios de bondad y planificación

La **fiabilidad interobservadores** o **interjueces** indica en qué medida dos observadores independientes registran lo mismo. Es la garantía básica de la observación y la que más se pregunta. Hay varios índices:

- **Porcentaje de acuerdo total o por frecuencia.** Se comparan los totales de cada observador: si uno cuenta 18 conductas y otro 20, el acuerdo es 18/20 = 90 %. Es el **más laxo**, porque los dos pueden haber contado episodios distintos y coincidir en el total.
- **Acuerdo por intervalos.** Se comparan intervalo a intervalo: acuerdos / (acuerdos + desacuerdos). Es más exigente, pero no corrige el acuerdo que se produciría **por azar**.
- **Índice por orden o secuencia.** Además de contar, mira si los dos observadores encadenan los acontecimientos igual (A, luego B, luego C); importa cuando se estudian secuencias, como las interacciones.
- **Kappa de Cohen** (Cohen, 1960). Corrige el acuerdo esperado por azar: κ = (acuerdo observado − acuerdo por azar) / (1 − acuerdo por azar). Vale 1 con acuerdo perfecto y 0 cuando el acuerdo no supera al azar.

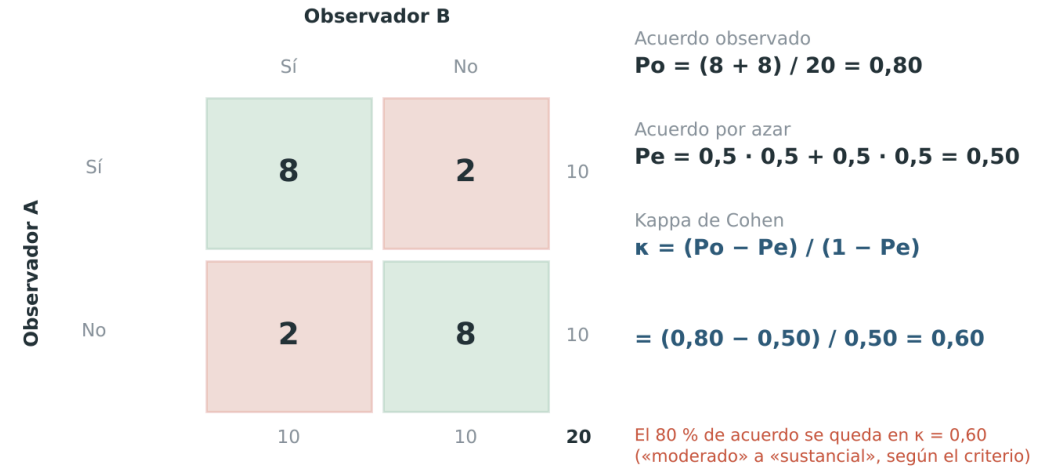


Figura 14.3. **Del porcentaje de acuerdo a kappa.** Dos observadores registran 20 intervalos: coinciden en 8 intervalos con conducta y en 8 sin ella, y discrepan en 4. El acuerdo es del 80 %, el acuerdo esperado por azar es 0,50 y κ = 0,60. Datos inventados. Elaboración propia.

Como muestra la figura 14.3, un 80 % de acuerdo se convierte en un κ de 0,60 cuando se descuenta lo que habría coincidido por azar. Para interpretar kappa se usa a menudo la propuesta de Landis y Koch (1977): por encima de 0,60, acuerdo **sustancial**, y por encima de 0,80, **casi perfecto**. El cálculo se detalla en el ejemplo resuelto.

Otros criterios de bondad. Además del acuerdo, se valora:

- la **estabilidad temporal**: si la conducta registrada se mantiene en distintas sesiones, lo que se comprueba correlacionando los datos de dos o más momentos;
- la **validez ecológica**: si lo observado se generaliza a la vida real, una cuestión crítica en la observación análoga;
- la **generalizabilidad**: la teoría de Cronbach, Gleser, Nanda y Rajaratnam (1972) permite estimar a la vez cuánto varían los datos según el observador, la sesión o la situación, en la línea del cubo de Cone (Unidad 4). Su desarrollo formal corresponde a Psicometría.

Planificación de la observación. Una observación bien planificada sigue ocho pasos:

1. definir el objetivo y las conductas de interés;
2. elaborar **definiciones operativas** con ejemplos y contraejemplos;
3. elegir la unidad de análisis y la unidad de medida;
4. elegir la técnica de registro;
5. decidir el muestreo de tiempo, situaciones y sujetos;
6. **entrenar** a los observadores hasta un criterio de acuerdo fijado de antemano;
7. hacer **controles periódicos y encubiertos** del acuerdo durante todo el registro;
8. analizar los datos y revisar el sistema si el acuerdo cae.

Ejemplo resuelto

Datos. Dos observadores registran si un niño está fuera de su asiento en 20 intervalos. Ambos marcan «sí» en 8 intervalos y «no» en 8; en 2 intervalos solo marca el observador A y en otros 2 solo el B.

1. Acuerdo observado. Acuerdos = 8 + 8 = 16. Acuerdo observado = 16 / 20 = 0,80 (80 %).

2. Proporciones de cada observador. A marca «sí» en 8 + 2 = 10 intervalos (0,50) y «no» en 10 (0,50); B, igual.

3. Acuerdo por azar. Ambos «sí»: 0,50 · 0,50 = 0,25. Ambos «no»: 0,50 · 0,50 = 0,25. Total = 0,50.

4. Kappa. κ = (0,80 − 0,50) / (1 − 0,50) = 0,30 / 0,50 = 0,60.

5. Interpretación. El acuerdo supera claramente al azar y queda justo en el techo de la franja que Landis y Koch (1977) llaman moderada (0,41–0,60), sin llegar a sustancial. Para un estudio de tratamiento convendría revisar las definiciones y reentrenar.

Variante: una conducta poco frecuente. Supongamos que ambos marcan «sí» en 1 intervalo, «no» en 17 y discrepan en 2 (1 + 1). El acuerdo observado es 18 / 20 = 0,90. Cada observador marca «sí» en 2 de 20 intervalos (0,10). Acuerdo por azar = 0,10 · 0,10 + 0,90 · 0,90 = 0,01 + 0,81 = 0,82. κ = (0,90 − 0,82) / (1 − 0,82) = 0,08 / 0,18 ≈ 0,44. El 90 % parece excelente, pero casi todo se debe a coincidir en que «no pasa nada»: con conductas raras, el porcentaje de acuerdo engaña.

Consenso y debate

Consenso: el intervalo parcial sobreestima, el intervalo total infraestima y el muestreo momentáneo yerra en ambos sentidos, con un error que crece al alargar el intervalo (Powell et al., 1975). Ningún método de observación es objetivo por sí mismo: la reactividad, las expectativas, la deriva y la reactividad del control de fiabilidad son errores documentados. El acuerdo debe medirse con índices que corrijan el azar, como kappa, y controlarse durante todo el registro.

Debate: los umbrales concretos de longitud de intervalo para el muestreo momentáneo son solo orientativos. Las categorías de Landis y Koch (1977) son convencionales y no hay un punto de corte universal de kappa. Tampoco hay acuerdo sobre cuánto se pueden generalizar a la vida real los datos de la observación análoga.

Mito frecuente

Mito: «Si dos observadores coinciden en un 90 %, el registro es exacto».

Realidad: el porcentaje de acuerdo no descuenta las coincidencias por azar, que son muy altas cuando la conducta es rara (Cohen, 1960). Además, dos observadores pueden coincidir mucho entre sí y alejarse juntos de la definición original por deriva (O'Leary y Kent, 1973), y el acuerdo medido sube cuando saben que se les controla (Romanczyk et al., 1973). Acuerdo no es lo mismo que exactitud.

Conceptos clave

Concepto	Definición
Registro continuo	Anotación de cada episodio con su inicio y su final; criterio de comparación del muestreo
Intervalo parcial	Se marca el intervalo si la conducta aparece en algún momento; sobreestima la duración
Intervalo total	Se marca el intervalo solo si la conducta lo ocupa entero; infraestima la duración
Muestreo momentáneo	Se registra si la conducta ocurre en un instante prefijado; yerra en ambos sentidos
Observación análoga	Observación en una situación recreada (*role-playing*, BAT); gana control, pierde validez externa
Reactividad	Cambio de la conducta del observado porque sabe que le observan

Concepto	Definición
Deriva del observador	Cambio gradual e inadvertido en cómo el observador aplica las definiciones del código
Kappa de Cohen	Índice de acuerdo entre observadores que corrige el acuerdo esperado por azar (Cohen, 1960)

Clave PIR

Prioridad alta. Se pregunta qué estrategia de muestreo sobreestima o infraestima, se pide calcular kappa a partir de una tabla 2×2 y se describe una situación para identificar reactividad, deriva o expectativas. Trampas típicas: creer que el intervalo parcial es el más preciso, confundir reactividad (cambia el observado) con deriva (cambia el observador) y tomar el porcentaje de acuerdo por kappa.

Autoevaluación

1. Una conducta ocupa realmente el 40 % de una sesión. ¿Qué estrategia tenderá a sobreestimarla de forma sistemática?
a) El muestreo de intervalo total
b) El muestreo momentáneo
c) El muestreo de intervalo parcial

2. Dos observadores formados juntos alcanzan un acuerdo muy alto, pero sus registros se alejan de la definición original. Es un caso de…
a) deriva del observador
b) reactividad del observado
c) efecto de las expectativas

3. Romanczyk et al. (1973) hallaron que, con un control de fiabilidad encubierto…
a) el acuerdo aumentaba y se registraba más conducta
b) el acuerdo bajaba y se registraba menos conducta disruptiva
c) el acuerdo no cambiaba respecto al control abierto

4. Con un acuerdo observado de 0,70 y un acuerdo por azar de 0,40, kappa vale…
a) 0,30
b) 0,70
c) 0,50

5. La principal limitación de la observación análoga, como un *role-playing*, es…
a) su baja validez externa
b) su falta de control sobre la situación
c) que no permite observar conducta motora

Soluciones

1 c. El intervalo parcial marca el intervalo con cualquier instante de conducta y sobreestima su duración. **2 a.** En la deriva cambia el observador; la pareja redefine el código y coincide sin ser exacta. **3 b.** Los observadores son menos precisos cuando no saben que se les controla. **4 c.** $\kappa = (0{,}70 - 0{,}40) / (1 - 0{,}40) = 0{,}30 / 0{,}60 = 0{,}50$. **5 a.** Gana control y validez interna, pero no garantiza que la conducta se generalice a la vida real.

Capítulo 6 · El autoinforme

Preguntar a la persona por lo que hace, piensa y siente es la vía más usada en evaluación psicológica, y también la más discutida. Este capítulo explica primero cómo se produce una respuesta, qué tipos de información ofrece el autoinforme y qué errores la amenazan. Después describe sus formas principales: cuestionarios, autorregistros, pensamiento en voz alta, entrevista y métodos narrativos.

Unidad 15 · Fundamentos del autoinforme

Objetivos: describir las fases de respuesta a una pregunta y el error típico de cada una; distinguir los autoinformes directos de los indirectos y clasificarlos según sus variables; identificar las variables que se evalúan y los formatos de pregunta y respuesta; reconocer las fuentes de error y los procedimientos para controlarlas.

15.1 El autoinforme y el procesamiento de la información

Un **autoinforme** es cualquier procedimiento en el que la persona evaluada aporta, de forma verbal o escrita, información sobre sí misma: lo que hace, lo que piensa, lo que siente, lo que le ocurre en el cuerpo o lo que ha vivido. Puede ser muy estructurado, como un cuestionario con opciones cerradas, o muy abierto, como una autobiografía. Por su variedad, se considera la categoría de métodos más amplia de la evaluación psicológica (Fernández-Ballesteros, 2011). En el continuo de métodos del cubo de Cone (Unidad 4), el autoinforme ocupa una posición indirecta: casi siempre informa de una conducta que ocurrió en otro lugar o en otro momento.

Responder a una pregunta no es leer un archivo interno. Es una tarea cognitiva en la que se interpreta lo que se pregunta, se busca información en la memoria, se combina y se traduce al formato que ofrece el instrumento. Tourangeau, Rips y Rasinski (2000) describieron este proceso en cuatro fases, cada una con sus errores característicos.

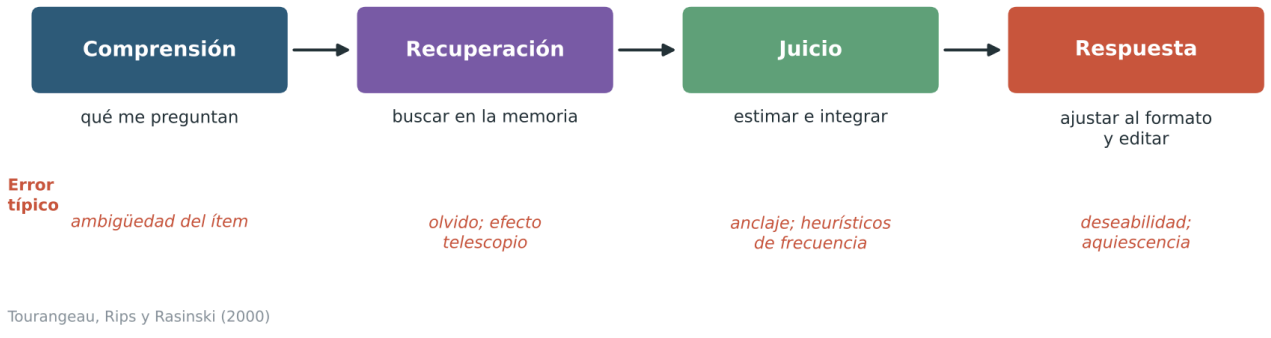


Figura 15.1. **Las cuatro fases de respuesta a un cuestionario.** Comprensión, recuperación, juicio y respuesta se suceden, y bajo cada fase aparece su error típico: ambigüedad; olvido y efecto telescopio; anclaje; deseabilidad y aquiescencia. Tourangeau, Rips y Rasinski (2000). Elaboración propia.

Como muestra la figura 15.1, el error puede aparecer en cualquier punto:

1. **Comprensión.** La persona tiene que entender la pregunta como la entiende el evaluador. «¿Bebe a menudo?» deja abierto qué es «a menudo» y si cuenta la cerveza del fin de semana.

2. **Recuperación.** Hay que buscar en la memoria los episodios relevantes. Algunos se **olvidan** y otros se sitúan en un momento equivocado: en el **efecto telescopio**, los hechos lejanos se fechan como más recientes de lo que son, y entran en el periodo preguntado sin pertenecer a él.
3. **Juicio.** Con lo recuperado hay que formar una respuesta: sumar, estimar o comparar. Cuando no se cuentan los episodios uno a uno, se recurre a heurísticos de frecuencia y a **anclajes**, como el primer número que se ofrece en la escala.
4. **Respuesta.** El juicio se ajusta al formato disponible y se filtra según lo que la persona está dispuesta a comunicar. Aquí actúan la deseabilidad social y los estilos de respuesta (apartado 15.4).

Un ejemplo: ante «¿Cuántas veces ha ido al médico en el último año?», alguien puede dudar si cuenta el dentista (comprensión), no recordar una visita breve (recuperación), estimar «unas cuatro» porque le parece una cifra normal (juicio) y marcar la opción intermedia de la escala (respuesta).

La calidad de la información depende también del tipo de suceso y del momento al que se refiere. No es lo mismo preguntar un dato concreto («¿En qué año empezó a trabajar?») que una elaboración («¿Cómo se sentía en aquel trabajo?»), ni un suceso de ayer que uno de hace diez años.

Otros dos criterios son la **accesibilidad** (si la persona puede llegar de verdad a la información que se le pide) y la **contrastabilidad** (si otro puede comprobarla): que alguien evita el metro puede verlo un acompañante; su miedo, no. La accesibilidad tiene un límite conocido. Nisbett y Wilson (1977) revisaron estudios en los que un factor influía en la conducta sin que los participantes lo advirtieran: al explicar su conducta, daban razones plausibles, pero no mencionaban ese factor. Concluyeron que las personas no informan con exactitud de las **causas** de su conducta y recurren a **teorías implícitas** sobre lo que suele causar qué. Ericsson y Simon matizaron después esta conclusión: lo que sí puede verbalizarse con fiabilidad es el **contenido** que se tiene presente en la memoria de trabajo (Unidad 16). La consecuencia práctica es clara: es más fiable preguntar qué hizo, pensó o sintió la persona que preguntarle por qué.

15.2 Autoinformes directos e indirectos

Fernández-Ballesteros separa los autoinformes en dos grupos según cuánto tiene que interpretar el evaluador para pasar de la respuesta al dato:

- **Directo o isomórfico.** Lo que la persona dice se toma como **muestra** de aquello que se evalúa. Si un paciente anota que esta semana se ha despertado tres veces cada noche, esa respuesta es el dato: no se infiere nada más allá.
- **Indirecto o inferencial.** Las respuestas se usan como **indicadores** de un constructo que no aparece en ellas de forma literal. Si alguien se muestra de acuerdo con «me preocupo por cosas sin importancia» y «me cuesta relajarme», el evaluador no se queda en esas dos frases, sino que infiere un nivel de neuroticismo o de ansiedad rasgo a partir del conjunto.

La distinción enlaza con la disyuntiva **signo frente a muestra** (Unidad 4). La evaluación conductual prefiere los autoinformes directos porque reducen la inferencia; los modelos psicométrico y dinámico usan con más frecuencia los indirectos. Un mismo instrumento puede usarse de las dos maneras según cómo se interprete.

Un error frecuente es pensar que **«isomórfico» equivale a «objetivo»**. Un autoinforme directo sigue pasando por las cuatro fases del apartado 15.1: el paciente que dice despertarse tres veces puede estar recordando mal o redondeando. Lo que cambia es la cantidad de inferencia del evaluador, no la exactitud de la persona.

Además del nivel de inferencia, los autoinformes pueden clasificarse según otras variables:

Variable	Opciones	Ejemplo
Tiempo	Pasado, presente o futuro	«¿Cuándo empezó el problema?» frente a «¿Qué cree que pasará si va a la fiesta?»

Variable	Opciones	Ejemplo
Tipo de manifestación	Motora, fisiológica, cognitiva o experiencia subjetiva	Evitar el metro; notar taquicardia; pensar «me voy a desmayar»; sentir miedo
Contrastabilidad	Con criterios externos o solo con otros autoinformes de la misma persona	Horas de sueño frente a grado de tristeza
Nivel de inferencia	Directo (muestra) o indirecto (signo)	Registro de despertares frente a escala de neuroticismo

La variable «tipo de manifestación» recuerda que el autoinforme no evalúa solo lo cognitivo. Como los tres sistemas de respuesta están débilmente acoplados, lo que se dice de uno no siempre coincide con lo que se mide en otro (Unidad 4).

Cuando no hay criterio externo, la información se refuerza por triangulación: se comprueba si la respuesta se sostiene al repetir la pregunta otro día o en otro contexto, si coincide con un instrumento de formato distinto, si deja huellas comprobables (un ticket, un historial de llamadas, la frecuencia cardiaca) y si concuerda con lo que cuentan otras personas.

En el metaanálisis de Achenbach, McConaughy y Howell (1987), la correlación media entre el propio sujeto y otros informantes fue de solo 0,22, frente a 0,60 entre informantes similares. La discrepancia no indica que uno mienta: cada informante ve una parte distinta de la conducta (Unidad 1).

15.3 Variables evaluadas y formatos de respuesta

Los autoinformes se han usado desde todos los modelos de evaluación (Unidad 3), y cada modelo les pide un tipo distinto de información.

Variable	Qué se busca	Ejemplo
Rasgos	Disposiciones estables, comparadas con un grupo normativo	Escalas de personalidad
Estados	Cómo se encuentra la persona en una situación o momento	STAI, escala de ansiedad estado (Spielberger)
Repertorios clínico-conductuales	Conductas concretas ligadas a un problema	*Fear Survey Schedule* (Wolpe y Lang, 1964)
Repertorios cognitivos	Pensamientos, autoinstrucciones, atribuciones	ATQ, pensamientos automáticos (Hollon y Kendall, 1980)
Construcciones idiográficas	Cómo la persona organiza su propio mundo	Rejilla de constructos personales (Kelly, 1955)
Narrativa	El relato que la persona hace de su vida	Historia de vida (McAdams)

Los autoinformes de **rasgos** usan ítems generales y comparan a la persona con un baremo (Unidad 9). Sus ítems pueden elegirse por tres vías: **racional**, según la teoría; **empírica**, según su capacidad para diferenciar grupos, como en el MMPI, y **factorial**, según su peso en un factor, como en el 16PF. El STAI ilustra bien la diferencia entre **rasgo y estado**: una de sus escalas pregunta cómo se siente la persona «en general» y la otra, cómo se siente «ahora mismo». Los repertorios **clínico-conductuales** y **cognitivos** son propios de la evaluación conductual y cognitivo-conductual: interesan las conductas o los pensamientos como muestras del problema, no como signos de un rasgo. Las técnicas idiográficas y narrativas se estudian con más detalle en Evaluación Psicológica II.

Modalidades de pregunta. Según su estructura, las preguntas pueden ser:

- **Estructuradas**: iguales para todos y con respuestas predeterminadas, lo que permite comparar.
- **Semiestructuradas**: dan una guía y dejan libertad para registrar; el ejemplo típico es el autorregistro.
- **No estructuradas**: una consigna abierta («Cuénteme cómo es un día normal para usted»).

Formatos de respuesta. Los más usados son estos:

- **Abierto**: la persona responde con sus palabras. Da riqueza, pero exige codificar las respuestas.
- **Dicotómico**: sí/no o verdadero/falso. Es rápido, pero obliga a decidir en casos dudosos.
- **Escalar o tipo Likert**: grado de acuerdo o frecuencia en varias opciones, por lo general entre 4 y 7. Con un número par se evita el punto medio.
- **Elección forzada**: hay que elegir entre afirmaciones de deseabilidad parecida. Produce puntuaciones **ipsativas**, que comparan las preferencias de la persona entre sí y no con las de otras personas (Unidad 4).
- **Escala analógico-visual**: una línea de 100 mm entre dos extremos («nada de dolor», «el peor dolor imaginable») en la que se marca un punto.
- **Q-sort** (Stephenson, 1953): la persona reparte un conjunto de tarjetas con afirmaciones en montones que van de «muy característico de mí» a «nada característico», siguiendo una **distribución forzada cuasinormal**: pocas tarjetas en los extremos y muchas en el centro.

La elección del formato no es neutra: un dolor crónico se sigue bien con una escala analógico-visual diaria, y cada formato favorece errores distintos (el dicotómico, la aquiescencia; el Likert, la tendencia central o extrema).

15.4 Fuentes de error

Ningún autoinforme es inmune al error, pero los errores son conocidos y en buena parte controlables. Algunos dependen de la intención de la persona y otros aparecen sin que se dé cuenta.

Simulación y disimulación. La **simulación** es el intento deliberado de dar una imagen peor de la real, por ejemplo para obtener una baja o una indemnización. La **disimulación** es lo contrario: ocultar problemas para parecer más ajustado, como en un proceso de selección o en una evaluación de custodia. Se controlan con instrucciones que piden sinceridad, con una buena relación con el evaluador y con **escalas de validez** diseñadas para detectar estos patrones (Evaluación Psicológica II).

Deseabilidad social. Es la tendencia a responder de la forma que se considera socialmente aceptable. Paulhus (1984) mostró que tiene dos componentes:

- **Autoengaño**: una visión de uno mismo positivamente sesgada, pero sincera. La persona cree de verdad lo que dice.
- **Manejo de la impresión**: el ajuste deliberado de las respuestas para causar una buena impresión a quien las va a leer.

Paulhus construyó el **BIDR** (*Balanced Inventory of Desirable Responding*) para medir ambos componentes con dos escalas: SDE, de realce autoengañoso, e IM, de manejo de la impresión. Más tarde, Paulhus y Reid (1991) dividieron el autoengaño en **realce** (atribuirse cualidades positivas) y **negación** (negar defectos).

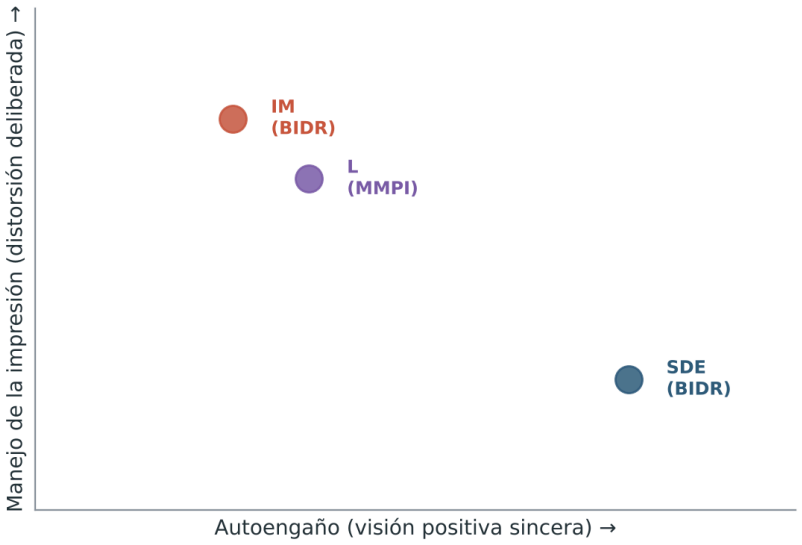


Figura 15.2. **Los dos componentes de la deseabilidad social.** Plano formado por el autoengaño y el manejo de la impresión, con las escalas SDE e IM del BIDR y la escala L del MMPI situada cerca del manejo de la impresión. La ubicación es orientativa. Elaboración propia.

Como muestra la figura 15.2, las escalas clásicas de «mentira», como la escala L del MMPI, se sitúan sobre todo del lado del manejo de la impresión. La distinción importa: un autoengaño alto no significa que la persona mienta, sino que se ve mejor de lo que la ven los demás.

Estilos de respuesta. Son tendencias que actúan con independencia del contenido de la pregunta:

- **Aquiescencia**: tendencia a responder «sí» o «de acuerdo». Se controla con **ítems equilibrados**, la mitad redactados en un sentido y la mitad en el contrario.
- **Errores escalares**: tendencia a elegir siempre el centro de la escala (**tendencia central**) o sus extremos (**tendencia extrema**).

Efectos de recuerdo. Olvido, efecto telescopio y reconstrucción de lo vivido según cómo se está ahora (apartado 15.1). Aumentan cuanto más lejano y menos llamativo es el suceso.

En conjunto, el autoinforme es más exacto cuando la persona está **motivada** para informar bien, los sucesos son **recientes**, conoce bien la conducta de la que informa, la pregunta es **concreta** y con un periodo definido («en las dos últimas semanas») y se le pide poca inferencia. Garantizar la confidencialidad y explicar para qué se usará la información también reduce las respuestas defensivas.

Una persona con dolor lumbar que solicita una incapacidad laboral puede exagerar sin querer, exagerar a propósito o minimizar por orgullo. El evaluador no descarta su autoinforme: lo combina con escalas de validez, otros informantes y datos funcionales.

Consenso y debate

Consenso: responder a un autoinforme es un proceso cognitivo con fases (comprensión, recuperación, juicio y respuesta), cada una con errores previsibles (Tourangeau, Rips y Rasinski, 2000). Las personas informan mejor del contenido de su experiencia que de las causas de su conducta (Nisbett y Wilson, 1977). La deseabilidad social, la aquiescencia y los errores escalares existen y pueden detectarse y reducirse con el diseño del instrumento, las instrucciones y las escalas de validez.

Debate: si la deseabilidad social es solo un sesgo o también refleja algo real. Paulhus (1984) la divide en autoengaño y manejo de la impresión, y algunos autores interpretan el manejo de la impresión como autocontrol interpersonal, es decir, como un rasgo verdadero, de modo que «corregir» las puntuaciones

por ella podría eliminar información válida. También se discute hasta dónde llega la introspección: Nisbett y Wilson (1977) subrayan sus límites y Ericsson y Simon defienden la validez de las verbalizaciones concurrentes.

Mito frecuente

Mito: «El autoinforme no sirve porque la gente miente».

Realidad: la mayoría de los errores del autoinforme no son mentiras, sino efectos de memoria, de comprensión o de estilo de respuesta, y se conocen y controlan con ítems equilibrados, instrucciones adecuadas y escalas de validez. Incluso la deseabilidad social incluye un autoengaño sincero (Paulhus, 1984). En constructos como la ansiedad, el dolor o el estado de ánimo, el autoinforme es la fuente principal de información, porque nadie más tiene acceso directo a esa experiencia.

Conceptos clave

Concepto	Definición
Autoinforme	Información verbal o escrita que la persona aporta sobre su conducta, pensamientos, emociones o historia
Modelo de Tourangeau	Cuatro fases de respuesta: comprensión, recuperación, juicio y respuesta (Tourangeau et al., 2000)
Efecto telescopio	Error de recuperación por el que sucesos lejanos se fechan como más recientes
Autoinforme isomórfico	Autoinforme directo cuya respuesta se toma como muestra de lo evaluado, con poca inferencia
Autoinforme inferencial	Autoinforme indirecto cuyas respuestas son indicadores de un constructo no observado
Autoengaño	Visión de uno mismo positivamente sesgada pero sincera; componente de la deseabilidad (Paulhus, 1984)
Manejo de la impresión	Ajuste deliberado de las respuestas para causar buena impresión (Paulhus, 1984)
Aquiescencia	Tendencia a responder «sí» con independencia del contenido; se controla con ítems equilibrados

Clave PIR

Prioridad alta. Se pregunta por los dos componentes de la deseabilidad social de Paulhus y el instrumento que los mide (BIDR), por la diferencia entre autoinforme directo e indirecto y por el contraste entre Nisbett y Wilson (1977) y Ericsson y Simon. Trampas típicas: confundir autoengaño con mentira, creer que un autoinforme isomórfico es objetivo y atribuir a Nisbett y Wilson la idea de que ningún autoinforme verbal es válido, cuando su crítica se refiere a las causas de la conducta.

Autoevaluación

1. En el modelo de Tourangeau, Rips y Rasinski (2000), el efecto telescopio es un error típico de la fase de…
a) comprensión
b) recuperación
c) respuesta

2. Un paciente anota cada día cuántos cigarrillos fuma y el evaluador toma ese número como dato sin más inferencia. Se trata de un autoinforme…
a) indirecto o inferencial
b) proyectivo o de signo
c) directo o isomórfico

3. Según Paulhus (1984), una persona que cree sinceramente ser más competente de lo que la ven los demás muestra sobre todo…
a) autoengaño
b) manejo de la impresión
c) aquiescencia

4. ¿Qué procedimiento es el más indicado para controlar la aquiescencia?
a) Pedir sinceridad en las instrucciones iniciales
b) Usar ítems equilibrados en ambos sentidos
c) Ampliar el número de opciones de respuesta

5. Nisbett y Wilson (1977) concluyeron que las personas…
a) no pueden verbalizar ningún contenido mental
b) informan con exactitud de sus estados de ánimo
c) no informan con exactitud de las causas de su conducta

Soluciones

1 b. Al recuperar, los sucesos lejanos se sitúan como más recientes y entran en el periodo preguntado. **2 c.** La respuesta se toma como muestra de la conducta; directo no significa exacto. **3 a.** El autoengaño es sincero; el manejo de la impresión es deliberado. **4 b.** Redactar la mitad de los ítems en sentido inverso neutraliza la tendencia a decir «sí». **5 c.** Recurren a teorías implícitas; su crítica no afecta a la verbalización del contenido presente.

Unidad 16 · Tipos de autoinforme

Objetivos: describir las características, usos y límites de los cuestionarios, inventarios y escalas; planificar un autorregistro y explicar los factores que influyen en su reactividad; explicar los niveles de verbalización de Ericsson y Simon y la evidencia sobre su efecto; situar la entrevista, la autobiografía y los métodos narrativos dentro del autoinforme.

16.1 Cuestionarios, inventarios y escalas

Los **cuestionarios**, **inventarios** y **escalas** son autoinformes estructurados: una lista fija de preguntas o afirmaciones, con un formato de respuesta cerrado, que se puntúa siguiendo normas establecidas. Los nombres se usan de forma bastante intercambiable. Por costumbre, se habla de «inventario» cuando se recorre de forma amplia un ámbito (síntomas, intereses), de «escala» cuando se mide la intensidad de una dimensión y de «listado» cuando la persona marca qué elementos le corresponden de una lista.

Sus ventajas explican por qué son el autoinforme estructurado más usado:

- **Economía**: se aplican en poco tiempo, de forma individual o colectiva, en papel o en pantalla.
- **Estandarización**: todas las personas responden a lo mismo y se corrigen igual, lo que reduce la influencia del evaluador.
- **Comparabilidad**: permiten situar a la persona en un baremo (Unidad 9) y comparar sus puntuaciones a lo largo del tiempo.
- **Garantías conocidas**: de un instrumento publicado pueden conocerse su fiabilidad y las evidencias de validez para un uso concreto (Unidades 9 y 10).

Sus límites son la otra cara de la estructura. Los ítems son iguales para todos y no recogen lo que es específico del caso; las respuestas cerradas no permiten matizar, y todos los errores de la Unidad 15 (deseabilidad, aquiescencia, efectos de recuerdo) siguen presentes.

Algunos instrumentos muy utilizados en España ilustran sus usos:

Instrumento	Qué evalúa	Nota
STAI (Spielberger)	Ansiedad estado y ansiedad rasgo	Adaptación española publicada por TEA
BDI-II (Beck, Steer y Brown, 1996)	Gravedad de los síntomas depresivos	21 ítems; adaptación española de Sanz y colaboradores (2003)
BAI	Gravedad de los síntomas de ansiedad	Adaptación española de Sanz y Navarro (2003)
SCL-90-R (Derogatis)	Síntomas psicopatológicos en varias dimensiones	90 ítems; adaptación española publicada por TEA

La adaptación española del BDI-II se estudió primero con 590 universitarios, con una consistencia interna de $\alpha = 0{,}89$ (Sanz, Navarro y Vázquez, 2003), y después en población general (Sanz, Perdigón y Vázquez, 2003). Conviene leer bien ese dato: un α alto indica que los ítems covarían mucho entre sí, pero **no demuestra que el test mida una sola dimensión**. La unidimensionalidad se comprueba con análisis de la estructura interna (Unidad 10).

En la práctica, estos instrumentos sirven sobre todo para cuatro cosas: **cribar** posibles problemas, **cuantificar** la gravedad, **describir** un perfil y **medir el cambio** antes, durante y después de una intervención. No sirven para diagnosticar por sí solos. Una puntuación alta en el BDI-II indica síntomas depresivos intensos, pero el diagnóstico exige una entrevista clínica, la historia del caso y otros datos (Unidad 12). Por ejemplo, una

estudiante obtiene una puntuación elevada en época de exámenes: la entrevista mostrará si se trata de un malestar transitorio ligado al estrés o de un episodio depresivo.

Las escalas de validez, los perfiles y los instrumentos concretos de personalidad, inteligencia o psicopatología se estudian en Evaluación Psicológica II; la teoría formal de su construcción, en Psicometría.

16.2 Autorregistros

El **autorregistro** es un procedimiento en el que la persona **observa su propia conducta y la anota** en el momento en que ocurre o poco después, siguiendo unas instrucciones previas. Korotitsch y Nelson-Gray (1999) lo describen con dos componentes: **discriminar** que la conducta objetivo se ha producido y **registrarla**. Es una técnica semiestructurada, porque el evaluador define qué y cómo se anota, pero quien observa y escribe es la propia persona, casi siempre en su medio natural. Es la herramienta básica de la autoobservación del cubo de Cone (Unidad 4).

Los formatos se adaptan a lo que interesa medir:

- **Frecuencia**: cuántas veces ocurre algo (cigarrillos, atracones, discusiones).
- **Duración**: cuánto tiempo dura (minutos de estudio, horas de sueño).
- **ABC o diario de pensamientos**: qué pasó antes, qué hizo o pensó la persona y qué ocurrió después.
- **Escala analógico-visual en momentos fijos**: intensidad del dolor o del ánimo a varias horas del día.

El soporte importa menos que la comodidad: una libreta de bolsillo, un contador de muñeca o una aplicación del móvil sirven si la persona puede usarlos en el momento.

Día y hora	A · Situación	B · Conducta o pensamiento	C · Consecuencia	Malestar 0-10
Lunes, 9:10	Reunión de equipo	No intervengo; «van a pensar que no sé»	Alivio; después, enfado conmigo	7
Martes, 14:30	Comida con compañeros	Me excuso y como sola	Tranquilidad; me siento aislada	5
Jueves, 18:00	Llamada a un cliente	La aplazo al día siguiente	Alivio; tarea pendiente	6

Ejemplo de hoja; datos inventados.

Figura 16.1. **Hoja de autorregistro ABC.** Columnas para el día y la hora, la situación o antecedente, la conducta o el pensamiento, la consecuencia y el malestar de 0 a 10, con tres entradas de ejemplo. Elaboración propia.

La hoja ABC de la figura 16.1 aporta datos directos para el análisis funcional (Unidad 4): con varias semanas de registro se ve qué situaciones preceden al problema y qué consecuencias lo mantienen.

Un autorregistro solo es útil si está bien planificado:

1. **Definir la conducta** de forma operativa y comprensible («cada vez que me levanto de la mesa de estudio sin haber terminado la tarea»).
2. **Elegir los parámetros**: frecuencia, duración, intensidad, antecedentes, consecuencias.
3. **Diseñar la hoja** de forma sencilla, con pocos campos y fácil de llevar encima.
4. **Entrenar** a la persona con ejemplos y practicar en consulta.
5. Pedir que se anote **justo después** de la conducta, no al final del día.
6. **Revisar** los registros en cada sesión, para reforzar el esfuerzo y corregir errores.

La reactividad. Observarse a uno mismo cambia la conducta observada. Según Nelson (1977), la **reactividad** del autorregistro es mayor cuando:

- la conducta tiene una **valencia** clara: las deseables tienden a aumentar y las indeseables a disminuir;

- se registra **antes** de realizar la conducta (por ejemplo, anotar el cigarrillo antes de encenderlo);
- el dispositivo de registro es **visible**;
- hay **metas** y **retroalimentación** sobre lo registrado.

Para la evaluación, la reactividad es un **problema**: la línea base puede no reflejar la conducta habitual. Para el tratamiento es una **ventaja**: el autorregistro se usa como técnica de cambio, algo que se estudia en Terapia de conducta. El evaluador debe tenerla en cuenta al interpretar los primeros días de registro.

La versión digital del autorregistro es la **evaluación ecológica momentánea** (EMA): el móvil pide respuestas breves varias veces al día, en el momento y en el lugar en que la persona se encuentra. Reduce el sesgo de recuerdo y gana validez ecológica, a cambio de más carga para quien responde y de cierta reactividad (Shiffman, Stone y Hufford, 2008; Unidad 6).

16.3 El pensamiento en voz alta

En el **pensamiento en voz alta** la persona verbaliza lo que piensa mientras realiza una tarea o inmediatamente después. No hay preguntas ni opciones: el evaluador propone una tarea, casi siempre en consulta o en el laboratorio, y la persona habla. Hay tres maneras de organizarlo:

- **Monólogo continuo**: la persona dice todo lo que le pasa por la cabeza mientras hace la tarea.
- **Muestreo de pensamientos**: suena una señal y la persona dice qué tenía en la cabeza en ese instante; el calendario de señales lo fija el evaluador.
- **Registro de sucesos**: la iniciativa pasa a la persona, que habla solo cuando detecta un pensamiento acordado, por ejemplo cada vez que empieza a preocuparse.

Si se graba con el móvil, el ejercicio puede hacerse en casa, sin el evaluador delante.

El marco de referencia es el **análisis de protocolos** de Ericsson y Simon (1980; *Protocol analysis*, 1984/1993). Su idea central es que la persona puede informar con fiabilidad del contenido que tiene presente en la memoria de trabajo, siempre que se le pida lo adecuado. Distinguieron tres **niveles de verbalización**:

1. **Nivel 1, verbalizar**: decir en voz alta lo que ya está en forma verbal («siete por ocho, cincuenta y seis…»).
2. **Nivel 2, recodificar**: poner en palabras contenido que no es verbal, como imágenes o sensaciones («veo el mapa y estoy girando a la izquierda»).
3. **Nivel 3, explicar**: justificar o describir los propios procesos («lo hago así porque me parece más seguro»).

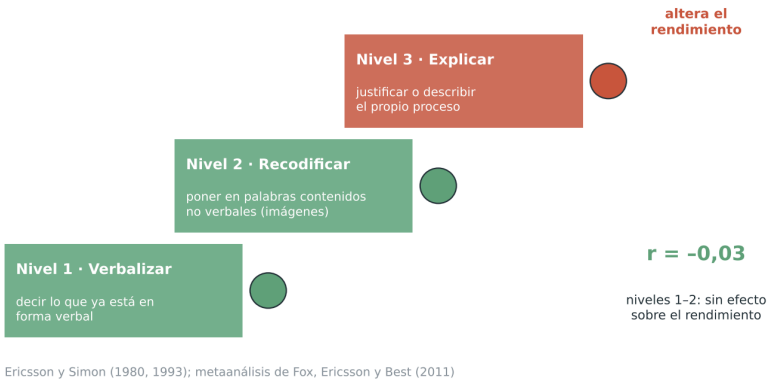


Figura 16.2. **Niveles de verbalización de Ericsson y Simon.** Escalera con los niveles 1 (verbalizar) y 2 (recodificar) en verde y el nivel 3 (explicar) en rojo; para los niveles 1 y 2, la relación con el rendimiento es r = –0,03 (Fox, Ericsson y Best, 2011). Elaboración propia.

Como muestra la figura 16.2, los dos primeros niveles se limitan a sacar fuera lo que ya se está pensando; el tercero obliga a hacer algo nuevo: analizar el propio proceso. El metaanálisis de Fox, Ericsson y Best (2011), con

94 estudios y casi 3.500 participantes, confirmó la predicción. Con instrucciones de **solo verbalizar** (niveles 1 y 2), el rendimiento en la tarea no cambia (r = –0,03), aunque la tarea **se alarga**. En cambio, cuando se piden **explicaciones** (nivel 3), el rendimiento sí se altera.

Estos datos son compatibles con Nisbett y Wilson (1977), que se vieron en la Unidad 15. Lo que no es fiable es preguntar por qué se actuó; lo que sí lo es, con buenas instrucciones, es verbalizar lo que se está pensando en el momento. La instrucción adecuada es «diga en voz alta todo lo que piense mientras lo hace», no «explique por qué lo hace así».

En evaluación clínica, el pensamiento en voz alta permite captar pensamientos que la persona no recuerda después. Un estudiante con ansiedad ante los exámenes que resuelve problemas en voz alta puede mostrar, en pocos minutos, frases como «esto no me va a salir» o «seguro que lo hago mal», junto a su estrategia de resolución. Después, las verbalizaciones se transcriben y se codifican en categorías (pensamientos de tarea, autoevaluaciones negativas, pensamientos irrelevantes). Su principal limitación es práctica: requiere grabar, transcribir y codificar, y no todas las personas verbalizan con fluidez.

16.4 La entrevista como autoinforme, la autobiografía y los métodos narrativos

La entrevista es, en la práctica, el autoinforme al que más se recurre: la persona informa verbalmente sobre sí misma en respuesta a las preguntas del entrevistador. Tiene rasgos que la distinguen del resto. Es interactiva, de modo que puede aclarar preguntas y seguir pistas; permite observar la conducta no verbal mientras se habla, y se usa a lo largo de todo el proceso, desde la primera toma de contacto hasta el seguimiento. Cuando informan familiares, docentes u otras personas cercanas, ya no se trata de un autoinforme, sino de información de otros informantes, que complementa la del propio evaluado (Unidad 15). Su fiabilidad y validez aumentan con la estructura (Unidades 11 y 12).

La autobiografía es un relato escrito u oral en el que la persona cuenta su propia vida y la interpreta. Es un método **idiográfico**: busca comprender cómo vive esa persona su historia, no compararla con otras. Puede ser:

- **Libre**: «Escriba la historia de su vida como quiera contarla».
- **Guiada**: el evaluador marca un índice de etapas o temas (infancia, estudios, relaciones, momentos de cambio); el relato gana orden y es más fácil cotejarlo con lo que cuentan otros.

Al relato se le pueden sumar **documentos personales** (un diario de adolescencia, una carta guardada, el álbum de fotos) y una **línea de vida**: una flecha del nacimiento al presente en la que la persona coloca los hechos que considera importantes, más arriba o más abajo según lo buenos o malos que fueron y cuánto pesaron. La línea de vida ayuda a quien tiene dificultades para escribir y ofrece de un vistazo la estructura de una biografía.

Los métodos narrativos amplían esta idea. Desde el enfoque de McAdams, la identidad se entiende como una **historia de vida** interiorizada y en evolución: lo que interesa no es solo qué ocurrió, sino cómo lo cuenta la persona, qué episodios elige como decisivos, qué tono predomina o si los sucesos negativos acaban teniendo un sentido. Un mismo despido puede aparecer en un relato como el principio de una caída y en otro como el comienzo de una etapa mejor.

Estos materiales se leen sobre todo de forma **cualitativa**, buscando temas, tono y estructura (**análisis de contenido**), aunque también pueden codificarse y contarse. Sus límites son los de todo autoinforme retrospectivo: la memoria reconstruye, y el relato depende del momento en que se hace y de a quién se cuenta. Las técnicas subjetivas afines, como la rejilla de constructos personales, se estudian en Evaluación Psicológica II.

Cada tipo de autoinforme ofrece un equilibrio distinto entre estructura, cercanía al momento y riqueza de la información:

Tipo	Estructura	Momento al que se refiere	Riesgo principal
Cuestionario	Alta	Pasado reciente o general	Deseabilidad y estilos de respuesta

Tipo	Estructura	Momento al que se refiere	Riesgo principal
Autorregistro	Media	Presente, en el medio natural	Reactividad y abandono
Pensamiento en voz alta	Baja	Presente, durante la tarea	Alteración si se piden explicaciones
Entrevista	Variable	Pasado y presente	Sesgos del entrevistador si falta estructura
Autobiografía	Baja o media	Toda la vida	Reconstrucción del recuerdo

Por eso lo recomendable es combinarlos: un cuestionario para cuantificar, un autorregistro para ver la conducta día a día y una entrevista para integrar ambos datos con la historia de la persona.

Consenso y debate

Consenso: el pensamiento en voz alta con instrucciones de solo verbalizar (niveles 1 y 2) no altera el rendimiento, aunque alarga la tarea; pedir explicaciones sí lo altera (Fox, Ericsson y Best, 2011). El autorregistro es reactivo, sobre todo con conductas de valencia clara, registro previo, dispositivos visibles y metas (Nelson, 1977). Los cuestionarios sirven para cribar, cuantificar y medir el cambio, pero no diagnostican por sí solos.

Debate: hasta qué punto la EMA y las métricas pasivas del móvil o de los dispositivos que se llevan puestos son válidas para evaluar estados psicológicos, y cómo equilibrar su ganancia ecológica con la carga y la reactividad. También se discute cómo analizar con rigor los relatos autobiográficos sin perder lo que tienen de singular al cuantificarlos.

Mito frecuente

Mito: «El pensamiento en voz alta siempre altera el proceso que se quiere estudiar».

Realidad: depende de lo que se pida. El metaanálisis de Fox, Ericsson y Best (2011), con 94 estudios, encontró que verbalizar lo que se piensa (niveles 1 y 2 de Ericsson y Simon) no cambia el rendimiento ($r = –0,03$), aunque hace la tarea más lenta. Lo que sí altera el proceso es pedir a la persona que explique o justifique lo que hace (nivel 3).

Conceptos clave

Concepto	Definición
Cuestionario	Autoinforme estructurado con ítems fijos, respuesta cerrada y corrección estandarizada
Autorregistro	Observación y anotación de la propia conducta en el momento en que ocurre o poco después
Hoja ABC	Autorregistro de antecedentes, conducta o pensamiento y consecuencias de cada episodio

Concepto	Definición
Reactividad	Cambio de la conducta producido por el hecho de observarla o registrarla (Nelson, 1977)
EMA	Evaluación ecológica momentánea: respuestas breves en el móvil en el momento y lugar reales
Análisis de protocolos	Método de Ericsson y Simon para recoger y codificar verbalizaciones durante una tarea
Nivel 3 de verbalización	Explicar o justificar el propio proceso; a diferencia de los niveles 1 y 2, altera el rendimiento
Línea de vida	Eje temporal en el que la persona sitúa sus acontecimientos vitales y su valencia emocional

Clave PIR

Prioridad media. Se pregunta por los niveles de verbalización de Ericsson y Simon y por qué nivel altera el rendimiento, por los factores que aumentan la reactividad del autorregistro y por los componentes del autorregistro (discriminar y registrar). Trampas típicas: afirmar que el pensamiento en voz alta siempre interfiere, creer que la reactividad hace aumentar cualquier conducta registrada (las deseables suben y las indeseables bajan) y usar un cuestionario como si bastara para diagnosticar.

Autoevaluación

1. Según Nelson (1977), la reactividad del autorregistro aumenta cuando…
a) la conducta se registra antes de realizarla
b) el dispositivo de registro queda oculto
c) la conducta registrada es neutra para la persona

2. Según Fox, Ericsson y Best (2011), pedir a la persona que solo verbalice lo que piensa mientras resuelve una tarea…
a) empeora su rendimiento de forma clara
b) no cambia su rendimiento, pero alarga la tarea
c) mejora su rendimiento y acorta la tarea

3. En el nivel 2 de verbalización de Ericsson y Simon, la persona…
a) explica por qué actúa como actúa
b) repite lo que ya está en forma verbal
c) pone en palabras contenidos no verbales

4. Una puntuación alta en el BDI-II indica…
a) síntomas depresivos intensos, sin bastar para diagnosticar
b) un diagnóstico de depresión mayor confirmado
c) una ansiedad rasgo elevada y estable en el tiempo

5. Un eje temporal en el que la persona sitúa sus acontecimientos vitales y marca si fueron positivos o negativos es…
a) un Q-sort
b) una escala analógico-visual
c) una línea de vida

Soluciones

1 a. También aumenta con la valencia clara, el dispositivo visible y las metas con retroalimentación. **2 b.** Con instrucciones de solo verbalizar, r = –0,03; lo que altera el rendimiento es pedir explicaciones. **3 c.** Recodificar es verbalizar imágenes o sensaciones; explicar corresponde al nivel 3. **4 a.** El diagnóstico exige entrevista, historia y otros datos. **5 c.** Complementa la autobiografía y muestra de un vistazo su estructura.

Apéndices

Estudios y datos clave

Estudio o modelo	Dato o idea central	Unidad
Achenbach, McConaughy y Howell (1987)	Metaanálisis de 119 estudios sobre acuerdo entre informantes: r ≈ 0,60 entre informantes similares, ≈ 0,28 entre informantes de distinto tipo y ≈ 0,22 entre el propio sujeto y otros	1
Huarte de San Juan (1575)	*Examen de ingenios para las ciencias*: ajustar la aptitud a la profesión; precursor de la orientación profesional	2
Binet y Simon (1905); Stern (1912); Terman (1916)	Primera escala de inteligencia (edad mental); cociente intelectual; Stanford-Binet con el factor ×100	2
Mira i López (1922)	Selección de conductores de autobuses en Barcelona; inicio de la evaluación empírica de aptitudes en España	2
Kanfer y Saslow (1965, 1969)	El análisis conductual como alternativa a la clasificación diagnóstica; guía de 7 áreas	4
Kanfer y Phillips (1970)	Sistematización de la fórmula E-O-R-K-C	4
Lang (1968); Rachman y Hodgson (1974)	Triple sistema de respuesta débilmente acoplado; desincronía	4
Cone (1978)	Cubo de evaluación conductual: contenidos × métodos × universos de generalización	4
Fernández-Ballesteros et al. (2001)	Guías para el Proceso de Evaluación (GAP): 96 directrices consensuadas en la EAPA	5
Meehl (1954)	Primera revisión sistemática de la predicción clínica frente a la estadística	6
Grove et al. (2000)	136 estudios: la predicción mecánica es en promedio un 10 % más precisa; en torno a la mitad de los estudios, empate	6
Forer (1949)	Efecto Barnum: un perfil vago común se valora como muy preciso	6
Harvey (1997, 2006)	Los informes psicológicos suelen exigir un nivel de lectura universitario; la jerga es la principal barrera	7
Standards AERA/APA/NCME (2014)	Se valida la interpretación de las puntuaciones para un uso; cinco fuentes de evidencia	10
Campbell y Fiske (1959)	Matriz multirrasgo-multimétodo	10
Hernández et al. (2016)	CET-R: modelo español de evaluación de la calidad de los tests, basado en el de la EFPA	10
Muñiz, Hernández y Fernández-Hermida (2020)	Los 25 tests más usados en España son psicométricos; solo el 22,5 % conoce las revisiones de la Comisión de Test	10
Rettew et al. (2009)	38 estudios, N = 15.967: diagnóstico clínico rutinario frente a entrevista estandarizada, κ medio = 0,27	12

Estudio o modelo	Dato o idea central	Unidad
Sackett et al. (2022)	Validez en selección: entrevista estructurada r ≈ 0,42 frente a no estructurada ≈ 0,19 (Schmidt y Hunter, 1998, daban 0,51 y 0,38)	12
Köhnken et al. (1999); Memon, Meissner y Fraser (2010)	Entrevista cognitiva: más detalles correctos (d = 0,87 y 1,20) con un aumento pequeño de errores (d = 0,28 y ≈ 0,24)	12
Powell, Martindale y Kulp (1975)	El intervalo parcial sobreestima, el total infraestima y el muestreo momentáneo yerra en ambos sentidos	14
Romanczyk et al. (1973); Kent et al. (1974)	Reactividad del control de fiabilidad; las expectativas sesgan más las calificaciones globales que los registros por categorías	14
Cohen (1960); Landis y Koch (1977)	Kappa corrige el acuerdo por azar; > 0,60 sustancial, > 0,80 casi perfecto	14
Tourangeau, Rips y Rasinski (2000)	Cuatro fases de respuesta a un cuestionario: comprensión, recuperación, juicio y respuesta	15
Nisbett y Wilson (1977)	Las personas informan mal de las causas de su conducta	15
Paulhus (1984)	Dos componentes de la deseabilidad social: autoengaño y manejo de la impresión	15
Fox, Ericsson y Best (2011)	94 estudios: pensar en voz alta sin explicar no altera el rendimiento (r = –0,03)	16
Nelson (1977); Korotitsch y Nelson-Gray (1999)	Reactividad del autorregistro y sus moduladores	16

Mitos y correcciones

Mito	Corrección	Unidad
«Evaluar en psicología es pasar tests»	Los tests son una herramienta dentro de un proceso de contraste de hipótesis que incluye entrevista, observación, integración e informe	1
«Wundt fundó la evaluación psicológica»	Wundt buscaba leyes generales; la medición de las diferencias individuales procede de Galton, Cattell y Binet	2
«La evaluación conductual solo admite la observación directa»	Usa también autoinformes y autorregistros, tratados como muestras de conducta y no como signos de rasgos	3
«La desincronía es un concepto de Lang»	Lang (1968) propuso el triple sistema; el término desincronía es de Rachman y Hodgson (1974)	4
«Evaluar es una secuencia lineal»	El proceso es iterativo: la contrastación puede obligar a reformular las hipótesis	5
«La intuición del evaluador experto integra los datos mejor que cualquier regla»	La combinación mecánica iguala o supera al juicio clínico (Grove et al., 2000)	6
«Cuanto más técnico es un informe, más riguroso»	La jerga dificulta la comprensión; el Código exige informes inteligibles para su destinatario	7

Mito	Corrección	Unidad
«Si un progenitor paga la evaluación de su hijo, decide él solo»	Con menores, ambos progenitores tienen derecho a ser informados, y en tratamiento suele exigirse el consentimiento de ambos	8
«Un α alto demuestra que el test mide una sola cosa»	α depende del número de ítems y no es un índice de unidimensionalidad	9
«Este test es válido»	Lo que se valida es una interpretación de las puntuaciones para un uso concreto	10
«La entrevista libre es más válida porque es más profunda»	La entrevista estructurada predice mejor el desempeño (Sackett et al., 2022), y el diagnóstico rutinario coincide poco con el estandarizado (Rettew et al., 2009)	11
«La entrevista cognitiva llena el testimonio de errores»	Aumenta mucho los detalles correctos y apenas los incorrectos; la exactitud se mantiene (≈85 % frente a ≈82 %)	12
«La observación es objetiva por definición»	Hay reactividad, expectativas del observador, deriva y complejidad del código	13
«Si dos observadores coinciden en un 90 %, el registro es exacto»	El porcentaje no corrige el azar y dos observadores pueden coincidir en el error (deriva)	14
«El autoinforme no sirve porque la gente miente»	Con escalas de validez y control de los estilos de respuesta es útil, y en muchos constructos es la fuente principal	15
«El pensamiento en voz alta siempre altera el proceso»	Solo lo altera cuando se piden explicaciones (nivel 3 de Ericsson y Simon)	16

Bibliografía

Manuales de referencia

- AERA, APA y NCME (2014). *Standards for educational and psychological testing*. American Educational Research Association.
- Cohen, R. J., Schneider, W. J. y Tobin, R. (2022). *Psychological testing and assessment* (10.ª ed.). McGraw-Hill.
- Ericsson, K. A. y Simon, H. A. (1993). *Protocol analysis: Verbal reports as data* (ed. rev.). MIT Press.
- Fernández-Ballesteros, R. (dir.) (2011). *Evaluación psicológica: conceptos, métodos y estudio de casos* (2.ª ed.). Pirámide.
- Groth-Marnat, G. y Wright, A. J. (2016). *Handbook of psychological assessment* (6.ª ed.). Wiley.
- Haynes, S. N. y O'Brien, W. H. (2000). *Principles and practice of behavioral assessment*. Kluwer Academic/Plenum.
- Kanfer, F. H. y Phillips, J. S. (1970). *Learning foundations of behavior therapy*. Wiley.
- Miller, W. R. y Rollnick, S. (2013). *Motivational interviewing: Helping people change* (3.ª ed.). Guilford.
- Tourangeau, R., Rips, L. J. y Rasinski, K. (2000). *The psychology of survey response*. Cambridge University Press.

Artículos seleccionados

- Achenbach, T. M., McConaughy, S. H. y Howell, C. T. (1987). Child/adolescent behavioral and emotional problems: Implications of cross-informant correlations for situational specificity. *Psychological Bulletin, 101*(2),

213–232.

- Campbell, D. T. y Fiske, D. W. (1959). Convergent and discriminant validation by the multitrait-multimethod matrix. *Psychological Bulletin, 56*(2), 81–105.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement, 20*(1), 37–46.
- Cone, J. D. (1978). The behavioral assessment grid (BAG): A conceptual framework and a taxonomy. *Behavior Therapy, 9*(5), 882–888.
- Fernández-Ballesteros, R. et al. (2001). Guidelines for the assessment process (GAP): A proposal for discussion. *European Journal of Psychological Assessment, 17*(3), 187–200.
- Forer, B. R. (1949). The fallacy of personal validation: A classroom demonstration of gullibility. *Journal of Abnormal and Social Psychology, 44*(1), 118–123.
- Fox, M. C., Ericsson, K. A. y Best, R. (2011). Do procedures for verbal reporting of thinking have to be reactive? A meta-analysis and recommendations for best reporting methods. *Psychological Bulletin, 137*(2), 316–344.
- Grove, W. M., Zald, D. H., Lebow, B. S., Snitz, B. E. y Nelson, C. (2000). Clinical versus mechanical prediction: A meta-analysis. *Psychological Assessment, 12*(1), 19–30.
- Harvey, V. S. (2006). Variables affecting the clarity of psychological reports. *Journal of Clinical Psychology, 62*(1), 5–18.
- Hernández, A., Ponsoda, V., Muñiz, J., Prieto, G. y Elosua, P. (2016). Revisión del modelo para evaluar la calidad de los tests utilizados en España. *Papeles del Psicólogo, 37*(3), 192–197.
- Kanfer, F. H. y Saslow, G. (1965). Behavioral analysis: An alternative to diagnostic classification. *Archives of General Psychiatry, 12*(6), 529–538.
- Kanfer, F. H. y Saslow, G. (1969). Behavioral diagnosis. En C. M. Franks (Ed.), *Behavior therapy: Appraisal and status* (pp. 417–444). McGraw-Hill.
- Kent, R. N., Kanowitz, J., O'Leary, K. D. y Cheiken, M. (1977). Observer reliability as a function of circumstances of assessment. *Journal of Applied Behavior Analysis, 10*(2), 317–324.
- Kent, R. N., O'Leary, K. D., Diament, C. y Dietz, A. (1974). Expectation biases in observational evaluation of therapeutic change. *Journal of Consulting and Clinical Psychology, 42*(6), 774–780.
- Köhnken, G., Milne, R., Memon, A. y Bull, R. (1999). The cognitive interview: A meta-analysis. *Psychology, Crime & Law, 5*(1–2), 3–27.
- Korotitsch, W. J. y Nelson-Gray, R. O. (1999). An overview of self-monitoring research in assessment and treatment. *Psychological Assessment, 11*(4), 415–425.
- Lamiell, J. T. (1981). Toward an idiothetic psychology of personality. *American Psychologist, 36*(3), 276–289.
- Landis, J. R. y Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics, 33*(1), 159–174.
- Memon, A., Meissner, C. A. y Fraser, J. (2010). The cognitive interview: A meta-analytic review and study space analysis of the past 25 years. *Psychology, Public Policy, and Law, 16*(4), 340–372.
- Muñiz, J., Hernández, A. y Fernández-Hermida, J. R. (2020). Utilización de los tests en España: el punto de vista de los psicólogos. *Papeles del Psicólogo, 41*(1), 1–15.
- Muñiz, J., Hernández, A. y Ponsoda, V. (2015). Nuevas directrices sobre el uso de los tests: investigación, control de calidad y seguridad. *Papeles del Psicólogo, 36*(3), 161–173.
- Nelson, R. O. (1977). Assessment and therapeutic functions of self-monitoring. En M. Hersen, R. M. Eisler y P. M. Miller (Eds.), *Progress in behavior modification* (Vol. 5, pp. 263–308). Academic Press.
- Nisbett, R. E. y Wilson, T. D. (1977). Telling more than we can know: Verbal reports on mental processes. *Psychological Review, 84*(3), 231–259.
- Paulhus, D. L. (1984). Two-component models of socially desirable responding. *Journal of Personality and Social Psychology, 46*(3), 598–609.

- Powell, J., Martindale, A. y Kulp, S. (1975). An evaluation of time-sample measures of behavior. *Journal of Applied Behavior Analysis, 8*(4), 463–469.
- Rettew, D. C., Lynch, A. D., Achenbach, T. M., Dumenci, L. e Ivanova, M. Y. (2009). Meta-analyses of agreement between diagnoses made from clinical evaluations and standardized diagnostic interviews. *International Journal of Methods in Psychiatric Research, 18*(3), 169–184.
- Romanczyk, R. G., Kent, R. N., Diament, C. y O'Leary, K. D. (1973). Measuring the reliability of observational data: A reactive process. *Journal of Applied Behavior Analysis, 6*(1), 175–184.
- Sackett, P. R., Zhang, C., Berry, C. M. y Lievens, F. (2022). Revisiting meta-analytic estimates of validity in personnel selection: Addressing systematic overcorrection for restriction of range. *Journal of Applied Psychology, 107*(11), 2040–2068.
- Sanz, J., Navarro, M. E. y Vázquez, C. (2003). Adaptación española del Inventario para la Depresión de Beck-II (BDI-II): 1. Propiedades psicométricas en estudiantes universitarios. *Análisis y Modificación de Conducta, 29*(124), 239–288.
- Schmidt, F. L. y Hunter, J. E. (1998). The validity and utility of selection methods in personnel psychology. *Psychological Bulletin, 124*(2), 262–274.

Documentos institucionales

- CNMC (2026). *INF/CNMC/130/26. Informe sobre el proyecto de Código Deontológico de la Psicología*.
- Colegio Oficial de Psicólogos (1987, con modificaciones de 2010, 2014 y 2015). *Código Deontológico del Psicólogo*.
- International Test Commission (2017). *ITC guidelines for translating and adapting tests* (2.ª ed.).
- Reglamento (UE) 2016/679, General de Protección de Datos, y Ley Orgánica 3/2018, de Protección de Datos Personales y garantía de los derechos digitales.

Créditos de las ilustraciones

Las figuras con gráficos, esquemas y tablas son de **elaboración propia** de SAIMAP. Las que llevan la indicación «Esquema ilustrativo, no datos» representan la forma general de un modelo o de un resultado y no datos reales. Los casos numéricos de ejemplo están marcados como hipotéticos. Las cifras reales proceden de los estudios citados en el pie de cada figura.

Las fotografías y grabados históricos proceden de **Wikimedia Commons**. SAIMAP los ha reunido en tres láminas (figuras 2.1, 2.2 y 2.3), redimensionándolos; no se ha alterado su contenido.

Figura	Archivo original (Wikimedia Commons)	Autor	Licencia
2.1	Juan Huarte de San Juan (1603) Examen de ingenios para las sciencias.jpg	Portada de la edición de 1603	Dominio público
2.1	Esquirol (BM 1874,1114.672).jpg	Charles Louis Bazin (grabado, 1838); British Museum	Dominio público
2.1	Wundt-research-group.jpg	Autor desconocido (hacia 1880)	Dominio público
2.1	Hipp Chronoscope, c. 1890, view 1 - Museum of Science and Industry (Chicago) - DSC06506.JPG	Daderot	CC0 1.0
2.2	Sir Francis Galton, circa 1890.jpg	Graham's Art Studios	Dominio público
2.2	James McKeen Cattell.jpg	Bain News Service	Dominio público

Figura	Archivo original (Wikimedia Commons)	Autor	Licencia
2.2	Alfred Binet.jpg	Fotógrafo no identificado (siglo XIX)	Dominio público
2.2	WLStern.jpg	Autor desconocido (principios del siglo XX)	Dominio público
2.2	Lewis Madison Terman.jpg	Autor desconocido (1923)	Dominio público
2.3	American soldiers taking a predecessor of the Army Alpha - November 1917.jpg	Departamento de Guerra de EE. UU.	Dominio público
Resto de figuras	—	Elaboración propia (SAIMAP)	Libre uso educativo con atribución