Evaluación Psicológica II

Tests e instrumentos de evaluación · Temario SAIMAP

16 unidades sobre los instrumentos de evaluación: técnicas objetivas, subjetivas y proyectivas, inteligencia y aptitudes (Wechsler, Raven, DAT), personalidad normal y patológica (MMPI, MCMI, PAI, NEO, PID-5), evaluación neuropsicológica, intereses vocacionales, actitudes y salud. Con recuadros de consenso y debate, mitos, claves PIR y autoevaluación.

Grado · 2.º **16 unidades** **Ampliación PIR**

SAIMAP PSICOLOGÍA

Índice

Presentación **3**
Cómo está organizado 3
Criterios de rigor 3
Aviso 4

Capítulo 1 · Técnicas objetivas, subjetivas y proyectivas **5**
Unidad 1 · Técnicas objetivas y psicofisiológicas 5
Unidad 2 · Técnicas subjetivas 14
Unidad 3 · Técnicas proyectivas I: supuestos, Rorschach y TAT 21
Unidad 4 · Técnicas proyectivas II: gráficas, narrativas y evidencia 29

Capítulo 2 · Evaluación de la inteligencia y las aptitudes **35**
Unidad 5 · Concepto y teorías de la inteligencia 35
Unidad 6 · Historia de la medición de la inteligencia y efecto Flynn 42
Unidad 7 · Las escalas de Wechsler 49
Unidad 8 · Otros tests de inteligencia y tests de aptitudes 56

Capítulo 3 · Evaluación de la personalidad **62**
Unidad 9 · Los autoinformes de personalidad 62
Unidad 10 · Construcción de pruebas e inventarios clínicos 69
Unidad 11 · Modelos dimensionales de la personalidad normal y patológica 77

Capítulo 4 · Evaluación neuropsicológica **84**
Unidad 12 · Historia, objetivos y métodos de la evaluación neuropsicológica 84
Unidad 13 · Cribado, CI premórbido, validez de rendimiento y pruebas específicas 91

Capítulo 5 · Intereses vocacionales y actitudes **97**
Unidad 14 · Evaluación de los intereses vocacionales 97
Unidad 15 · Evaluación de actitudes 104

Capítulo 6 · Evaluación de la salud y la calidad de vida **111**
Unidad 16 · Evaluación en psicología de la salud 111

Apéndices **118**
Estudios y datos clave 118
Mitos y correcciones 119
Bibliografía 120
Créditos de las ilustraciones 122

Presentación

Versión 1.0 · noviembre de 2026

Este temario forma parte de **SAIMAP Psicología**, una plataforma de estudio para estudiantes de Psicología y para cualquier persona interesada en la disciplina. Cubre los contenidos de la asignatura de segundo curso *Evaluación Psicológica II* (en otros planes de estudio, *Técnicas de Evaluación Psicológica* o *Evaluación de constructos psicológicos*) y sirve de base a las unidades de la aplicación. Es el libro hermano de *Evaluación Psicológica I. Procesos, garantías y métodos*, que trata el proceso de evaluación, la ética, la fiabilidad y la validez, la entrevista, la observación y el autoinforme. Aquí se da por sabido ese marco y se pasa a los instrumentos concretos.

El texto es original y sigue el orden habitual de la asignatura:

- las técnicas objetivas, subjetivas y proyectivas;
- la evaluación de la inteligencia y las aptitudes;
- la personalidad normal y patológica;
- la evaluación neuropsicológica;
- los intereses vocacionales y las actitudes;
- la evaluación en psicología de la salud.

De cada instrumento se explica qué mide, cómo está construido, con qué población se usa y qué dice la evidencia sobre su fiabilidad y su validez.

El temario está actualizado a noviembre de 2026:

- la WAIS-5 (2024) y su adaptación española, todavía en curso;
- el MMPI-3 en español (2026);
- los modelos dimensionales de los trastornos de personalidad del DSM-5 y la CIE-11;
- la evidencia metaanalítica que matiza viejas certezas sobre el Rorschach, el efecto Flynn o el polígrafo.

Cómo está organizado

El temario tiene **6 capítulos y 16 unidades**. Cada unidad se divide en **4 apartados**, que corresponden a los 4 módulos de la unidad en la aplicación; el quinto módulo de la aplicación es el repaso.

Cada unidad incluye además:

- **Consenso y debate**: qué está establecido y qué sigue discutiéndose en la investigación actual.
- **Mito frecuente**: una idea popular errónea y su corrección.
- **Conceptos clave**: los términos que hay que dominar, con una definición breve.
- **Clave PIR**: qué contenidos suelen preguntarse en el examen de Psicólogo Interno Residente y qué trampas conviene evitar.
- **Autoevaluación**: cinco preguntas de tres opciones, con sus soluciones comentadas.

Criterios de rigor

- El contenido refleja el **consenso académico actual**. Cuando la ciencia no tiene una respuesta cerrada, se dice, y se presentan las posturas.

- Los datos técnicos de los tests (número de ítems, escalas, edades, adaptaciones españolas) proceden de sus manuales, de las editoriales y de las revisiones de la Comisión de Test del Colegio Oficial de la Psicología. Lo que no se ha podido confirmar no se incluye.
- **No se reproduce ningún ítem real ni ningún material protegido de los tests**, por respeto a los derechos de autor y a la seguridad de las pruebas. Los ejemplos de ítems, perfiles y puntuaciones son inventados y así se indica.
- Las cifras de los estudios son las publicadas por sus autores y se dan como aproximadas cuando así se citan en la literatura. Las figuras marcadas como esquema son ilustrativas.
- Los gráficos y esquemas son de elaboración propia. Las fotografías históricas proceden de Wikimedia Commons y llevan su atribución.
- Las fuentes principales están en la bibliografía final. No se incluye ninguna referencia que no se haya podido verificar.

Aviso

Este material tiene una finalidad exclusivamente educativa. No sustituye la evaluación ni el consejo de un profesional, y no capacita para aplicar ni interpretar los tests que describe, cuyo uso está reservado a profesionales cualificados. SAIMAP Psicología es un proyecto independiente y no está vinculado a ninguna universidad ni a ninguna editorial de tests.

Capítulo 1 · Técnicas objetivas, subjetivas y proyectivas

Antes de estudiar tests concretos conviene saber qué tipo de dato ofrece cada técnica: una respuesta fisiológica que la persona apenas controla, una descripción de sí misma o de su mundo, o una interpretación libre de un estímulo ambiguo. Este capítulo recorre esas tres familias. Empieza por las técnicas objetivas y psicofisiológicas, sigue con las subjetivas (listas de adjetivos, diferencial semántico y rejilla) y termina con las proyectivas y la evidencia sobre su validez.

Unidad 1 · Técnicas objetivas y psicofisiológicas

Objetivos: definir qué es una técnica objetiva y distinguirla de un test psicométrico; clasificar las técnicas objetivas en cognitivas, motoras y psicofisiológicas; describir los principales registros psicofisiológicos, lo que miden y sus límites; valorar las aplicaciones y la ética de estas técnicas, con especial atención al polígrafo.

1.1 Qué es una técnica objetiva

En evaluación psicológica, «objetivo» tiene un sentido técnico más estrecho que en el lenguaje corriente. Una **técnica objetiva** es una tarea estructurada en la que la persona evaluada desconoce qué se está midiendo o no puede modificar fácilmente su respuesta a voluntad, y cuyo resultado se registra y puntúa sin que intervenga el juicio del evaluador. Esta idea procede de la tradición de **Raymond B. Cattell**, que distinguió tres fuentes de datos sobre la personalidad:

Fuente	Qué recoge	Ejemplo
Datos L (*life*)	Registros de la vida real o valoraciones de observadores	Expediente académico, bajas laborales, informes de profesores
Datos Q (*questionnaire*)	Lo que la persona dice de sí misma	Un cuestionario de ansiedad
Datos T (*test*)	Conducta en una situación de prueba estandarizada y enmascarada	Tiempo de reacción, conductancia de la piel ante una imagen

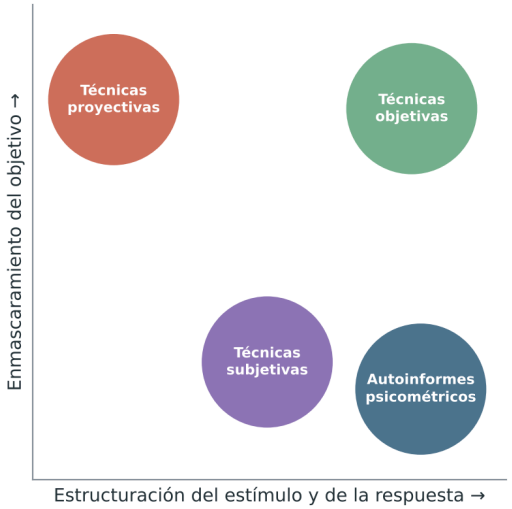
Las técnicas objetivas corresponden a los **datos T**. Es un error llamar «técnica objetiva» a cualquier test psicométrico. Un cuestionario de personalidad bien construido se corrige de forma objetiva, con una plantilla, pero su dato es lo que la persona decide contestar: es un dato Q y puede falsearse. La objetividad de la corrección no convierte un autoinforme en una técnica objetiva. Los autoinformes se estudian en *Evaluación Psicológica I* y en la Unidad 9.

Las técnicas objetivas comparten varios rasgos:

- **Estímulo y respuesta muy estructurados.** La tarea está definida al detalle y la respuesta posible es limitada, como pulsar una tecla.
- **Objetivo enmascarado.** La persona no sabe qué aspecto de su conducta interesa, o no puede controlarlo sin entrenamiento, como la sudoración de las manos.

- **Registro instrumental.** Aparatos o programas que miden con precisión, a menudo en milisegundos.
- **Independencia del evaluador.** El resultado es un número que no depende de quién aplique la prueba.

Como muestra la figura 1.1, estos dos criterios, la estructuración y el enmascaramiento, permiten situar las grandes familias de técnicas que recorre el capítulo.



Esquema ilustrativo, no datos

Figura 1.1. **Mapa de las técnicas de evaluación.** Las técnicas se sitúan según la estructuración del estímulo y de la respuesta y según el enmascaramiento del objetivo: las objetivas combinan estructuración alta y enmascaramiento alto; los autoinformes psicométricos, estructuración alta y enmascaramiento bajo; las subjetivas, estructuración media y enmascaramiento bajo; las proyectivas, estructuración baja y enmascaramiento alto. Elaboración propia.

Las técnicas objetivas nacieron en los laboratorios de psicología experimental del siglo XIX, que querían medir los procesos mentales con la misma precisión que la física medía el tiempo o la fuerza. Los aparatos de relojería para medir tiempos de reacción, como el de la figura 1.2, son sus antepasados directos.



Figura 1.2. **Cronoscopio de Hipp (hacia 1890).** Aparato de relojería que medía tiempos de reacción en milésimas de segundo, una de las primeras técnicas objetivas de laboratorio. Fuente: Daderot, Wikimedia Commons, CC0.

Hoy los cronómetros se han sustituido por ordenadores y sensores, pero la lógica es la misma. En una tarea de atención, el evaluado sabe que tiene que atender, pero no puede decidir cuántos milisegundos tarda ni cuánto se alarga su tiempo de reacción cuando se cansa. Ahora bien, el dato objetivo no dice por sí solo qué significa: un tiempo de reacción lento puede deberse a falta de atención, a lentitud motora, a un fármaco o a desinterés. La técnica objetiva reduce el sesgo de la medida, no la necesidad de interpretarla.

1.2 Clasificación funcional: técnicas cognitivas, motoras y psicofisiológicas

Según la función que evalúan, las técnicas objetivas se agrupan en tres categorías. La frontera no siempre es nítida: casi toda tarea cognitiva exige una respuesta motora, y muchas se combinan con registros fisiológicos.

Técnicas cognitivas. Se centran en la eficacia con que se percibe, se atiende, se retiene información, se frena una respuesta o se procesa con rapidez. Los instrumentos clásicos son el **taquistoscopio**, que presenta estímulos visuales durante tiempos muy breves y controlados, y las tareas de **tiempo de reacción**. Hoy predominan las tareas informatizadas: versiones del Stroop, tareas *go/no-go* (responder ante un estímulo e inhibir la respuesta ante otro), tareas *n-back* de memoria de trabajo o pruebas de atención sostenida. Muchas de ellas se usan en neuropsicología (Unidad 13).

Dentro de este grupo se incluyen también las medidas de **estilos cognitivos**, formas habituales de procesar la información que no son ni mejores ni peores en sí mismas:

- **Dependencia-independencia de campo** (Witkin). En el **Test de Figuras Enmascaradas** (EFT) hay que localizar una figura simple escondida dentro de otra compleja. Quien la encuentra deprisa se describe como independiente de campo: separa bien un elemento de su contexto.

- **Reflexividad-impulsividad** (Kagan). En el **MFF** (*Matching Familiar Figures*) hay que elegir, entre varias figuras casi idénticas, la que coincide con un modelo. Se registran la latencia de la primera respuesta y los errores. El estilo **reflexivo** combina latencias largas y pocos errores; el **impulsivo**, latencias cortas y muchos errores.

Técnicas motoras. Evalúan la rapidez, la precisión y la coordinación de los movimientos: el **tapping** (golpear una tecla tan rápido como se pueda), los tableros de **destreza manual** en los que se insertan piezas en orificios o las tareas de **seguimiento** de un objetivo en movimiento. Se usan en desarrollo, rehabilitación y valoración de efectos de fármacos o de la fatiga.

Técnicas psicofisiológicas. Registran respuestas del organismo (eléctricas, cardiovasculares, respiratorias) mientras la persona realiza una tarea o recibe estímulos controlados. Se clasifican según el sistema implicado:

Sistema	Respuestas registradas	Ejemplos de registro
Nervioso autónomo	Actividad electrodérmica, frecuencia cardiaca, presión arterial, temperatura periférica, pupila	Conductancia de la piel, ECG, pletismografía, pupilometría
Nervioso somático	Tensión muscular, movimientos oculares, respiración	EMG, electrooculografía, neumografía
Nervioso central	Actividad eléctrica cerebral espontánea y provocada	EEG, potenciales evocados

Conviene distinguir la **evaluación psicofisiológica** de la **psicología fisiológica**. En la primera, la variable que se manipula es psicológica (una imagen, una tarea, una pregunta) y se mide la respuesta fisiológica en personas, con procedimientos no invasivos. En la segunda, se manipula una variable biológica, por ejemplo con un fármaco o una lesión, y se observa su efecto en la conducta, a menudo en animales. Las bases biológicas de cada sistema se estudian en *Neuropsicología y Psicología Fisiológica*.

Un ejemplo combina las tres categorías. Una investigadora estudia cómo afecta la falta de sueño a los conductores. Mide el tiempo de reacción ante estímulos inesperados (cognitiva), la precisión al seguir una trayectoria con un volante (motora) y la frecuencia de parpadeo y la actividad cerebral (psicofisiológica). Ninguna medida depende de lo que el conductor diga sobre su cansancio, que es justo lo menos fiable tras muchas horas sin dormir.

1.3 Registros psicofisiológicos: qué miden y sus límites

Toda evaluación psicofisiológica combina dos elementos: un **registro** fiable de la señal biológica y una **situación psicológica** bien diseñada que permita relacionar los cambios de la señal con un proceso concreto. Sin el segundo elemento, el registro es solo fisiología. La figura 1.3 sitúa los registros más habituales.

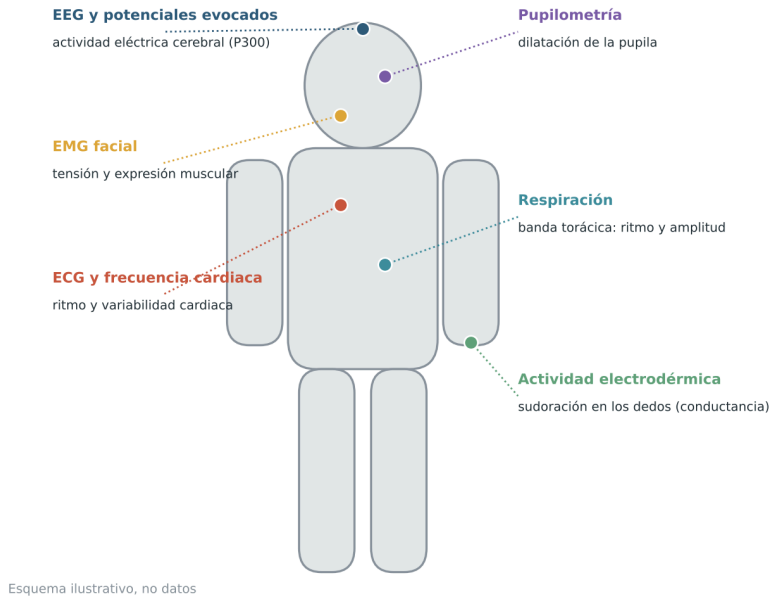


Figura 1.3. **Puntos de registro psicofisiológico.** EEG y potenciales evocados en el cuero cabelludo; pupilometría en el ojo; EMG en un músculo facial; ECG y frecuencia cardiaca en el tórax; respiración mediante una banda torácica; actividad electrodérmica en los dedos. Elaboración propia.

Como muestra la figura 1.3, cada sensor capta una señal distinta:

- **Actividad electrodérmica.** Las glándulas sudoríparas de las palmas y los dedos dependen del sistema simpático. Se registra el **nivel de conductancia** (tónico, ligado a la activación general) y las **respuestas** breves (fásicas) ante un estímulo nuevo o significativo, como la **respuesta de orientación**. Es la medida clásica de activación emocional.
- **Registros cardiovasculares.** Frecuencia cardiaca, presión arterial y **variabilidad de la frecuencia cardiaca**, que refleja el equilibrio entre la actividad simpática y la parasimpática.
- **Respiración.** Frecuencia y profundidad, registradas con una banda que detecta la expansión del tórax.
- **Electromiografía (EMG).** Actividad eléctrica de los músculos. Sirve para medir la tensión muscular y, en la cara, pequeñas contracciones que acompañan a las emociones aunque no se vean a simple vista.
- **EEG y potenciales evocados.** El EEG registra la actividad eléctrica cerebral espontánea. Los potenciales evocados son cambios ligados en el tiempo a un estímulo; el más conocido es la **P300**, una onda positiva que aparece hacia los 300 milisegundos ante estímulos infrecuentes o relevantes.
- **Pupilometría.** El diámetro de la pupila aumenta con la activación y con el esfuerzo mental.
- **Temperatura periférica.** Disminuye en los dedos con la activación simpática.

Estas técnicas tienen dos **ventajas** claras: son **difíciles de falsear**, porque la mayoría de estas respuestas no se controlan a voluntad sin entrenamiento, y permiten una **medida continua**, segundo a segundo, sin interrumpir lo que la persona está haciendo.

Sus **límites** son igual de importantes:

1. **Inespecificidad.** Una subida de la conductancia indica activación, pero no qué emoción ni por qué. El miedo, la sorpresa, la vergüenza o el interés pueden producir respuestas parecidas.
2. **Fraccionamiento direccional de la respuesta** (Lacey). Los distintos sistemas no siempre cambian en la misma dirección. Ante una tarea de atención al exterior, la conductancia puede subir mientras la frecuencia cardiaca baja. Por eso la «activación» no es un estado único que cualquier registro refleje por igual.
3. **Estereotipia individual de respuesta.** Cada persona tiende a responder con más intensidad en un sistema concreto: unas en el cardiovascular, otras en el muscular o en el electrodérmico. Un registro único puede pasar por alto la activación de quien responde por otra vía.

4. **Artefactos.** Movimientos, hablar, la temperatura de la sala o un sensor mal colocado alteran la señal.
5. **Coste y formación.** El equipo es caro y exige preparación específica.
6. **Validez ecológica limitada.** El laboratorio, con cables y sensores, no es la vida real.

Un ejemplo muestra la inespecificidad. Dos personas ven la imagen de una araña y ambas tienen una respuesta electrodérmica intensa. Una tiene fobia; la otra es bióloga y le ha llamado la atención una especie desconocida. El registro es casi idéntico; el significado, opuesto.

1.4 Aplicaciones, ética y el caso del polígrafo

Aplicaciones. Estas técnicas se usan sobre todo en investigación, pero tienen aplicaciones clínicas consolidadas:

- **Ansiedad y estrés**: reactividad ante estímulos temidos y su cambio tras el tratamiento.
- **Biofeedback**: devolver a la persona, en tiempo real, información sobre una señal (tensión muscular, temperatura) para que aprenda a modificarla, por ejemplo en cefaleas tensionales.
- **Sueño**: el registro conjunto de EEG, EMG y movimientos oculares identifica sus fases.
- **Dolor**, sobre todo cuando la persona no puede informar bien.

Ética. Que el dato sea difícil de falsear lo vuelve también delicado. Exige **consentimiento informado** (qué se registra, para qué y con qué molestias), **uso dentro del marco validado**, **protección de datos** (la información fisiológica puede constituir un dato de salud, categoría especial en el RGPD) e **interpretación integrada** con otras fuentes. La ética general del uso de tests se estudia en *Evaluación Psicológica I*.

El polígrafo. Es el ejemplo más conocido de técnica psicofisiológica y también el más malinterpretado. Como muestra la figura 1.4, registra varias respuestas autónomas a la vez.



Figura 1.4. **Polígrafo Keeler de mediados del siglo XX conservado por el FBI.** Registra la respiración (neumógrafo), la presión arterial (manguito) y la actividad electrodérmica sobre papel continuo. Fuente: Federal Bureau of Investigation, Wikimedia Commons; dominio público.

El polígrafo **no detecta mentiras**: detecta **activación**. Lo que se interpreta es si la persona se activa más ante unas preguntas que ante otras. Hay dos procedimientos principales:

Procedimiento	Lógica	Problema principal
Test de la pregunta de control	Compara las preguntas sobre el delito con otras de control, incómodas para casi todos	Un inocente nervioso puede activarse más ante las preguntas del delito
Test de información oculta (*Concealed Information Test*)	Comprueba si la persona reacciona ante detalles del hecho que solo conocería el autor	Requiere detalles que no se hayan difundido

El **test de información oculta** tiene más base científica, porque no depende de suponer que el culpable se pondrá más nervioso, sino de que reconoce lo que no debería conocer. El informe del National Research Council (NRC, 2003) concluyó que el polígrafo discrimina **por encima del azar** cuando se investiga un incidente concreto, pero que es **vulnerable a contramedidas** y produce **muchos falsos positivos** cuando se usa como cribado en poblaciones donde casi nadie es culpable.

La razón es la **tasa base**. Imagínese un cribado de 1.000 empleados en el que hay 10 culpables, con una prueba que acierta en el 85 % de los culpables y en el 85 % de los inocentes. Como muestra la figura 1.5, se detectarían unos 8 o 9 culpables, pero también se señalaría a unos 150 inocentes. De cada 100 personas que la prueba marca como sospechosas, solo unas 5 lo serían de verdad.



Figura 1.5. **El problema de la tasa base en un cribado con polígrafo.** Con 1.000 personas, 10 culpables y una sensibilidad y especificidad de 0,85, se identifican 8,5 culpables frente a 148,5 inocentes señalados: el valor predictivo positivo ronda el 5 %. Dato calculado sobre un caso hipotético. Elaboración propia.

Consenso y debate

Consenso: las técnicas objetivas reducen el sesgo del evaluador y son difíciles de falsear, pero sus datos no se interpretan solos. Los registros psicofisiológicos indican activación y son inespecíficos: no identifican una emoción concreta ni el motivo de la respuesta. El polígrafo discrimina por encima del azar en incidentes concretos, pero no es fiable como cribado con tasas base bajas (NRC, 2003).

Debate: cuánta validez ecológica tienen los registros de laboratorio y si los dispositivos portátiles la mejoran de verdad sin perder precisión. También se discute qué uso, si alguno, debe tener el polígrafo fuera de la investigación, y si el test de información oculta podría aplicarse con garantías en contextos reales.

Mito frecuente

Mito: «El polígrafo detecta cuándo alguien miente».

Realidad: el polígrafo registra activación autónoma, no engaño. Un inocente asustado puede activarse mucho y un culpable entrenado puede usar contramedidas. Su precisión supera el azar en incidentes concretos, pero en cribados con pocos culpables la mayoría de las personas señaladas son inocentes (National Research Council, 2003).

Conceptos clave

Concepto	Definición
Técnica objetiva	Tarea estructurada y enmascarada, difícil de falsear, cuyo resultado no depende del evaluador
Datos T	En Cattell, datos de conducta en una situación de prueba estandarizada; base de los tests objetivos
Dependencia de campo	Estilo cognitivo de dificultad para separar un elemento de su contexto (Witkin, EFT)
Reflexividad-impulsividad	Estilo cognitivo medido por latencia y errores en el MFF de Kagan
Actividad electrodérmica	Cambios en la conductancia de la piel por la sudoración; indicador de activación simpática
P300	Potencial evocado positivo hacia los 300 ms ante estímulos infrecuentes o relevantes
Fraccionamiento direccional	Cambio de los sistemas fisiológicos en direcciones distintas ante una misma situación (Lacey)
Estereotipia individual	Tendencia de cada persona a responder con más intensidad en un sistema fisiológico concreto

Clave PIR

Prioridad media. Se pregunta la definición de técnica objetiva, la clasificación de los registros por sistema nervioso, los estilos cognitivos con sus pruebas (EFT, MFF) y los límites de los registros psicofisiológicos, como el fraccionamiento direccional de Lacey. Trampa típica: confundir técnica objetiva con test psicométrico corregido con plantilla. Otra trampa es dar por hecho que el polígrafo detecta el engaño, o ignorar el efecto de la tasa base en los falsos positivos.

Autoevaluación

1. En la clasificación de Cattell, un cuestionario de personalidad corregido con plantilla proporciona…
a) datos T, porque su corrección es objetiva
b) datos Q, porque recoge lo que dice la persona
c) datos L, porque refleja su vida cotidiana

2. Un niño responde muy deprisa en el MFF y comete muchos errores. Su estilo cognitivo se describe como…
a) impulsivo
b) dependiente de campo
c) reflexivo

3. Ante una tarea de atención, la conductancia de la piel sube mientras la frecuencia cardiaca baja. Este fenómeno se denomina…
a) estereotipia individual de respuesta
b) respuesta de orientación tónica
c) fraccionamiento direccional de la respuesta

4. ¿Cuál es la principal limitación de la actividad electrodérmica como medida emocional?
a) Puede falsearse con facilidad a voluntad
b) Indica activación, pero no qué emoción la causa
c) Solo puede registrarse durante el sueño

5. En un cribado con polígrafo en una población con muy pocos culpables, lo esperable es que…
a) la mayoría de las personas señaladas sean inocentes
b) casi todos los señalados sean realmente culpables
c) no se produzca ningún falso positivo

Soluciones

1 b. La corrección objetiva no convierte un autoinforme en técnica objetiva: sigue siendo un dato Q. **2 a.** Latencias cortas con muchos errores definen el estilo impulsivo. **3 c.** Lacey mostró que los sistemas pueden cambiar en direcciones opuestas. **4 b.** Es un índice de activación inespecífico. **5 a.** Con una tasa base baja, los falsos positivos superan con mucho a los aciertos.

Unidad 2 · Técnicas subjetivas

Objetivos: describir las características que definen las técnicas subjetivas y su lugar entre los métodos de evaluación; conocer las listas de adjetivos y sus usos; explicar el diferencial semántico de Osgood y sus tres factores; describir la técnica de rejilla de Kelly, su aplicación y sus principales índices.

2.1 Características de las técnicas subjetivas

Las **técnicas subjetivas** son procedimientos en los que la persona describe, califica o clasifica a sí misma, a otras personas, objetos o conceptos a partir de su propia experiencia. Lo que interesa no es tanto si la descripción es exacta como **el significado** que la persona atribuye a lo que describe. En el mapa de la figura 1.1 ocupan una posición intermedia: el material está más abierto que en un autoinforme psicométrico, pero menos que en una técnica proyectiva, y el objetivo no está enmascarado.

Sus rasgos principales son:

- **Material semiestructurado.** El evaluador fija el formato (una lista, unas escalas, una matriz), pero el contenido puede ser elegido o generado en parte por la persona. En la rejilla de Kelly, por ejemplo, la persona produce sus propios criterios de comparación.
- **Objetivo no enmascarado.** La persona sabe qué se le pregunta. Por eso la respuesta es **voluntaria** y puede falsearse, igual que en un autoinforme.
- **Fuente de la información.** Puede ser la propia persona o un informante cercano: un familiar, un docente, una pareja.
- **Interpretación idiográfica.** El objetivo principal es comprender cómo organiza su experiencia esa persona concreta, aunque algunas técnicas disponen también de normas para comparar con un grupo.
- **Análisis cualitativo y cuantitativo.** Los resultados pueden leerse como un mapa de significados o tratarse con estadísticos: distancias, correlaciones, componentes principales.

Rasgo	Autoinforme psicométrico	Técnica subjetiva
Material	Ítems cerrados, iguales para todos	Semiestructurado, a veces generado por la persona
Interpretación	Nomotética: comparación con normas	Sobre todo idiográfica
Objetivo	Medir un rasgo o síntoma definido de antemano	Conocer el significado personal de la experiencia
Ejemplo	Cuestionario de ansiedad	Rejilla de constructos personales

Ventajas. Dan acceso directo al mundo de significados de la persona, se adaptan a preguntas muy distintas y sirven para evaluar el **cambio**, porque pueden repetirse antes y después de una intervención.

Limitaciones. Al no estar enmascaradas, están expuestas a la **deseabilidad social** y a otros sesgos de respuesta (*Evaluación Psicológica I*). Muchas versiones se construyen *ad hoc* y carecen de normas, lo que dificulta comparar personas.

Un ejemplo: una pareja acude a consulta porque «no se entienden». Cada miembro describe con una misma lista de adjetivos cómo se ve, cómo ve al otro y cómo cree que el otro le ve. Las diferencias orientan la intervención: él se ve «tranquilo» y ella le ve «distante»; ella se ve «implicada» y él la ve «controladora».

Una técnica afín: el Q-sort. En el **Q-sort** (Stephenson, 1953) la persona ordena un conjunto de tarjetas con enunciados descriptivos en varias pilas, desde «muy característico de mí» hasta «nada característico de mí», con un número fijo de tarjetas en cada pila, que reproduce una distribución aproximadamente normal. Como cada

enunciado se sitúa en relación con los demás, la medida es **ipsativa**: indica qué rasgos pesan más dentro de la persona, no cuánto tiene de cada rasgo comparada con otras. Se usó, por ejemplo, para estudiar la distancia entre el yo real y el yo ideal en la terapia centrada en el cliente.

2.2 Listas de adjetivos

Las **listas de adjetivos** presentan un conjunto de adjetivos para que la persona indique cuáles se aplican a ella, a otra persona, a un objeto o a una situación. Son la técnica subjetiva más sencilla y una de las más antiguas.

Hay dos formatos de respuesta:

- **Lista de marcado** (*checklist*): se marcan los adjetivos que describen al objeto evaluado y se dejan en blanco los demás.
- **Escala de valoración**: cada adjetivo se puntúa según el grado en que se aplica, por ejemplo de 1 a 5.

La **consigna** permite medir cosas distintas con el mismo material. «Marque los adjetivos que describen cómo es usted en general» apunta a **rasgos**; «marque los que describen cómo se siente hoy» apunta a **estados**. Lo mismo puede pedirse sobre otra persona, sobre el yo ideal o sobre cómo cree uno que le ven los demás.

Dos instrumentos clásicos son:

Instrumento	Autores	Características
ACL (*Adjective Check List*)	Gough y Heilbrun (1965)	300 adjetivos; se marcan los que describen a la persona; varias escalas de personalidad
MAACL (*Multiple Affect Adjective Check List*)	Zuckerman y Lubin (1965)	Lista de adjetivos de estados afectivos como ansiedad, depresión y hostilidad

La **ACL** contiene 300 adjetivos de uso común (como «activo», «desconfiado», «generoso») y se puntúa en escalas que agrupan los adjetivos relacionados con distintas características de personalidad. Uno de sus problemas, común a toda lista de marcado, es que **el número de adjetivos marcados** influye en las puntuaciones: quien marca muchos tiende a puntuar más alto en casi todas las escalas. Por eso la propia ACL tiene en cuenta el total de adjetivos marcados al interpretar el perfil.

Las listas de adjetivos de **estado de ánimo** se usan mucho en investigación y en psicología de la salud y del deporte, porque son breves y pueden repetirse con frecuencia para seguir los cambios del estado afectivo. En psicología del deporte se ha usado mucho el POMS (*Profile of Mood States*; McNair, Lorr y Droppleman, 1971), con escalas de tensión-ansiedad, depresión, cólera-hostilidad, vigor, fatiga y confusión.

Ventajas. Son rápidas, fáciles de entender y aplicables a casi cualquier persona con un vocabulario básico. Se adaptan a distintos objetos de evaluación y a distintos momentos, y permiten comparar perspectivas: autodescripción y heterodescripción, yo actual y yo ideal.

Limitaciones. Son muy transparentes y, por tanto, sensibles a la **deseabilidad social**: pocos se marcan «egoísta» o «perezoso». Están expuestas a la **aquiescencia** y a estilos de respuesta como marcar mucho o marcar poco. El significado de un adjetivo puede variar entre personas: «exigente» es un elogio para unos y una crítica para otros. Además, un adjetivo aislado ofrece poco contexto sobre cuándo y con quién se manifiesta la característica.

Un minicaso: un servicio de rehabilitación cardiaca pide a sus pacientes que marquen cada semana, en una lista breve, cómo se sienten («cansado», «animado», «preocupado»…). En pocas semanas los adjetivos de preocupación disminuyen y los de vigor aumentan, salvo en un paciente cuya lista no cambia. Ese dato no diagnostica nada, pero señala a quién conviene evaluar con más detalle.

2.3 El diferencial semántico de Osgood

El **diferencial semántico** fue desarrollado por Osgood, Suci y Tannenbaum (1957) para medir el **significado connotativo** de los conceptos: no lo que una palabra designa, que es su significado denotativo, sino lo que evoca en cada persona. «Hospital» designa lo mismo para todos, pero para un médico puede ser «activo» y «útil», y para quien perdió allí a un familiar, «frío» y «triste».

Procedimiento. Se presenta un concepto (por ejemplo, «Mi trabajo», «Mi madre», «La universidad», «Yo mismo») y debajo una serie de **escalas bipolares** de **siete puntos**, cada una con un adjetivo en un extremo y su opuesto en el otro. La persona marca el punto que mejor refleja lo que el concepto significa para ella. El centro de la escala indica neutralidad o que ninguno de los dos adjetivos se aplica.

Un error frecuente es confundir el diferencial semántico con una **escala Likert**. En una escala Likert se valora el grado de acuerdo con un enunciado («Mi trabajo me gusta»: de «totalmente en desacuerdo» a «totalmente de acuerdo»). En el diferencial semántico no hay enunciado: hay un concepto y **dos adjetivos opuestos** en los extremos. Las escalas Likert se estudian en la Unidad 15.

Los tres factores. Al aplicar muchas escalas a muchos conceptos y analizar las respuestas con análisis factorial, Osgood y sus colaboradores encontraron que la mayor parte de la variación se explicaba con tres dimensiones, conocidas por sus iniciales como **EPA**:

Factor	Qué recoge	Pares de adjetivos típicos
Evaluación	Valoración positiva o negativa	Bueno-malo, agradable-desagradable, útil-inútil
Potencia	Fuerza o intensidad atribuida	Fuerte-débil, grande-pequeño, pesado-ligero
Actividad	Dinamismo o movimiento	Activo-pasivo, rápido-lento, vivo-apagado

La **evaluación** es el factor que más peso tiene. Por eso el diferencial semántico se ha usado mucho para medir **actitudes**: la puntuación en las escalas evaluativas expresa cuánto agrada o desagrada un objeto. Las actitudes se tratan en *Psicología Social* y en la Unidad 15.

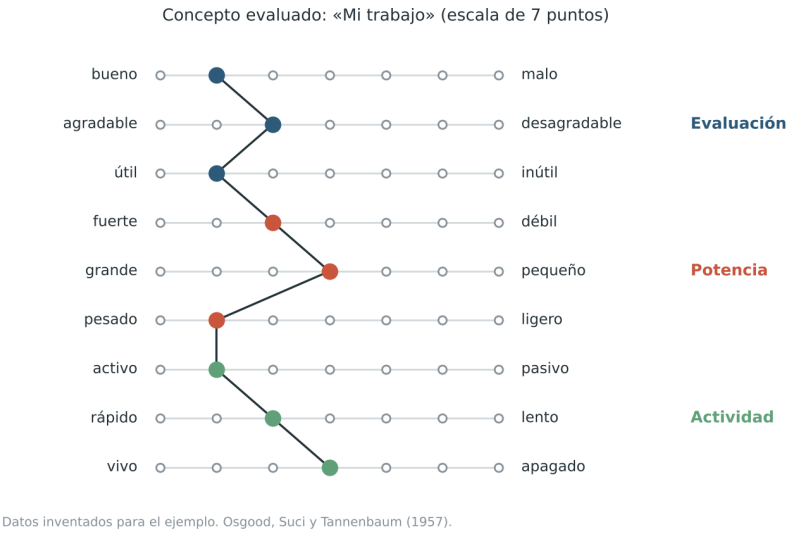


Figura 2.1. **Perfil de un concepto en el diferencial semántico.** El concepto «Mi trabajo» se puntúa en nueve pares bipolares de siete puntos agrupados en evaluación (bueno-malo, agradable-desagradable, útil-inútil), potencia (fuerte-débil, grande-pequeño, pesado-ligero) y actividad (activo-pasivo, rápido-lento, vivo-apagado). Datos inventados. Elaboración propia.

Como muestra la figura 2.1, el resultado es un **perfil**: la línea que une las puntuaciones de un concepto en todas las escalas. En el ejemplo, la persona valora su trabajo como útil y activo, pero también como pesado y poco agradable: un perfil que podría encajar con alguien implicado pero sobrecargado.

Análisis. Los resultados pueden analizarse de varias formas:

- Calcular la puntuación media de cada concepto en cada factor.
- Comparar **perfiles** entre conceptos («Yo» frente a «Yo ideal»), entre personas o entre momentos, por ejemplo antes y después de una terapia.
- Calcular la **distancia** entre dos conceptos a partir de las diferencias en todas las escalas: cuanto menor es, más parecido es su significado para esa persona.

Aplicaciones. Se usa para evaluar el **autoconcepto** (distancia entre el yo actual y el ideal), las actitudes hacia grupos o instituciones, el significado de la enfermedad para un paciente y los cambios tras una intervención. Su ventaja es la versatilidad; su exigencia, elegir pares de adjetivos que tengan sentido para cada concepto: «rápido-lento» encaja con «Mi trabajo», pero menos con «La justicia».

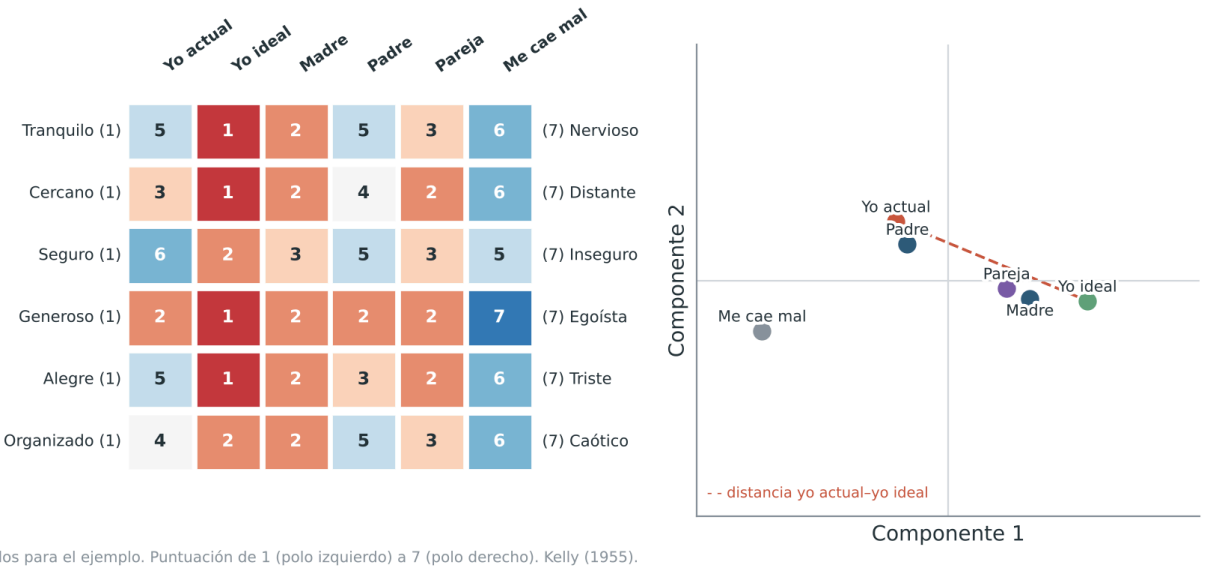
2.4 La técnica de rejilla de Kelly

La **técnica de rejilla** procede de la **teoría de los constructos personales** de George A. Kelly (1955). Kelly propuso que cada persona actúa como un **científico**: interpreta lo que le ocurre mediante un sistema propio de categorías, los **constructos personales**, y los pone a prueba para anticipar los acontecimientos. Un constructo es siempre **bipolar**: alguien que ve a los demás como «cercanos o distantes» organiza su experiencia de forma distinta de quien los ve como «fiables o interesados». La teoría se estudia en *Psicología de la Personalidad*; aquí interesa su técnica de evaluación.

Procedimiento. La rejilla tiene tres componentes:

1. **Elementos.** Lo que se va a comparar. En la versión clínica habitual son personas significativas (madre, padre, pareja, alguien que cae mal) y el **yo actual** y el **yo ideal**.
2. **Constructos.** Se obtienen de la propia persona, por lo general con el **método de las tríadas**: se presentan tres elementos y se pregunta en qué se parecen dos de ellos y se diferencian del tercero. Si la respuesta es «mi madre y mi pareja son cariñosas, mi padre es frío», se obtiene el constructo «cariñoso-frío». Se repite con otras tríadas hasta reunir un conjunto de constructos.
3. **Puntuaciones.** La persona valora cada elemento en cada constructo, por ejemplo de 1 a 7. El resultado es una **matriz** de elementos por constructos.

Lo característico de la rejilla es que combina un **contenido idiográfico**, los constructos son de la persona y no del evaluador, con un **formato cuantificable** que permite análisis estadísticos.



Datos inventados para el ejemplo. Puntuación de 1 (polo izquierdo) a 7 (polo derecho). Kelly (1955).

Figura 2.2. **Rejilla de constructos personales y su representación gráfica.** A la izquierda, seis elementos (yo actual, yo ideal, madre, padre, pareja y persona que me cae mal) puntuados de 1 a 7 en seis constructos bipolares; a la derecha, los elementos situados en el espacio de los dos primeros componentes, con la distancia entre el yo actual y el yo ideal destacada. Datos inventados. Elaboración propia.

Análisis. Como muestra la figura 2.2, la matriz se analiza con **correlaciones** entre constructos (qué constructos van juntos en la mente de la persona) y con **componentes principales**, que sitúan elementos y constructos en un espacio de pocas dimensiones. De ahí se obtienen varios **índices**:

Índice	Qué indica
Diferenciación cognitiva o complejidad	Si la persona usa muchas dimensiones distintas o casi todo se reduce a una sola
Polarización	Proporción de puntuaciones extremas, ligada a una visión rígida en blanco y negro
Distancia yo actual–yo ideal	Grado de insatisfacción con uno mismo, un indicador de autoestima
Dilemas implicativos	Conflictos en los que un cambio deseado arrastra otro no deseado

Los **dilemas implicativos**, desarrollados en España por Feixas y Saúl, ayudan a entender por qué alguien no cambia aunque quiera. Un joven con fobia social quiere pasar de «tímido» a «sociable», pero para él «sociable» va unido a «superficial», y valora mucho ser «profundo». Cambiar el síntoma amenaza su identidad.

Aplicaciones y límites. La rejilla se usa en **psicoterapia**, sobre todo constructivista, para describir con qué dimensiones interpreta la persona sus relaciones y comprobar si cambian con el tratamiento, y en **orientación vocacional**, con profesiones como elementos. Su aplicación es larga, exige que la persona verbalice sus constructos y dificulta la comparación entre personas, porque cada rejilla tiene constructos distintos.

Consenso y debate

Consenso: las técnicas subjetivas permiten conocer el significado personal que alguien atribuye a sí mismo, a los demás y a los conceptos de su mundo, y pueden analizarse de forma cualitativa y cuantitativa. El diferencial semántico se organiza en tres factores (evaluación, potencia y actividad), con la evaluación como el de más peso (Osgood et al., 1957). La rejilla combina constructos generados por la persona con análisis estadísticos (Kelly, 1955).

Debate: cómo comparar personas cuando los constructos o las escalas cambian de un caso a otro, y qué garantías psicométricas exigir a instrumentos construidos *ad hoc*. También se discute hasta qué punto controlar la deseabilidad social en técnicas cuyo objetivo es transparente.

Mito frecuente

Mito: «Las técnicas subjetivas son pura opinión y no pueden analizarse de forma cuantitativa».

Realidad: el diferencial semántico se basa en escalas numéricas y su estructura de tres factores se obtuvo con análisis factorial (Osgood et al., 1957). La rejilla de Kelly (1955) se analiza con correlaciones y componentes principales, y da índices como la polarización o la distancia entre el yo actual y el ideal. Lo subjetivo es el contenido, no la falta de rigor en el análisis.

Conceptos clave

Concepto	Definición
Técnica subjetiva	Procedimiento en que la persona describe o califica su experiencia con material semiestructurado
Lista de adjetivos	Conjunto de adjetivos que se marcan o puntúan según se apliquen al objeto evaluado
ACL	Lista de 300 adjetivos para describir la personalidad (Gough y Heilbrun, 1965)
Diferencial semántico	Escalas bipolares de 7 puntos para medir el significado connotativo (Osgood et al., 1957)
Factores EPA	Evaluación, potencia y actividad: las tres dimensiones del diferencial semántico
Constructo personal	Dimensión bipolar con la que una persona interpreta y anticipa su experiencia (Kelly, 1955)
Método de las tríadas	Obtención de constructos preguntando en qué se parecen dos elementos y difieren del tercero
Dilema implicativo	Conflicto en que el cambio deseado en un constructo implica otro no deseado (Feixas y Saúl)

Clave PIR

Prioridad baja. Cuando aparece, se pregunta por los tres factores del diferencial semántico, por el autor de cada técnica y por el procedimiento de la rejilla (método de las tríadas, elementos y constructos, análisis de componentes principales). Trampa típica: confundir el diferencial semántico con una escala Likert. También se confunde a veces «potencia» con «actividad», o se olvida que en la rejilla los constructos los aporta la persona y no el evaluador.

Autoevaluación

1. ¿Qué rasgo caracteriza a las técnicas subjetivas frente a las proyectivas?
a) El estímulo es ambiguo y el objetivo está enmascarado
b) El material es semiestructurado y el objetivo no está enmascarado
c) La respuesta se registra con instrumentos fisiológicos

2. El par «fuerte-débil» del diferencial semántico pertenece al factor de…
a) evaluación
b) actividad
c) potencia

3. En la técnica de rejilla, el método de las tríadas sirve para…
a) obtener los constructos de la propia persona
b) calcular la distancia entre yo actual e ideal
c) elegir los elementos que se van a comparar

4. En una lista de marcado como la ACL, una fuente de sesgo conocida es…
a) el número de láminas presentadas en la sesión
b) el número total de adjetivos que marca la persona
c) el tiempo que tarda en comenzar a responder

5. Una persona quiere dejar de ser «dependiente», pero asocia «independiente» con «frío», algo que rechaza. En la rejilla, esto es un…
a) índice de polarización
b) dilema implicativo
c) constructo de diferenciación

Soluciones

1 b. Las proyectivas usan estímulos ambiguos y enmascaran el objetivo; las subjetivas, no. **2 c.** La potencia recoge la fuerza atribuida; la actividad, el dinamismo. **3 a.** Comparar tres elementos permite que la persona genere sus propios constructos. **4 b.** Quien marca muchos adjetivos tiende a puntuar alto en casi todas las escalas. **5 b.** El cambio deseado en un constructo arrastra un cambio no deseado en otro.

Unidad 3 · Técnicas proyectivas I: supuestos, Rorschach y TAT

Objetivos: explicar la hipótesis proyectiva y los supuestos que comparten las técnicas proyectivas; clasificar las técnicas según el esquema de Lindzey; describir el material, la administración y la codificación del Rorschach; comparar el Sistema Comprehensivo de Exner con el R-PAS; describir el TAT, su administración y sus formas de análisis.

3.1 La hipótesis proyectiva y la clasificación de las técnicas

En psicoanálisis, la **proyección** es un mecanismo de defensa: se atribuyen a otros deseos o impulsos propios que no se aceptan. Las técnicas proyectivas toman la palabra en un sentido más amplio. Lawrence K. Frank (1939) llamó **métodos proyectivos** a los procedimientos en los que la persona, ante un material poco definido, tiene que organizarlo a su manera, y en esa organización se expresaría su forma de percibir, sentir y pensar. Es la **hipótesis proyectiva**: cuanto menos estructurado está el estímulo, más depende la respuesta de quien responde y menos del material.

Una comparación cotidiana ayuda a entenderla. Si se pide a alguien que describa una foto nítida de una cocina, casi todo el mundo dirá lo mismo. Si se le pide que cuente qué ve en una mancha de humedad del techo, las respuestas variarán mucho, y esa variación es lo que interesa al evaluador.

De la hipótesis se derivan cuatro **supuestos** compartidos:

- **Estímulo ambiguo.** El material (manchas, escenas, frases a medias, una hoja en blanco) admite muchas lecturas.
- **Respuesta libre.** No hay opciones cerradas ni respuestas correctas; la persona dice, dibuja o construye lo que quiere.
- **Objetivo enmascarado.** La persona no sabe bien qué se va a valorar, lo que en teoría dificulta el falseamiento.
- **Interpretación global.** El resultado se analiza como un todo, de forma **idiográfica**, buscando la organización de la personalidad más que puntuaciones aisladas.

En el plano de las técnicas presentado en la Unidad 1, las proyectivas ocupan el extremo de baja estructuración del estímulo y alto enmascaramiento del objetivo. Frente a ellas, los autoinformes psicométricos son estructurados y transparentes.

La clasificación de Lindzey. Gardner Lindzey (1959) ordenó las técnicas según el tipo de respuesta que piden, no según el material. Es la clasificación más citada.

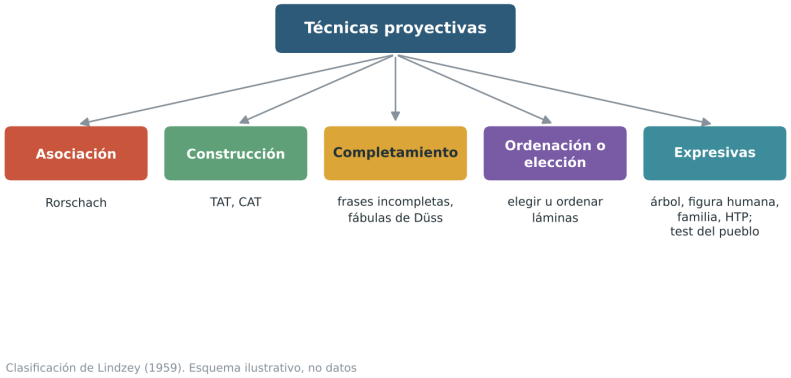


Figura 3.1. **Clasificación de las técnicas proyectivas de Lindzey (1959).** Cinco familias según la respuesta que se pide: asociación (Rorschach), construcción (TAT, CAT), completamiento (frases incompletas, fábulas de Düss), ordenación o elección y expresivas (dibujos del árbol, la figura humana, la familia y el HTP; test del pueblo). Elaboración propia.

Como muestra la figura 3.1, las cinco familias son:

Familia	Qué se pide	Ejemplos
Asociación	Decir lo primero que evoca un estímulo	Rorschach
Construcción	Crear un producto completo, por lo general una historia	TAT, CAT
Completamiento	Terminar algo que se da empezado	Frases incompletas, fábulas de Düss
Ordenación o elección	Ordenar o escoger estímulos según una preferencia	Test de Szondi, hoy en desuso
Expresivas	Dibujar, jugar o construir con materiales	Árbol, figura humana, familia, HTP, test del pueblo

Las fronteras no son nítidas: el test del pueblo entra en las expresivas porque Lindzey incluye en ellas el juego y la construcción con objetos. Muchos manuales en español usan otra clasificación, también de cinco grupos: técnicas **estructurales** (Rorschach), **temáticas** (TAT), **expresivas** (dibujos), **constructivas** (test del pueblo) y **asociativas** (frases incompletas, fábulas). Conviene reconocer ambas y no mezclar sus etiquetas: el Rorschach es «de asociación» para Lindzey y «estructural» en la otra clasificación.

Nacidas en la psicología dinámica, las proyectivas deben cumplir, como cualquier test, las garantías de administración estandarizada, codificación fiable, normas y validez (Evaluación Psicológica I). La Unidad 4 resume cómo han salido de ese examen.

3.2 El test de Rorschach: material y administración

Hermann Rorschach, psiquiatra suizo, publicó en 1921 *Psychodiagnostik*, donde presentaba su prueba de interpretación de formas fortuitas. La concibió más como una tarea **perceptiva** que como una ventana al inconsciente: le interesaba cómo organiza cada persona un estímulo ambiguo. La lectura psicoanalítica llegó después, de la mano de sus continuadores.

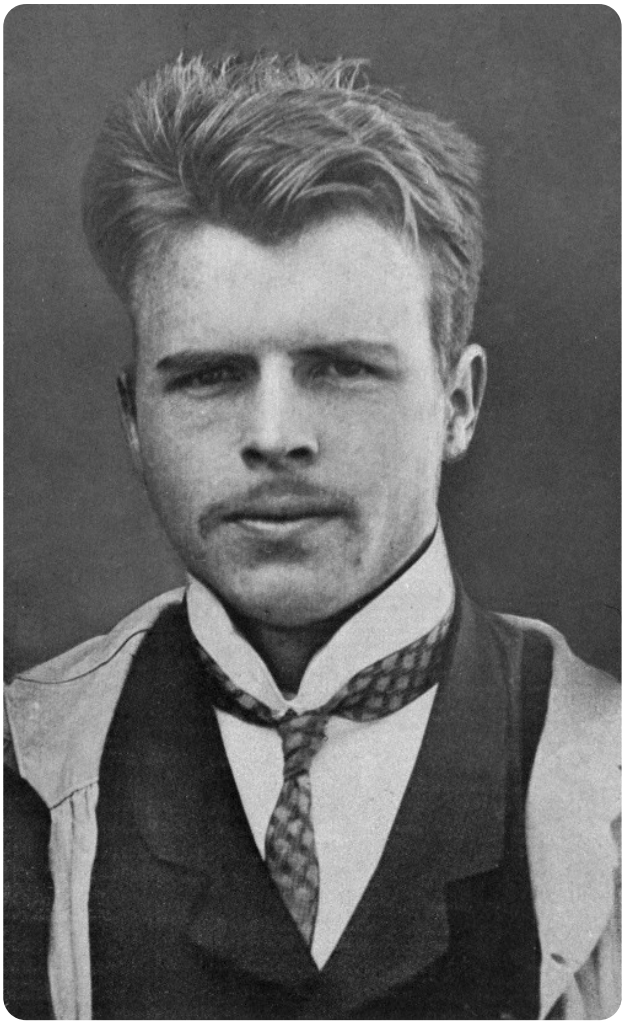


Figura 3.2. **Hermann Rorschach (hacia 1910).** Por ética profesional y para proteger la seguridad del test, este libro no reproduce ninguna de sus láminas. Fuente: Wikimedia Commons; dominio público.

El material. El test consta de **10 láminas** con manchas de tinta simétricas, que se presentan siempre en el mismo orden:

Grupo	Láminas	Rasgo
Acromáticas	I, IV, V, VI y VII	Negro y grises
Bicolores	II y III	Negro y rojo
Cromáticas	VIII, IX y X	Varios colores

Las láminas son de dominio público por antigüedad y circulan por internet, pero la ética profesional pide no difundirlas ni comentar sus respuestas habituales: si una persona llega a la evaluación con las respuestas aprendidas, el test pierde su valor.

La administración tiene dos fases:

1. **Respuesta libre** (o asociación). El evaluador entrega las láminas una a una y pregunta qué podría ser aquello. La persona puede dar tantas respuestas como quiera y girar la lámina. El evaluador anota **literalmente** cada respuesta, el tiempo que tarda y la posición de la lámina, sin comentar ni orientar.
2. **Indagación** (o encuesta). Terminadas las diez láminas, el evaluador vuelve a cada respuesta, la lee en voz alta y pide a la persona que muestre **dónde** la vio y **qué** le hizo verla así. No se trata de obtener respuestas nuevas, sino de reunir la información necesaria para codificar las que ya se dieron.

La indagación exige mucha pericia. Una pregunta sugerente («¿le ha influido el color?») contamina el protocolo, porque la persona puede aceptar algo en lo que no había pensado. Por eso los sistemas modernos fijan qué preguntas se permiten. En el Sistema Comprehensivo, además, evaluador y evaluado se sientan uno al lado del otro y no frente a frente, para reducir la influencia de los gestos del evaluador.

Un ejemplo con una mancha inventada: alguien dice «un mapa» y, en la indagación, explica que lo ve en toda la mancha por sus bordes recortados, como una costa. Con eso el evaluador puede codificar la localización y el rasgo que determinó la respuesta.

El Rorschach requiere entrenamiento supervisado en administración y codificación, y su aplicación completa lleva varias horas de trabajo profesional, un coste que hay que sopesar frente a lo que añade al caso. Durante décadas, además, se aplicó con procedimientos distintos según la escuela, lo que impedía comparar resultados, como se ve en el apartado siguiente.

3.3 Del Sistema Comprehensivo de Exner al R-PAS

La codificación. Cada respuesta se traduce a un conjunto de códigos. Las categorías básicas, comunes a casi todos los sistemas, son:

- **Localización**: qué parte de la mancha se usa (toda la mancha, un detalle frecuente, un detalle inusual o el espacio en blanco).
- **Determinantes**: qué rasgo del estímulo produce la respuesta: la **forma**, el **color**, el **sombreado** o el **movimiento** que la persona atribuye a lo que ve.
- **Contenido**: qué se ve (figuras humanas, animales, objetos, anatomía, naturaleza…).
- **Populares**: respuestas muy frecuentes en la población de referencia en una lámina concreta.
- **Calidad formal**: grado en que lo que se describe se ajusta a la forma real de la mancha.

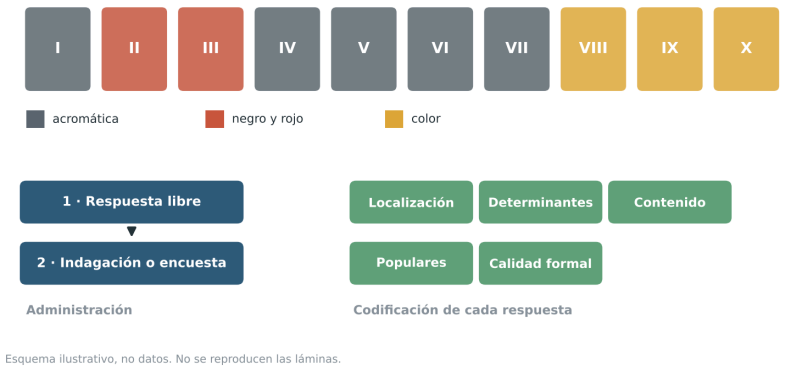


Figura 3.3. **Estructura del Rorschach.** Las diez láminas agrupadas en acromáticas (I, IV, V, VI y VII), negro y rojo (II y III) y color (VIII, IX y X); las dos fases de administración, respuesta libre e indagación, y las cinco categorías de codificación: localización, determinantes, contenido, populares y calidad formal. Esquema sin reproducción de láminas. Elaboración propia.

Como muestra la figura 3.3, la codificación conecta la administración con la interpretación. Los códigos se cuentan y se combinan en proporciones e índices, y estos se comparan con normas.

Los sistemas previos. Tras la muerte prematura de Rorschach, el test se extendió en Estados Unidos de la mano de cinco autores con sistemas propios: **Beck**, **Klopfer**, **Hertz**, **Piotrowski** y **Rapaport**. Cada uno administraba y codificaba a su manera, de modo que un mismo protocolo podía recibir interpretaciones distintas según la escuela del evaluador.

El Sistema Comprehensivo. John E. Exner (1974) revisó los cinco sistemas y se quedó con los códigos que mostraban mejor acuerdo entre evaluadores y más apoyo empírico. El resultado, el **Sistema Comprehensivo**

(SC), unificó la administración y la codificación y aportó normas. Durante décadas fue el estándar internacional, también en España, y permitió acumular investigación comparable por primera vez.

Pero el SC recibió críticas serias:

- **Normas que sobrepatologizaban.** Con las normas del SC, muchas personas sin trastorno aparecían como alteradas (Wood et al., 2001).
- **Número de respuestas muy variable.** Unas personas daban pocas respuestas y otras muchísimas, y como muchos índices dependen de ese número, la variabilidad complicaba la interpretación.
- **Variables con poco apoyo.** No todos los índices del sistema se habían validado de forma independiente.

El R-PAS. Tras la muerte de Exner, un grupo de investigadores de su entorno publicó el **R-PAS** (*Rorschach Performance Assessment System*; Meyer, Viglione, Mihura, Erard y Erdberg, 2011). Sus tres cambios principales son:

1. **Administración «R-optimizada»**: se pide a la persona que dé **dos o tres respuestas por lámina**, lo que reduce la variabilidad del número total de respuestas.
2. **Selección de variables por su apoyo empírico**: se conservan las que mostraron validez en el metaanálisis de Mihura, Meyer, Dumitrascu y Bombel (2013), que se verá en la Unidad 4, y se relegan o eliminan las demás.
3. **Normas internacionales**, elaboradas con muestras de varios países, que corrigen el sesgo patologizante.

El nombre refleja un cambio de enfoque: el Rorschach se presenta como una **tarea de rendimiento**, en la que se observa cómo resuelve la persona un problema perceptivo, idea más cercana a la intención original de Rorschach que a la tradición psicoanalítica.

Rasgo	Sistema Comprehensivo	R-PAS
Autoría y año	Exner, 1974	Meyer et al., 2011
Número de respuestas	Libre	Dos o tres por lámina
Criterio para incluir variables	Integración de los sistemas previos	Apoyo empírico metaanalítico
Normas	Estadounidenses, con tendencia a sobrepatologizar	Internacionales

3.4 El Test de Apercepción Temática (TAT)

El **Test de Apercepción Temática** (TAT) fue creado en la Clínica Psicológica de Harvard por **Christiana D. Morgan y Henry A. Murray** (1935), y la versión definitiva de las láminas se publicó en 1943. La autoría compartida es un dato de examen: durante años se atribuyó el test solo a Murray. **Apercepción** significa que lo percibido se interpreta a la luz de la experiencia previa: dos personas ante la misma escena la «leen» de forma distinta.

El material. Son **31 láminas**: 30 con escenas en blanco y negro, de ambigüedad variable, y **una en blanco**. Algunas se destinan a todos los evaluados y otras a grupos concretos según la **edad y el sexo**. De ellas se seleccionan habitualmente entre **10 y 20**, en función de la persona y de lo que se quiere explorar.

La administración. Se presentan las láminas una a una y se pide que se invente una historia sobre cada una que diga qué ocurre en la escena, qué ha llevado hasta ella, qué pasa por la cabeza de los personajes y cómo acaba. Ante la lámina en blanco, la persona imagina primero una escena y luego cuenta la historia. El evaluador registra los relatos de forma literal, junto con las pausas, los comentarios y el tiempo; puede pedir aclaraciones si falta alguna parte de la consigna, pero sin sugerir contenidos.

El análisis clásico. Murray interpretaba los relatos con su modelo de **necesidades y presiones**, basado en el sistema de necesidades que había descrito en 1938:

- **Héroe**: el personaje con el que se identifica el narrador, por lo general el protagonista.

- **Necesidades**: motivos del héroe (logro, afiliación, dominio, agresión, autonomía…).
- **Presiones**: fuerzas del entorno que facilitan o frenan esas necesidades (un padre exigente, un rival, una pérdida).
- **Tema**: la combinación de necesidades y presiones que organiza la historia.
- **Desenlace**: cómo se resuelve el conflicto (éxito, fracaso, final abierto) y por qué medios.

Se buscan **temas recurrentes** a lo largo de las láminas, no el contenido de una sola historia. Un ejemplo inventado: si en casi todos los relatos de un estudiante el protagonista se esfuerza mucho y aun así fracasa por culpa de otros, el patrón sugiere una hipótesis sobre su forma de entender el logro, que habrá que contrastar con la entrevista y otras pruebas.

Versiones y sistemas modernos.

- **CAT** (*Children's Apperception Test*), de Leopold Bellak, para niños: las escenas muestran animales en situaciones humanas, con la idea de que los niños se identifican con ellos más fácilmente.
- **SCORS** (*Social Cognition and Object Relations Scale*), de Drew Westen: codifica en los relatos aspectos de las **relaciones objetales** y la cognición social, como la complejidad con que se representa a los demás o la carga afectiva de las relaciones.
- En investigación motivacional, McClelland y sus colaboradores usaron láminas de tipo TAT para codificar la **motivación de logro**.

Límites. El TAT nunca tuvo un sistema de corrección único ni normas generales. Cada evaluador elige láminas distintas y muchos interpretan de forma intuitiva, lo que impide hablar de «la» fiabilidad o «la» validez del TAT. Su lugar razonable es el de una entrevista apoyada en estímulos, útil para generar hipótesis.

Consenso y debate

Consenso: las técnicas proyectivas se apoyan en la hipótesis proyectiva de Frank (1939) y presentan estímulos ambiguos, respuesta libre y objetivo enmascarado. El Rorschach tiene 10 láminas y se administra en dos fases, respuesta libre e indagación. El Sistema Comprehensivo de Exner (1974) unificó los sistemas previos, y sus normas sobrepatologizaban (Wood et al., 2001). El TAT es de Morgan y Murray y se interpreta con el modelo de necesidades y presiones.

Debate: si el Rorschach debe entenderse como tarea de rendimiento perceptivo-cognitivo, como propone el R-PAS, o como acceso a contenidos inconscientes, como en la tradición psicoanalítica. También se discute si el TAT puede considerarse un test, dada la falta de normas y de un sistema de corrección común, o solo una técnica de entrevista.

Mito frecuente

Mito: «El Rorschach no tiene ninguna validez; es como leer los posos del café».

Realidad: el metaanálisis de Mihura et al. (2013) halló que una parte de las variables del Sistema Comprehensivo tiene validez aceptable, sobre todo las de distorsión perceptiva y pensamiento desorganizado. Otras carecen de apoyo, y por eso el R-PAS las descartó. La conclusión correcta es intermedia: validez desigual según la variable, no validez nula (Lilienfeld et al., 2000).

Conceptos clave

Concepto	Definición
Hipótesis proyectiva	Ante un estímulo ambiguo, la respuesta refleja sobre todo la organización personal (Frank, 1939)
Clasificación de Lindzey	Asociación, construcción, completamiento, ordenación o elección y expresivas (1959)
Indagación	Segunda fase del Rorschach: se pregunta dónde y por qué se vio cada respuesta
Determinante	Rasgo de la mancha que produce la respuesta: forma, color, sombreado o movimiento
Calidad formal	Grado en que lo descrito se ajusta a la forma real de la mancha
Sistema Comprehensivo	Sistema de Exner (1974) que unificó administración, codificación y normas del Rorschach
R-PAS	Sistema de Meyer et al. (2011): dos o tres respuestas por lámina y variables con apoyo empírico
Necesidades y presiones	Modelo de Murray para analizar el TAT: motivos del héroe frente a fuerzas del entorno

Clave PIR

Prioridad media. Se pregunta la clasificación de Lindzey, el número y tipo de láminas del Rorschach, sus fases de administración, sus categorías de codificación y quién creó el Sistema Comprehensivo. Del TAT, el número de láminas y el modelo de Murray. Trampas típicas: olvidar a Christiana Morgan como coautora del TAT, confundir la indagación con una segunda ronda de respuestas y atribuir el R-PAS a Exner.

Autoevaluación

1. Según la clasificación de Lindzey (1959), el TAT es una técnica de…
a) asociación
b) construcción
c) completamiento

2. ¿Qué láminas del Rorschach combinan el negro y el rojo?
a) La I y la V
b) La VIII y la IX
c) La II y la III

3. La fase de indagación del Rorschach sirve sobre todo para…
a) reunir la información necesaria para codificar cada respuesta
b) pedir respuestas nuevas a las láminas con pocas respuestas
c) comprobar si la persona recuerda las láminas vistas

4. ¿Qué caracteriza la administración «R-optimizada» del R-PAS?
a) Se administran solo las cinco láminas cromáticas
b) Se elimina la fase de indagación para ahorrar tiempo
c) Se piden dos o tres respuestas por cada lámina

5. En el análisis de Murray, las fuerzas del entorno que facilitan o frenan los motivos del héroe se llaman…
a) necesidades
b) presiones
c) desenlaces

Soluciones

1 b. El TAT pide construir una historia completa; el Rorschach es de asociación. **2 c.** La I, IV, V, VI y VII son acromáticas y la VIII, IX y X, de color. **3 a.** Se pregunta dónde y por qué se vio cada respuesta, sin buscar respuestas nuevas. **4 c.** Así se reduce la variabilidad del número de respuestas, uno de los problemas del Sistema Comprehensivo. **5 b.** Las necesidades son los motivos del héroe; las presiones, las fuerzas externas.

Unidad 4 · Técnicas proyectivas II: gráficas, narrativas y evidencia

Objetivos: describir las principales técnicas gráficas y sus autores; describir el test del pueblo, las fábulas de Düss y las frases incompletas; resumir la evidencia sobre la fiabilidad y la validez de las técnicas proyectivas; identificar los sesgos que amenazan su interpretación; aplicar criterios de uso responsable.

4.1 Técnicas gráficas: árbol, figura humana, familia y HTP

Las **técnicas gráficas** piden a la persona que dibuje algo a partir de una consigna sencilla. Son baratas, rápidas y bien aceptadas por los niños, lo que explica su difusión en la escuela y en la clínica infantil. Comparten un procedimiento básico: hoja en blanco, lápiz, consigna abierta, observación del proceso (orden de trazado, borrados, comentarios) y, con frecuencia, una entrevista posterior sobre el dibujo.

El test del árbol. Karl Koch (1949) lo sistematizó a partir de una idea del orientador suizo Jucker, que usaba el dibujo de un árbol en orientación profesional. Se pide dibujar un árbol, y los manuales interpretativos asignan significado a la posición en la hoja, al tamaño y a cada parte del dibujo.

El dibujo de la figura humana. Tiene dos tradiciones que no conviene confundir:

Autor	Año	Uso del dibujo
Florence Goodenough	1926	Medida de **madurez intelectual** en niños: se puntúan los detalles presentes y se estima una edad mental
Dale B. Harris	1963	Revisión y ampliación de la escala de Goodenough
Karen Machover	1949	Técnica **proyectiva**: el dibujo expresaría la imagen corporal y los conflictos
Elizabeth Koppitz	1968	Indicadores **evolutivos** (lo esperable a cada edad) e **indicadores emocionales** en niños

La diferencia es importante. Goodenough no buscaba conflictos, sino un índice de desarrollo cognitivo: cuantos más detalles correctos dibuja un niño, más maduro es su concepto de la figura humana. Machover tomó el mismo material y le dio una lectura simbólica. Koppitz intentó una vía intermedia, con criterios explícitos y separando lo que es propio de la edad de lo que sería un signo emocional.

El test de la familia. Louis Corman (1961) propuso pedir al niño que dibuje **una familia que imagine**, en lugar de pedirle directamente la suya. La consigna indirecta buscaba reducir la censura: el niño representaría su propia familia sin sentirse obligado a hacerlo. Tras el dibujo se pregunta quién es cada personaje, quién es el más feliz o el menos simpático y con quién le gustaría estar. El análisis atiende a quién aparece y quién falta, al orden y el tamaño de las figuras, a las distancias entre ellas y a la identificación del niño con alguno de los personajes.

El HTP (*House-Tree-Person*, casa-árbol-persona). John N. Buck (1948) pidió dibujar una casa, un árbol y una persona, cada uno en su propia hoja, seguidos de un interrogatorio sobre cada uno. La casa se asocia al ámbito familiar, el árbol a la vivencia de uno mismo en un nivel más profundo y la persona a la autoimagen y las relaciones. La interpretación compara los tres dibujos entre sí.

Dos formas de interpretar. Conviene distinguir:

- **Interpretación por signos**: cada rasgo aislado se traduce en un significado (un tamaño, un trazo, una omisión). Es la base de buena parte de los manuales clásicos.
- **Valoración global**: se juzga el dibujo en conjunto, a menudo con escalas explícitas, como hicieron Goodenough y Koppitz.

La interpretación por signos **carece de validez**: los significados atribuidos a rasgos concretos no se confirman en estudios controlados (Lilienfeld, Wood y Garb, 2000). Que los dibujos infantiles cambian con la edad sí está bien establecido, y las escalas evolutivas (Goodenough-Harris, Koppitz) correlacionan de forma moderada con el CI, pero no sustituyen a un test de inteligencia.

Un ejemplo ilustra el riesgo. Si una niña de seis años dibuja una familia diminuta en una esquina, antes de pensar en inseguridad hay que considerar su desarrollo gráfico, la prisa por volver al recreo o su costumbre en clase. Un dibujo es una conducta con muchas causas posibles.

4.2 Técnicas constructivas y narrativas: test del pueblo, fábulas de Düss y frases incompletas

El test del pueblo. Henri Arthus (1949) diseñó una técnica en la que la persona construye un pueblo sobre una superficie con un conjunto de piezas: casas, edificios públicos, árboles, personajes, animales y otros elementos. Se observa el proceso (qué coloca primero, qué deja fuera, si rectifica), la organización final del espacio y el relato que la persona hace de su pueblo. Es una técnica lúdica y no verbal, útil con niños que hablan poco. En la clasificación de Lindzey entra entre las expresivas; otros manuales la llaman constructiva. No dispone de normas ni de un sistema de codificación con apoyo empírico, de modo que su uso es exploratorio.

Las fábulas de Düss. Louisa Düss (1940) escribió **10 fábulas incompletas**, breves y protagonizadas a menudo por animales, para niños. Cada fábula plantea una situación de conflicto y termina con una pregunta que el niño debe responder: qué hace el personaje, qué pasará después, por qué se siente así. Las fábulas se diseñaron desde la teoría psicoanalítica, para explorar los conflictos de los **estadios psicosexuales** (dependencia, rivalidad, celos, miedo, culpa). Son técnicas de completamiento, con un componente narrativo. Como con el test del pueblo, la interpretación es cualitativa y sin normas, y la teoría en que se basan ha perdido peso en la psicología actual.

Las frases incompletas. Se presentan comienzos de frase que la persona termina con lo primero que se le ocurre, por ejemplo:

- «Los domingos por la tarde…»
- «Cuando estoy solo…»
- «Mi jefe…»

Hay varias versiones clásicas, como las de **Sacks** y **Rotter**. La de Rotter incluye un sistema de puntuación del **ajuste** general, con criterios para valorar cada respuesta como más o menos conflictiva. De todas las técnicas proyectivas, el completamiento de frases es la más estructurada y la más cercana a un autoinforme: el estímulo es verbal y concreto, el objetivo es relativamente transparente y la persona controla bien lo que escribe. Por eso se sitúa en la frontera entre las proyectivas y las técnicas subjetivas (Unidad 2).

Técnica	Autor y año	Tipo de respuesta	Población habitual
Test del pueblo	Arthus, 1949	Construcción con piezas y relato	Niños, también adultos
Fábulas de Düss	Düss, 1940	Completar 10 fábulas	Niños
Frases incompletas	Sacks; Rotter	Terminar frases por escrito	Adolescentes y adultos

Un minicaso muestra el uso más razonable de estas técnicas. Un adolescente que apenas habla en la entrevista completa la frase «Cuando hablo en voz alta…» con «nadie escucha». La respuesta no diagnostica nada, pero ofrece un tema concreto para retomar en la siguiente sesión. Así entendidas, las técnicas narrativas funcionan como **facilitadoras de la entrevista** y como fuente de hipótesis, no como tests que miden un constructo.

A diferencia de un cuestionario, donde cada respuesta suma a una escala con propiedades conocidas, aquí cada respuesta se lee por su contenido. Esa riqueza cualitativa es su ventaja y la razón por la que cuesta demostrar que dos evaluadores llegarían a la misma conclusión.

4.3 Fiabilidad y validez de las técnicas proyectivas

Las técnicas proyectivas deben cumplir las mismas exigencias que cualquier instrumento: fiabilidad, validez y normas adecuadas (Evaluación Psicológica I). Que «capten lo profundo» no las exime: si guían decisiones sobre personas, hay que saber con qué error lo hacen.

Fiabilidad. Los problemas aparecen en varios frentes:

- **Administración.** Cuando cada evaluador elige las láminas, la consigna o el número de dibujos, los resultados no son comparables.
- **Codificación.** En el Rorschach codificado con el Sistema Comprehensivo o el R-PAS, el **acuerdo entre codificadores** es aceptable cuando hay entrenamiento. Sin un sistema explícito, como ocurre en la mayoría de los usos del TAT y de los dibujos, la fiabilidad entre evaluadores no se puede garantizar.
- **Interpretación.** Aunque los códigos coincidan, el paso de los códigos a las conclusiones sigue dependiendo del juicio clínico.

Validez. El gran estudio de referencia sobre el Rorschach es el metaanálisis de Mihura, Meyer, Dumitrascu y Bombel (2013), que revisó la validez de **65 variables** del Sistema Comprehensivo.

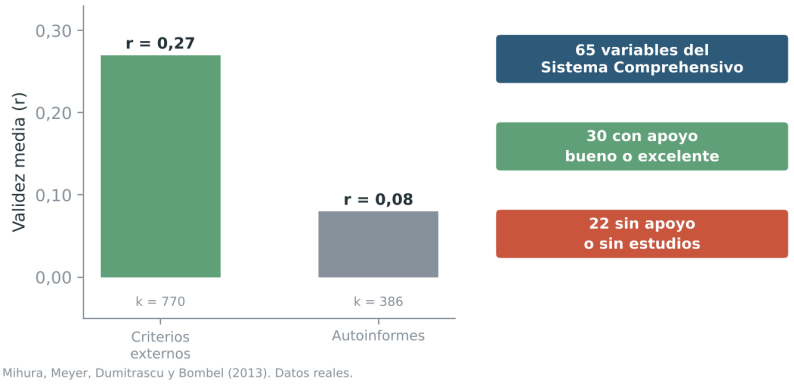


Figura 4.1. **Validez de las variables del Rorschach.** Correlación media de r = 0,27 con criterios externos (k = 770) frente a r = 0,08 con autoinformes (k = 386); de 65 variables analizadas, 30 tuvieron apoyo bueno o excelente y 22 carecieron de apoyo o de estudios. Datos de Mihura et al. (2013). Elaboración propia.

Como muestra la figura 4.1, el resultado tiene dos lecturas:

1. **Validez real, pero desigual.** Con criterios externos (diagnósticos, observación, rendimiento) la correlación media fue **r = 0,27**, un efecto moderado. Las variables con mejor apoyo fueron las de **distorsión perceptiva** y **pensamiento desorganizado**, útiles para detectar procesos psicóticos. Pero 22 de las 65 variables no tuvieron apoyo o no se habían estudiado.
2. **Poca relación con los autoinformes.** Con cuestionarios la correlación fue de solo **r = 0,08**. No significa que el Rorschach no valga: mide cómo actúa la persona ante una tarea, no lo que dice de sí misma, y es lógico que coincida poco con un autoinforme.

Este trabajo sirvió de base al R-PAS, que conservó las variables con apoyo.

Para las demás técnicas, la revisión de Lilienfeld, Wood y Garb (2000) llegó a conclusiones más severas:

- La interpretación de los **dibujos por signos** (figura humana, HTP, árbol) carece de validez, y los dibujos apenas aportan **validez incremental** sobre otras fuentes más baratas.
- **Pocos índices proyectivos** tienen validez incremental, es decir, mejoran la predicción cuando ya se dispone de una entrevista o un cuestionario.
- No hay **hallazgos replicados** que permitan detectar el abuso sexual infantil a partir de dibujos u otras técnicas proyectivas.

Normas. Las normas del Sistema Comprehensivo clasificaban como patológicas a muchas personas sanas (Wood et al., 2001), y la mayoría de las técnicas gráficas y narrativas carecen de normas actualizadas.

Uso real. En España, la encuesta de Muñiz, Hernández y Fernández-Hermida (2020) mostró que los 25 tests más utilizados por los psicólogos son psicométricos, con el WISC, el MCMI y el PAI a la cabeza; las técnicas proyectivas no figuran entre ellos.

Técnica	Fiabilidad entre codificadores	Validez	Normas
Rorschach (SC, R-PAS)	Aceptable con entrenamiento	Desigual: buena en algunas variables, nula en otras	Internacionales en el R-PAS
TAT	Depende del sistema; sin sistema, no garantizada	Limitada y poco documentada en el uso clínico	Sin normas generales
Dibujos por signos	Baja o desconocida	Sin validez demostrada	Escasas o antiguas

4.4 Uso responsable y sesgos de interpretación

Buena parte de los errores con las proyectivas no se debe al material, sino a cómo razona quien interpreta. Varios sesgos están bien documentados.

Correlación ilusoria. Chapman y Chapman (1967) dieron a estudiantes sin formación clínica una serie de dibujos de la figura humana, cada uno emparejado con los síntomas de su supuesto autor. Las parejas se habían hecho al azar, de modo que no había ninguna relación entre rasgos del dibujo y síntomas. Aun así, los estudiantes «descubrieron» las mismas asociaciones que defendían los clínicos, como «ojos grandes = suspicacia o paranoia». Las asociaciones procedían de sus expectativas, no de los datos. La lección es incómoda: lo que «se ve» en la práctica clínica puede ser una relación que no existe.

Efecto Barnum. Las descripciones vagas y generales («a veces se muestra seguro, pero en el fondo duda de sí mismo») parecen precisas a casi cualquier persona. Un informe proyectivo lleno de frases de este tipo convence al evaluado y al propio evaluador, pero no discrimina entre personas.

Otros sesgos frecuentes:

- **Confirmación**: buscar en el protocolo lo que apoya la hipótesis previa y pasar por alto lo que la contradice.
- **Sobrepatologización**: leer como síntoma lo que es normal para la edad o el contexto, un riesgo agravado por normas poco adecuadas.
- **Sesgo cultural**: interpretar como signo lo que es una costumbre gráfica o narrativa del grupo de la persona.

Criterios de uso responsable.

1. **Usar las técnicas como generadoras de hipótesis**, que se contrastan con la entrevista, la observación y tests con garantías.
2. **Preferir sistemas de codificación explícitos** con normas y apoyo empírico, como el R-PAS, frente a la interpretación intuitiva.
3. **Interpretar solo las variables validadas.** Del Rorschach, las de distorsión perceptiva y pensamiento desorganizado tienen apoyo; muchas otras, no.
4. **No basar decisiones forenses o de custodia en signos gráficos**, ni concluir que hubo abuso sexual a partir de un dibujo. Un error en estos contextos tiene consecuencias graves para niños y familias.
5. **Formación y supervisión**: aplicar e interpretar estas técnicas exige entrenamiento específico.
6. **Proteger la seguridad del material**: no difundir láminas ni respuestas habituales.

Los principios generales de ética en el uso de tests, el consentimiento informado y la comunicación de resultados se estudian en Evaluación Psicológica I.

Un minicaso resume la unidad. En un procedimiento de custodia, un informe concluye que un niño «rechaza a su padre» porque lo dibujó pequeño y apartado en el test de Corman. La conclusión no se sostiene: el signo no tiene validez demostrada y hay muchas explicaciones alternativas. El dibujo, como mucho, sugiere una pregunta para la entrevista.

Queda abierta una cuestión práctica: si las técnicas gráficas deben seguir enseñándose. Este temario las presenta como contenido histórico y de cobertura, acompañado de sus datos de validez, para que el lector sepa reconocerlas y valorar con criterio los informes que las usan.

Consenso y debate

Consenso: algunas variables del Rorschach tienen validez aceptable, sobre todo las de distorsión perceptiva y pensamiento desorganizado (Mihura et al., 2013). La interpretación de los dibujos por signos carece de validez, pocos índices proyectivos tienen validez incremental y no hay hallazgos replicados para detectar abuso sexual infantil (Lilienfeld et al., 2000). En la práctica española dominan los tests psicométricos (Muñiz et al., 2020).

Debate: si las técnicas gráficas deben seguir enseñándose y usándose, o solo como contenido histórico. También se discute qué valor tienen las proyectivas como facilitadoras de la relación y de la entrevista, aunque no funcionen como tests.

Mito frecuente

Mito: «Las técnicas proyectivas son tan fiables y válidas como los tests psicométricos; solo miden cosas más profundas».

Realidad: su fiabilidad y validez son muy desiguales. El Rorschach codificado con sistemas explícitos tiene variables válidas y otras sin apoyo (Mihura et al., 2013), mientras que los dibujos interpretados por signos carecen de validez y aportan poca validez incremental (Lilienfeld et al., 2000). Tampoco es cierto lo contrario: no todas las proyectivas son inútiles.

Conceptos clave

Concepto	Definición
Figura humana de Goodenough	Dibujo de una persona usado como medida de madurez intelectual en niños (1926)
Indicadores emocionales	Rasgos del dibujo infantil que Koppitz (1968) separó de los indicadores evolutivos
Test de la familia	Dibujo de «una familia que imagines» seguido de entrevista (Corman, 1961)
HTP	Dibujo de una casa, un árbol y una persona con interrogatorio posterior (Buck, 1948)
Fábulas de Düss	Diez fábulas incompletas para niños sobre conflictos de los estadios psicosexuales (1940)
Interpretación por signos	Atribuir un significado fijo a cada rasgo aislado de un dibujo; carece de validez
Correlación ilusoria	Percepción de una relación inexistente que encaja con las expectativas (Chapman y Chapman, 1967)

Concepto	Definición
Validez incremental	Mejora de la predicción que aporta una prueba sobre la información ya disponible

Clave PIR

Prioridad media. Se preguntan autores y años de las técnicas gráficas y narrativas, la diferencia entre Goodenough y Machover y las conclusiones sobre la validez de las proyectivas. Trampas típicas: atribuir a Machover el uso de la figura humana como medida de inteligencia (fue Goodenough), afirmar que el Rorschach no tiene ninguna validez y creer que un dibujo permite detectar abuso sexual.

Autoevaluación

1. ¿Quién usó por primera vez el dibujo de la figura humana como medida de madurez intelectual?
a) Florence Goodenough
b) Karen Machover
c) Elizabeth Koppitz

2. En el metaanálisis de Mihura et al. (2013), la correlación media de las variables del Rorschach con criterios externos fue…
a) r = 0,08
b) r = 0,52
c) r = 0,27

3. El experimento de Chapman y Chapman (1967) mostró que…
a) los clínicos expertos no cometen errores al interpretar dibujos
b) se perciben asociaciones entre dibujos y síntomas aunque no existan
c) el tamaño de los ojos en el dibujo predice la suspicacia

4. ¿Qué técnica consiste en construir un pueblo con piezas?
a) El test de Arthus
b) El test de Corman
c) El test de Buck

5. Según Lilienfeld, Wood y Garb (2000), la interpretación de los dibujos por signos…
a) tiene validez alta para detectar abuso sexual
b) es tan válida como el Rorschach codificado con el R-PAS
c) carece de validez y aporta poca validez incremental

Soluciones

1 a. Goodenough (1926) puntuaba los detalles del dibujo; Machover lo convirtió después en técnica proyectiva. **2 c.** Con autoinformes fue de 0,08, porque el Rorschach mide rendimiento y no autopercepción. **3 b.** Las parejas eran aleatorias, y aun así se «vieron» las asociaciones esperadas. **4 a.** Corman creó el test de la familia y Buck, el HTP. **5 c.** Tampoco hay hallazgos replicados para detectar abuso sexual a partir de dibujos.

Capítulo 2 · Evaluación de la inteligencia y las aptitudes

La inteligencia es el constructo con más tradición en la evaluación psicológica y también uno de los más discutidos. Este capítulo recorre primero las teorías que han intentado describirla y la historia de su medición, y después los instrumentos que se usan hoy: las escalas de Wechsler, otros tests individuales y colectivos y las baterías de aptitudes.

Unidad 5 · Concepto y teorías de la inteligencia

Objetivos: distinguir los enfoques empírico, factorial, genético y cognitivo en el estudio de la inteligencia; describir los modelos factoriales clásicos y situar a cada autor con su propuesta; explicar la distinción entre inteligencia fluida y cristalizada, el modelo de tres estratos y el modelo CHC; valorar con datos las teorías de Gardner, Sternberg y la inteligencia emocional.

5.1 Tres enfoques para definir la inteligencia

No existe una definición de inteligencia aceptada por todos. Casi todas incluyen la capacidad de **razonar**, **resolver problemas nuevos**, **aprender** de la experiencia y **adaptarse** al entorno, pero cada escuela pone el acento en un aspecto distinto. Para la evaluación, lo importante es que cada forma de entender la inteligencia lleva a una forma distinta de medirla. Se suelen distinguir tres grandes enfoques clásicos, a los que se ha sumado un cuarto.

El enfoque empírico o pragmático. Parte de una idea de la inteligencia cercana al sentido común y se preocupa más de medirla bien que de definirla. Los primeros tests de Binet y Simon nacieron así: tenían un fin práctico, detectar a los escolares que necesitaban ayuda, y se construyeron eligiendo tareas que diferenciaban a los niños de distintas edades. La versión extrema de esta postura es la célebre frase de Boring (1923): la inteligencia es **lo que miden los tests**. La definición es operacional y evita discusiones, pero es circular: no dice qué tienen en común las tareas ni por qué unas sirven y otras no.

El enfoque factorial o psicométrico. Busca la estructura de la inteligencia a partir de las **correlaciones** entre tests. Si las personas que puntúan alto en vocabulario también suelen puntuar alto en razonamiento con figuras, algo comparten ambas tareas. Spearman (1904) introdujo el análisis factorial para estudiar esas correlaciones, y de ahí nacieron los modelos del apartado 5.2. Es el enfoque que más ha influido en los tests actuales. Los detalles técnicos del análisis factorial se estudian en Psicometría.

El enfoque genético o evolutivo. Piaget no se interesó por las diferencias entre personas, sino por **cómo se construye** el pensamiento a lo largo del desarrollo. La inteligencia es para él una forma de adaptación que busca el **equilibrio** entre dos procesos: la **asimilación**, que incorpora lo nuevo a los esquemas que ya se tienen, y la **acomodación**, que modifica los esquemas cuando lo nuevo no encaja. Su método de evaluación es la **evaluación operatoria**, basada en el **método clínico**: se plantea al niño una tarea (por ejemplo, si cambia la cantidad de agua al pasarla a un vaso más estrecho) y se le pregunta y repregunta para conocer el razonamiento que hay detrás de su respuesta. No interesa tanto si acierta como el nivel de pensamiento que revela. Piaget no buscaba tests estandarizados ni baremos, y las pruebas operatorias se usan sobre todo en la escuela y en investigación. Las etapas del desarrollo se estudian en Psicología del Desarrollo.

El enfoque cognitivo o de procesamiento. Más reciente, se pregunta qué **procesos mentales** producen la conducta inteligente. Un ejemplo con aplicación directa a la evaluación es el **modelo PASS** de Das y Naglieri, inspirado en las ideas de Luria sobre la organización funcional del cerebro. Distingue cuatro procesos: **planificación**, **atención**, procesamiento **simultáneo** (integrar elementos en un todo, como al interpretar un mapa) y procesamiento **sucesivo** (manejar información en serie, como al repetir un número de teléfono). El modelo se evalúa con el **CAS** (*Cognitive Assessment System*).

Enfoque	Pregunta central	Método típico	Ejemplo
Empírico	¿Qué tareas discriminan bien?	Selección práctica de ítems	Escala Binet-Simon
Factorial	¿Qué estructura tienen las aptitudes?	Análisis factorial de correlaciones	Spearman, Thurstone, CHC
Genético	¿Cómo se construye el pensamiento?	Método clínico y pruebas operatorias	Piaget
Cognitivo	¿Qué procesos producen la conducta inteligente?	Tareas experimentales y de procesamiento	Modelo PASS (CAS)

Los enfoques no se excluyen: las baterías actuales combinan una estructura factorial con tareas que captan procesos concretos.

5.2 Los modelos factoriales clásicos: Spearman, Thurstone, Guilford y Vernon

Spearman: el factor g. Spearman (1904) observó que todos los tests de capacidad correlacionan positivamente entre sí: quien rinde bien en uno tiende a rendir bien en los demás. Lo explicó con su **teoría bifactorial**: cada tarea depende de un **factor general (g)**, común a todas, y de un **factor específico (s)**, propio de esa tarea. El factor *g* sería una especie de energía mental general; los factores *s*, habilidades concretas que no se transfieren. Los tests que más saturan en *g* son los de razonamiento abstracto, como las matrices de Raven y los dominós (Unidad 8).

Thurstone: las aptitudes primarias. Thurstone (1938) aplicó un análisis factorial múltiple a una batería amplia de tests y no encontró un único factor dominante, sino varias **Aptitudes Mentales Primarias** relativamente independientes:

- comprensión verbal;
- fluidez verbal;
- aptitud numérica;
- aptitud espacial;
- memoria;
- velocidad perceptiva;
- razonamiento.

De su modelo procede el **PMA** (Unidad 8) y, en general, la idea de evaluar la inteligencia mediante un **perfil** de aptitudes en lugar de una sola cifra. Pero las aptitudes primarias resultaron estar correlacionadas entre sí, y esas correlaciones dejaban espacio para un factor general de orden superior. El aparente choque entre Spearman y Thurstone era, en parte, una diferencia de nivel de análisis.

Vernon: el modelo jerárquico. Vernon (1950) reconcilió ambas posturas con una **jerarquía**. En la cúspide está *g*. Debajo, dos grandes factores de grupo: uno **verbal-educativo** y otro **práctico-mecánico-espacial**. Por debajo de estos aparecen factores de grupo menores (verbal, numérico, mecánico, espacial…) y, en la base, los factores específicos de cada test. Esta organización por niveles anticipa el modelo de Carroll y el CHC.

Guilford: la estructura del intelecto. Guilford (1967) rechazó la existencia de *g* y propuso un modelo de tres dimensiones que se cruzan como las aristas de un cubo:

Dimensión	Qué indica	Categorías
Operaciones	Qué hace la mente	Cognición, memoria, producción divergente, producción convergente, evaluación
Contenidos	Sobre qué material trabaja	Figurativo, simbólico, semántico, conductual
Productos	Qué forma toma el resultado	Unidades, clases, relaciones, sistemas, transformaciones, implicaciones

Cada combinación sería una capacidad distinta: 5 × 4 × 6 = 120 en la versión original, y hasta 180 en revisiones posteriores, que desdoblaron algunas categorías. Su aportación más duradera fue la **producción divergente**, generar muchas respuestas posibles a un problema abierto (por ejemplo, pensar usos para un ladrillo), que impulsó el estudio de la **creatividad**. Su punto débil es empírico: muchas celdas nunca se confirmaron de forma independiente, y sus análisis recibieron críticas metodológicas por forzar factores no correlacionados.

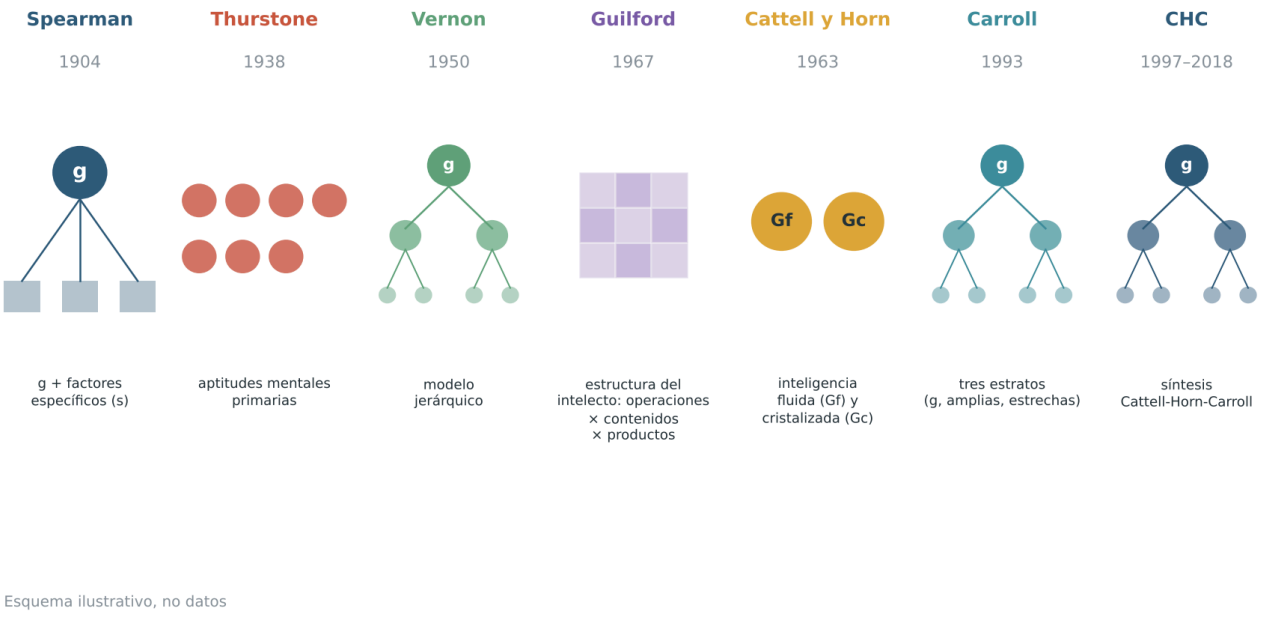


Figura 5.1. **Siete modelos factoriales de la inteligencia.** Comparación de Spearman (*g* y *s*, 1904), Thurstone (aptitudes primarias, 1938), Vernon (jerárquico, 1950), Guilford (estructura del intelecto, 1967), Cattell-Horn (Gf-Gc, 1963), Carroll (tres estratos, 1993) y el modelo CHC, con un pictograma de la estructura de cada uno. Elaboración propia.

Como muestra la figura 5.1, se pasó de un factor único a muchos factores y, finalmente, a los modelos **jerárquicos**, hoy la mejor descripción de los datos, en los que *g* y las aptitudes específicas conviven en niveles distintos. El papel de *g* en las diferencias individuales se trata en Personalidad y Diferencias Individuales.

5.3 Inteligencia fluida y cristalizada, Carroll y el modelo CHC

Cattell y Horn: Gf y Gc. R. B. Cattell (1963) dividió la capacidad general en dos componentes, una distinción que su discípulo Horn desarrolló después:

- La **inteligencia fluida (Gf)** es la capacidad de razonar ante problemas nuevos, descubrir relaciones y resolver situaciones para las que no sirve lo aprendido. Depende poco de la escolarización. Se evalúa con tareas como las series o las matrices.
- La **inteligencia cristalizada (Gc)** es el conjunto de conocimientos, vocabulario y destrezas adquiridos a través de la cultura y la educación. Se evalúa con pruebas de vocabulario, información o comprensión.

Según la **teoría de la inversión** de Cattell, la Gf se «invierte» en experiencias de aprendizaje y produce Gc. Las dos siguen trayectorias diferentes con la edad: la Gf alcanza su máximo en la juventud y declina después, mientras que la Gc se mantiene o sigue creciendo hasta edades avanzadas. Un ejemplo cotidiano: una persona de setenta años puede tardar más que su nieto en entender un videojuego nuevo y, sin embargo, ganarle sin esfuerzo en un crucigrama. Horn amplió el modelo con otras capacidades amplias (visual, auditiva, velocidad, memoria) y se mostró escéptico ante la existencia de *g*.

Carroll: los tres estratos. Carroll (1993) reanalizó con un mismo procedimiento más de 460 conjuntos de datos acumulados durante décadas. El resultado fue una jerarquía de **tres estratos**:

1. **Estrato III**: un factor general, *g*.
2. **Estrato II**: unas pocas capacidades **amplias**, como la inteligencia fluida, la cristalizada, la memoria, la percepción visual o auditiva y la velocidad.
3. **Estrato I**: decenas de capacidades **estrechas**, muy específicas.

La solidez de su base de datos convirtió el modelo de Carroll en una referencia: confirmaba la jerarquía de Vernon, recogía la distinción Gf-Gc y mantenía *g* en la cúspide.

El modelo CHC. McGrew (1997, 2009) integró las propuestas de Cattell, Horn y Carroll en el modelo **Cattell-Horn-Carroll (CHC)**, revisado por Schneider y McGrew (2018). Mantiene los tres estratos y ofrece una taxonomía común de capacidades amplias.

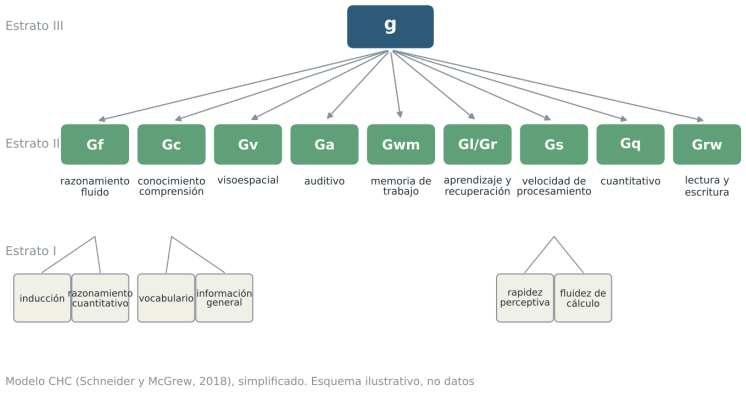


Figura 5.2. **Estructura del modelo CHC.** El factor *g* ocupa el estrato III; nueve capacidades amplias forman el estrato II (Gf, Gc, Gv, Ga, Gwm, Gl/Gr, Gs, Gq, Grw), y bajo algunas de ellas se muestran capacidades estrechas de ejemplo del estrato I. Elaboración propia.

Como muestra la figura 5.2, las principales capacidades del estrato II son estas:

Sigla	Capacidad amplia	Ejemplo de tarea
Gf	Razonamiento fluido	Completar una matriz de figuras
Gc	Conocimiento o comprensión cultural	Definir palabras
Gv	Procesamiento visoespacial	Reproducir un diseño con cubos
Ga	Procesamiento auditivo	Distinguir sonidos del habla
Gwm	Memoria de trabajo	Repetir dígitos en orden inverso
Gl / Gr	Eficiencia del aprendizaje / fluidez de recuperación	Aprender pares asociados / decir palabras de una categoría
Gs	Velocidad de procesamiento	Copiar símbolos con rapidez

Sigla	Capacidad amplia	Ejemplo de tarea
Gq	Conocimiento cuantitativo	Resolver problemas aritméticos
Grw	Lectura y escritura	Comprender un texto

La revisión de Schneider y McGrew (2018) separó la antigua capacidad de almacenamiento y recuperación a largo plazo en **eficiencia del aprendizaje (Gl)** y **fluidez de recuperación (Gr)**. En el modelo hay cuestiones abiertas, como si *g* es una capacidad real o un simple resumen estadístico, pero eso no impide su uso práctico.

El modelo CHC es hoy el **marco de referencia** para construir e interpretar las baterías de inteligencia. Los cinco índices primarios del WISC-V y de la WAIS-5 se corresponden, a grandes rasgos, con Gc, Gv, Gf, Gwm y Gs (Unidad 7). Para el evaluador, el CHC es un vocabulario común para comparar tests distintos.

5.4 Teorías alternativas: Gardner, Sternberg e inteligencia emocional

Gardner: las inteligencias múltiples. Gardner (1983) propuso que no hay una inteligencia, sino varias, con bastante **autonomía** entre sí: lingüística, lógico-matemática, espacial, musical, corporal-cinestésica, interpersonal e intrapersonal; después añadió la naturalista. Para identificarlas no usó el análisis factorial, sino criterios de otro tipo, como la existencia de lesiones cerebrales que afectan a una capacidad aislada o de personas con un talento excepcional en un solo dominio. La teoría tuvo un enorme éxito en la escuela, porque invita a valorar capacidades que los tests clásicos ignoran.

El problema es la **evidencia**. Gardner no desarrolló instrumentos estandarizados para medir cada inteligencia, y la independencia que postula no se confirma: Visser, Ashton y Vernon (2006) hallaron que las inteligencias de contenido más académico correlacionan entre sí y saturan en *g*, en lugar de ser independientes. La revisión de Waterhouse (2006) concluyó que la teoría carece de validación empírica. Algo parecido ocurre con los **estilos de aprendizaje**, con los que a menudo se mezcla: no hay pruebas de que enseñar a cada alumno en su estilo preferido (visual, auditivo…) mejore su rendimiento (Pashler et al., 2008). Ambos temas se amplían en Psicología Educativa y Orientación.

Sternberg: la teoría triárquica. Sternberg (1985) propuso tres subteorías que explican aspectos distintos de la conducta inteligente:

Subteoría	Aspecto de la inteligencia	Ejemplo
Componencial	Analítica: procesos para analizar, comparar y evaluar	Detectar el fallo de un argumento
Experiencial	Creativa: afrontar lo nuevo y automatizar lo conocido	Improvisar una solución cuando falla el plan
Contextual	Práctica: adaptarse al entorno, modificarlo o elegir otro	Saber cómo tratar con un jefe difícil

Más tarde la amplió como **inteligencia exitosa**: la capacidad de lograr las propias metas en un contexto, combinando y equilibrando las tres facetas. Su mérito es llamar la atención sobre la inteligencia práctica y creativa; su límite, que las medidas propuestas no han demostrado la independencia de *g* que se esperaba.

La inteligencia emocional (IE). Salovey y Mayer (1990) la definieron como un conjunto de **capacidades** para procesar la información emocional. Su modelo de cuatro ramas incluye percibir las emociones, usarlas para facilitar el pensamiento, comprenderlas y regularlas. Se mide con tareas de rendimiento con respuestas mejores y peores, como el **MSCEIT**. Goleman (1995) popularizó el término con un **modelo mixto**, que añade rasgos de personalidad, motivación y competencias sociales. De ahí surgieron muchos cuestionarios de autoinforme, que miden la IE como **rasgo**: cómo se percibe cada uno.

Modelo	Concepción	Medida típica
De capacidad (Mayer y Salovey)	Habilidades emocionales	Tareas de rendimiento (MSCEIT)
Mixto (Goleman)	Capacidades más rasgos y competencias	Autoinforme o informe de otros
De rasgo	Autopercepción emocional	Autoinforme

La cuestión discutida es si la IE añade algo a lo que ya explican *g* y los rasgos de personalidad, sobre todo cuando se mide por autoinforme, que se solapa mucho con la estabilidad emocional y la extraversión.

Consenso y debate

Consenso: la inteligencia tiene una estructura **jerárquica**, con un factor general en la cúspide y capacidades amplias y estrechas por debajo. El modelo CHC es el marco de referencia de las baterías actuales (Schneider y McGrew, 2018). La distinción entre inteligencia fluida y cristalizada está bien establecida, también en su distinta evolución con la edad.

Debate: qué es exactamente *g* (una capacidad real o un resumen estadístico de correlaciones), y si la inteligencia emocional debe entenderse como capacidad (MSCEIT) o como rasgo medido por autoinforme, con una validez incremental sobre *g* y la personalidad que sigue en discusión.

Mito frecuente

Mito: «La teoría de las inteligencias múltiples está avalada empíricamente: cada persona tiene un perfil de ocho inteligencias independientes».

Realidad: la teoría no tiene una validación empírica sólida (Waterhouse, 2006), y las inteligencias de contenido académico correlacionan entre sí y saturan en *g* (Visser, Ashton y Vernon, 2006). Su valor educativo como invitación a atender capacidades diversas no equivale a evidencia sobre la estructura de la inteligencia.

Conceptos clave

Concepto	Definición
Factor *g*	Factor general común a todas las tareas cognitivas, propuesto por Spearman (1904)
Aptitudes Mentales Primarias	Siete capacidades relativamente independientes identificadas por Thurstone (1938)
Estructura del intelecto	Modelo de Guilford (1967): operaciones × contenidos × productos
Inteligencia fluida (Gf)	Capacidad de razonar ante problemas nuevos, poco dependiente de lo aprendido
Inteligencia cristalizada (Gc)	Conocimientos y destrezas adquiridos mediante la cultura y la educación
Modelo de tres estratos	Jerarquía de Carroll (1993): *g*, capacidades amplias y capacidades estrechas
Modelo CHC	Integración de Cattell, Horn y Carroll; marco de referencia de las baterías actuales

Concepto	Definición
Modelo PASS	Planificación, atención, procesamiento simultáneo y sucesivo (Das y Naglieri; CAS)

Clave PIR

Prioridad alta. Se pregunta qué autor propuso cada modelo, cuántas aptitudes primarias describió Thurstone, las tres dimensiones de Guilford, la diferencia entre Gf y Gc y los estratos de Carroll. Trampas típicas: atribuir a Thurstone la teoría bifactorial, olvidar que Guilford negaba *g*, confundir la Gf (que declina con la edad) con la Gc (que se mantiene) y presentar las inteligencias múltiples como un modelo factorial.

Autoevaluación

1. ¿Qué autor propuso que todas las tareas cognitivas dependen de un factor general y de un factor específico?
a) Thurstone
b) Spearman
c) Guilford

2. En el modelo de Guilford (1967), la producción divergente es…
a) una de las operaciones
b) uno de los contenidos
c) uno de los productos

3. Una persona mayor rinde peor que antes en tareas de matrices nuevas, pero conserva un vocabulario excelente. Esto encaja con…
a) un descenso de la Gc con la Gf estable
b) un descenso por igual de Gf y Gc
c) un descenso de la Gf con la Gc estable

4. El modelo de tres estratos de Carroll (1993) se basó en…
a) el reanálisis de más de 460 conjuntos de datos
b) estudios de pacientes con lesiones cerebrales
c) la observación clínica del razonamiento infantil

5. ¿Qué afirmación sobre la inteligencia emocional es correcta?
a) El modelo de Goleman la mide solo con tareas de rendimiento
b) El MSCEIT la evalúa como capacidad con tareas de rendimiento
c) Su validez incremental sobre *g* está ya demostrada sin discusión

Soluciones

1 b. Es la teoría bifactorial de Spearman (1904); Thurstone defendió aptitudes primarias y Guilford negó *g*. **2 a.** Las operaciones incluyen cognición, memoria, producción divergente, producción convergente y evaluación. **3 c.** La inteligencia fluida declina con la edad, mientras que la cristalizada se mantiene o crece. **4 a.** Carroll aplicó un mismo procedimiento a datos acumulados durante décadas. **5 b.** El MSCEIT corresponde al modelo de capacidad de Mayer y Salovey; el de Goleman es mixto y su validez incremental se discute.

Unidad 6 · Historia de la medición de la inteligencia y efecto Flynn

Objetivos: situar en el tiempo las principales etapas de la medición de la inteligencia y sus protagonistas; diferenciar la edad mental, el CI de razón y el CI de desviación; explicar el efecto Flynn, su inversión y sus consecuencias prácticas; valorar las críticas a los tests de inteligencia y las alternativas, como la evaluación dinámica.

6.1 De Galton a Binet y Simon

La idea de **medir** en qué se diferencian intelectualmente las personas es reciente: tomó forma en la segunda mitad del siglo XIX, cuando la teoría de la evolución puso el foco en la variación entre individuos y la estadística ofreció herramientas para describirla.

Francis Galton, primo de Darwin, estaba convencido de que la capacidad intelectual se hereda, y lo defendió estudiando la frecuencia de personas eminentes en ciertas familias. En 1884 abrió en Londres un **laboratorio antropométrico** en el que, a cambio de una pequeña cantidad, los visitantes se sometían a mediciones de estatura, fuerza, agudeza visual y auditiva, discriminación sensorial y **tiempo de reacción**. Su hipótesis era que una mente capaz debía tener sentidos más finos y reacciones más rápidas. Galton hizo aportaciones metodológicas duraderas, como la idea de **correlación** y el uso de la distribución normal para describir diferencias individuales. También acuñó el término «eugenesia» y la promovió, una herencia que la psicología actual rechaza.

En 1879, Wundt había fundado en Leipzig el primer laboratorio de psicología experimental. **James McKeen Cattell**, que trabajó con Wundt y conocía a Galton, llevó estas mediciones a Estados Unidos y popularizó la expresión «test mental». El proyecto fracasó en lo esencial: sus pruebas sensoriales y de rapidez apenas se relacionaban con el rendimiento académico, como mostró el estudio de Wissler (1901). Medir procesos tan elementales no captaba lo que se quería medir.

Alfred Binet tomó el camino contrario. Pensaba que la inteligencia se manifiesta en procesos **complejos**: comprender, juzgar, razonar, mantener una dirección en el pensamiento. A principios del siglo XX, el Gobierno francés quería identificar a los escolares que no avanzaban con la enseñanza ordinaria y necesitaban educación especial. Con **Théodore Simon** publicó en 1905 la primera **escala de inteligencia**: un conjunto de tareas ordenadas por dificultad creciente, desde seguir un objeto con la mirada hasta definir palabras abstractas.

En las revisiones de 1908 y 1911, las tareas se agruparon por **niveles de edad**: las que resolvía la mayoría de los niños de una edad determinada se asignaban a ese nivel. Así nació la **edad mental (EM)**: el nivel de edad que corresponde al rendimiento del niño. Si una niña de ocho años resuelve las tareas propias de los diez, su edad mental es de diez años. El concepto era intuitivo y útil para maestros y familias.



Figura 6.1. **Pioneros de la medición de la inteligencia.** Francis Galton (hacia 1890), Alfred Binet, William Stern y Lewis M. Terman (1923). Fuente: Wikimedia Commons; dominio público.

La figura 6.1 reúne a los cuatro nombres de esta etapa fundacional. Conviene precisar el papel de Binet: **no inventó el CI**. Trabajó con la edad mental y la diferencia entre esta y la edad real, y desconfiaba de reducir la inteligencia a una sola cifra. Además, consideraba que la inteligencia podía mejorar con la enseñanza adecuada, y no veía su escala como una medida de una capacidad fija e innata. El cociente intelectual llegó después, con Stern y Terman (apartado 6.2).

Rasgo	Galton y J. M. Cattell	Binet y Simon
Qué medían	Procesos sensoriales y motores simples	Procesos mentales superiores
Ejemplo de tarea	Tiempo de reacción ante un sonido	Comprender una situación cotidiana
Finalidad	Estudiar la herencia de la capacidad	Detectar necesidades educativas
Resultado	Escasa relación con el rendimiento escolar	Buena capacidad de discriminar entre niños

6.2 Expansión: CI, tests colectivos y CI de desviación

Del cociente de Stern al Stanford-Binet. La edad mental tenía un problema: una diferencia de dos años no significa lo mismo a los cuatro que a los catorce. **Stern (1912)** propuso dividir la edad mental entre la edad cronológica (EC). **Terman (1916)**, en la Universidad de Stanford, multiplicó el cociente por 100 para evitar decimales y lo incorporó a su adaptación estadounidense de la escala de Binet, el **Stanford-Binet**:

CI de razón = (EM / EC) × 100

Un niño de diez años con una edad mental de doce obtiene un CI de 120. El índice tuvo un éxito inmediato, pero arrastraba dos defectos. En los adultos la edad mental deja de crecer mientras la cronológica sigue aumentando, de modo que el CI bajaría artificialmente con los años. Y la dispersión del cociente variaba de una edad a otra, por lo que un mismo CI no indicaba la misma posición relativa a todas las edades.

Los tests colectivos. Hasta entonces los tests se aplicaban de forma individual. La entrada de Estados Unidos en la Primera Guerra Mundial creó la necesidad de clasificar con rapidez a un número enorme de reclutas. Un comité dirigido por Yerkes elaboró en 1917 dos pruebas de **aplicación colectiva**: el **Army Alpha**, verbal, y el **Army Beta**, no verbal, para quienes no sabían leer o no dominaban el inglés. Partieron de los formatos colectivos de respuesta cerrada que había desarrollado **Arthur Otis**, alumno de Terman.



Figura 6.2. **Evaluación colectiva en el ejército de EE. UU.** Soldados estadounidenses realizando un precursor del Army Alpha en noviembre de 1917. Fuente: Departamento de Guerra de EE. UU., Wikimedia Commons; dominio público.

La figura 6.2 muestra a varios reclutas respondiendo a la vez, cada uno con su hoja; con este formato, un solo examinador podía evaluar a decenas de personas. Tras la guerra, el formato pasó a la escuela y a la empresa. La experiencia tuvo también un lado oscuro: los resultados se usaron para apoyar argumentos racistas y políticas de restricción de la inmigración, sin tener en cuenta que muchos evaluados apenas hablaban inglés o habían ido poco a la escuela.

En 1938 aparecieron las **matrices de Raven**, para medir *g* con material no verbal, y entre 1940 y 1960 llegó el **auge factorial**: baterías que ofrecían un perfil de aptitudes (apartado 5.2).

El CI de desviación. Wechsler (1939) resolvió los problemas del CI de razón con la escala **Wechsler-Bellevue**. En lugar de comparar con la edad mental, comparó a cada persona con las de **su misma edad** y transformó su puntuación en una escala de **media 100 y desviación típica 15**:

CI de desviación = 100 + 15 × z

Quien se sitúa una desviación típica por encima de la media de su grupo de edad obtiene 115, tenga diez años o sesenta. Este procedimiento lo usan hoy todas las escalas de inteligencia. Las puntuaciones típicas y su transformación se estudian en Evaluación Psicológica I.

Rasgo	CI de razón	CI de desviación
Autores	Stern (1912), Terman (1916)	Wechsler (1939)
Cálculo	(EM / EC) × 100	100 + 15 × z respecto al propio grupo de edad
Validez en adultos	Mala: la edad mental se estanca	Buena: compara con la misma edad
Significado de 115	Varía según la edad	Siempre una DT por encima de la media

Las escalas de Wechsler y el Stanford-Binet son de **aplicación individual**, no colectiva: un examinador con una sola persona, lo que permite observar cómo trabaja.

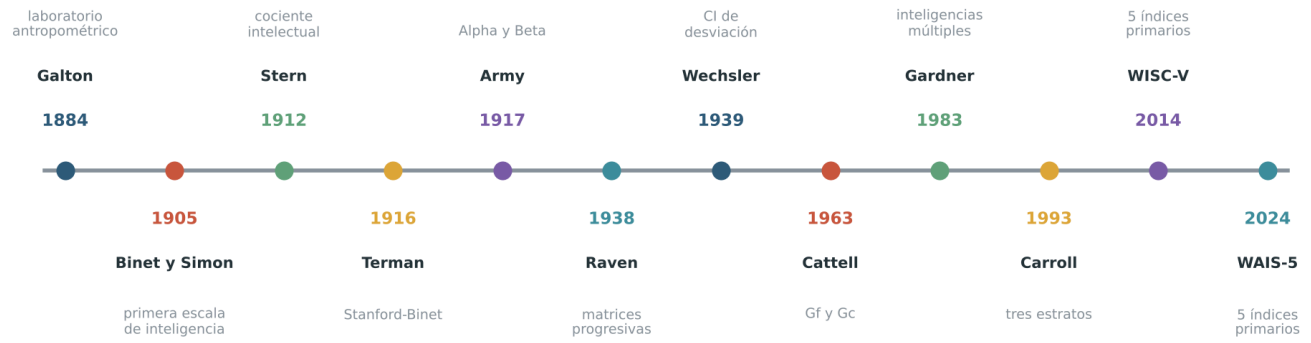


Figura 6.3. **Hitos en la medición de la inteligencia.** De Galton (1884) a la escala Binet-Simon (1905), el CI de Stern (1912), el Stanford-Binet de Terman (1916), los Army Alpha y Beta (1917), Raven (1938), la Wechsler-Bellevue (1939), el modelo Gf-Gc (1963), Gardner (1983), Carroll (1993), el WISC-V (2014) y la WAIS-5 (2024). Elaboración propia.

La figura 6.3 resume más de un siglo de historia.

6.3 El efecto Flynn y su inversión

El efecto Flynn. Flynn (1984, 1987) documentó un fenómeno inesperado: a lo largo del siglo XX, las puntuaciones brutas en los tests de inteligencia **aumentaron de generación en generación** en muchos países. Como los tests se baremaban cada cierto tiempo, cada nueva versión era más exigente, y la subida pasaba desapercibida. El metaanálisis de Trahan, Stuebing, Fletcher y Hiscock (2014), con 285 estudios y 14.031 participantes, estimó una ganancia media de **2,31 puntos de CI por década** (IC 95 %: 1,99–2,64), y de 2,93 puntos con las versiones modernas de Wechsler y Stanford-Binet. Las ganancias fueron mayores en las tareas de razonamiento fluido, como las matrices, que en las de conocimiento (Flynn, 1987).

Un aumento tan rápido no puede deberse a cambios genéticos: unas pocas décadas no bastan para modificar el acervo genético de una población. Las explicaciones propuestas son **ambientales**: mejor nutrición y salud, más años de escolarización, familias más pequeñas y un entorno cotidiano más exigente en pensamiento abstracto. Su peso relativo se sigue discutiendo. Tampoco significa necesariamente que las generaciones nuevas sean «más listas» en todo: lo que ha aumentado es el rendimiento en lo que miden los tests.

La inversión del efecto. En varios países del norte de Europa las ganancias se frenaron e incluso se invirtieron en las cohortes nacidas a partir de mediados de los años setenta. El estudio más sólido es el de Bratsberg y Rogeberg (2018), con los datos de más de 730.000 reclutas noruegos nacidos entre 1962 y 1991. Las puntuaciones subieron hasta la **cohorte de 1975** y descendieron después. Lo decisivo es que la subida y la bajada aparecen también **dentro de las familias**, al comparar hermanos. Si el descenso se debiera a cambios en la composición de la población (por ejemplo, a que ciertos grupos tuvieran más hijos), no aparecería entre hermanos. La causa, por tanto, es ambiental, aunque no se sabe todavía cuál.

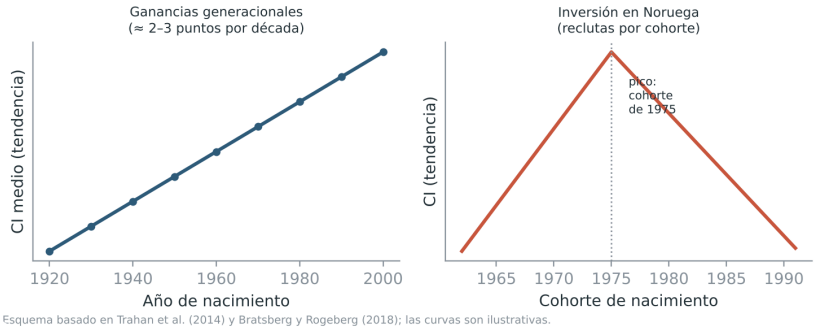


Figura 6.4. **El efecto Flynn y su inversión.** A la izquierda, curva esquemática de las ganancias de CI por cohorte, de unos 2–3 puntos por década. A la derecha, el patrón noruego, con subida hasta la cohorte de 1975 y descenso posterior (Bratsberg y Rogeberg, 2018). Esquema basado en datos reales. Elaboración propia.

Como muestra la figura 6.4, el CI medio de una población no es una constante, sino que cambia con las condiciones de vida.

Consecuencias prácticas. Si las puntuaciones suben con el tiempo, un test con **baremos antiguos** compara a la persona con una generación que rendía menos y, por tanto, **infla su CI**. Con una ganancia de unos 2–3 puntos por década, un baremo de hace quince años puede sobrestimar el CI en torno a 3–4 puntos. Por eso los tests deben **renormarse** periódicamente, y el evaluador debe usar siempre la versión y los baremos más recientes. La cuestión tiene consecuencias serias cuando el diagnóstico depende de un punto de corte. En Estados Unidos, el efecto Flynn se ha discutido en procesos judiciales en los que se dirimía si una persona tenía discapacidad intelectual.

Un minicaso: Lucía, de 15 años, obtiene un CI de 72 en un test baremado hace dos décadas. Con unos baremos actuales, su puntuación sería probablemente algo más baja, y eso puede cambiar la valoración de sus necesidades de apoyo. No hay que corregir el dato a ojo, sino repetir la evaluación con un instrumento actualizado. El efecto Flynn se estudia también en Personalidad y Diferencias Individuales.

6.4 Críticas, evaluación dinámica y perspectivas futuras

Sesgo cultural. Desde los años sesenta, los tests de inteligencia recibieron críticas de varios tipos. Los tests se construyen en una cultura y una lengua concretas. Un ítem de vocabulario o de información general favorece a quien ha crecido rodeado de ese conocimiento. La respuesta de la psicometría ha sido doble: desarrollar pruebas con **menor carga cultural**, como las no verbales, y estudiar con métodos estadísticos si un ítem funciona igual en grupos distintos (Psicometría). Ningún test está **libre** de cultura: incluso las matrices exigen familiaridad con tareas de papel y lápiz y con el razonamiento abstracto escolar.

La polémica de la heredabilidad. Los debates sobre la herencia de las diferencias de CI entre grupos fueron muy agrios. Una heredabilidad alta dentro de un grupo no implica que las diferencias entre grupos sean genéticas ni que el CI sea inmodificable. El tema se trata en Personalidad y Diferencias Individuales.

Estable, pero no inmutable. El CI es uno de los rasgos psicológicos más estables a partir de la adolescencia, pero puede cambiar. Además del efecto Flynn, la escolarización tiene un efecto causal: Ritchie y Tucker-Drob (2018), con más de 600.000 participantes, estiman entre **1 y 5 puntos de CI por cada año adicional de educación**.

Una medida estática. Un test clásico mide lo que la persona hace sola, en un momento dado, con lo que ya ha aprendido. No dice cuánto puede aprender con ayuda. La **evaluación dinámica** intenta medir precisamente ese **potencial de aprendizaje**. Su formato típico es **test-enseñanza-retest**: se evalúa, se ofrece una ayuda o mediación estructurada y se vuelve a evaluar. La mejora indica la capacidad de aprovechar la enseñanza. La propuesta más conocida es la de **Feuerstein**, con su dispositivo de evaluación del potencial de aprendizaje (**LPAD**), basado en la idea de experiencia de aprendizaje mediado. Conecta con la **zona de desarrollo próximo** de Vygotsky: la distancia entre lo que alguien hace solo y lo que hace con la guía de otro.

Rasgo	Evaluación estática	Evaluación dinámica
Pregunta	¿Qué sabe hacer ahora?	¿Cuánto puede mejorar con ayuda?
Papel del evaluador	Neutral, sin ayudas	Mediador activo
Resultado	Puntuación comparada con un baremo	Ganancia y tipo de ayuda que funciona
Utilidad especial	Clasificación y comparación normativa	Personas con escasa escolarización o de otra cultura

Su principal inconveniente es la **estandarización**: cuanto más se adapta la ayuda a cada persona, más difícil es comparar resultados y estimar su fiabilidad.

Perspectivas futuras. La informática ha cambiado la aplicación de los tests. Los **tests adaptativos informatizados (TAI)**, basados en la teoría de respuesta al ítem (Psicometría), eligen cada ítem según las respuestas anteriores y logran la misma precisión con menos preguntas. La **evaluación en línea** facilita llegar a más personas, aunque obliga a controlar quién responde y en qué condiciones. La **inteligencia artificial** abre posibilidades en la corrección y la generación de ítems, junto con nuevas dudas sobre la transparencia y la equidad. La ética del uso de tests se estudia en Evaluación Psicológica I.

Consenso y debate

Consenso: el CI de desviación (media 100, DT 15) sustituyó al CI de razón y es el estándar actual. El efecto Flynn existe, es de origen ambiental, y obliga a renormar los tests (Trahan et al., 2014). Su inversión en Noruega también es ambiental, porque aparece entre hermanos (Bratsberg y Rogeberg, 2018). La escolarización aumenta el CI (Ritchie y Tucker-Drob, 2018).

Debate: qué factores ambientales explican el efecto Flynn y su inversión, y cuánto pesa cada uno. También se discute cómo estandarizar la evaluación dinámica sin perder su flexibilidad.

Mito frecuente

Mito: «El CI es inmutable: el que se tiene de niño es el que se tendrá toda la vida».

Realidad: el CI es bastante estable, pero no fijo. Las puntuaciones de poblaciones enteras han subido unos 2,3 puntos por década (Trahan et al., 2014) y han bajado en cohortes recientes de algunos países (Bratsberg y Rogeberg, 2018), y cada año adicional de escolarización añade entre 1 y 5 puntos (Ritchie y Tucker-Drob, 2018).

Conceptos clave

Concepto	Definición
Laboratorio antropométrico	Centro de Galton (1884) que medía capacidades sensoriales y tiempo de reacción
Escala Binet-Simon	Primera escala de inteligencia (1905), con tareas ordenadas por dificultad
Edad mental	Nivel de edad que corresponde al rendimiento de una persona en la escala
CI de razón	Edad mental entre edad cronológica, por 100 (Stern, 1912; Terman, 1916)
CI de desviación	Posición respecto al propio grupo de edad en una escala de media 100 y DT 15 (Wechsler)

Concepto	Definición
Army Alpha y Beta	Tests colectivos, verbal y no verbal, del ejército de EE. UU. (1917)
Efecto Flynn	Aumento de las puntuaciones de CI de generación en generación, de unos 2–3 puntos por década
Evaluación dinámica	Evaluación del potencial de aprendizaje mediante test, ayuda mediada y retest

Clave PIR

Prioridad media. Se pregunta quién introdujo la edad mental, el cociente intelectual y el factor 100, qué diferencia hay entre el CI de razón y el de desviación, y qué es el efecto Flynn. Trampa típica: atribuir el CI a Binet, cuando Binet usó la edad mental, Stern propuso el cociente (1912) y Terman lo multiplicó por 100 (1916). Otra trampa es interpretar el efecto Flynn como un cambio genético.

Autoevaluación

1. ¿Quién propuso por primera vez dividir la edad mental entre la edad cronológica?
a) Binet
b) Terman
c) Stern

2. El principal problema del CI de razón en adultos es que…
a) la edad mental deja de crecer y el CI baja artificialmente
b) exige comparar a la persona con un grupo de su misma edad
c) solo puede calcularse con tests de aplicación colectiva

3. El Army Beta se diseñó para…
a) seleccionar oficiales con alto nivel verbal
b) evaluar a reclutas que no sabían leer o no dominaban el inglés
c) medir el tiempo de reacción de los soldados

4. Que la inversión del efecto Flynn aparezca también entre hermanos indica que…
a) se debe a cambios en la composición genética de la población
b) es un artefacto de los baremos utilizados
c) su origen es ambiental

5. Si se aplica un test con baremos de hace veinte años, lo más probable es que el CI obtenido…
a) esté sobrestimado
b) esté infraestimado
c) no se vea afectado

Soluciones

1 c. Stern (1912) propuso el cociente; Terman lo multiplicó por 100 y Binet trabajó con la edad mental. **2 a.** La edad cronológica sigue aumentando y el cociente desciende sin que la capacidad cambie. **3 b.** El Alpha era verbal y el Beta, no verbal. **4 c.** Los hermanos comparten familia y origen, de modo que los cambios entre ellos no se explican por la composición de la población. **5 a.** Por el efecto Flynn, la persona se compara con una generación que rendía menos.

Unidad 7 · Las escalas de Wechsler

Objetivos: describir la lógica común de las escalas de Wechsler, su aplicación individual y sus métricas de puntuación; conocer la estructura de la WAIS-IV, la WAIS-5, el WISC-V y el WPPSI-IV y elegir la escala adecuada según la edad; interpretar los resultados por niveles y evitar los errores más frecuentes.

7.1 Lógica común de las escalas de Wechsler

David Wechsler publicó en 1939 el **Wechsler-Bellevue**, la primera escala de una familia que hoy domina la evaluación de la inteligencia en todo el mundo. Su aportación más duradera fue sustituir el cociente entre edad mental y edad cronológica por el **CI de desviación**: la puntuación expresa la posición de la persona respecto a las de su mismo grupo de edad (Unidad 6). A partir de esa escala se creó una serie de instrumentos que comparten diseño y métrica, pero se dirigen a edades distintas:

Escala	Población	Edad	Adaptación española vigente
WPPSI-IV	Preescolar y primeros cursos	2:6 a 7:7	Pearson, 2014
WISC-V	Niños y adolescentes	6:0 a 16:11	Pearson, 2015
WAIS-IV	Adultos	16 a 89	Pearson, 2012
WAIS-5	Adultos	16:0 a 90:11	En estandarización en España

Todas son de **aplicación individual**. Un examinador formado trabaja con una sola persona: lee las preguntas en voz alta, presenta láminas y cubos, cronometra las tareas con límite de tiempo y anota las respuestas literalmente. Cada subtest tiene **reglas de inicio** según la edad, **reglas de retorno** si fallan los primeros ítems y **reglas de terminación** tras varios errores seguidos. Este formato permite además observar cómo trabaja la persona: si se precipita, si abandona ante la dificultad, si necesita que se le repitan las instrucciones. Ninguna escala de Wechsler está pensada para pasarse en grupo; confundirlas con los tests colectivos (Unidad 8) es un error de concepto.

Las puntuaciones siguen siempre la misma secuencia:

1. La **puntuación directa** de cada subtest (aciertos o puntos obtenidos).
2. La **puntuación escalar**, que compara la directa con el grupo de edad: **media 10 y DT 3**.
3. Las **puntuaciones compuestas** (índices y CI total), que suman varias escalares: **media 100 y DT 15**.
4. El **percentil** y el **intervalo de confianza** de cada puntuación compuesta.

Los baremos, el error típico de medida y los intervalos de confianza se explican en *Evaluación Psicológica I* (Unidad 9).

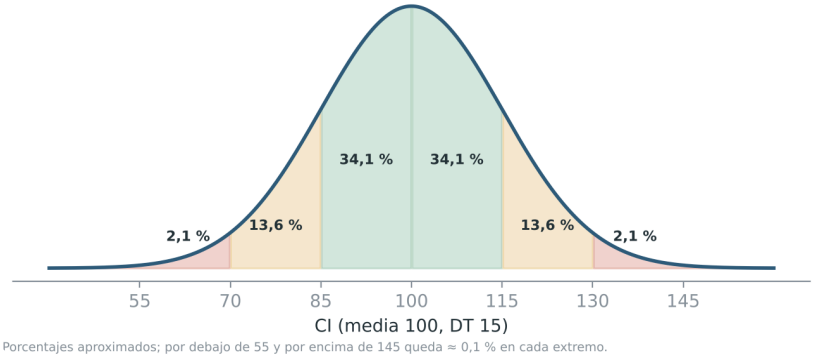


Figura 7.1. **Distribución del CI de desviación.** Con media 100 y DT 15, cada franja de una DT a ambos lados de la media reúne en torno al 34,1 % de la población, la siguiente el 13,6 % y la tercera el 2,1 %, más un 0,1 % aproximado en cada extremo. Así, cerca del 68 % puntúa entre 85 y 115 y cerca del 95 % entre 70 y 130. Elaboración propia.

Como muestra la figura 7.1, una puntuación de 115 está una DT por encima de la media y corresponde aproximadamente al percentil 84. Una de 70 está dos DT por debajo y la superan cerca del 98 % de las personas de esa edad. En un subtest, una escalar de 13 tiene el mismo significado que un índice de 115: una DT por encima de la media.

Las primeras escalas separaban un **CI verbal** y un **CI manipulativo** (o de ejecución). Las versiones actuales abandonaron esa división y organizan los subtests en **índices** que se corresponden con aptitudes amplias del modelo CHC (Unidad 5): comprensión verbal, razonamiento fluido, procesamiento visoespacial, memoria de trabajo y velocidad de procesamiento. El **CI total (CIT)** sigue siendo la puntuación más fiable y la que mejor representa el factor *g*.

Se usan en contextos clínicos, educativos, neuropsicológicos y forenses; su papel en la evaluación neuropsicológica y la estimación del CI premórbido se tratan en la Unidad 13.

7.2 WAIS-IV y WAIS-5

La WAIS-IV. Publicada en 2008 y adaptada en España por Pearson en 2012, se aplica de los 16 a los 89 años. Tiene **cuatro índices** y un CIT, con 10 subtests principales y 5 opcionales:

Índice	Subtests principales	Subtests opcionales
Comprensión Verbal (CV)	Semejanzas, Vocabulario, Información	Comprensión
Razonamiento Perceptivo (RP)	Cubos, Matrices, Puzles visuales	Balanzas, Figuras incompletas
Memoria de Trabajo (MT)	Dígitos, Aritmética	Letras y números
Velocidad de Procesamiento (VP)	Búsqueda de símbolos, Claves	Cancelación

Los subtests opcionales sustituyen a uno principal que no puede aplicarse o queda invalidado, por ejemplo si una persona con temblor no puede manipular los cubos. El CIT se obtiene con los 10 principales. Además, la WAIS-IV ofrece el **Índice de Capacidad General (ICG)**, que se calcula solo con los subtests de CV y RP. El ICG depende menos de la memoria de trabajo y de la rapidez, por lo que resulta útil cuando estas están alteradas, como ocurre a menudo tras un traumatismo craneoencefálico o con algunos tratamientos farmacológicos.

La WAIS-5. Publicada en EE. UU. en 2024, cubre de los 16:0 a los 90:11 años. El cambio principal es estructural: divide el antiguo Razonamiento Perceptivo en dos índices, **Visoespacial (VE)** y **Razonamiento Fluido (RF)**, igual que ya hacía el WISC-V. Así pasa a tener **cinco índices primarios**: CV, VE, RF, MT y VP.

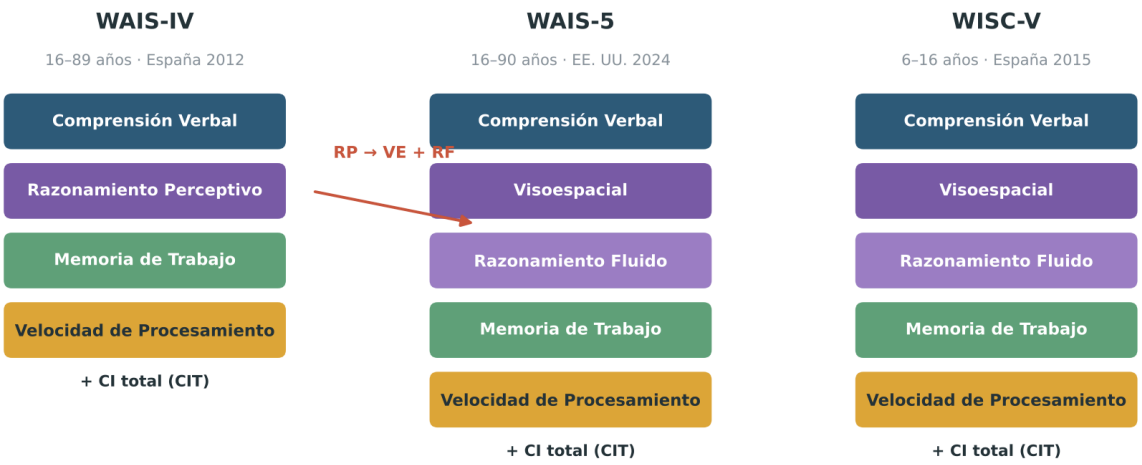


Figura 7.2. **Índices primarios de tres escalas de Wechsler.** La WAIS-IV (16–89 años) tiene cuatro índices: CV, RP, MT y VP. La WAIS-5 (16:0–90:11) y el WISC-V (6:0–16:11) tienen cinco: CV, VE, RF, MT y VP, porque el Razonamiento Perceptivo se divide en Visoespacial y Razonamiento Fluido. Elaboración propia.

Como muestra la figura 7.2, la WAIS-5 acerca la escala de adultos a la infantil y al modelo CHC. Según la editorial, tiene:

- **Batería primaria** de 10 subtests, de un total de unos 20.
- **CIT** calculado con 7 subtests.
- **15 índices auxiliares**, que agrupan subtests de otras formas para responder a preguntas concretas.
- Varios **subtests nuevos**, que Pearson denomina en inglés *Set Relations*, *Running Digits*, *Naming Speed Quantity*, *Spatial Addition* y *Symbol Span*.

Dos precauciones: los nombres españoles de los subtests nuevos se fijarán en la adaptación y aún no hay traducción oficial, y la composición exacta del CIT está pendiente de confirmar en el manual técnico.

La situación en España. Mientras la WAIS-5 se estandariza, la escala de adultos disponible es la WAIS-IV con normas de 2012. Esto tiene una consecuencia práctica que conecta con el efecto Flynn (Unidad 6): durante buena parte del siglo XX las puntuaciones subieron unos 2,3 puntos por década (Trahan et al., 2014), y unas normas antiguas tienden a **inflar el CI** porque comparan a la persona con una generación que puntuaba menos. Las normas de la WAIS-IV tienen ya más de una década, y es un factor que hay que tener en cuenta cuando una puntuación está cerca de un punto de corte, como en una valoración de discapacidad intelectual.

Un ejemplo: tras un ictus, un hombre de 45 años obtiene un CIT de 88, con CV de 108 y VP de 76. El ICG, que no incluye velocidad, refleja mejor su razonamiento; la VP señala una lentitud que conviene explorar con pruebas neuropsicológicas.

7.3 WISC-V y WPPSI-IV

El WISC-V. Publicado en 2014 y adaptado por Pearson en 2015, evalúa de los 6:0 a los 16:11 años. Fue la primera escala de la familia con **cinco índices primarios**, cada uno formado por dos subtests:

Índice primario	Subtests
Comprensión Verbal (CV)	Semejanzas, Vocabulario
Visoespacial (VE)	Cubos, Puzles visuales
Razonamiento Fluido (RF)	Matrices, Balanzas

Índice primario	Subtests
Memoria de Trabajo (MT)	Dígitos, Span de dibujos
Velocidad de Procesamiento (VP)	Claves, Búsqueda de símbolos

El **CIT** se obtiene con **7 subtests**, y no con los 10. Además de los primarios, el WISC-V ofrece **cinco índices secundarios**:

- **Razonamiento Cuantitativo**: problemas con números y cantidades.
- **Memoria de Trabajo Auditiva**: tareas de retención presentadas de forma oral.
- **No Verbal**: reduce al mínimo las demandas de lenguaje expresivo; útil con niños con trastornos del lenguaje o que dominan poco el castellano.
- **Capacidad General**: equivalente al ICG de la WAIS-IV, basado en subtests de comprensión verbal, visoespacial y razonamiento fluido.
- **Competencia Cognitiva**: reúne la memoria de trabajo y la velocidad de procesamiento.

Comparar Capacidad General y Competencia Cognitiva es habitual: un niño puede razonar bien y rendir peor en clase porque procesa con lentitud. Ese patrón no diagnostica nada por sí solo, pero orienta la evaluación y las adaptaciones escolares.

El WPPSI-IV. Publicado en 2012 y adaptado en 2014, cubre de los 2:6 a los 7:7 años, con 15 subtests en total. Tiene dos tramos de edad con estructura distinta, porque la capacidad de los más pequeños es menos diferenciada y su atención es más breve:

Tramo	Índices primarios	Índices secundarios
2:6 a 3:11	3: Comprensión Verbal, Visoespacial y Memoria de Trabajo	Sí, en menor número
4:0 a 7:7	5: CV, VE, RF, MT y VP	4

Con preescolares, la aplicación exige sesiones cortas, pausas y un examinador que mantenga el interés sin dar pistas: un niño que no colabora puede obtener una puntuación que no refleja su capacidad.

Elegir la escala por la edad. Los rangos de las escalas se **solapan**: entre los 6:0 y los 7:7 años pueden aplicarse tanto el WPPSI-IV como el WISC-V, y a los 16 años, tanto el WISC-V como la WAIS. En el solapamiento se elige según el nivel esperado. Si se sospecha un rendimiento bajo, conviene la escala de menor edad, que tiene más ítems fáciles y discrimina mejor en la parte baja (más **suelo**). Si se sospechan altas capacidades, conviene la de mayor edad, que tiene ítems más difíciles (más **techo**).

Un minicaso: Hugo tiene 6 años y 10 meses, y su tutora sospecha un retraso en el desarrollo. Con el WPPSI-IV, sus respuestas correctas a los ítems más sencillos permiten distinguir niveles por debajo de la media; con el WISC-V, muchos subtests empezarían por encima de lo que puede resolver y la puntuación quedaría «aplastada» en el suelo. Para una compañera de su edad con un desarrollo muy adelantado, en cambio, el WISC-V evitaría que acertara casi todo.

El uso escolar de estas escalas (necesidades educativas, altas capacidades, dificultades de aprendizaje) se estudia en Psicología Educativa y Orientación.

7.4 Interpretación por niveles y errores frecuentes

Una escala de Wechsler no produce un número, sino un conjunto de puntuaciones que se interpretan de lo más general a lo más particular. La lógica es sencilla: cuanto más general es la puntuación, más ítems la sostienen y más fiable es.

1. **CIT.** Primero se valora el nivel global con su intervalo de confianza y su percentil. Es la puntuación más fiable y la que mejor predice criterios como el rendimiento académico.
2. **Índices.** Después se describe cada índice. Si un índice reúne subtests con resultados muy dispares, conviene interpretarlo con cautela, porque deja de representar una capacidad unitaria.
3. **Discrepancias entre índices.** Se comprueba si las diferencias son **estadísticamente significativas** (superan lo esperable por el error de medida) y si son **infrecuentes** en la muestra normativa. Muchas personas sin ningún problema muestran diferencias notables entre índices, de modo que una diferencia significativa no es por sí misma un signo clínico.
4. **Puntos fuertes y débiles.** Cada índice o subtest se compara con la media de la propia persona. Es una comparación **ipsativa**: dice qué hace mejor o peor cada uno respecto a sí mismo, no respecto a los demás.
5. **Análisis cualitativo.** Tipo de errores, estrategias, conducta durante la prueba.

Cuándo el CIT deja de ser un buen resumen. Si hay discrepancias grandes entre índices, el CIT es una media de capacidades muy distintas y **no conviene interpretarlo** como si describiera a la persona. Imaginemos a Marta, de 34 años, con CV de 121, RP de 112, MT de 95 y VP de 79. Su CIT, en torno a 102, sugiere una capacidad «media» que no se parece a nadie: razona muy bien con material verbal y trabaja con lentitud. En estos casos se describe el perfil de índices y se recurre al ICG, que en este ejemplo refleja mejor su capacidad de razonamiento.

Errores frecuentes.

Error	Por qué es un error
Llamar «colectivas» a las escalas de Wechsler	Son de aplicación individual, con un examinador y una persona
Atribuir cinco índices a la WAIS-IV	Tiene cuatro; los cinco son del WISC-V, el WPPSI-IV (4:0–7:7) y la WAIS-5
Confundir WISC y WPPSI por la edad	El WPPSI-IV llega a 7:7; el WISC-V empieza en 6:0
Interpretar subtests aislados como si fueran diagnósticos	Son menos fiables que los índices; un perfil de subtests no basta para diagnosticar un trastorno
Leer la puntuación sin intervalo de confianza	Un CIT de 72 puede ser compatible con valores por encima y por debajo de 70
Diagnosticar solo con el CI	La discapacidad intelectual exige también limitaciones en el funcionamiento adaptativo
Ignorar la antigüedad de los baremos	Las normas antiguas tienden a inflar el CI (efecto Flynn)

En la discapacidad intelectual, una puntuación en torno a dos DT por debajo de la media, considerando el error de medida, es solo una parte: el DSM-5-TR y la CIE-11 exigen también **limitaciones en el funcionamiento adaptativo** con inicio en el desarrollo, que se evalúan con otros instrumentos y con información de la familia o la escuela (asignatura de Psicopatología).

Hay que considerar también las **condiciones de la persona**: una lengua materna distinta, un déficit sensorial, un trastorno motor o una escolarización irregular pueden bajar puntuaciones que no miden lo que pretenden. Recordemos además que el CI es estable, pero no inmutable: cada año adicional de escolarización se asocia con una ganancia estimada de entre 1 y 5 puntos (Ritchie y Tucker-Drob, 2018). La ética del uso de tests y la comunicación de resultados se tratan en *Evaluación Psicológica I*.

Consenso y debate

Consenso: las escalas de Wechsler son de aplicación individual y se interpretan por niveles, empezando por el CIT, que es la puntuación más fiable y la mejor medida de *g*. Las versiones actuales organizan los índices según el modelo CHC (Schneider y McGrew, 2018), con cinco índices primarios en el WISC-V y la WAIS-5. Los baremos envejecen y deben renovarse (Trahan et al., 2014).

Debate: cuánto aportan los índices más allá del CIT. Como gran parte de la varianza de los subtests se debe a *g*, se discute hasta qué punto los índices miden capacidades distintas y si su interpretación tiene validez incremental. También se discute cómo tratar puntuaciones cercanas a un punto de corte cuando los baremos tienen más de una década.

Mito frecuente

Mito: «Las escalas de Wechsler se pueden aplicar en grupo, como cualquier test de inteligencia de lápiz y papel».

Realidad: el WAIS-IV, el WISC-V y el WPPSI-IV son de aplicación individual, con un examinador formado que presenta los ítems, cronometra y registra las respuestas siguiendo reglas de inicio y terminación (Wechsler, 2012; 2015). Esa forma de aplicación es la que da validez a las normas y permite observar la conducta de la persona durante la prueba.

Conceptos clave

Concepto	Definición
CI de desviación	Posición de la persona respecto a su grupo de edad, con media 100 y DT 15 (Wechsler, 1939)
Puntuación escalar	Puntuación de cada subtest normalizada por edad, con media 10 y DT 3
CIT	CI total; la puntuación compuesta más fiable y la mejor medida de *g* en las escalas de Wechsler
Índice primario	Puntuación compuesta de una aptitud amplia, como Comprensión Verbal o Velocidad de Procesamiento
ICG	Índice de Capacidad General; usa solo los subtests de comprensión verbal y razonamiento
Subtest opcional	Subtest que puede sustituir a uno principal invalidado o no aplicable
Suelo y techo	Capacidad de un test para discriminar en los niveles más bajos y más altos de rendimiento
Comparación ipsativa	Comparación de cada puntuación con la media de la propia persona, no con el grupo normativo

Clave PIR

Prioridad alta. Se pregunta el número de índices de cada escala, el rango de edad de cada una, las métricas (media 10 y DT 3 en los subtests, media 100 y DT 15 en los compuestos) y qué hacer cuando hay discrepancias grandes entre índices. Trampas típicas: atribuir cinco índices a la WAIS-IV, confundir la división de Razonamiento Perceptivo en Visoespacial y Razonamiento Fluido, equivocar el solapamiento de edades entre WPPSI-IV y WISC-V, y presentar las escalas de Wechsler como colectivas.

Autoevaluación

1. ¿Cuántos índices primarios tiene la WAIS-IV?
a) Cinco, igual que el WISC-V
b) Cuatro: CV, RP, MT y VP
c) Tres, más el CI total

2. Una puntuación escalar de 13 en un subtest de Wechsler indica un rendimiento…
a) una DT por encima de la media
b) en torno al percentil 13
c) dos DT por encima de la media

3. Para evaluar la inteligencia de una niña de 3 años, la escala adecuada es…
a) el WISC-V
b) la WAIS-IV
c) el WPPSI-IV

4. ¿Qué cambio estructural introduce la WAIS-5 respecto a la WAIS-IV?
a) Divide Razonamiento Perceptivo en Visoespacial y Razonamiento Fluido
b) Recupera la división entre CI verbal y CI manipulativo
c) Elimina el índice de Velocidad de Procesamiento

5. Si una persona muestra discrepancias muy grandes entre sus índices, lo más adecuado es…
a) basar el informe en el CIT, que compensa las diferencias
b) describir el perfil de índices sin resumirlo en el CIT
c) repetir la escala en una aplicación colectiva

Soluciones

1 b. Los cinco índices corresponden al WISC-V, al WPPSI-IV a partir de 4:0 y a la WAIS-5. **2 a.** Con media 10 y DT 3, una escalar de 13 está una DT por encima, como un índice de 115. **3 c.** El WPPSI-IV cubre de 2:6 a 7:7; el WISC-V empieza a los 6:0. **4 a.** Es la misma división que ya hacía el WISC-V. **5 b.** Con discrepancias grandes, el CIT promedia capacidades muy distintas; el ICG o el perfil de índices informan mejor.

Unidad 8 · Otros tests de inteligencia y tests de aptitudes

Objetivos: describir las matrices de Raven y los tests de dominós como medidas no verbales de *g* y explicar por qué no están libres de cultura; conocer el Stanford-Binet 5, el K-BIT y el RIAS y distinguir las pruebas individuales de las colectivas; diferenciar aptitud e inteligencia general y describir las baterías DAT-5, FACT y PMA.

8.1 Matrices de Raven y tests de dominós

Las matrices progresivas de Raven. John C. Raven publicó en 1938 un test que se ha convertido en el prototipo de la medida de la **inteligencia fluida (Gf)** y del **factor g**. Cada ítem presenta una matriz de figuras abstractas que siguen una o varias reglas (de forma, de número, de posición) y a la que le falta una pieza; la persona debe elegir entre varias opciones la que completa el patrón. No hay que leer ni hablar, y el contenido no remite a conocimientos escolares. La dificultad aumenta de forma progresiva, de ahí el nombre: los primeros ítems se resuelven por percepción de la forma y los últimos exigen descubrir varias reglas a la vez y combinarlas.

Existen varias versiones según el nivel de la población:

Versión	Población	Rasgo principal
Matrices Generales o Estándar (SPM)	Adolescentes y adultos	60 ítems en cinco series (A a E)
Matrices Coloreadas (CPM)	Niños pequeños, personas mayores y personas con discapacidad	Ítems más sencillos y en color
Matrices Avanzadas (APM)	Personas con capacidad alta	Ítems más difíciles, para evitar el efecto techo
Raven 2	Distintas edades	Revisión más reciente de la prueba

Raven es un **test de poder**, no de velocidad: lo que importa es hasta qué dificultad llega la persona, no lo rápido que trabaja. Puede aplicarse de forma individual o colectiva, lo que lo hace útil en selección de personal, en orientación escolar y en investigación transcultural. Los resultados suelen expresarse en percentiles respecto a baremos de edad.

¿Es un test libre de cultura? No. Raven tiene una **carga cultural reducida**, pero no nula. Resolver matrices requiere familiaridad con el formato de las tareas abstractas, con las hojas de respuesta y con la idea misma de buscar reglas en patrones geométricos, algo que la escolarización entrena. La prueba más clara es histórica: las ganancias asociadas al efecto Flynn han sido especialmente grandes en tests de tipo Raven (Flynn, 1987), y unas subidas tan rápidas, en pocas décadas, solo pueden deberse a cambios ambientales (Unidad 6). Un test que se ve tan afectado por el entorno no puede estar «libre» de él.

Los tests de dominós. Siguen la misma lógica que Raven con otro material: series de fichas de dominó cuya última ficha está vacía. La persona debe deducir la regla que gobierna la serie (una progresión, una alternancia, una suma) y escribir los puntos que corresponden a cada mitad de la ficha. Las versiones más conocidas son el **D-48**, derivado del trabajo de Anstey, y el **D-70**. Se consideran medidas **no verbales de g** y tienen un componente de razonamiento numérico mayor que las matrices. Se aplican de forma individual o colectiva, con un tiempo límite holgado, porque lo que interesa es el nivel de razonamiento y no la rapidez.

Rasgo	Raven	Dominós
Material	Matrices de figuras geométricas	Series de fichas de dominó
Respuesta	Elegir una opción entre varias	Escribir los puntos de la ficha vacía

Rasgo	Raven	Dominós
Qué mide sobre todo	Gf y *g*	*g* no verbal, con más peso del razonamiento numérico
Aplicación	Individual o colectiva	Individual o colectiva

Estas pruebas no sustituyen a una escala completa: un candidato con un percentil 90 en Raven razona muy bien con material nuevo, pero eso no informa de su vocabulario, su memoria de trabajo o su capacidad para redactar un informe.

8.2 Stanford-Binet 5, K-BIT y RIAS

Estas tres pruebas son de **aplicación individual**, como las escalas de Wechsler. Las dos últimas son pruebas breves, pensadas para estimar el nivel intelectual cuando no se necesita una evaluación completa.

Stanford-Binet 5 (SB5). La quinta edición (Roid, 2003) es la heredera de la escala de Binet y Simon revisada por Terman (Unidad 6). Cubre una franja de edad muy amplia, de los 2 a los 85 años o más. Su estructura cruza **cinco factores** con **dos dominios**:

Factor	Dominio verbal	Dominio no verbal
Razonamiento fluido	Subtest verbal	Subtest no verbal
Conocimiento	Subtest verbal	Subtest no verbal
Razonamiento cuantitativo	Subtest verbal	Subtest no verbal
Procesamiento visoespacial	Subtest verbal	Subtest no verbal
Memoria de trabajo	Subtest verbal	Subtest no verbal

El resultado son 10 subtests que permiten obtener un CI total, un CI verbal, un CI no verbal y puntuaciones en los cinco factores. La ventaja del diseño es que cada factor puede valorarse con y sin lenguaje, lo que ayuda con personas con dificultades de expresión oral. Desde la revisión de 1960 hasta la cuarta edición (1986), el Stanford-Binet usaba un CI de desviación con DT 16; la SB5 adopta la métrica habitual, con media 100 y DT 15. Sus ítems muy fáciles y muy difíciles le dan buen suelo y buen techo, útiles en la discapacidad intelectual grave y en las altas capacidades.

K-BIT. El Test Breve de Inteligencia de Kaufman (Kaufman y Kaufman, 1990) tiene solo **dos subtests**: **vocabulario**, que se relaciona con la inteligencia cristalizada, y **matrices**, que se relaciona con la fluida. Ofrece una puntuación verbal, una no verbal y un CI compuesto. Su brevedad lo hace útil para un cribado, para estimar el nivel intelectual en una investigación o para decidir si hace falta una evaluación más completa. Pearson tiene en curso una revisión del KBIT-2.

RIAS. Las Escalas de Inteligencia de Reynolds (Reynolds y Kamphaus, 2003), adaptadas por TEA, ofrecen un **índice verbal**, un **índice no verbal** y un **índice de memoria**, además de un índice global. Se aplican en relativamente poco tiempo y reducen las exigencias motoras y de velocidad, lo que permite separar mejor la capacidad de razonamiento de la rapidez manual.

Cribado frente a diagnóstico. Las pruebas breves sacrifican amplitud: con dos o cuatro subtests no se puede describir un perfil de capacidades ni detectar con fiabilidad discrepancias entre áreas. Por eso sirven para decidir **quién necesita** una evaluación completa, no para sustituirla. Por ejemplo, el K-BIT basta para comprobar si una paciente puede responder un autoinforme largo; si el resultado se acercara al límite de la discapacidad intelectual, harían falta una escala completa y una evaluación del funcionamiento adaptativo.

Prueba	Aplicación	Uso principal
Escalas de Wechsler	Individual	Evaluación completa con perfil de índices

Prueba	Aplicación	Uso principal
Stanford-Binet 5	Individual	Evaluación completa, rango de edad muy amplio
K-BIT	Individual	Cribado y estimación rápida
RIAS	Individual	Estimación con índice de memoria y pocas demandas motoras

8.3 Tests colectivos: IG-2, Otis y BADyG

Los **tests colectivos** permiten evaluar a muchas personas a la vez. Nacieron con el Army Alpha y el Army Beta en 1917 (Unidad 6) y hoy se usan sobre todo en la orientación escolar y en la selección de personal. Comparten varios rasgos:

- Se presentan en un **cuadernillo** o en pantalla, con instrucciones escritas y ejemplos.
- Tienen **tiempo limitado** por prueba.
- Las respuestas se marcan en una **hoja** y se corrigen con plantilla o de forma informatizada.
- Un solo aplicador puede atender a un aula entera.

Rasgo	Tests individuales	Tests colectivos
Coste y tiempo por persona	Alto	Bajo
Observación de la conducta	Rica	Casi nula
Dependencia de la lectura	Baja; las instrucciones son orales	Alta en la mayoría
Control de la motivación y la comprensión	El examinador puede detectar problemas	Difícil de comprobar
Uso típico	Diagnóstico y decisiones individuales	Cribado, orientación y selección

Hay que insistir en una distinción que a menudo se confunde: **las escalas de Wechsler, el Stanford-Binet y el K-BIT son de aplicación individual**. Raven y los dominós pueden aplicarse de ambas formas. Los tests de esta sección están pensados desde el principio para la aplicación colectiva.

IG-2. El test de Inteligencia General de TEA evalúa el **razonamiento abstracto** y el **razonamiento verbal**. Es una prueba rápida, de uso frecuente en selección de personal y en orientación, que proporciona una estimación global de la capacidad de razonamiento.

Test de Otis. Arthur Otis participó en el desarrollo de los tests colectivos del ejército estadounidense, y su test es uno de los ejemplos clásicos de prueba de inteligencia general en grupo. El **Otis sencillo** fue adaptado en España por TEA en 1958, con la participación de Mariano Yela. Combina ítems verbales, numéricos y de razonamiento de dificultad creciente. Su antigüedad obliga a valorar con cautela sus baremos.

BADyG. La Batería de Aptitudes Diferenciales y Generales, publicada por CEPE, se organiza en **niveles** que siguen las etapas escolares, desde infantil hasta bachillerato. Combina pruebas de razonamiento verbal, numérico y espacial con otras aptitudes, y ofrece tanto una puntuación global como un **perfil**. Es uno de los instrumentos más usados por los departamentos de orientación de los centros educativos españoles.

Límites de la aplicación colectiva. Un test colectivo mide la capacidad de quien comprende las instrucciones, lee con soltura y mantiene la motivación durante la sesión. Cuando alguna de estas condiciones falla, la puntuación baja por razones ajenas a la inteligencia. Un minicaso: el departamento de orientación de un instituto aplica el BADyG a todo segundo de ESO. Daniel obtiene un percentil 15 en las pruebas verbales y un 70 en las espaciales. Antes de concluir nada, la orientadora revisa su historia: tiene un diagnóstico de dislexia y en la sesión no terminó ninguna prueba verbal. Una evaluación individual, con instrucciones orales y sin tiempo

ajustado a la lectura, ofrecerá una imagen más fiel. El resultado colectivo ha cumplido su función de cribado, pero no sirve como diagnóstico.

8.4 Evaluación de aptitudes: DAT-5, FACT y PMA

Aptitud e inteligencia. Una **aptitud** es una capacidad relativamente específica (verbal, numérica, espacial, mecánica, perceptiva) que predice la facilidad con la que una persona **aprenderá** a desempeñarse en un ámbito concreto. Se distingue de dos conceptos cercanos:

- De la **inteligencia general**, que es una capacidad amplia, común a todas las tareas cognitivas.
- Del **rendimiento** o la **habilidad adquirida**, que describe lo que la persona ya sabe hacer. Una aptitud mira al futuro: alguien con buena aptitud espacial y sin formación técnica aprenderá antes a leer planos que otra persona con poca aptitud.

La evaluación de aptitudes es heredera del modelo de **aptitudes mentales primarias** de Thurstone (Unidad 5). Su ámbito natural es la orientación académica y profesional y la selección de personal. Las **baterías de aptitudes múltiples** reúnen varias pruebas, cada una centrada en una aptitud, y tienen una ventaja metodológica: al compartir **grupo normativo**, sus puntuaciones están en la misma escala, y eso permite comparar las aptitudes de una persona entre sí y obtener un **perfil**.

DAT y DAT-5. El **Test de Aptitudes Diferenciales** de Bennett, Seashore y Wesman es la batería de aptitudes múltiples más conocida; en España se usa la adaptación de TEA del DAT-5. Evalúa razonamiento verbal, razonamiento numérico, razonamiento abstracto, razonamiento mecánico, relaciones espaciales, ortografía y velocidad y precisión perceptiva. La suma de razonamiento verbal y numérico se ha usado tradicionalmente como indicador de **aptitud académica**, porque es la combinación que mejor predice el rendimiento escolar.

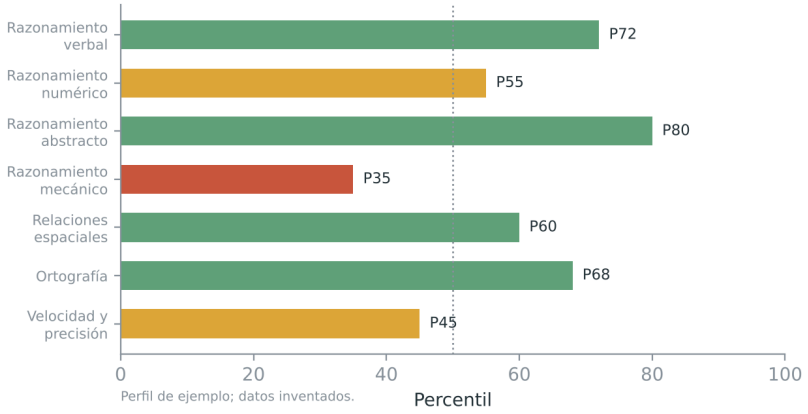


Figura 8.1. **Perfil de aptitudes de una estudiante de bachillerato.** Percentiles en siete escalas de una batería tipo DAT, con la línea del percentil 50 como referencia: destacan el razonamiento abstracto (80) y el verbal (72), y el punto más bajo es el razonamiento mecánico (35). Datos inventados. Elaboración propia.

Como muestra la figura 8.1, el perfil permite ver de un vistazo qué aptitudes destacan dentro de la misma persona. Una estudiante con este patrón, buena en razonamiento abstracto y verbal y menos en el mecánico, podría inclinarse por estudios en los que pese más el razonamiento con conceptos que el manejo de máquinas, pero la decisión debe integrar también sus intereses (Unidad 14), su rendimiento académico y sus circunstancias. Un perfil de aptitudes informa; no decide.

FACT. Las **Pruebas de Clasificación de Aptitudes** de Flanagan derivan del trabajo de este psicólogo en la selección de tripulaciones de vuelo para las fuerzas aéreas estadounidenses en la Segunda Guerra Mundial. Su rasgo diferencial es el método: en lugar de partir del análisis factorial, se identificaron los **elementos del trabajo** mediante el **análisis de incidentes críticos**, es decir, recogiendo conductas concretas que distinguían un desempeño eficaz de uno ineficaz en distintas ocupaciones. Cada prueba mide uno de esos elementos

(inspección, memoria, coordinación, comprensión mecánica, entre otros), y las puntuaciones se combinan para estimar la adecuación a diferentes ocupaciones.

PMA. El test de **Aptitudes Mentales Primarias**, en la adaptación de TEA, traslada directamente el modelo de Thurstone a una batería breve. Evalúa cinco factores: verbal, espacial, razonamiento, numérico y fluidez verbal. Ilustra bien cómo un modelo teórico se convierte en un instrumento.

Batería	Origen	Qué aporta
DAT-5	Bennett, Seashore y Wesman	Perfil de aptitudes para la orientación académica y profesional
FACT	Flanagan; incidentes críticos	Aptitudes ligadas a elementos concretos del trabajo
PMA	Thurstone	Cinco aptitudes primarias en formato breve

Una cautela. Las pruebas de una batería de aptitudes correlacionan bastante entre sí, porque todas comparten una parte importante de *g*. Por eso, buena parte de su capacidad predictiva procede del factor general, y la ventaja de usar un perfil diferenciado frente a una sola puntuación global es más modesta de lo que sugiere la batería. El uso de estas baterías en la orientación se amplía en la asignatura de Psicología Educativa y Orientación.

Consenso y debate

Consenso: las matrices de Raven y los dominós son buenas medidas no verbales de *g* y Gf, pero no están libres de cultura (Flynn, 1987). Las escalas de Wechsler, el Stanford-Binet 5 y el K-BIT son de aplicación individual; los tests colectivos sirven para el cribado, la orientación y la selección, no para el diagnóstico individual. Las pruebas breves no sustituyen a una evaluación completa.

Debate: la validez diferencial de las baterías de aptitudes múltiples. Como sus pruebas comparten mucha varianza con *g*, se discute cuánto añade el perfil de aptitudes específicas a la predicción que ya ofrece una medida global, y en qué decisiones (orientación frente a selección) merece la pena interpretar el perfil.

Mito frecuente

Mito: «Las matrices de Raven son un test libre de cultura: como no usan palabras, miden la inteligencia pura sin influencia del entorno».

Realidad: Raven reduce la carga cultural, pero no la elimina. Las puntuaciones en este tipo de tests subieron con gran rapidez a lo largo del siglo XX (Flynn, 1987), y la escolarización se asocia con ganancias en el CI (Ritchie y Tucker-Drob, 2018). La familiaridad con las tareas abstractas y con el formato de examen influye en el rendimiento.

Conceptos clave

Concepto	Definición
Matrices de Raven	Test no verbal de matrices incompletas; prototipo de medida de Gf y *g* (Raven, 1938)
Test de poder	Test que mide el nivel de dificultad alcanzado, no la rapidez de ejecución
Carga cultural	Grado en que el rendimiento en un test depende de conocimientos y experiencias culturales

Concepto	Definición
Stanford-Binet 5	Escala individual de 2 a 85 años o más con 5 factores en dominios verbal y no verbal (Roid, 2003)
K-BIT	Test breve individual con vocabulario y matrices, útil para el cribado (Kaufman y Kaufman, 1990)
Test colectivo	Prueba diseñada para aplicarse a muchas personas a la vez con instrucciones escritas
Aptitud	Capacidad específica que predice la facilidad para aprender en un ámbito concreto
Batería de aptitudes múltiples	Conjunto de pruebas de aptitudes baremadas con la misma muestra, que permite un perfil

Clave PIR

Prioridad media. Se pregunta qué mide cada test (Raven y dominós, *g* no verbal), cuáles son individuales y cuáles colectivos, la estructura del Stanford-Binet 5 y el método de construcción del FACT. Trampas típicas: describir Raven como «libre de cultura», incluir las escalas de Wechsler o el Stanford-Binet entre los tests colectivos, confundir aptitud con inteligencia general y atribuir al FACT un origen factorial en lugar del análisis de incidentes críticos.

Autoevaluación

1. ¿Qué afirmación sobre las matrices de Raven es correcta?
a) Son un test libre de cultura porque no usan lenguaje
b) Tienen carga cultural reducida y miden sobre todo Gf y *g*
c) Son la medida de referencia de la inteligencia cristalizada

2. ¿Cuál de estas pruebas es de aplicación individual?
a) El Stanford-Binet 5
b) El BADyG
c) El IG-2

3. El K-BIT estima el nivel intelectual a partir de…
a) cubos, claves y búsqueda de símbolos
b) cinco factores en dos dominios
c) un subtest de vocabulario y otro de matrices

4. Los elementos que evalúan las pruebas FACT se identificaron mediante…
a) el análisis de incidentes críticos en distintas ocupaciones
b) el análisis factorial de las aptitudes primarias
c) la comparación de grupos clínicos y controles

5. ¿Qué distingue mejor una aptitud de la inteligencia general?
a) La aptitud es innata y la inteligencia, aprendida
b) La aptitud es específica y predice el aprendizaje en un ámbito concreto
c) La aptitud describe solo lo que la persona ya sabe hacer

Soluciones

1 b. Raven reduce la carga cultural, pero no la elimina; las ganancias del efecto Flynn lo demuestran. **2 a.** El Stanford-Binet 5 es individual; el BADyG y el IG-2 son colectivos. **3 c.** Vocabulario se relaciona con la inteligencia cristalizada y matrices con la fluida. **4 a.** Flanagan partió de conductas concretas que distinguían un desempeño eficaz de uno ineficaz. **5 b.** La inteligencia general es amplia; la aptitud es específica y mira al aprendizaje futuro, no al rendimiento actual.

Capítulo 3 · Evaluación de la personalidad

Los cuestionarios e inventarios de personalidad son, con diferencia, los instrumentos de personalidad más usados en la práctica profesional. Este capítulo estudia cómo funcionan, cómo se protegen frente a las respuestas sesgadas, con qué estrategias se construyen y qué miden los grandes inventarios clínicos y dimensionales, desde el MMPI hasta los modelos actuales de los trastornos de personalidad.

Unidad 9 · Los autoinformes de personalidad

Objetivos: describir las características que definen las pruebas objetivas de personalidad y sus usos principales; clasificar los instrumentos según su cobertura, su modelo, su modo de aplicación y su población; distinguir los principales sesgos de respuesta; explicar las estrategias de control de esos sesgos y las limitaciones de las escalas de validez.

9.1 Características y usos de las pruebas objetivas de personalidad

Se llama **prueba objetiva de personalidad** a un cuestionario o inventario de autoinforme con **estímulos estructurados**, **respuesta cerrada** y **corrección objetiva**. La persona lee frases cortas o palabras sueltas que la describen y elige entre unas pocas opciones: verdadero o falso, una escala de acuerdo de cuatro o cinco puntos, o una elección entre dos frases. Las respuestas se suman en **escalas** según una plantilla fija, de modo que dos correctores, o un programa informático, llegan exactamente a la misma puntuación.

Conviene aclarar el adjetivo. Lo «objetivo» es el paso de las respuestas a la puntuación (la **corrección**): cualquier corrector, con la misma plantilla, obtiene el mismo número. La interpretación posterior sigue exigiendo juicio clínico, y las respuestas pueden estar sesgadas. En las técnicas proyectivas (Unidades 3 y 4), en cambio, ya la codificación depende del evaluador. Hay además una ambigüedad terminológica. En la tradición de Cattell, los «datos T» o de test objetivo eran pruebas de rendimiento en las que la persona no sabe qué se mide (Unidad 1); en el uso habitual, en cambio, «prueba objetiva de personalidad» designa el autoinforme estructurado. En esta unidad se usa este segundo sentido.

Los rasgos que definen estos instrumentos son cinco:

- **Ítems estructurados** y formato de respuesta cerrado.
- **Escalas** que agrupan los ítems según un rasgo o un síndrome.
- **Corrección mecánica**, manual o informatizada.
- **Baremos** que permiten comparar a la persona con un grupo de referencia, normalmente mediante puntuaciones T o percentiles (Evaluación Psicológica I).
- **Escalas o índices de validez** que informan de si las respuestas son interpretables (apartados 9.3 y 9.4).

Su base es el **autoinforme**: la persona informa de cómo se ve a sí misma. Los fundamentos de este método, sus fuentes de error y los tipos de autoinforme se estudian en Evaluación Psicológica I (Unidades 15 y 16), y aquí no se repiten.

Usos principales. Estas pruebas se emplean en cuatro grandes ámbitos:

Ámbito	Para qué se usan	Ejemplos de instrumentos
Clínico y forense	Describir el funcionamiento, orientar el diagnóstico, medir el cambio, valorar la credibilidad del perfil	MMPI-2, MCMI-IV, PAI
Orientación	Aportar información sobre el propio estilo que ayude a elegir estudios o profesión	16PF-5, NEO-FFI
Selección y organizaciones	Completar con datos de personalidad la valoración de candidatos (p. ej., responsabilidad o estabilidad emocional)	Inventarios de cinco factores, 16PF-5
Investigación	Poner a prueba modelos de rasgos y examinar qué predicen	NEO-PI-R, EPQ-R, HEXACO

En la práctica española dominan los instrumentos psicométricos. En la encuesta de Muñiz, Hernández y Fernández-Hermida (2020) a profesionales de la psicología, los 25 tests más usados eran psicométricos, con el WISC, el MCMI y el PAI a la cabeza, y ninguna técnica proyectiva figuraba entre ellos.

Ventajas y límites. Las pruebas objetivas son económicas, pueden aplicarse a muchas personas a la vez, se corrigen sin error de juicio y ofrecen datos de fiabilidad y validez conocidos. Su punto débil es que dependen de que la persona **quiera y pueda** describirse con precisión. Quien no se conoce bien, no entiende los ítems o tiene motivos para dar una imagen concreta puede producir un perfil engañoso. Por eso incluyen controles de validez y su resultado se integra con la entrevista, la historia y otras fuentes. Una misma puntuación alta en ansiedad no se lee igual en quien pide ayuda por voluntad propia que en quien reclama una indemnización.

9.2 Clasificación de los instrumentos

No existe una clasificación única de los autoinformes de personalidad. Se combinan varios criterios, y un mismo instrumento puede describirse con todos ellos: el MMPI-2, por ejemplo, es multidimensional, clínico-empírico, aplicable en papel o en ordenador y destinado a adultos.

Por cobertura. Es el criterio más útil para elegir un instrumento.

- Los **inventarios multidimensionales** o integrales evalúan muchas dimensiones a la vez y ofrecen un perfil global. Son largos, pero permiten una visión de conjunto: NEO-PI-R, 16PF-5, MMPI-2.
- Los **instrumentos específicos** o de dominio restringido miden un solo constructo. Son breves y se usan para el cribado, el seguimiento o la investigación focalizada. Ejemplos clásicos son el STAI de Spielberger (ansiedad estado y rasgo), la escala de autoestima de Rosenberg, la escala de locus de control de Rotter o la BIS-11 de Barratt (impulsividad).

Por modelo de referencia. Los instrumentos se apoyan en marcos distintos, que determinan qué se mide y cómo se interpretan las puntuaciones:

1. **Rasgo-factorial**: describen la personalidad normal mediante dimensiones obtenidas por análisis factorial. Es el caso del 16PF-5, el EPQ-R, el NEO-PI-R o el BFQ (Unidad 11).
2. **Clínico-empírico**: sus escalas se definieron por su capacidad para distinguir grupos diagnósticos. El ejemplo por excelencia es el MMPI (Unidad 10).
3. **Teórico**: parten de una teoría concreta de la personalidad. El MCMI se basa en la teoría de Millon y el TCI-R, en el modelo psicobiológico de Cloninger (Unidades 10 y 11).

Este criterio está muy ligado al método de construcción, que se estudia en el apartado 10.1. Otra distinción próxima separa los instrumentos para **población general**, que describen la personalidad normal, de los **clínicos**, que buscan psicopatología. El California Psychological Inventory (CPI) de Gough es un ejemplo del primer grupo: se pensó para describir rasgos adaptativos, como la sociabilidad o la responsabilidad, en personas sin trastorno.

Por modo de aplicación. La versión de **papel y lápiz** sigue siendo frecuente, pero casi todos los inventarios actuales tienen una versión **informatizada**, que evita errores de corrección, registra los tiempos de respuesta y genera informes automáticos. Algunos permiten una aplicación **adaptativa**, en la que el programa elige los ítems según las respuestas previas; sus fundamentos (la teoría de respuesta al ítem) corresponden a Psicometría.

Por población. Los ítems, el vocabulario y los baremos cambian con la edad. Hay versiones específicas para **adolescentes**, como el MMPI-A o el MACI de Millon, y para **niños**, como el EPQ-J, la versión infantil y juvenil del cuestionario de Eysenck. Algunas escalas de autoconcepto infantil, como la de Piers-Harris, completan el abanico.

Un caso práctico muestra cómo se combinan los criterios. Un servicio de prevención de riesgos laborales quiere conocer el nivel de estrés de una plantilla de doscientas personas. Lo razonable es un instrumento **específico**, breve y aplicable en línea. Si una de esas personas inicia después un tratamiento psicológico por un posible trastorno, el clínico recurrirá a un inventario **multidimensional** y **clínico**, con escalas de validez y baremos de población clínica. La elección depende de la pregunta de evaluación, no de la fama del test.

9.3 Sesgos de respuesta: deseabilidad, aquiescencia y falseamiento

Un **sesgo de respuesta** es cualquier tendencia a contestar por razones distintas del contenido del ítem. Su efecto es añadir a la puntuación una parte que no refleja el rasgo medido. Conviene distinguir dos grandes tipos:

- Los **estilos de respuesta** son tendencias estables y en gran parte no intencionadas, que aparecen sea cual sea el contenido de los ítems.
- Las **actitudes de respuesta** o de distorsión son intentos, más o menos deliberados, de dar una imagen concreta en una situación concreta.

Deseabilidad social. Es la tendencia a responder lo que se considera socialmente aceptable: declararse paciente, honrado o trabajador con más frecuencia de lo que corresponde. Paulhus (1984) separó en ella un componente de **autoengaño**, sincero, y otro de **manejo de la impresión**, deliberado. El modelo y su instrumento de medida se estudian en Evaluación Psicológica I (Unidad 15). Para esta asignatura basta retener que la deseabilidad no es siempre mentira y que aumenta cuando hay algo en juego.

Aquiescencia. Es la tendencia a mostrarse de acuerdo con los ítems, sea cual sea su contenido. Su opuesto es la tendencia a responder sistemáticamente «no», a veces llamada **noesismo**. En una escala cuyos ítems están todos redactados en la misma dirección, una persona aquiescente obtiene puntuaciones altas sin poseer el rasgo.

Respuesta extrema y central. En las escalas de varias opciones, algunas personas eligen casi siempre los extremos y otras se refugian en el punto medio. Estos estilos alteran la dispersión de las puntuaciones y dificultan comparar a personas con hábitos de respuesta distintos.

Respuesta aleatoria. Ocurre cuando se contesta sin leer o sin entender: por cansancio, por falta de motivación, por dificultades de lectura o por un estado mental alterado. El perfil resultante parece patológico, pero no describe nada.

Falseamiento. Es la distorsión intencionada de las respuestas, y adopta dos direcciones:

Tipo	Qué busca la persona	Contexto típico
Falseamiento positivo (*faking good*) o disimulación	Parecer más sana, equilibrada o capaz de lo que es; ocultar problemas	Selección de personal, custodia de hijos, permisos de armas
Falseamiento negativo (*faking bad*)	Parecer más afectada de lo que está	Peritajes por indemnización, bajas laborales, procesos penales
Simulación	Producir o exagerar síntomas de un trastorno concreto para obtener un beneficio externo	Evaluación forense y de incapacidad

Los términos se solapan en parte. La **simulación** es la forma extrema del falseamiento negativo y está ligada a un incentivo externo; la **disimulación** es su equivalente en sentido contrario. No hay que confundir la simulación con la exageración de quien sufre de verdad y teme no ser creído, ni con los trastornos en los que la persona no controla sus síntomas, temas que pertenecen a Psicopatología.

Por qué importa el contexto. En selección, casi todos los candidatos se presentan de forma favorable; en una consulta voluntaria predomina la sinceridad, y en un peritaje con compensación económica aumenta el riesgo de exageración. La misma puntuación en una escala de validez se interpreta, por tanto, según la situación de evaluación.

Un ejemplo cotidiano: Marta responde un cuestionario de personalidad para un puesto de jefa de equipo. Sin mentir en ningún ítem concreto, elige siempre la opción que la hace parecer más organizada y tranquila, porque así se ve en sus mejores días. No hay engaño consciente, sino una mezcla de autoengaño y manejo de la impresión que el evaluador debe tener en cuenta antes de concluir que Marta es excepcionalmente estable.

9.4 Estrategias de control de las respuestas sesgadas

Los autores de tests han ideado varias estrategias para reducir los sesgos o, al menos, detectarlos. Unas actúan en la **construcción** del instrumento y otras en la **corrección**, mediante escalas o índices que informan de cómo ha respondido la persona.

Sesgo de respuesta	Estrategia de control	Ejemplo
Deseabilidad social	Escalas de deseabilidad o defensividad	L y K del MMPI-2; IM del BIDR
Aquiescencia	Ítems en sentido directo e inverso	TRIN del MMPI-2
Respuesta aleatoria	Pares de ítems de contenido parecido	VRIN del MMPI-2
Simulación (exagerar síntomas)	Ítems de frecuencia muy baja	F, F(p) y FBS del MMPI-2
Falseamiento positivo	Elección forzada entre opciones de igual deseabilidad	EPPS de Edwards (puntuación ipsativa)

Figura 9.1. **Sesgos de respuesta y estrategias de control.** Cada sesgo de respuesta, desde la deseabilidad social hasta el falseamiento positivo, aparece junto a la estrategia que lo controla y un instrumento de ejemplo (BIDR, escalas del MMPI-2, EPPS). Elaboración propia.

La figura 9.1 recoge las cinco que se aplican en la construcción y la corrección; la sexta es un método de investigación. Las estrategias principales son seis:

1. **Frecuencia empírica de respuesta.** Se incluyen ítems que casi nadie contesta en una dirección determinada; elegir muchas respuestas infrecuentes es una señal de alarma. Es la lógica de la escala F del MMPI.
2. **Consistencia entre pares de ítems.** Se seleccionan pares de ítems de contenido parecido u opuesto. Responder de forma incoherente a muchos pares indica respuesta aleatoria o descuidada. En el MMPI-2, la escala **VRIN** aplica este principio.
3. **Equilibrio de la dirección de los ítems.** Una parte de los ítems se redacta en sentido directo y otra en sentido inverso, de modo que la aquiescencia se compense. La escala **TRIN** del MMPI-2 detecta la tendencia a responder «verdadero» o «falso» de forma indiscriminada.
4. **Escalas de deseabilidad y defensividad.** Recogen virtudes poco frecuentes o la negación de defectos comunes. Ejemplos: las escalas L y K del MMPI, la escala S de presentación superlativa del MMPI-2, el

índice de manipulación de la imagen del 16PF-5 o la escala de distorsión del BFQ.

5. **Elección forzada con igual deseabilidad.** La persona debe elegir entre dos frases que se han igualado en deseabilidad social, de modo que no puede quedar bien eligiendo la más favorable. Es el procedimiento de Edwards en el **EPPS**. Su coste es que produce **puntuaciones ipsativas**: lo que se suma en una escala se resta en otra, y la puntuación indica la fuerza relativa de cada rasgo dentro de la persona, no su nivel en comparación con los demás.
6. **Diseños de simulación análoga.** Es un método de investigación: se pide a un grupo que finja, por ejemplo, un trastorno, y se comprueba qué indicadores lo distinguen de pacientes reales y de personas sinceras.

Las escalas de validez del MMPI-2. Reúnen casi todas estas estrategias y son las más preguntadas:

Escala	Qué detecta
? (interrogante)	Ítems sin responder o respondidos en ambas opciones
VRIN	Inconsistencia en pares de ítems: respuesta aleatoria
TRIN	Inconsistencia por responder casi todo «verdadero» o casi todo «falso»
F	Respuestas infrecuentes en la primera parte del cuadernillo
F(B)	Respuestas infrecuentes en la segunda parte del cuadernillo
F(p)	Respuestas infrecuentes incluso en pacientes psiquiátricos; ayuda a separar exageración de patología real
FBS	Exageración de quejas somáticas y cognitivas, sobre todo en contextos de lesión y litigio
L	Atribuirse virtudes poco realistas: defensividad ingenua
K	Defensividad más sutil, propia de personas con buen nivel educativo
S	Presentación superlativa: imagen de calma, armonía y virtud

Qué indican y qué no. Estas escalas no son detectores de mentiras. Detectan **patrones de respuesta atípicos**, y un patrón atípico tiene varias explicaciones posibles. Una F muy alta puede deberse a respuesta aleatoria, a exageración, a una petición de ayuda o a una psicopatología grave; por eso se crearon F(p) y VRIN, que ayudan a discriminar entre esas causas. Ante indicadores dudosos, el perfil se interpreta con cautela o se considera no válido. Tampoco hay que confundir estos **índices de validez del protocolo**, que hablan de cómo respondió una persona concreta, con la **validez del test**, que se refiere a si el instrumento mide lo que pretende (Evaluación Psicológica I).

Consenso y debate

Consenso: los autoinformes estructurados de personalidad son los instrumentos de personalidad más usados y tienen fiabilidad y validez conocidas. Están expuestos a sesgos de respuesta, sobre todo cuando hay incentivos, y su control requiere escalas de validez, ítems equilibrados y la integración con otras fuentes. Un índice de validez elevado obliga a interpretar con cautela, no a concluir que la persona miente.

Debate: si la deseabilidad social es solo un sesgo o también un rasgo con significado propio, y por tanto si conviene «corregir» las puntuaciones por ella. También se discute el valor de los formatos de elección forzada: reducen el falseamiento, pero sus puntuaciones ipsativas dificultan las comparaciones entre personas.

Mito frecuente

Mito: «Las escalas de validez de un inventario detectan cuándo una persona miente».

Realidad: detectan patrones de respuesta poco habituales, como respuestas incoherentes, infrecuentes o excesivamente favorables, que pueden deberse a descuido, a dificultades de lectura, a un trastorno grave, a autoengaño sincero o a falseamiento. Paulhus (1984) mostró que parte de la deseabilidad social es autoengaño, no mentira. Una puntuación elevada genera una hipótesis que hay que contrastar con otras fuentes.

Conceptos clave

Concepto	Definición
Prueba objetiva de personalidad	Autoinforme con ítems estructurados, respuesta cerrada y corrección que no depende del evaluador
Inventario multidimensional	Instrumento que evalúa muchas dimensiones de personalidad y ofrece un perfil global
Estilo de respuesta	Tendencia estable a contestar de un modo determinado al margen del contenido del ítem
Aquiescencia	Tendencia a mostrarse de acuerdo con los ítems sea cual sea su contenido
Falseamiento negativo	Intento de parecer más afectado de lo que se está
Simulación	Producción o exageración de síntomas para obtener un beneficio externo
Puntuación ipsativa	Puntuación relativa dentro de la persona, propia de la elección forzada; no compara entre sujetos
VRIN	Escala del MMPI-2 que detecta respuestas incoherentes entre pares de ítems

Clave PIR

Prioridad alta. Se pregunta qué detecta cada escala de validez del MMPI-2 (sobre todo L, F, K, VRIN, TRIN y F(p)), qué estrategia controla cada sesgo y qué consecuencia tiene la elección forzada. Trampas típicas: asignar a TRIN la respuesta aleatoria (es VRIN), creer que una F alta indica siempre simulación y confundir la validez del protocolo con la validez del test.

Autoevaluación

1. Una persona responde «verdadero» a casi todos los ítems de un inventario, incluidos los de contenido opuesto. La escala del MMPI-2 más sensible a este patrón es…
a) VRIN
b) TRIN
c) F(B)

2. El formato de elección forzada entre frases de igual deseabilidad social, como en el EPPS, tiene como principal inconveniente que…
a) produce puntuaciones ipsativas
b) aumenta la aquiescencia
c) impide la corrección mecánica

3. Un candidato a un puesto de seguridad se describe con un nivel de calma y virtud muy superior al de la población general. ¿Qué sesgo es más probable?
a) Respuesta aleatoria
b) Falseamiento negativo
c) Falseamiento positivo

4. La escala F(p) del MMPI-2 se añadió sobre todo para…
a) medir la defensividad de personas con estudios
b) separar la exageración de la psicopatología real
c) detectar ítems que se han dejado sin responder

5. ¿Cuál de estos instrumentos es específico y no multidimensional?
a) El STAI
b) El NEO-PI-R
c) El 16PF-5

Soluciones

1 b. TRIN detecta la tendencia indiscriminada al «verdadero» o al «falso»; VRIN, la incoherencia aleatoria. **2 a.** Lo que se suma en una escala se resta en otra, y no permite comparar niveles entre personas. **3 c.** En selección es esperable una presentación favorable; escalas como L, K o S ayudan a valorarla. **4 b.** Recoge respuestas infrecuentes incluso en pacientes psiquiátricos, lo que reduce la ambigüedad de una F alta. **5 a.** Mide ansiedad estado y rasgo; los otros dos evalúan muchas dimensiones.

Unidad 10 · Construcción de pruebas e inventarios clínicos

Objetivos: comparar las estrategias racional, empírica, factorial y secuencial de construcción de pruebas de personalidad; describir la evolución de la familia MMPI y sus versiones españolas; conocer las escalas de validez y clínicas del MMPI-2 y los pasos de su interpretación; describir la estructura, las puntuaciones y el uso del MCMI-IV y el PAI.

10.1 Cuatro estrategias de construcción

Antes de usar un inventario conviene saber cómo se eligieron sus ítems, porque de ello depende qué significa una puntuación. Se distinguen cuatro estrategias, que en la práctica se combinan. Los procedimientos técnicos, como el análisis de ítems o el análisis factorial, se estudian en Psicometría; aquí interesa su lógica.

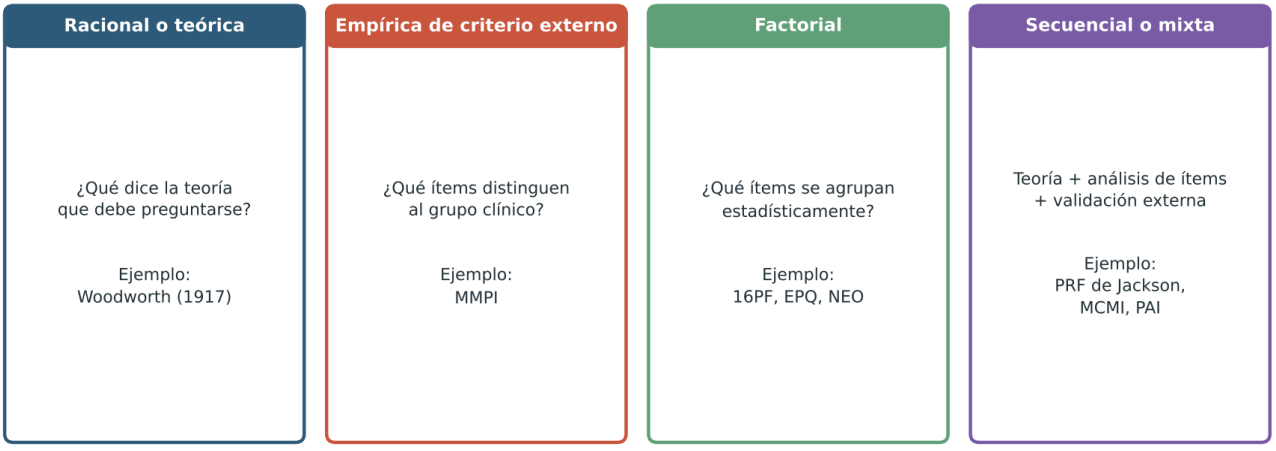


Figura 10.1. **Cuatro estrategias de construcción de pruebas de personalidad.** Para cada una, su pregunta guía y un ejemplo: racional o teórica (Woodworth, 1917), empírica de criterio externo (MMPI), factorial (16PF, EPQ, NEO) y secuencial o mixta (PRF de Jackson, MCMI, PAI). Elaboración propia.

Como muestra la figura 10.1, cada estrategia responde a una pregunta distinta.

1. Racional o teórica (por contenido). Pregunta: «¿qué ítems describen este rasgo según su definición o según una teoría?». El autor redacta ítems cuyo contenido refleja directamente lo que quiere medir. Para la sociabilidad, por ejemplo, escribiría ítems sobre el gusto por las reuniones o la facilidad para hablar con desconocidos. El ejemplo histórico es la **Personal Data Sheet de Woodworth (1917)**, creada para detectar a los reclutas con problemas emocionales en la Primera Guerra Mundial. Ventajas: es sencilla y tiene buena validez aparente. Inconvenientes: los ítems son transparentes, lo que facilita el falseamiento y la deseabilidad social, y su validez depende de que el autor haya acertado al definir el rasgo. Dentro de esta estrategia se suele situar también la construcción **teórica** en sentido estricto, en la que los ítems derivan de una teoría formal, como la de Millon.

2. Empírica de criterio externo. Pregunta: «¿qué ítems responden de forma distinta los miembros de un grupo criterio y los de un grupo de comparación?». No importa lo que dice el ítem, sino que **discrimine**. Se aplica un gran conjunto de ítems a un grupo con un diagnóstico, por ejemplo depresión, y a un grupo de personas sin trastorno, y se conservan los ítems en los que difieren, aunque su contenido no tenga relación evidente con el criterio. Es el método del **MMPI**. Ventajas: la escala predice el criterio y contiene ítems **sutiles**, difíciles de falsear. Inconvenientes: las escalas son heterogéneas, comparten ítems entre sí, carecen de una teoría que las explique y quedan atadas a los diagnósticos de la época en que se construyeron.

3. Factorial. Pregunta: «¿qué ítems tienden a responderse juntos?». Se aplica un amplio conjunto de ítems, se estudian sus correlaciones y se agrupan en factores, que pasan a ser las escalas. Así se construyeron el **16PF** de Cattell y los cuestionarios de Eysenck, y el análisis factorial fue decisivo en los inventarios de cinco factores, como el NEO. Ventajas: escalas homogéneas, con buena consistencia interna y poco solapamiento. Inconvenientes: si un aspecto de la personalidad no estaba representado entre los ítems iniciales, ningún análisis lo hará aparecer; además, cuántos factores retener y cómo llamarlos son decisiones del investigador.

4. Secuencial o mixta. Es el modelo actual. Combina las anteriores por etapas: se define el constructo a partir de una teoría, se redactan ítems por contenido, se depuran con análisis estadísticos para lograr escalas homogéneas y poco sensibles a la deseabilidad, y se comprueba su relación con criterios externos. Jackson la sistematizó en el **PRF** y el **JPI**, y es la lógica del **MCMI** y del **PAI** (apartado 10.4).

Estrategia	Pregunta guía	Fortaleza	Debilidad
Racional	¿Qué describe el rasgo?	Sencillez, validez aparente	Ítems transparentes, falseables
Empírica	¿Qué distingue a los grupos?	Predicción del criterio, ítems sutiles	Escalas heterogéneas, sin teoría
Factorial	¿Qué se responde junto?	Escalas homogéneas	Depende de los ítems iniciales
Secuencial	Todas, por etapas	Teoría, homogeneidad y validez externa	Proceso largo y costoso

Un ejemplo para fijar la diferencia. Se quiere una escala de impulsividad. Con la estrategia racional se redactarían ítems sobre actuar sin pensar. Con la empírica se buscarían, entre cientos de ítems de todo tipo, los que distinguen a personas con problemas de control de impulsos de las demás, aunque uno de ellos trate, por ejemplo, de preferencias de lectura. Con la factorial se vería qué ítems se agrupan con los de impaciencia y búsqueda de sensaciones. Con la secuencial se haría todo ello en orden.

10.2 La familia MMPI

El **Inventario Multifásico de Personalidad de Minnesota** (MMPI) es el inventario clínico más estudiado de la historia. Lo publicaron en 1943 el psicólogo Starke Hathaway y el psiquiatra J. Charnley McKinley, de la Universidad de Minnesota. Su objetivo era práctico: disponer de una herramienta que ayudara a asignar diagnósticos a los pacientes de un hospital.

La construcción original. Hathaway y McKinley reunieron un amplio conjunto de afirmaciones sobre síntomas, actitudes, costumbres y salud física, con respuesta verdadero o falso. Las aplicaron a grupos de pacientes con diagnósticos concretos y a un grupo de comparación de personas sin trastorno, y para cada escala conservaron los ítems que separaban a los pacientes de ese diagnóstico de los demás. Es el método **empírico de criterio externo** (apartado 10.1), no el factorial. De ahí los nombres de las escalas clínicas, como psicastenia o histeria, que reflejan las categorías diagnósticas de la época. La forma de cuadernillo quedó en 566 ítems (550 distintos y 16 repetidos), con tres escalas de validez (L, F y K) y diez escalas clínicas.

Las revisiones. Con el tiempo, el MMPI acumuló problemas: baremos antiguos, ítems con lenguaje anticuado o inapropiado y escalas clínicas muy correlacionadas entre sí por compartir ítems. Las versiones posteriores responden a esos problemas.

Versión	Año	Adaptación española	Ítems	Escalas
MMPI	1943	—	566	L, F, K y 10 clínicas
MMPI-2	1989	1999 (TEA)	567	Validez, clínicas, contenido, suplementarias, PSY-5
MMPI-2-RF	2008	TEA	338	51 escalas; clínicas reestructuradas (RC)
MMPI-3	2020	Hogrefe TEA, 2026	335	52 escalas (nuevas: alimentación, compulsividad…)

Figura 10.2. **La familia MMPI.** MMPI (1943, 566 ítems), MMPI-2 (1989, 567 ítems; adaptación española de 1999), MMPI-2-RF (2008, 338 ítems y 51 escalas) y MMPI-3 (2020, 335 ítems y 52 escalas; adaptación española de 2026). Elaboración propia.

Como muestra la figura 10.2, la evolución ha seguido cuatro pasos:

Versión	Año	Ítems	Novedades principales	Adaptación española
MMPI	1943	566	Escalas de validez L, F, K y diez escalas clínicas	—
MMPI-2	1989	567	Nuevos baremos, ítems revisados, nuevas escalas de validez, escalas de contenido, suplementarias y PSY-5	Ávila-Espada y Jiménez-Gómez (1999), TEA
MMPI-2-RF	2008	338	51 escalas; escalas clínicas reestructuradas (RC)	TEA
MMPI-3	2020	335	52 escalas; nuevas escalas de problemas de alimentación, compulsividad, impulsividad y autoimportancia	Hogrefe TEA (2026), adaptación de P. Santamaría

MMPI-2. Mantuvo las escalas clínicas originales para conservar la enorme investigación acumulada, pero actualizó los baremos y añadió las escalas de validez VRIN, TRIN y F(B); F(p) y S se incorporaron en 1995 y FBS, de forma oficial, en 2007 (Unidad 9), las **escalas de contenido**, construidas por contenido y por tanto más transparentes, las **escalas suplementarias** y las escalas **PSY-5**, que describen cinco dimensiones de personalidad patológica.

MMPI-2-RF. Es una versión reducida y reestructurada. Su núcleo son las **escalas clínicas reestructuradas (RC)**: se extrajo de las escalas clínicas un factor general de malestar, la **desmoralización**, que explicaba buena parte de su solapamiento, y se depuraron las escalas para que fueran más homogéneas y distintas entre sí. Es un buen ejemplo de cómo un instrumento nacido de la estrategia empírica incorpora después procedimientos factoriales.

MMPI-3. Continúa la línea del MMPI-2-RF con baremos nuevos, ítems revisados y nuevas escalas. Su adaptación española, publicada por Hogrefe TEA y adaptada por P. Santamaría, se presentó en octubre de 2026.

Versión para adolescentes. El **MMPI-A** adapta el inventario a adolescentes, con ítems y baremos propios para esa edad.

El principal motivo de que el MMPI-2 siga en uso junto a las versiones nuevas es la **continuidad**: buena parte de la investigación y de la práctica forense y clínica se apoya en sus escalas clásicas, y el cambio de versión exige reaprender la interpretación. Saber qué versión se usó en un informe es imprescindible para leerlo bien: 567 ítems corresponden al MMPI-2, y 338, al MMPI-2-RF.

10.3 Escalas e interpretación del MMPI-2

Las escalas clínicas. Las diez escalas básicas del MMPI y el MMPI-2 se identifican por un número y una abreviatura:

N.º	Escala	Qué recoge hoy, en términos generales
1	Hs, hipocondría	Preocupación por el cuerpo y quejas somáticas
2	D, depresión	Tristeza, desánimo, falta de energía
3	Hy, histeria	Quejas físicas junto con negación de problemas psicológicos
4	Pd, desviación psicopática	Conflicto con las normas y la autoridad, impulsividad
5	Mf, masculinidad-feminidad	Intereses y actitudes asociados a los roles de género tradicionales
6	Pa, paranoia	Suspicacia, sensibilidad interpersonal, ideas de persecución
7	Pt, psicastenia	Ansiedad, rumiación, dudas obsesivas
8	Sc, esquizofrenia	Pensamiento extraño, alienación, experiencias inusuales
9	Ma, hipomanía	Energía elevada, aceleración, expansividad
0	Si, introversión social	Retraimiento e incomodidad en situaciones sociales

Los nombres son históricos. Una puntuación alta en la escala 8 no significa que la persona tenga esquizofrenia; indica que ha respondido como lo hacían aquellos pacientes en una serie de ítems. Por eso muchos clínicos prefieren referirse a las escalas por su **número**.

Las puntuaciones. Las puntuaciones directas se transforman en **puntuaciones T** (media 50, desviación típica 10; Evaluación Psicológica I). En el MMPI-2, el punto de corte de significación clínica es **T ≥ 65**. Una peculiaridad del inventario es la **corrección K**: a algunas escalas clínicas se les suma una fracción de la puntuación en K para compensar la tendencia defensiva a minimizar problemas.

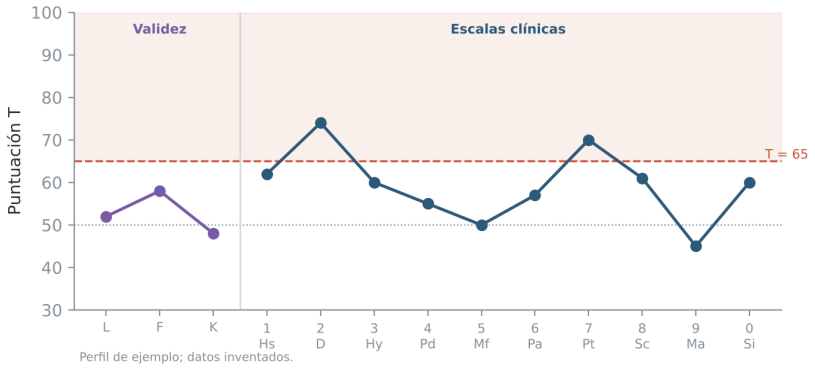


Figura 10.3. **Perfil del MMPI-2.** Perfil inventado con las escalas de validez L, F y K y las diez escalas clínicas en puntuaciones T; la línea horizontal marca T = 65, el umbral de significación clínica. Elaboración propia.

Los pasos de la interpretación. La figura 10.3 representa la hoja de perfil que se usa en la práctica. Su lectura sigue un orden:

1. **Validez.** Primero se revisan las omisiones, VRIN y TRIN (¿la persona respondió al contenido?) y después las escalas de infrecuencia y de defensividad (¿exageró o minimizó?). Si el perfil no es válido, no se interpreta el resto.
2. **Escalas clínicas elevadas.** Se identifican las escalas por encima de T = 65 y su grado de elevación.

3. **Tipos de código.** Se combinan las dos o tres escalas más altas. Un **código 2-7**, por ejemplo, reúne depresión y ansiedad, y la investigación ha descrito los correlatos típicos de cada código. Se describen también configuraciones clásicas: la **tríada neurótica** (escalas 1, 2 y 3), la **tétrada psicótica** (6, 7, 8 y 9) o la **«V de conversión»**, con 1 y 3 elevadas y 2 más baja.
4. **Escalas complementarias.** Las escalas de contenido, suplementarias, PSY-5 o RC ayudan a precisar qué ítems explican una elevación.
5. **Integración.** Las hipótesis del perfil se contrastan con la entrevista, la historia y otras pruebas. El perfil sugiere; no diagnostica por sí solo.

Un minicaso. Andrés, de 45 años, acude por insomnio y cansancio. Sus escalas de validez están en el rango normal. Las escalas 2 y 7 superan T = 65 y las demás no. El perfil sugiere malestar emocional con ansiedad y preocupación, coherente con lo que cuenta en la entrevista. El psicólogo no concluye un diagnóstico a partir del código, sino que lo usa para orientar las preguntas: desde cuándo, qué lo mantiene, qué ha cambiado en su vida.

Los errores más frecuentes al interpretar el MMPI-2 son leer las escalas por su nombre literal, saltarse la validez, interpretar elevaciones moderadas aisladas como si fueran diagnósticos y aplicar baremos que no corresponden a la versión o a la población. Los criterios diagnósticos actuales pertenecen a Psicopatología: el MMPI-2 aporta información para el diagnóstico, no lo sustituye.

10.4 MCMI-IV y PAI

El MMPI no es el único inventario clínico. En la práctica española, el **MCMI** y el **PAI** figuran entre los tests más usados (Muñiz, Hernández y Fernández-Hermida, 2020). Ambos se construyeron con la estrategia secuencial.

El MCMI-IV. El Inventario Clínico Multiaxial de Millon, en su cuarta versión (Millon, Grossman y Millon, 2015; adaptación española de Pearson, 2018), se basa en la **teoría evolutiva de la personalidad de Millon** y está pensado para evaluar los patrones de personalidad y los síndromes clínicos en adultos que reciben atención psicológica.

- **Formato**: 195 ítems de verdadero o falso, desde los 18 años.
- **Patrones de personalidad**: 15, de los cuales 12 son **patrones clínicos**, entre ellos el nuevo **4B, tempestuoso**, y 3 son **patologías graves de la personalidad**: esquizotípica (S), límite (C) y paranoide (P).
- **Síndromes clínicos**: escalas de ansiedad, depresión, consumo de sustancias y otros cuadros, además de los síndromes graves.
- **Facetas de Grossman**: subescalas que precisan qué aspectos de cada patrón explican su elevación.
- **Índices modificadores y de validez**: valoran la apertura, la deseabilidad y la tendencia a devaluarse.

Su rasgo más característico son las **puntuaciones de tasa base (TB)**, que no son puntuaciones T. Las TB tienen en cuenta la **prevalencia** de cada trastorno en la población clínica, de modo que el punto de corte se ajusta a lo frecuente que es el rasgo. En la tradición del MCMI, una TB de 75 sugiere la presencia de un rasgo o síndrome y una de 85, su prominencia. Como sus baremos proceden de **población clínica**, el MCMI no debe usarse para describir la personalidad de personas sin problemas psicológicos, por ejemplo en selección de personal: tendería a sobrestimar la patología.

El PAI. El Inventario de Evaluación de la Personalidad (Morey, 1991; adaptación española de Ortiz-Tallo, Santamaría, Cardenal y Sánchez, TEA, 2011) tiene **344 ítems con cuatro opciones de respuesta**, desde «falso» hasta «totalmente verdadero». Esta graduación permite matizar más que el formato dicotómico. Sus **22 escalas** se reparten así:

Grupo	N.º	Contenido
Validez	4	Inconsistencia, infrecuencia, impresión negativa e impresión positiva

Grupo	N.º	Contenido
Clínicas	11	Quejas somáticas, ansiedad, trastornos relacionados con la ansiedad, depresión, manía, paranoia, esquizofrenia, rasgos límites, rasgos antisociales, problemas con el alcohol y con las drogas
Consideraciones para el tratamiento	5	Agresión, ideación suicida, estrés, falta de apoyo social y rechazo al tratamiento
Interpersonales	2	Dominancia y afabilidad

El PAI se diseñó para que sus escalas **no compartieran ítems**, lo que evita el solapamiento que se criticaba al MMPI. Según la revisión de la Comisión de Test del Colegio Oficial de la Psicología, su consistencia interna mediana está en torno a 0,80–0,85. Sus escalas de tratamiento, como la de ideación suicida o la de rechazo al tratamiento, lo hacen útil para planificar la intervención.

Comparación de los tres inventarios.

Rasgo	MMPI-2	MCMI-IV	PAI
Construcción	Empírica de criterio externo	Secuencial, basada en la teoría de Millon	Secuencial
Ítems	567, verdadero o falso	195, verdadero o falso	344, cuatro opciones
Puntuaciones	T (corte en 65)	Tasa base (75 y 85)	T
Punto fuerte	Investigación acumulada y escalas de validez	Patrones de personalidad	Escalas sin solapamiento y orientadas al tratamiento
Población	Adultos, clínica y general	Adultos en atención clínica	Adultos, clínica y general

La elección depende de la pregunta. Si interesa sobre todo la personalidad patológica, el MCMI-IV es la opción natural; si se necesita un cribado amplio de psicopatología con información para el tratamiento, el PAI; si el contexto es forense y se requiere el máximo respaldo empírico de las escalas de validez, el MMPI-2 o sus sucesores. Los trastornos de personalidad como tales se estudian en Psicopatología.

Consenso y debate

Consenso: el MMPI se construyó por el método empírico de criterio externo, y las versiones posteriores han incorporado escalas más homogéneas. La estrategia secuencial, que combina teoría, análisis estadístico y validación externa, es el estándar actual. MMPI-2, MCMI y PAI son inventarios clínicos de uso habitual que requieren comprobar primero la validez del protocolo e integrar el perfil con otras fuentes.

Debate: si conviene mantener las escalas clínicas clásicas del MMPI-2, con su investigación acumulada pero también su heterogeneidad, o pasar a las escalas reestructuradas del MMPI-2-RF y el MMPI-3. También se discute hasta qué punto las puntuaciones de tasa base del MCMI funcionan bien cuando la prevalencia del centro difiere de la de la muestra normativa.

Mito frecuente

Mito: «El MMPI se construyó mediante análisis factorial».

Realidad: Hathaway y McKinley (1943) seleccionaron los ítems por su capacidad para distinguir a grupos de pacientes con un diagnóstico de un grupo sin trastorno, con independencia de su contenido: es el método empírico de criterio externo. El análisis factorial es la estrategia del 16PF de Cattell o de los

cuestionarios de Eysenck. Solo más tarde, con las escalas reestructuradas (RC; Tellegen et al., 2003), integradas después en el MMPI-2-RF (2008), los procedimientos factoriales pasaron a ocupar un lugar central en la familia MMPI.

Conceptos clave

Concepto	Definición
Estrategia racional	Construcción de ítems a partir de la definición del rasgo o de su contenido evidente
Criterio externo	Selección de ítems por su capacidad para diferenciar un grupo criterio de otro de comparación
Estrategia secuencial	Construcción por etapas que combina teoría, análisis estadístico y validación externa
Ítem sutil	Ítem que discrimina entre grupos aunque su contenido no se relacione claramente con el criterio
Tipo de código	Combinación de las dos o tres escalas clínicas más elevadas del perfil del MMPI
Escalas RC	Escalas clínicas reestructuradas del MMPI-2-RF, depuradas del factor de desmoralización
Tasa base (TB)	Puntuación del MCMI que tiene en cuenta la prevalencia del trastorno en población clínica
Corrección K	Suma de una fracción de K a algunas escalas clínicas para compensar la defensividad

Clave PIR

Prioridad alta. Se pregunta qué método de construcción usa cada inventario, el número de ítems de cada versión del MMPI, el contenido de las escalas clínicas por número y el tipo de puntuación del MCMI. Trampas típicas: decir que el MMPI es factorial, confundir los 567 ítems del MMPI-2 con los 338 del MMPI-2-RF, confundir las puntuaciones TB con las T e interpretar el nombre de una escala clínica como un diagnóstico.

Autoevaluación

1. Un autor conserva un ítem sobre preferencias de lectura porque lo contestan de forma distinta los pacientes deprimidos y las personas sin trastorno. Está aplicando la estrategia…
a) racional o de contenido
b) factorial
c) empírica de criterio externo

2. ¿Cuántos ítems tiene el MMPI-2-RF?
a) 338
b) 567
c) 335

3. En el MMPI-2, la escala 7 (Pt) recoge sobre todo…
a) suspicacia e ideas de persecución
b) ansiedad, rumiación y dudas obsesivas
c) energía elevada y expansividad

4. El MCMI-IV utiliza puntuaciones de tasa base porque…
a) tienen en cuenta la prevalencia de cada trastorno en población clínica
b) son puntuaciones T con media 50 y desviación típica 10
c) permiten usar el inventario en población no clínica

5. Una característica de diseño del PAI frente al MMPI-2 es que…
a) sus escalas se construyeron por criterio externo puro
b) usa un formato de verdadero o falso más breve
c) sus escalas no comparten ítems entre sí

Soluciones

1 c. Lo que cuenta es que el ítem discrimine entre grupos, no su contenido. **2 a.** El MMPI-2 tiene 567 y el MMPI-3, 335. **3 b.** Suspicacia corresponde a la escala 6 y expansividad, a la 9. **4 a.** Por eso no son puntuaciones T, y sus baremos clínicos desaconsejan usarlo en población general. **5 c.** Además usa cuatro opciones de respuesta y se construyó con la estrategia secuencial.

Unidad 11 · Modelos dimensionales de la personalidad normal y patológica

Objetivos: describir la estructura del 16PF-5 y del EPQ-R; explicar el modelo de los cinco factores y sus instrumentos principales (NEO-PI-R, NEO-FFI y BFQ); conocer los modelos de Cloninger y HEXACO; describir el PID-5 y los modelos dimensionales de los trastornos de personalidad del DSM-5 y la CIE-11; valorar por qué el MBTI no es un buen instrumento de personalidad.

11.1 16PF-5 y EPQ-R

Los inventarios de esta unidad describen la personalidad mediante **dimensiones continuas** obtenidas, en su mayoría, por análisis factorial. Las teorías de rasgo que los sustentan se estudian en Psicología de la Personalidad y Diferencias Individuales; aquí el foco está en los instrumentos.

El 16PF-5. Raymond B. Cattell buscó una descripción completa de la personalidad a partir del lenguaje y del análisis factorial de distintos tipos de datos: los registros de la vida real (datos L), los cuestionarios (datos Q) y las pruebas objetivas de rendimiento (datos T; Unidad 1). El resultado fue el **Cuestionario de 16 factores de personalidad**. Su quinta edición (Cattell, Cattell y Cattell, 1993; adaptación española de Seisdedos, TEA, 1995) tiene **185 ítems** y ofrece:

- **16 escalas primarias**, que en la adaptación española llevan nombres como afabilidad, razonamiento, estabilidad, dominancia, animación, atención a las normas, atrevimiento, sensibilidad, vigilancia, abstracción, privacidad, aprensión, apertura al cambio, autosuficiencia, perfeccionismo y tensión.
- **5 dimensiones globales** de segundo orden: extraversión, ansiedad, dureza, independencia y autocontrol.
- **3 índices de estilo de respuesta**: manipulación de la imagen, infrecuencia y aquiescencia.

Una peculiaridad del 16PF es que una de sus escalas primarias, la de **razonamiento** (factor B), no es un rasgo de personalidad en sentido estricto, sino una breve medida de capacidad intelectual. Otra es que sus cinco globales se parecen bastante a los cinco grandes factores (apartado 11.2), lo que se ha interpretado como un punto de convergencia entre modelos. El 16PF-5 es muy usado en **selección de personal** y **orientación**, porque describe la personalidad normal con un nivel de detalle alto.

El EPQ-R. Hans Eysenck defendió un modelo con pocas dimensiones amplias, de base biológica, que se fue ampliando con los años. El **Cuestionario de Personalidad de Eysenck revisado** (Eysenck y Eysenck, 1985; adaptación española de TEA) mide:

Escala	Qué recoge una puntuación alta
E, extraversión	Sociabilidad, actividad, búsqueda de estimulación
N, neuroticismo	Inestabilidad emocional, preocupación, reactividad al estrés
P, psicoticismo	Dureza, frialdad, impulsividad, despreocupación por las normas
L, sinceridad	Tendencia a dar una imagen favorable; escala de control

El nombre **psicoticismo** es una fuente clásica de errores. No mide psicosis ni síntomas psicóticos: una persona con P alto es fría, poco empática, impulsiva o poco convencional, no alguien con alucinaciones. La escala P ha sido también la más criticada por su menor consistencia interna. El cuestionario tiene una versión para niños y adolescentes, el **EPQ-J**.

Rasgo	16PF-5	EPQ-R
Autor	Cattell	Eysenck

Rasgo	16PF-5	EPQ-R
Nivel de análisis	Muchos factores primarios y cinco globales	Tres superfactores amplios
Control de sesgos	Manipulación de la imagen, infrecuencia, aquiescencia	Escala L
Uso típico	Selección, orientación, descripción detallada	Investigación, cribado rápido

La diferencia de fondo es de **nivel de análisis**. Cattell prefería muchas dimensiones estrechas, que predicen con detalle; Eysenck, pocas dimensiones amplias, más estables y fáciles de relacionar con la biología. No es que uno tenga razón y el otro no: describen la misma personalidad a distintos niveles de la jerarquía de rasgos.

Un ejemplo. Una empresa necesita un coordinador que trabaje con autonomía y cumpla normas estrictas de seguridad. Las escalas primarias del 16PF-5, como atención a las normas o autosuficiencia, le dan información más ajustada que la puntuación global de extraversión del EPQ-R. En cambio, en un estudio con miles de participantes sobre neuroticismo y salud, la brevedad del EPQ-R es una ventaja clara.

11.2 El modelo de los cinco factores: NEO-PI-R, NEO-FFI y BFQ

El **modelo de los cinco factores** es hoy el marco de referencia para describir la personalidad normal. Surge de dos líneas que convergieron: la **hipótesis léxica**, según la cual las diferencias de personalidad importantes acaban codificadas en el lenguaje, y los análisis factoriales de cuestionarios. Ambas encontraron de forma repetida cinco grandes dimensiones: **neuroticismo**, **extraversión**, **apertura a la experiencia**, **amabilidad** y **responsabilidad**.

El NEO-PI-R. Paul Costa y Robert McCrae construyeron el inventario más usado del modelo (Costa y McCrae, 1992; adaptación española de Cordero, Pamos y Seisdedos, TEA, 1999, con tercera edición en 2008). Tiene **240 ítems** con respuesta en escala de cinco puntos y una estructura jerárquica: **cinco factores**, cada uno con **seis facetas**.

Factor	Facetas
Neuroticismo	Ansiedad, hostilidad, depresión, ansiedad social, impulsividad, vulnerabilidad
Extraversión	Cordialidad, gregarismo, asertividad, actividad, búsqueda de emociones, emociones positivas
Apertura	Fantasía, estética, sentimientos, acciones, ideas, valores
Amabilidad	Confianza, franqueza, altruismo, actitud conciliadora, modestia, sensibilidad a los demás
Responsabilidad	Competencia, orden, sentido del deber, necesidad de logro, autodisciplina, deliberación

Las facetas permiten matizar. Dos personas con la misma puntuación en neuroticismo pueden diferir mucho: una por ansiedad y vulnerabilidad, otra por hostilidad e impulsividad. El inventario dispone de una forma de autoinforme y otra para que la conteste un observador que conozca bien a la persona.

Versiones del NEO. El **NEO-FFI** es la forma breve, con **60 ítems**, que mide solo los cinco factores; es útil en investigación y cribado. El **NEO-PI-3** (McCrae, Costa y Martin, 2005) es una revisión del NEO-PI-R que sustituye ítems difíciles para hacerlo **más legible**, también para adolescentes.

El BFQ. El **Cuestionario «Big Five»** de Caprara, Barbaranelli y Borgogni (1993; adaptación española de TEA) se elaboró en Italia y usa sus propias denominaciones para los factores, cada uno con dos subdimensiones:

Factor del BFQ	Equivalente aproximado	Subdimensiones
Energía	Extraversión	Dinamismo, dominancia
Afabilidad	Amabilidad	Cooperación, cordialidad

Factor del BFQ	Equivalente aproximado	Subdimensiones
Tesón	Responsabilidad	Escrupulosidad, perseverancia
Estabilidad emocional	Neuroticismo (polo opuesto)	Control de las emociones, control de los impulsos
Apertura mental	Apertura	Apertura a la cultura, apertura a la experiencia

Además incluye una **escala de distorsión** para detectar una imagen excesivamente favorable, algo que el NEO-PI-R no incorpora como escala formal. Atención al detalle de dirección: el BFQ mide **estabilidad** emocional, el polo contrario del neuroticismo del NEO.

En la misma editorial española existen otros cuestionarios de personalidad normal, como el **CPS** (Cuestionario de Personalidad Situacional) de Seisdedos y Roig Fuste, orientado a describir cómo se comporta la persona en distintas situaciones.

Utilidad y límites. Los cinco factores predicen resultados relevantes: la responsabilidad se relaciona con el rendimiento académico y laboral, y el neuroticismo con el malestar emocional y diversos problemas de salud mental. Se han replicado en muchas culturas y lenguas, aunque no de forma idéntica en todas. Sus límites principales son dos. Primero, describen más que explican: decir que alguien es extravertido no aclara por qué. Segundo, al ser autoinformes con ítems transparentes, son sensibles a la deseabilidad social en contextos como la selección (Unidad 9).

Un ejemplo. Lucía obtiene en el NEO-FFI una puntuación alta en apertura y baja en responsabilidad. Si solicita después el NEO-PI-R completo, puede que la baja responsabilidad se deba a la deliberación y al orden, pero no al sentido del deber. Esa diferencia, invisible con 60 ítems, cambia el consejo que recibirá en una orientación profesional.

11.3 Otros modelos: TCI-R de Cloninger y HEXACO

El modelo de los cinco factores no es el único. Dos alternativas aparecen con frecuencia en la evaluación: el modelo psicobiológico de Cloninger y el modelo HEXACO.

El TCI-R de Cloninger. Robert Cloninger propuso un modelo **psicobiológico** que distingue dos componentes de la personalidad:

- El **temperamento**: tendencias emocionales básicas, en gran parte heredables y estables desde la infancia, ligadas al aprendizaje de respuestas automáticas.
- El **carácter**: lo que la persona hace de sí misma, sus metas y valores, que madura con la edad y la experiencia.

El **Inventario de Temperamento y Carácter revisado** (TCI-R), con adaptación española, mide **siete dimensiones**:

Componente	Dimensión	Qué recoge una puntuación alta
Temperamento	Búsqueda de novedad	Exploración, impulsividad, aburrimiento ante la rutina
Temperamento	Evitación del daño	Preocupación anticipatoria, miedo a la incertidumbre, timidez, fatiga
Temperamento	Dependencia de la recompensa	Sensibilidad a la aprobación social, apego, calidez
Temperamento	Persistencia	Perseverancia a pesar de la frustración y el cansancio
Carácter	Autodirección	Responsabilidad, propósito, autoaceptación
Carácter	Cooperación	Aceptación de los demás, empatía, ayuda

Componente	Dimensión	Qué recoge una puntuación alta
Carácter	Autotrascendencia	Espiritualidad, sentimiento de unidad con algo mayor

Cloninger propuso que las dimensiones de temperamento se relacionaban con sistemas neuroquímicos concretos, una hipótesis que la investigación posterior no ha confirmado de forma sencilla. En la clínica, el TCI-R es útil porque las dimensiones de carácter, sobre todo una **autodirección** y una **cooperación** bajas, se han propuesto como indicadores generales de trastorno de personalidad, mientras que el temperamento ayudaría a describir su forma. Un error típico es atribuir el TCI a Eysenck: es de Cloninger, y su lógica (temperamento frente a carácter) es distinta de la de los superfactores de Eysenck.

El modelo HEXACO. Michael Ashton y Kibeom Lee reanalizaron estudios léxicos en varias lenguas y encontraron, con frecuencia, **seis factores** en lugar de cinco. El nombre resume sus iniciales en inglés: Honestidad-Humildad, Emocionalidad, eXtraversión, Amabilidad, Responsabilidad (*Conscientiousness*) y Apertura. La gran novedad es el factor **Honestidad-Humildad**, que recoge la sinceridad, la justicia, la falta de codicia y la modestia. Su polo bajo describe a personas manipuladoras, interesadas o pretenciosas.

Este sexto factor es útil para predecir conductas que los cinco grandes captan peor, como el comportamiento poco ético, la explotación de los demás o la conducta laboral contraproducente. El instrumento de referencia, el **HEXACO-PI-R**, se usa sobre todo en **investigación**.

Rasgo	Cinco factores	HEXACO	TCI-R
Origen	Léxico y factorial	Léxico transcultural	Psicobiológico
N.º de dimensiones	5	6	7 (4 + 3)
Aportación propia	Marco de referencia compartido	Honestidad-Humildad	Distinción temperamento-carácter
Uso principal	Clínica, selección, investigación	Investigación	Clínica e investigación

Los modelos no son tan distintos como parecen. Muchas de sus dimensiones se corresponden en parte: la evitación del daño se relaciona con el neuroticismo y la búsqueda de novedad, con la extraversión y la baja responsabilidad. Lo que cambia es dónde se trazan los límites y qué se considera más básico. Elegir un modelo depende del propósito: describir con un lenguaje común (cinco factores), predecir conductas éticas (HEXACO) o separar lo temperamental de lo madurativo (TCI-R).

Un ejemplo. En un estudio sobre fraude académico, dos estudiantes tienen la misma puntuación en amabilidad del NEO. Solo el HEXACO distingue que uno de ellos puntúa muy bajo en honestidad-humildad, que es lo que mejor se asocia con copiar en los exámenes.

11.4 Trastornos de personalidad dimensionales: PID-5, DSM-5 y CIE-11

Tradicionalmente, los trastornos de personalidad se han clasificado como **categorías**: se tiene o no se tiene un trastorno límite o uno evitativo. Este enfoque tiene problemas bien conocidos, como la **comorbilidad** excesiva entre trastornos, la heterogeneidad dentro de cada uno y los umbrales arbitrarios. Los modelos **dimensionales** proponen describir la patología de la personalidad como grados extremos o desadaptativos de rasgos continuos. El estudio clínico de los trastornos corresponde a Psicopatología.

El Modelo Alternativo del DSM-5. El DSM-5 (2013), y después el DSM-5-TR (2022), mantienen el modelo categorial en el cuerpo del manual, pero incluyen en su Sección III un **Modelo Alternativo de los Trastornos de la Personalidad** con dos criterios:

- **Criterio A, funcionamiento de la personalidad**: grado de deterioro en el funcionamiento del yo (identidad y autodirección) e interpersonal (empatía e intimidad), valorado con la **Escala del Nivel de Funcionamiento de la Personalidad (LPFS)**.
- **Criterio B, rasgos patológicos**: cinco dominios con sus facetas, medidos con el **PID-5**.

Con esta combinación, el modelo define seis trastornos específicos (antisocial, evitativo, límite, narcisista, obsesivo-compulsivo y esquizotípico) y permite describir cualquier otro caso por su nivel de funcionamiento y sus rasgos.

El PID-5. El **Inventario de Personalidad para el DSM-5** (Krueger et al., 2012) tiene **220 ítems**, **25 facetas** y **5 dominios**: **afectividad negativa**, **desapego**, **antagonismo**, **desinhibición** y **psicoticismo**. Se usa en investigación y en la clínica.

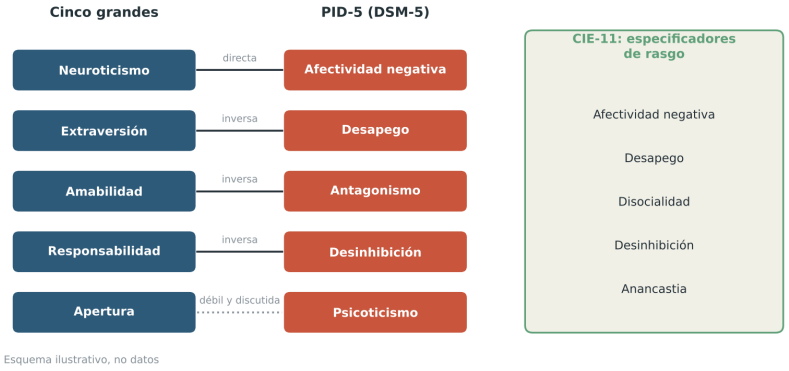


Figura 11.1. **Los cinco grandes y los dominios patológicos.** Neuroticismo se corresponde con afectividad negativa; extraversión, con desapego (en sentido inverso); amabilidad, con antagonismo (inverso), y responsabilidad, con desinhibición (inverso). La relación entre apertura y psicoticismo es débil y discutida. Al lado, los cinco especificadores de rasgo de la CIE-11. Elaboración propia.

Como muestra la figura 11.1, cuatro de los cinco dominios del PID-5 se entienden como versiones desadaptativas de los cinco grandes. El desapego es el polo extremo de la introversión; el antagonismo, el de la baja amabilidad, y la desinhibición, el de la baja responsabilidad. El psicoticismo, que recoge experiencias y creencias excéntricas o inusuales, es la excepción: su relación con la apertura es débil y sigue en discusión. Esta continuidad entre personalidad normal y patológica es uno de los argumentos principales a favor de los modelos dimensionales.

La CIE-11. La CIE-11, en vigor desde 2022, ha ido más lejos que el DSM: **suprime los tipos** de trastorno de personalidad y adopta un modelo plenamente dimensional en dos pasos:

1. **Gravedad**: se decide si hay trastorno de personalidad y se gradúa como **leve, moderado o grave**, según el deterioro en el funcionamiento propio e interpersonal. Por debajo del umbral se puede registrar una **dificultad de personalidad**.
2. **Especificadores de rasgo**: se describen los rasgos predominantes con cinco especificadores: **afectividad negativa**, **desapego**, **disocialidad**, **desinhibición** y **anancastia**. Se añade un **especificador de patrón límite** para la práctica clínica.

Rasgo	DSM-5 Sección III	CIE-11
Estatus	Modelo alternativo, junto al categorial	Modelo oficial
Funcionamiento	Criterio A (LPFS)	Gravedad: leve, moderada, grave
Rasgos	5 dominios del PID-5	5 especificadores
Diferencias en los rasgos	Incluye psicoticismo	Incluye anancastia; no incluye psicoticismo
Tipos	Seis trastornos específicos	Solo el patrón límite

Un minicaso. Elena, de 30 años, tiene relaciones muy inestables, cambios bruscos de ánimo y conductas impulsivas que le causan problemas graves en el trabajo. Con la CIE-11 se registraría un trastorno de personalidad de gravedad moderada o grave, con rasgos de afectividad negativa y desinhibición, y se podría

añadir el patrón límite. Con el PID-5, el clínico obtendría su perfil en los cinco dominios y sus facetas, lo que ayuda a decidir en qué centrar la intervención.

Consenso y debate

Consenso: el modelo de los cinco factores es el marco de referencia para la personalidad normal, y sus instrumentos (NEO-PI-R, NEO-FFI, BFQ) tienen buenas propiedades psicométricas. El psicoticismo del EPQ-R no mide psicosis. La personalidad normal y la patológica forman un continuo, y cuatro dominios del PID-5 se corresponden con los cinco grandes. La CIE-11 es dimensional.

Debate: si los trastornos de personalidad deben clasificarse de forma categorial o dimensional. El DSM-5-TR mantiene ambos modelos y la CIE-11 adopta el dimensional; se discuten su utilidad clínica, la familiaridad de los profesionales con las categorías y el lugar del patrón límite. También se debate si la estructura básica de la personalidad tiene cinco o seis factores (HEXACO) y si el psicoticismo del PID-5 encaja en la apertura.

Mito frecuente

Mito: «El MBTI (indicador de tipos de Myers-Briggs) es un buen test de personalidad».

Realidad: el MBTI clasifica a las personas en tipos dicotómicos a partir de dimensiones que en realidad son continuas, de modo que dos personas muy parecidas pueden quedar en tipos opuestos. En un retest a cinco semanas, en torno a la mitad de las personas cambia de categoría en al menos una escala, y su validez predictiva es baja (Pittenger, 2005). Para describir la personalidad, los inventarios dimensionales como el NEO-PI-R son mucho más fiables y válidos.

Conceptos clave

Concepto	Definición
16PF-5	Cuestionario de Cattell con 16 escalas primarias, 5 globales y 3 índices de estilo de respuesta
Psicoticismo (EPQ-R)	Dimensión de Eysenck de dureza, frialdad e impulsividad; no mide psicosis
Faceta	Rasgo específico dentro de un factor amplio; el NEO-PI-R tiene seis por factor
Temperamento y carácter	Distinción de Cloninger entre tendencias heredables y rasgos que maduran con la experiencia
Honestidad-Humildad	Sexto factor del modelo HEXACO: sinceridad, justicia, falta de codicia y modestia
PID-5	Inventario de rasgos patológicos del DSM-5: 220 ítems, 25 facetas y 5 dominios
LPFS	Escala del funcionamiento de la personalidad (Criterio A del Modelo Alternativo del DSM-5)
Anancastia	Especificador de rasgo de la CIE-11: perfeccionismo y control rígido de la conducta

Clave PIR

Prioridad media. Se pregunta qué autor corresponde a cada instrumento, la estructura del NEO-PI-R (5 × 6), las dimensiones del EPQ-R y del TCI-R, los dominios del PID-5 y los especificadores de la CIE-11. Trampas típicas: confundir el psicoticismo del EPQ-R con psicosis, atribuir el TCI a Eysenck, olvidar que el BFQ mide estabilidad y no neuroticismo, e intercambiar la anancastia de la CIE-11 con el psicoticismo del PID-5.

Autoevaluación

1. Una puntuación alta en la escala P del EPQ-R indica sobre todo…
a) presencia de síntomas psicóticos
b) dureza, frialdad e impulsividad
c) inestabilidad emocional y preocupación

2. ¿Qué estructura tiene el NEO-PI-R?
a) Cinco factores con seis facetas cada uno
b) Dieciséis factores primarios y cinco globales
c) Cuatro dimensiones de temperamento y tres de carácter

3. La autodirección y la cooperación son dimensiones…
a) del modelo HEXACO
b) de temperamento del TCI-R
c) de carácter del TCI-R

4. ¿Cuál de estos especificadores de rasgo pertenece a la CIE-11 pero no es un dominio del PID-5?
a) Desinhibición
b) Anancastia
c) Afectividad negativa

5. En la correspondencia entre los cinco grandes y el PID-5, el desapego se relaciona con…
a) la extraversión, en sentido inverso
b) la amabilidad, en sentido inverso
c) la apertura, de forma débil

Soluciones

1 b. El nombre es engañoso: describe rasgos de personalidad, no psicosis. **2 a.** La opción b describe el 16PF-5, y la c, el TCI-R. **3 c.** Junto con la autotrascendencia; el temperamento incluye búsqueda de novedad, evitación del daño, dependencia de la recompensa y persistencia. **4 b.** El PID-5 incluye psicoticismo en su lugar. **5 a.** La baja amabilidad se corresponde con el antagonismo, y la relación débil es la de apertura con psicoticismo.

Capítulo 4 · Evaluación neuropsicológica

La evaluación neuropsicológica estudia cómo se refleja en la conducta y en el rendimiento cognitivo el estado del cerebro. Este capítulo recorre su historia, sus objetivos y sus dos grandes formas de trabajar, y después repasa los instrumentos que más se usan: las pruebas de cribado, la estimación del CI premórbido, las pruebas de validez de rendimiento y las pruebas específicas de atención, funciones ejecutivas, memoria y visoconstrucción.

Unidad 12 · Historia, objetivos y métodos de la evaluación neuropsicológica

Objetivos: situar los hitos históricos de la neuropsicología, de Broca y Wernicke a Luria y Lezak; enumerar los objetivos y ámbitos de la evaluación neuropsicológica y valorar su papel frente a la neuroimagen; comparar la batería fija y la batería flexible o de proceso; describir el Test Barcelona y el proyecto NEURONORMA.

12.1 Antecedentes históricos

La idea de que cada capacidad mental depende de una parte concreta del cerebro tiene un precedente poco científico: la **frenología** de Franz Joseph Gall, a comienzos del siglo XIX, que suponía un «órgano» cerebral para cada facultad y creía poder estimar su tamaño palpando el cráneo. Carecía de base empírica, pero puso sobre la mesa la pregunta que guiaría el siglo: ¿están localizadas las funciones mentales?

La primera respuesta sólida llegó del **método anatomoclínico**: observar a un paciente en vida y relacionar sus síntomas con la lesión hallada en la autopsia. En 1861, **Paul Broca** estudió a Louis Victor Leborgne, un paciente que entendía buena parte de lo que se le decía, pero apenas podía producir otra cosa que la sílaba «tan». La autopsia mostró una lesión en la parte posterior del lóbulo frontal izquierdo. Unos años después, **Carl Wernicke** (1874) describió el cuadro inverso: pacientes que hablaban con fluidez, pero con un discurso poco comprensible y una comprensión muy alterada, con lesiones en la región temporal posterior izquierda.



Figura 12.1. **Los inicios de la neuropsicología.** Paul Broca; el cerebro de su paciente Louis Victor Leborgne («Tan»), conservado en el Museo Dupuytren de París, cuya lesión frontal izquierda describió Broca en 1861, y Carl Wernicke (hacia 1900). Fuente: Wikimedia Commons; retratos de dominio público; cerebro: Selbymay, CC BY-SA 4.0.

Como muestra la figura 12.1, estos casos convirtieron el lenguaje en el primer gran ejemplo de especialización cerebral. Antes incluso, en 1848, un accidente laboral había aportado otro caso célebre: **Phineas Gage**, a quien una barra de hierro atravesó el lóbulo frontal. Sobrevivió, y su médico, John Harlow, describió años después (1868) un cambio notable en su carácter, con más impulsividad y menos respeto por las normas; casi todo lo que se sabe procede de ese testimonio.

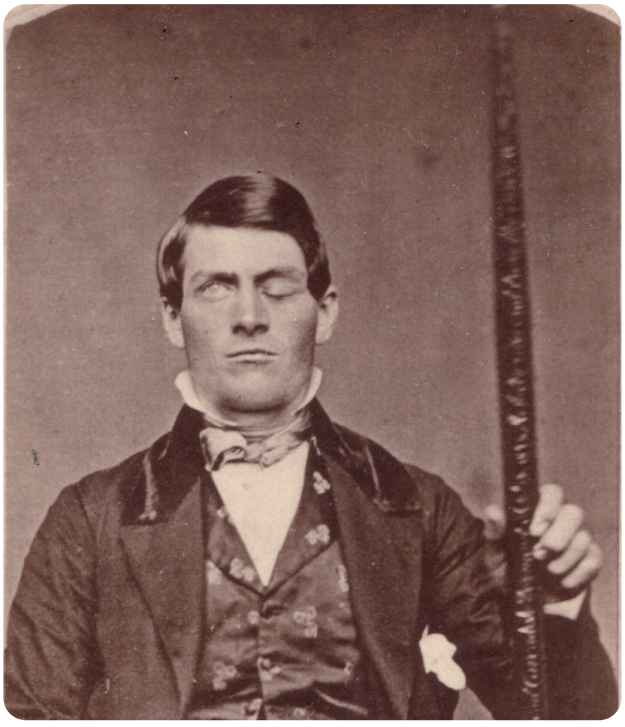


Figura 12.2. **Phineas Gage con la barra de hierro que le atravesó el lóbulo frontal en 1848.** Su caso, documentado sobre todo por su médico, se convirtió en un clásico de la relación entre lóbulo frontal y conducta. Fuente: retrato de autor desconocido, Wikimedia Commons; dominio público.

El caso de la figura 12.2 conviene contarlo con prudencia. La versión popular se fue exagerando con los años, y hoy se sabe que en su última etapa Gage mostró cierta recuperación de su adaptación social. Sigue siendo un caso clásico, pero no una prueba de que el lóbulo frontal sea «el centro de la personalidad».

En el siglo XX, **Aleksandr Luria** superó la oposición entre localizar y no localizar. Tras evaluar a muchos soldados con heridas cerebrales en la Segunda Guerra Mundial, propuso que las funciones complejas no residen en un punto, sino en **sistemas funcionales**: redes de zonas que aportan cada una un componente distinto. Una lesión en lugares diferentes puede alterar la misma función por motivos diferentes. Su obra *Las funciones corticales superiores del hombre* (1962) defendía una evaluación **cualitativa**, centrada en analizar por qué falla el paciente. Luria organizó además el cerebro en tres grandes unidades funcionales: una que regula el tono y la vigilia, otra que recibe, analiza y almacena la información, y otra que programa, regula y verifica la actividad.

En paralelo creció una tradición **psicométrica**. Ward **Halstead** (1947) reunió en su laboratorio pruebas capaces de diferenciar a personas con y sin lesión cerebral, y Ralph **Reitan** las desarrolló hasta formar una batería con un **índice de deterioro**. Muriel **Lezak** publicó en 1976 *Neuropsychological Assessment*, el manual de referencia de la disciplina (5.ª ed., 2012; 6.ª ed., 2023).

Hito	Autor y fecha	Aportación
Afasia de expresión	Broca (1861)	Relación entre lesión frontal izquierda y producción del habla
Afasia de comprensión	Wernicke (1874)	Relación entre lesión temporal izquierda y comprensión
Caso Gage	Accidente de 1848	Lóbulo frontal y regulación de la conducta
Sistemas funcionales	Luria (1962)	Evaluación cualitativa y análisis del síntoma
Batería e índice de deterioro	Halstead (1947) y Reitan	Medición cuantitativa y estandarizada
Manual de referencia	Lezak (1976)	Síntesis de métodos y pruebas de la disciplina

12.2 Ámbitos de aplicación y objetivos

La **evaluación neuropsicológica** es el estudio de las funciones cognitivas, emocionales y conductuales de una persona para conocer el estado de su cerebro y las consecuencias de una posible alteración en su vida diaria. Explora la atención, la memoria, el lenguaje, la percepción, la praxis, la velocidad de procesamiento y las funciones ejecutivas. Las bases neuroanatómicas de estas funciones y los síndromes que produce su lesión se estudian en la asignatura de Neuropsicología y Psicología Fisiológica.

Durante décadas, la pregunta principal era si había o no lesión y dónde estaba. La llegada de la **neuroimagen** (TAC, resonancia magnética) cambió el papel de la disciplina. La imagen muestra muy bien la estructura del cerebro, pero no informa de cómo funciona la persona: dos pacientes con lesiones parecidas pueden tener rendimientos muy distintos, y hay alteraciones funcionales importantes con una resonancia normal o casi normal, como en las fases iniciales de algunas demencias o tras un traumatismo leve. Hoy la evaluación neuropsicológica sigue aportando al diagnóstico, pero su valor principal está en describir el funcionamiento.

Sus objetivos principales son seis:

1. **Diagnóstico.** Detectar alteraciones cognitivas y contribuir al diagnóstico diferencial, por ejemplo entre un deterioro neurodegenerativo incipiente y las quejas de memoria asociadas a una depresión.
2. **Perfil funcional.** Describir qué capacidades están conservadas y cuáles alteradas. Ese mapa de fortalezas y debilidades es la base de casi todo lo demás.
3. **Seguimiento.** Comparar evaluaciones sucesivas de la misma persona para saber si mejora, se mantiene o empeora, y ajustar con ello el tratamiento.
4. **Rehabilitación y reinserción.** Diseñar programas de rehabilitación cognitiva y orientar decisiones como la vuelta al trabajo, la conducción o la vida independiente.
5. **Evaluación forense.** Valorar secuelas en litigios, incapacidades o procedimientos penales, donde la validez del rendimiento debe comprobarse siempre (Unidad 13).

6. **Investigación.** Aportar datos sobre la relación entre cerebro y conducta y servir de medida de resultado en ensayos de fármacos o de programas de rehabilitación.

Los **ámbitos** de aplicación son amplios: neurología (ictus, traumatismos, epilepsia, esclerosis múltiple, demencias), psiquiatría (alteraciones cognitivas en la esquizofrenia o la depresión), neurodesarrollo (TDAH, dificultades de aprendizaje), envejecimiento, contexto laboral y contexto judicial.

El proceso sigue las fases generales de cualquier evaluación psicológica, descritas en el libro de Evaluación Psicológica I. Incluye una **entrevista** con el paciente y, casi siempre, con un familiar, porque muchas personas con daño cerebral no perciben bien sus propios déficits. Siguen la revisión de la historia clínica, la aplicación de pruebas, la integración de los resultados y la devolución.

Un ejemplo: Carmen, de 68 años, acude porque olvida citas y repite preguntas. La resonancia muestra cambios propios de la edad. La evaluación revela que aprende mal la información nueva y la olvida rápido, aunque el lenguaje y la atención están conservados. El informe no se limita a «hay deterioro». Indica qué está alterado, qué conserva y qué apoyos le pueden servir, como una agenda o recordatorios en el móvil, y propone una nueva evaluación en un año para valorar la evolución. Ese es el valor añadido frente a la imagen.

12.3 Batería fija y batería flexible

Hay dos formas clásicas de organizar una evaluación neuropsicológica. En la **batería fija** se aplica a todas las personas el mismo conjunto de pruebas, en el mismo orden y con las mismas normas de corrección. En la **batería flexible** el profesional elige las pruebas según el motivo de consulta y las hipótesis que va formulando.

	Batería fija	Batería flexible o de proceso
Procedimiento	Las mismas pruebas para todos, en el mismo orden	Pruebas elegidas según las hipótesis; se analizan también los errores
Ventajas	Comparabilidad entre casos; útil para investigar	Adaptada al caso; más breve; informa del «cómo» del fallo
Inconvenientes	Larga y rígida; puede evaluar lo que no hace falta	Depende más de la pericia del evaluador; menos comparable
Ejemplos	Halstead-Reitan; Luria-Nebraska	Enfoque de Boston (Kaplan); la práctica más extendida hoy

Figura 12.3. **Batería fija y batería flexible.** Comparación del procedimiento, las ventajas, los inconvenientes y los ejemplos de cada enfoque: Halstead-Reitan y Luria-Nebraska frente al enfoque de proceso de Boston. Elaboración propia.

Como muestra la figura 12.3, las dos baterías fijas clásicas son estas:

- **Batería Halstead-Reitan.** Procede del trabajo de Halstead (1947) y Reitan. Incluye pruebas como el Test de Categorías (formación de conceptos), el golpeteo digital (velocidad motora), la Prueba de Ejecución Táctil, el Test de Ritmo de Seashore y la percepción de sonidos del habla, además del Trail Making Test. Varias de sus puntuaciones se combinan en un **índice de deterioro** que indica si el rendimiento global es compatible con daño cerebral. Su aplicación es muy larga.
- **Batería Luria-Nebraska** (Golden, 1980). Intenta convertir en una prueba estandarizada y puntuable los procedimientos de exploración de Luria. Ofrece escalas clínicas para áreas como la motricidad, el lenguaje, la lectura, la escritura o la memoria. Se le ha reprochado que simplifica en exceso el método de Luria, que era cualitativo, y que sus escalas de localización no tienen la validez que su nombre sugiere.

Las ventajas de la batería fija son la **comparabilidad** entre pacientes y centros y su utilidad para la **investigación**: con las mismas pruebas en todos los casos, se pueden acumular datos y comparar grupos. Sus inconvenientes son la **duración**, la **rigidez** (se aplican pruebas innecesarias y faltan otras que harían falta) y el desgaste del paciente.

La batería flexible responde a esas críticas. La evaluación empieza con la entrevista y unas pruebas generales y, según lo que aparece, se profundiza en unas áreas y se abrevian otras. Una versión influyente es el **enfoque de proceso** desarrollado en Boston por Edith **Kaplan**: además de la puntuación final, se analiza **cómo** llega el paciente al resultado y **qué tipo de errores** comete. Dos personas pueden obtener la misma puntuación al copiar un dibujo complejo. Una lo hace de forma organizada, empezando por la estructura general, y otra lo copia trozo a trozo, sin plan. La puntuación es igual, pero el problema de fondo, probablemente ejecutivo en el segundo caso, es distinto.

Rasgo	Batería fija	Batería flexible o de proceso
Selección de pruebas	La misma para todos	Según el caso y las hipótesis
Interés principal	Puntuaciones y su comparación con normas	Puntuaciones y forma de resolver la tarea
Ventaja	Comparabilidad, investigación	Eficiencia, adaptación al paciente
Inconveniente	Larga, rígida, cansa	Menos estandarizada, depende de la pericia
Ejemplos	Halstead-Reitan, Luria-Nebraska	Enfoque de Boston (Kaplan)

El enfoque flexible o de proceso es el **predominante hoy**. Su riesgo es que depende mucho del criterio del evaluador: si las hipótesis iniciales están sesgadas, la selección de pruebas puede confirmar lo que ya se esperaba. Por eso exige formación sólida y pruebas con buenas normas.

12.4 Baterías españolas: Test Barcelona y NEURONORMA

Las pruebas neuropsicológicas no se pueden importar sin más. El rendimiento depende de la lengua, de la escolaridad y de la edad, y unas normas obtenidas en otro país pueden hacer que una persona sana parezca deteriorada o al revés. En España, dos proyectos dirigidos por Jordi **Peña-Casanova** han sido decisivos.

El Test Barcelona. Publicado en 1990, es el resultado de un programa integrado de exploración neuropsicológica adaptado a la población española. Se inspira en la exploración de Luria y en el enfoque de proceso, y reúne unos **42 subtests** según la mayoría de las fuentes. Explora, entre otras áreas:

- orientación y atención;
- lenguaje (fluidez, repetición, denominación, comprensión), lectura y escritura;
- praxias y gnosias (gestos, copia de dibujos, reconocimiento visual);
- memoria verbal y visual;
- abstracción, cálculo y otras funciones ejecutivas.

Sus resultados se representan en un **perfil** que permite ver de un vistazo qué áreas están conservadas y cuáles alteradas. Existe una versión abreviada para cuando el tiempo es limitado, y en 2019 apareció el **Test Barcelona-2**, una edición revisada.

El proyecto NEURONORMA. No es una batería nueva, sino un proyecto para obtener **normas españolas** de pruebas neuropsicológicas muy utilizadas. Peña-Casanova et al. (2009) evaluaron a **356 personas mayores de 49 años** con una selección de pruebas clásicas, como el Stroop, el Trail Making Test, las fluencias verbales o la Figura compleja de Rey (Unidad 13). Su aportación más importante es que ofrece **normas conjuntas** (conormalización), ajustadas por **edad y escolaridad**:

1. Todas las pruebas se baremaron con la **misma muestra**. Así se pueden comparar los rendimientos de una persona en distintas pruebas sin que las diferencias se deban a que cada baremo procede de un grupo diferente.
2. Las puntuaciones se ajustan por **edad** y por **años de escolaridad**, dos variables con un peso enorme en el rendimiento de las personas mayores.
3. Se centra en la población en la que más se plantea el diagnóstico de **deterioro cognitivo** y demencia.

Un ejemplo muestra por qué importa el ajuste. Dos mujeres de 75 años nombran 11 animales en un minuto. Para una que dejó la escuela a los diez años, puede ser un rendimiento dentro de lo esperable. Para una catedrática jubilada, el mismo resultado puede ser bajo para su nivel previo. Sin normas ajustadas, a la primera se la podría etiquetar de deteriorada y a la segunda se le pasaría por alto un cambio real.

La conversión de las puntuaciones directas en puntuaciones típicas y percentiles se explica en el libro de Evaluación Psicológica I. Además del Test Barcelona y de NEURONORMA, en España se usan adaptaciones de pruebas internacionales con normas propias, como el TAVEC para la memoria verbal (Unidad 13).

Consenso y debate

Consenso: la evaluación neuropsicológica aporta información sobre el funcionamiento que la neuroimagen no proporciona, y su valor está tanto en el diagnóstico como en el perfil funcional, el seguimiento y la rehabilitación. En la práctica actual predomina el enfoque flexible o de proceso frente a las baterías fijas. Las normas deben ser locales y estar ajustadas por edad y escolaridad.

Debate: cuánto debe estandarizarse una evaluación flexible para que sea comparable entre profesionales y centros sin perder su capacidad de adaptarse al caso, y qué papel deben conservar las baterías fijas fuera de la investigación.

Mito frecuente

Mito: «Con las pruebas de neuroimagen actuales, la evaluación neuropsicológica ya no es necesaria».

Realidad: la neuroimagen muestra la estructura, pero no qué puede hacer la persona, cómo afecta la lesión a su vida diaria ni cómo evoluciona. Hay alteraciones cognitivas con imagen normal y lesiones parecidas con consecuencias muy distintas. Por eso la evaluación neuropsicológica sigue siendo necesaria para el perfil funcional, el seguimiento y la rehabilitación (Lezak et al., 2012).

Conceptos clave

Concepto	Definición
Método anatomoclínico	Relación entre los síntomas observados en vida y la lesión hallada en la autopsia
Sistema funcional	Red de zonas cerebrales que aportan componentes distintos a una función compleja (Luria)
Evaluación cualitativa	Análisis de cómo y por qué falla el paciente, además de su puntuación
Índice de deterioro	Puntuación global de la batería Halstead-Reitan que indica posible daño cerebral
Batería fija	Conjunto de pruebas idéntico para todos los pacientes, con el mismo orden y corrección
Batería flexible	Selección de pruebas según el motivo de consulta y las hipótesis del evaluador
Enfoque de proceso	Enfoque de Boston (Kaplan) que analiza la estrategia y los errores, no solo el resultado
Normas conjuntas	Baremos de varias pruebas obtenidos en la misma muestra, como en NEURONORMA

Clave PIR

Prioridad media. Se pregunta la asociación entre autores y aportaciones (Broca, Wernicke, Luria, Halstead-Reitan, Kaplan), los objetivos de la evaluación neuropsicológica y las ventajas e inconvenientes de las baterías fija y flexible. Trampas típicas: atribuir a Luria una batería fija (la Luria-Nebraska es de Golden), confundir la afasia de Broca con la de Wernicke y pensar que NEURONORMA es una batería nueva en lugar de un proyecto de normas.

Autoevaluación

1. Leborgne, el paciente que Broca estudió en 1861, se caracterizaba por…
a) un habla fluida con la comprensión muy alterada
b) una comprensión bastante conservada con habla casi nula
c) una pérdida grave de la memoria de hechos recientes

2. La noción de sistema funcional de Luria implica que…
a) cada función compleja depende de varias zonas coordinadas
b) cada función compleja reside en un único centro cortical
c) el cerebro funciona como un todo sin especialización

3. Repetir una evaluación seis meses después de un traumatismo craneoencefálico para valorar la recuperación responde al objetivo de…
a) diagnóstico diferencial de la lesión
b) investigación de nuevos tratamientos
c) seguimiento de la evolución del paciente

4. Analizar cómo copia un paciente un dibujo complejo, y no solo su puntuación, es propio de…
a) la batería Halstead-Reitan
b) el enfoque de proceso de Boston
c) el índice de deterioro global

5. Una aportación característica de NEURONORMA es que…
a) ofrece normas conjuntas ajustadas por edad y escolaridad
b) sustituye a la entrevista clínica con el paciente
c) está baremado sobre todo con población infantil

Soluciones

1 b. Entendía buena parte de lo que se le decía, pero apenas producía la sílaba «tan». **2 a.** Una función compleja depende de una red de zonas que aportan componentes distintos. **3 c.** Repetir la evaluación permite valorar la recuperación o el deterioro. **4 b.** El enfoque de proceso analiza la estrategia y los errores además del resultado. **5 a.** Todas las pruebas se baremaron en la misma muestra de personas mayores de 49 años.

Unidad 13 · Cribado, CI premórbido, validez de rendimiento y pruebas específicas

Objetivos: describir el MMSE, el MoCA, el test del reloj y el cuestionario de Pfeiffer y valorar sus límites; explicar el papel de la inteligencia en la evaluación neuropsicológica y los métodos para estimar el CI premórbido; definir la validez de rendimiento y explicar la lógica del TOMM; identificar qué función evalúan las principales pruebas específicas.

13.1 Cribado del estado mental: MMSE, MoCA, reloj y Pfeiffer

Una **prueba de cribado** es una exploración breve que sirve para decidir si hay indicios suficientes para hacer una evaluación completa. No diagnostica: separa a quienes probablemente no tienen un problema de quienes necesitan un estudio más detallado. Se usa mucho en atención primaria, en neurología y en geriatría. Los conceptos de sensibilidad, especificidad y punto de corte se tratan en el libro de Evaluación Psicológica I.

El MMSE (*Mini-Mental State Examination*; Folstein, Folstein y McHugh, 1975) es la prueba de cribado más conocida. Se aplica en unos minutos y su puntuación máxima es **30**. Explora la orientación en el tiempo y en el espacio, el registro y el recuerdo de tres palabras, la atención y el cálculo, el lenguaje (denominar, repetir, obedecer una orden, leer y escribir una frase) y la copia de dos pentágonos que se cruzan. En España se usa también el **MEC** de Lobo, su adaptación española. Suele tomarse como referencia un punto de corte en torno a 24, que debe ajustarse por edad y escolaridad. Sus límites principales son tres:

- Tiene **efecto techo**: muchas personas con estudios obtienen 29 o 30 aunque tengan un deterioro leve.
- Apenas explora las **funciones ejecutivas** y la memoria con demora.
- Depende mucho de la **escolaridad**, de modo que puede señalar como deterioradas a personas con poca formación.

El MoCA (*Montreal Cognitive Assessment*; Nasreddine et al., 2005) se diseñó para detectar el **deterioro cognitivo leve** (DCL). También puntúa sobre 30, pero sus tareas son más exigentes: una versión breve del Trail Making Test, la copia de un cubo, el dibujo de un reloj, denominación, recuerdo diferido de cinco palabras, atención, fluidez, abstracción y orientación. Se suma un punto a quienes tienen 12 años de escolaridad o menos.

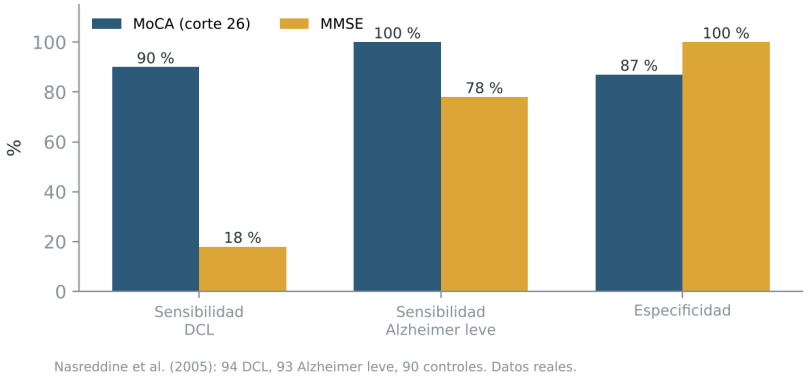


Figura 13.1. **Sensibilidad y especificidad del MoCA y del MMSE.** Con un punto de corte de 26, el MoCA detectó el 90 % de los casos de deterioro cognitivo leve y el MMSE, el 18 %; en el Alzheimer leve, el 100 % frente al 78 %. La especificidad fue del 87 % frente al 100 %. Datos de Nasreddine et al. (2005). Elaboración propia.

Como muestra la figura 13.1, en el estudio original (94 personas con DCL, 93 con Alzheimer leve y 90 controles) el MoCA fue mucho más sensible que el MMSE, a cambio de una especificidad algo menor. Estudios posteriores en población general sugieren que el corte de 26 puede ser **demasiado alto** y clasificar como deterioradas a muchas personas sanas, sobre todo con poca escolaridad. Por eso se recomienda usar normas locales.

El test del reloj pide dibujar la esfera de un reloj con todos los números y las agujas marcando una hora concreta. Parece sencillo, pero exige comprensión, planificación, memoria semántica y visoconstrucción. Es breve, se tolera bien y existen varios sistemas de corrección.

El cuestionario de Pfeiffer (SPMSQ, 1975) consta de **10 preguntas** sobre orientación, datos personales, información general y cálculo sencillo. Se cuentan los errores y se ajusta por nivel educativo.

Prueba	Puntuación	Punto fuerte	Límite principal
MMSE	0–30	Muy difundida, rápida	Efecto techo; poco sensible al DCL
MoCA	0–30	Sensible al DCL; incluye funciones ejecutivas	El corte de 26 puede ser alto
Test del reloj	Según el sistema	Breve, explora varias funciones	Corrección poco unificada
Pfeiffer	Errores sobre 10	Solo verbal, muy breve	Poco sensible a cambios leves

Un resultado positivo en un cribado obliga a evaluar a fondo. Un resultado negativo no descarta un problema si hay quejas consistentes o cambios observados por la familia.

13.2 La inteligencia como complemento y el CI premórbido

Las escalas de inteligencia, sobre todo la **WAIS-IV** (Unidad 7), son un complemento habitual de la evaluación neuropsicológica. Sitúan el rendimiento global de la persona respecto a su grupo de edad y, con sus cuatro índices (comprensión verbal, razonamiento perceptivo, memoria de trabajo y velocidad de procesamiento), sugieren qué áreas conviene explorar con más detalle. Una velocidad de procesamiento muy por debajo del resto, por ejemplo, es frecuente tras un traumatismo craneoencefálico.

Conviene no confundir los dos tipos de evaluación. Una **evaluación de la inteligencia no es una evaluación neuropsicológica**. Las escalas de inteligencia no exploran a fondo la memoria a largo plazo, el lenguaje o muchas funciones ejecutivas, y una persona puede tener un CI total en la media con una alteración grave de la memoria. Además, las diferencias entre índices deben interpretarse con cautela: diferencias de varios puntos son frecuentes en la población sin lesión, y no indican por sí solas un deterioro.

Para saber si una persona ha perdido capacidades, no basta con compararla con la media de la población: hay que compararla **consigo misma**. El **CI premórbido** es una estimación del nivel intelectual que tenía antes de la enfermedad o la lesión. Su utilidad se ve en un ejemplo. Un CI de 95 en una arquitecta de 55 años tras un ictus está dentro de la media, pero puede suponer una pérdida importante si su nivel previo era claramente superior. El mismo 95 en otra persona puede reflejar su nivel de siempre.

Casi nunca hay una evaluación anterior, así que el CI premórbido se **estima**. Los métodos principales son:

1. **Lectura de palabras irregulares.** Leer en voz alta palabras que no se pronuncian como se escriben exige haberlas aprendido antes. Es una habilidad muy sobreaprendida que **resiste bastante al daño cerebral** y se relaciona con el nivel intelectual previo. Es la base del **WTAR** (2001), en inglés, y del **TAP** (Test de Acentuación de Palabras), en español, que presenta palabras escritas sin tilde para que la persona las lea con el acento correcto.
2. **Fórmulas demográficas.** Estiman el CI a partir de la edad, los años de escolaridad y la ocupación, mediante ecuaciones obtenidas en muestras normativas.
3. **Subtests resistentes.** Algunas pruebas de las escalas de Wechsler, como Vocabulario o Información, se ven menos afectadas por el daño que otras, como las de velocidad. Su rendimiento puede servir de referencia del nivel previo.

4. **Historia académica y laboral.** Las notas, los estudios terminados y el tipo de trabajo dan pistas, aunque menos precisas.

Ningún método es perfecto. La lectura de palabras falla cuando el daño afecta al propio lenguaje (afasias, demencias avanzadas), y las fórmulas demográficas tienden a acercar las estimaciones a la media, de modo que subestiman los niveles altos y sobrestiman los bajos. Lo recomendable es **combinar varios métodos** y contrastar los resultados con la historia de la persona.

13.3 Validez de rendimiento y simulación

Las pruebas neuropsicológicas solo informan de las capacidades de una persona si esta se esfuerza de verdad. La **validez de rendimiento** es el grado en que los resultados reflejan el nivel real de capacidad. Un rendimiento bajo puede deberse a un déficit, pero también a fatiga, dolor, desmotivación, un estado de ánimo muy bajo o la intención deliberada de rendir mal.

Este último caso es especialmente importante cuando hay **incentivos externos**: indemnizaciones por accidentes, incapacidades laborales, litigios o procedimientos penales. Por eso la evaluación de la validez de rendimiento es **imprescindible en contextos forenses y de compensación**, y cada vez se recomienda más en la práctica clínica general.

Conviene distinguir dos tipos de indicadores:

Tipo	Qué evalúa	Ejemplo
Validez de rendimiento	Si el esfuerzo en las pruebas cognitivas es adecuado	TOMM; indicadores integrados en otras pruebas
Validez de síntomas	Si los síntomas que se refieren son creíbles	Escalas de validez de autoinformes como el MMPI-2 (Unidad 10)

El TOMM (*Test of Memory Malingering*; Tombaugh, 1996) es la prueba independiente de validez de rendimiento más conocida. La persona ve una serie de dibujos de objetos cotidianos y después, en cada ensayo, debe elegir entre dos dibujos cuál había visto. Aunque parece una prueba de memoria, es **tan fácil** que la mayoría de las personas con daño cerebral real la resuelven bien. Su lógica descansa en dos ideas:

- Un rendimiento muy inferior al de personas con lesiones cerebrales demostradas es poco creíble.
- En una prueba de **elección forzada** con dos opciones, quien responde al azar acierta en torno al 50 %. Un resultado **claramente por debajo del azar** indica que la persona reconoce la respuesta correcta y elige la incorrecta.

Además de las pruebas independientes, hay **indicadores integrados** en pruebas de uso habitual: patrones de rendimiento poco verosímiles, como reconocer peor que se recuerda libremente o fallar en ítems muy fáciles y acertar en otros difíciles. Su ventaja es que no alargan la evaluación y son menos fáciles de identificar.

La interpretación exige prudencia por varios motivos:

1. Ningún indicador aislado basta; se recomienda usar **varios** a lo largo de la evaluación.
2. Fallar una prueba de validez significa que los resultados de esa sesión **no son interpretables** como medida de capacidad. No demuestra por sí solo que la persona mienta.
3. La **simulación** (producción intencionada de síntomas falsos o exagerados por un incentivo externo) es una conclusión que integra todos los datos: pruebas, historia clínica, coherencia con la vida diaria y contexto. El DSM-5-TR no la considera un trastorno mental, sino un problema que puede ser objeto de atención clínica (asignatura de Psicopatología).

Un ejemplo: tras un accidente de tráfico leve, un hombre reclama una indemnización por graves problemas de memoria. En la evaluación recuerda menos palabras que muchos pacientes con Alzheimer, pero explica con

detalle todos sus trámites, y su resultado en el TOMM está por debajo del azar. Estos datos no permiten describir su memoria real, y obligan a informar de que el rendimiento no es válido. El juicio de simulación corresponde al conjunto de la evidencia, no a una sola puntuación.

13.4 Pruebas de atención, funciones ejecutivas, memoria y visoconstrucción

En una batería flexible se combinan pruebas específicas según las hipótesis. Ninguna prueba es «pura»: todas requieren varias funciones a la vez, y la interpretación depende de comparar unas con otras.

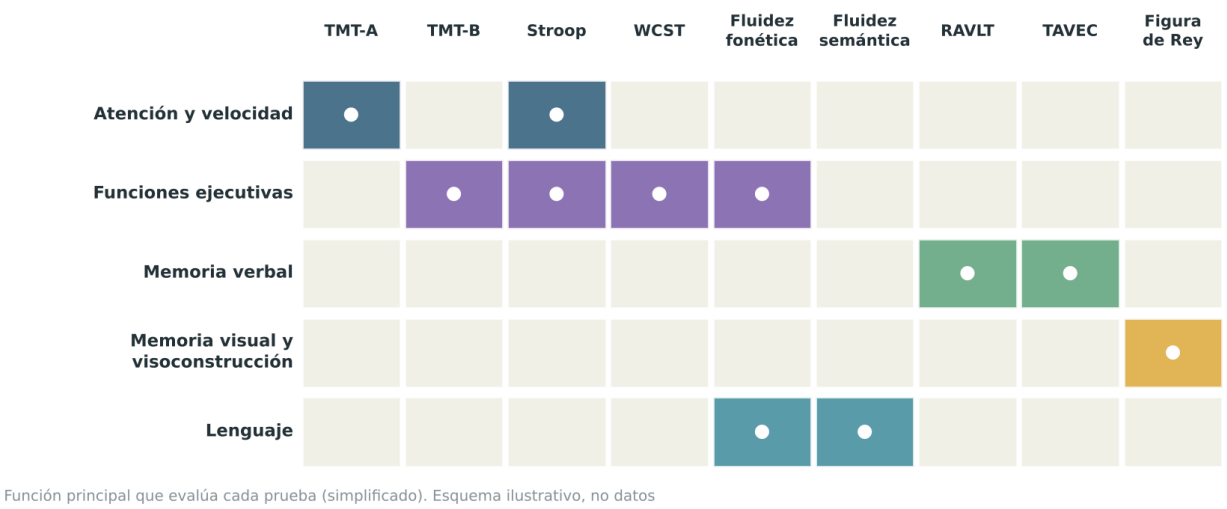


Figura 13.2. **Funciones cognitivas y pruebas que las evalúan.** Matriz que relaciona la atención y la velocidad (TMT-A, Stroop), las funciones ejecutivas (TMT-B, interferencia del Stroop, WCST, fluidez fonética), la memoria verbal (RAVLT, TAVEC), la memoria visual y la visoconstrucción (Figura de Rey) y el lenguaje (fluidez fonética y semántica). Elaboración propia.

Como muestra la figura 13.2, cada función se explora con varias pruebas y cada prueba aporta información sobre varias funciones.

Atención, velocidad y funciones ejecutivas.

- **Trail Making Test (TMT).** En la parte A se unen con una línea números en orden (1-2-3…); mide sobre todo atención y velocidad. En la parte B se alternan números y letras (1-A-2-B…), lo que exige **flexibilidad cognitiva**. La comparación entre B y A ayuda a separar la lentitud general del problema ejecutivo.
- **Stroop** (1935; versión de Golden). Tras leer palabras de colores y nombrar colores, la persona debe decir el color de la tinta de palabras que nombran otro color (la palabra «rojo» escrita en verde). La dificultad para inhibir la lectura, muy automatizada, es el **efecto de interferencia**, una medida de control inhibitorio.
- **Wisconsin Card Sorting Test** (WCST; Grant y Berg, 1948). Hay que clasificar tarjetas por color, forma o número sin que se diga el criterio; solo se informa de si cada respuesta es correcta. Tras varios aciertos, el criterio cambia sin aviso. Los **errores perseverativos**, seguir aplicando la regla anterior, reflejan dificultades de flexibilidad. Son frecuentes en lesiones frontales, pero no exclusivos de ellas.
- **Fluidez verbal.** Se pide decir en un minuto palabras que empiecen por una letra (**fluidez fonética**) o que pertenezcan a una categoría, como animales (**fluidez semántica**). La fonética depende más de las funciones ejecutivas; la semántica, más de la memoria semántica y del lenguaje.

Memoria verbal.

- **RAVLT** (Test de Aprendizaje Auditivo Verbal de Rey). Se lee una lista de 15 palabras en cinco ensayos, se presenta una lista de interferencia y se pide el recuerdo inmediato, el diferido y el reconocimiento. Permite ver la **curva de aprendizaje**, el olvido y si el problema está en guardar la información o en recuperarla.

- **TAVEC** (Test de Aprendizaje Verbal España-Complutense; Benedet y Alejandre, 1998; nueva edición en 2014). Usa una lista de la compra con palabras de varias categorías semánticas. Además del aprendizaje y el olvido, informa de si la persona **organiza** la información por categorías y de si mejora con claves.

Memoria visual y visoconstrucción. En la **Figura compleja de Rey** (Rey, 1941; Osterrieth, 1944), la persona copia un dibujo geométrico complejo y después lo reproduce de memoria. La copia evalúa la **visoconstrucción** y la planificación; la reproducción, la **memoria visual**. Como se vio en el apartado 12.3, la estrategia de copia aporta tanta información como la puntuación.

Consenso y debate

Consenso: el MoCA detecta el deterioro cognitivo leve mejor que el MMSE (Nasreddine et al., 2005). Un cribado no diagnostica, y un cribado normal no descarta un deterioro leve. La validez de rendimiento debe evaluarse siempre en contextos con incentivos, con varios indicadores. La evaluación de la inteligencia complementa, pero no sustituye, a la neuropsicológica.

Debate: el punto de corte del MoCA, porque los estudios poblacionales sugieren que 26 puede ser demasiado alto y conviene usar normas locales. También se discute con qué frecuencia deben incluirse pruebas de validez de rendimiento en la práctica clínica sin incentivos y cómo interpretar un fallo aislado.

Mito frecuente

Mito: «Si el MMSE sale normal, se puede descartar el deterioro cognitivo».

Realidad: el MMSE tiene efecto techo y es poco sensible al deterioro leve: en el estudio de Nasreddine et al. (2005) detectó solo el 18 % de los casos de deterioro cognitivo leve, frente al 90 % del MoCA. Ante quejas consistentes, sobre todo en personas con estudios, un MMSE normal no excluye el deterioro, y conviene completar la evaluación.

Conceptos clave

Concepto	Definición
Prueba de cribado	Exploración breve que indica si se necesita una evaluación completa; no diagnostica
Efecto techo	Acumulación de puntuaciones cerca del máximo que impide detectar diferencias leves
CI premórbido	Estimación del nivel intelectual previo a la enfermedad o la lesión
Lectura de palabras irregulares	Método de estimación premórbida basado en una habilidad que resiste al daño (TAP, WTAR)
Validez de rendimiento	Grado en que los resultados de las pruebas reflejan la capacidad real de la persona
Elección forzada	Formato con opciones fijas; acertar claramente por debajo del azar indica respuesta intencionada
Efecto de interferencia	Dificultad para nombrar el color de la tinta cuando la palabra nombra otro color (Stroop)

Concepto	Definición
Error perseverativo	Seguir aplicando una regla que ya no es válida, típico del WCST

Clave PIR

Prioridad alta. Se pregunta qué mide cada prueba (Stroop, TMT, WCST, Figura de Rey, TAVEC), la comparación entre MoCA y MMSE, los métodos de estimación del CI premórbido y la lógica de la validez de rendimiento. Trampas típicas: creer que un MMSE normal descarta el deterioro, atribuir la Figura de Rey solo a la memoria (la copia evalúa visoconstrucción), confundir evaluar la inteligencia con hacer una evaluación neuropsicológica y suponer que fallar una prueba de validez demuestra simulación.

Autoevaluación

1. En el estudio de Nasreddine et al. (2005), con un corte de 26, la sensibilidad para el deterioro cognitivo leve fue…
a) muy parecida en el MoCA y en el MMSE
b) del 90 % en el MoCA y del 18 % en el MMSE
c) del 100 % en el MMSE y del 87 % en el MoCA

2. La lectura de palabras irregulares se usa para estimar el CI premórbido porque…
a) es una habilidad sobreaprendida que resiste bastante al daño
b) mide sobre todo la velocidad de procesamiento actual
c) no guarda relación con la escolaridad de la persona

3. En una prueba de elección forzada con dos opciones, un resultado claramente inferior al 50 % sugiere…
a) un daño cerebral grave y difuso
b) la fatiga normal tras una sesión larga
c) que la persona reconoce la respuesta y elige la incorrecta

4. Los errores perseverativos en el Wisconsin Card Sorting Test reflejan sobre todo…
a) dificultad para cambiar de criterio cuando cambia la regla
b) un déficit en el aprendizaje de listas de palabras
c) lentitud motora al colocar las tarjetas

5. Una ingeniera jubilada con quejas de memoria obtiene 29 en el MMSE. Lo más adecuado es concluir que…
a) el resultado descarta cualquier deterioro cognitivo
b) el resultado indica una demencia en fase leve
c) el resultado no descarta un deterioro leve

Soluciones

1 b. El MoCA fue mucho más sensible, a cambio de una especificidad algo menor (87 % frente a 100 %). **2 a.** Es una habilidad muy consolidada que se relaciona con el nivel previo. **3 c.** Responder al azar daría en torno al 50 % de aciertos; quedar claramente por debajo indica respuesta intencionada. **4 a.** La persona sigue aplicando la regla anterior tras el cambio de criterio. **5 c.** El MMSE tiene efecto techo; ante quejas consistentes conviene usar pruebas más sensibles, como el MoCA, y completar la evaluación.

Capítulo 5 · Intereses vocacionales y actitudes

Saber qué le gusta hacer a una persona y qué opina de un objeto, un grupo o una idea no es lo mismo que medir su inteligencia o su personalidad, aunque los tres ámbitos se tocan. Este capítulo estudia dos familias de instrumentos clásicas: los inventarios de intereses vocacionales, nacidos de la orientación profesional, y las escalas de actitudes, nacidas de la psicología social. Ambas comparten un problema de fondo: convertir preferencias y opiniones en puntuaciones que tengan sentido.

Unidad 14 · Evaluación de los intereses vocacionales

Objetivos: definir los intereses vocacionales y distinguir sus formas de evaluación; describir el modelo RIASEC de Holland, el hexágono y sus conceptos de congruencia, consistencia y diferenciación; explicar el formato ipsativo del Kuder y sus consecuencias; describir el método empírico de Strong y compararlo con los enfoques tipológico y temático.

14.1 Concepto y enfoques metodológicos

Los **intereses vocacionales** son preferencias relativamente estables por ciertas actividades, ambientes de trabajo y ocupaciones. Responden a la pregunta «¿qué me gustaría hacer?», no a «¿qué sé hacer?» ni a «¿cómo soy?». Esa distinción importa. Una persona puede tener mucha aptitud numérica y aburrirse con la contabilidad, o adorar la música sin oído para tocar un instrumento. Por eso la orientación profesional combina la evaluación de intereses con la de aptitudes (Unidad 8) y, a menudo, con la de personalidad.

Intereses, rasgos y actitudes se solapan en parte (el gusto por tratar con gente tiene algo de las tres cosas); se estudian por separado más por tradición y propósito que por una separación teórica clara.

Formas de conocer los intereses. Hay tres vías principales, que no se excluyen:

- **Intereses expresados.** Se pregunta directamente: «¿qué te gustaría estudiar?». Es lo más rápido, pero la respuesta depende de lo que la persona conoce. Un adolescente no puede expresar interés por profesiones de cuya existencia no sabe nada.
- **Intereses manifiestos.** Se infieren de la **conducta**: en qué actividades participa alguien por voluntad propia, qué asignaturas elige, en qué gasta su tiempo libre. Son datos valiosos, pero dependen de las oportunidades que se han tenido.
- **Intereses inventariados.** Se obtienen con **tests**: listas de actividades, ocupaciones o asignaturas que la persona valora. Permiten comparar con grupos normativos y explorar campos que la persona no había considerado.

Dentro de los inventarios conviven tres **enfoques de construcción**, que organizan el resto de la unidad:

Enfoque	Representante	Cómo se forman las escalas	Pregunta que responde
Tipológico	Holland (RIASEC)	A partir de una teoría de seis tipos de personas y ambientes	¿A qué tipo se parece esta persona?

Enfoque	Representante	Cómo se forman las escalas	Pregunta que responde
Por áreas temáticas	Kuder	Agrupando actividades por su contenido (cálculo, música, aire libre…)	¿Qué áreas de actividad prefiere?
Empírico o de criterio	Strong	Comparando las respuestas con las de profesionales satisfechos	¿Se parecen sus gustos a los de quienes ejercen tal profesión?

Formato absoluto y formato relativo. En el **formato absoluto** (o normativo) cada actividad se valora por separado («me gusta», «me es indiferente», «me disgusta»), y las escalas pueden compararse con un baremo y entre personas. En el **formato relativo** o **ipsativo** se elige entre varias actividades a la vez, de modo que preferir una supone renunciar a otra; el perfil se interpreta entonces dentro de la propia persona (apartado 14.3).

Para qué sirven. Se usan sobre todo en la **orientación académica** al final de la secundaria, pero también en los **cambios de carrera** de la vida adulta y, con más prudencia, en selección de personal, donde el candidato sabe qué intereses «convienen» y puede ajustar sus respuestas (Evaluación Psicológica I). Los intereses son bastante **estables** desde el final de la adolescencia, aunque no inmutables, así que conviene leer el resultado como punto de partida para explorar opciones y repetir la evaluación si las circunstancias cambian. La orientación como proceso educativo se trata en Psicología Educativa y Orientación.

14.2 El modelo RIASEC de Holland y el SDS

John L. Holland (1959/1997) propuso la teoría más influyente sobre la elección vocacional. Tanto las **personas** como los **ambientes de trabajo** pueden describirse con los mismos seis tipos. La gente busca ambientes que le permitan ejercer sus capacidades y expresar sus valores, y la conducta laboral depende de la interacción entre persona y ambiente.

Los seis tipos se conocen por sus iniciales, **RIASEC**:

Tipo	Prefiere	Ejemplos de ocupaciones
Realista (R)	Trabajar con objetos, máquinas, herramientas, animales o plantas	Electricista, mecánica, agricultor
Investigador (I)	Observar, analizar y resolver problemas abstractos	Bióloga, analista de datos, químico
Artístico (A)	Crear y expresarse en contextos poco estructurados	Ilustrador, actriz, músico
Social (S)	Ayudar, enseñar, cuidar e informar a otras personas	Maestra, enfermero, trabajadora social
Emprendedor (E)	Persuadir, dirigir y asumir riesgos para lograr metas	Comercial, gerente, abogada
Convencional (C)	Ordenar datos y seguir procedimientos claros	Administrativo, contable, auxiliar de archivo

El hexágono. Holland dispuso los seis tipos en un hexágono, en el orden R-I-A-S-E-C. La distancia entre dos tipos refleja su semejanza: los **adyacentes** (R-I, A-S, E-C…) tienen mucho en común; los **alternos** (R-A, I-S…), algo menos; y los **opuestos** (R-S, I-E, A-C) son los más distintos.

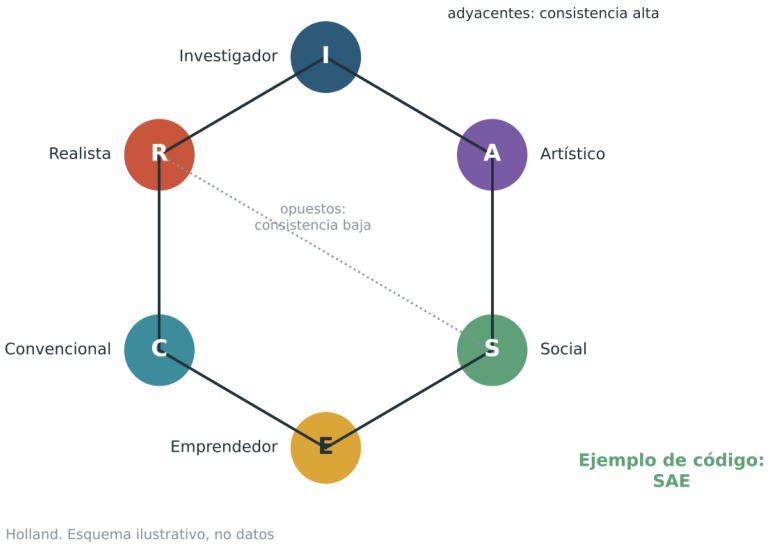


Figura 14.1. **El hexágono RIASEC.** Los seis tipos de Holland aparecen en su orden circular. Los tipos adyacentes indican una combinación de consistencia alta y los opuestos, de consistencia baja; el ejemplo destacado es el código SAE. Elaboración propia.

Como muestra la figura 14.1, el resultado de una evaluación no es un solo tipo, sino un **código de tres letras** con los tipos más altos en orden. Un código SAE describe a alguien sobre todo social, después artístico y después emprendedor. Las ocupaciones también reciben código (bases de datos como O∗NET las clasifican así), de modo que se buscan las que coinciden con el de la persona.

Cuatro conceptos clave. El hexágono permite definir los conceptos con los que se interpreta un perfil:

- **Congruencia:** grado de ajuste entre el tipo de la persona y el del ambiente. Un perfil social en un trabajo social es congruente; en un puesto convencional de archivo, no. Se espera que la congruencia se asocie con satisfacción y permanencia.
- **Consistencia:** grado en que los dos primeros tipos del código están **próximos en el hexágono**. SA es consistente (adyacentes); SR no lo es (opuestos). Es una propiedad del perfil de la persona, no de su relación con el ambiente.
- **Diferenciación:** nitidez del perfil, es decir, distancia entre las puntuaciones más altas y las más bajas. Un perfil plano, con todo parecido, está poco diferenciado y es más difícil de orientar.
- **Identidad:** claridad y estabilidad de las metas, intereses y capacidades que la persona percibe en sí misma.

Confundir congruencia con consistencia es un error clásico. La primera compara persona y ambiente; la segunda compara dos letras del código de la misma persona.

El SDS. El *Self-Directed Search* (SDS) es el instrumento que Holland creó a partir de su teoría. Es **autoaplicado y autocorregido**: la persona responde a secciones sobre actividades, competencias, ocupaciones y autovaloraciones de capacidad, suma sus puntuaciones en cada tipo y obtiene su código, que busca después en un listado de ocupaciones. En España se dispone de la adaptación de Martínez-Vicente y Valls (2006). Su sencillez no elimina la conveniencia de comentar el resultado con un orientador.

Valoración. A su favor están la claridad y una amplia base empírica: el orden circular de los intereses se reproduce bien en muchas muestras y el código RIASEC se ha convertido en un lenguaje común. En contra, la forma exacta del hexágono no se replica igual en todas las culturas, la relación entre congruencia y satisfacción es modesta y tres letras simplifican una identidad vocacional que depende también del contexto social.

14.3 El modelo de Kuder

Los inventarios de **Kuder** representan el enfoque por **áreas temáticas**. En lugar de partir de una teoría de tipos o de grupos profesionales, agrupan las actividades por su contenido y miden cuánto prefiere la persona cada área. La versión clásica que comercializa TEA en España, el **Kuder-C**, tiene **10 escalas** de interés y una **escala de verificación**:

Escala	Ejemplo de actividad preferida
Aire libre	Trabajar en el campo o en un vivero
Mecánico	Reparar una bicicleta o montar un mueble
Cálculo	Llevar las cuentas de una asociación
Científico	Hacer experimentos o investigar causas
Persuasivo	Convencer, vender o negociar
Artístico	Diseñar, dibujar o decorar
Literario	Leer y escribir textos
Musical	Tocar un instrumento o ir a conciertos
Servicio social	Ayudar, cuidar o enseñar
Oficina	Archivar, ordenar documentos, tramitar

Las áreas recuerdan a los tipos RIASEC, pero no se derivan de una teoría de la personalidad, sino del contenido de las tareas.

Elección forzada en tríadas. El rasgo que más distingue al Kuder es su formato. Cada ítem presenta **tres actividades** y la persona señala su actividad **preferida** y la que **menos** le atrae. Por ejemplo: «visitar un museo de ciencias», «organizar una fiesta benéfica» y «ordenar la biblioteca de casa». Nadie puede decir que le encanta todo: cada elección favorece un área a costa de otra.

Este formato da lugar a puntuaciones **ipsativas**: la suma de las puntuaciones de todas las escalas es aproximadamente la misma para todo el mundo, porque lo que se reparte es una cantidad fija de preferencias. Las consecuencias son importantes:

1. El perfil indica qué áreas prefiere la persona **en relación con sus otras áreas**, no cuánto interés tiene en términos absolutos.
2. Las comparaciones **entre personas** son problemáticas. Que Ana puntúe más que Luis en Musical no significa que le guste más la música; puede que a Luis le guste mucho, pero aún más otra cosa.
3. Las escalas no son independientes: si una sube, otras bajan, lo que genera correlaciones negativas artificiales.
4. A cambio, el formato **reduce** la aquiescencia y la tendencia a responder que todo gusta, y dificulta presentarse de forma favorable cuando las opciones son igual de deseables.

El mismo principio de elección forzada aparece en algunos inventarios de personalidad, como el EPPS, para controlar la deseabilidad social (Unidad 9). Las propiedades estadísticas de las puntuaciones ipsativas se estudian en Psicometría.

La escala de verificación. Incluye tríadas de respuesta muy previsible. Muchas elecciones inusuales en ellas sugieren descuido, azar o problemas de comprensión, y el protocolo no debe interpretarse sin más. Es un control de validez, no un detector de mentiras.

Interpretación. Las puntuaciones directas se convierten en **percentiles** y se interpreta el perfil completo, atendiendo a las combinaciones de áreas altas. Un caso: Irene, de 16 años, puntúa alto en Literario y Persuasivo

y muy bajo en Cálculo y Mecánico. El orientador no concluye que «vale para el Derecho», sino que explora con ella profesiones donde escribir y convencer se combinan (periodismo, comunicación, gestión cultural) y comprueba si sus aptitudes las apoyan.

Un error frecuente es creer que el Kuder es un inventario empírico como el Strong: es temático e ipsativo.

14.4 El modelo empírico de Strong

Edward K. Strong publicó en 1927 el *Strong Vocational Interest Blank* (SVIB), el primer gran inventario de intereses. Su heredero actual es el **Strong Interest Inventory**. Lo que lo hace singular es su método de construcción: el **método empírico de criterio externo**.

Se reúne un grupo de profesionales de una ocupación, con experiencia y **satisfechos** con ella, por ejemplo ingenieros, y se les aplica una larga lista de ítems sobre ocupaciones, asignaturas, ocio y tipos de personas. Sus respuestas se comparan con las de una **muestra de referencia** de personas de muchas profesiones. Los ítems que diferencian a los ingenieros del grupo de referencia, sea cual sea su contenido, forman la **escala ocupacional** de ingeniero. Si una persona responde como suelen hacerlo los ingenieros satisfechos, puntuará alto en esa escala.

La apuesta de Strong era que parecerse en los gustos a quienes disfrutan de un oficio anticipa la propia satisfacción en él. Nótese que el criterio es la satisfacción, no la competencia: la escala dice si alguien se parece en sus gustos a los ingenieros, no si sería un buen ingeniero.

Es la misma estrategia con la que se construyó el MMPI, que comparaba pacientes con personas sin diagnóstico (Unidad 10). Y tiene las mismas ventajas e inconvenientes:

Ventajas	Inconvenientes
Las escalas se basan en datos reales, no en suposiciones del autor	Los ítems de una escala pueden ser heterogéneos y difíciles de interpretar
Buena capacidad para diferenciar grupos profesionales	Cada escala depende de cómo se formaron los grupos de criterio y de referencia
Permite predecir la elección y la permanencia en una profesión	Las profesiones cambian y las escalas envejecen si no se renuevan
Ítems con poco contenido evidente, más difíciles de falsear	Hacen falta muestras grandes de cada ocupación y normas actualizadas

Escalas del inventario actual. Para superar la falta de interpretación teórica, las versiones posteriores añadieron otros niveles de puntuación, de lo general a lo específico:

- **Temas ocupacionales generales:** los seis tipos RIASEC de Holland, que dan una visión global.
- **Escalas de intereses básicos:** áreas más concretas agrupadas dentro de cada tema (por ejemplo, enseñanza o asesoramiento dentro del tema Social).
- **Escalas ocupacionales:** el núcleo empírico original, que compara a la persona con los profesionales satisfechos de cada ocupación.
- **Estilos personales** e índices de control de la aplicación.

La integración del RIASEC en el Strong muestra que los tres enfoques de la unidad no son rivales.

Normas y sexo. Hombres y mujeres difieren en promedio en algunos intereses, por lo que los inventarios ofrecen a menudo normas separadas por sexo o combinadas. Se debate cuál es más justa: las separadas evitan perfiles estereotipados, pero pueden ocultar diferencias reales. Lo importante es que el resultado amplíe opciones.

Un caso: Mario, de 41 años, trabaja en un banco y piensa en cambiar de vida. En el Strong puntúa alto en el tema Social y en las escalas de orientador y de formador de adultos. El dato no le dice que deba dejar su trabajo, pero le da una pista concreta que explorar.

Consenso y debate

Consenso: los intereses vocacionales son preferencias relativamente estables desde el final de la adolescencia y distintas de las aptitudes. El modelo RIASEC de Holland (1959/1997) es el marco de referencia, y el orden circular de los seis tipos se reproduce bien en muchas muestras. Las puntuaciones ipsativas del Kuder describen preferencias dentro de la persona y no sirven para comparar a personas entre sí. El método de Strong (1927) es empírico de criterio externo, como el del MMPI.

Debate: si la forma hexagonal es universal o varía entre culturas y grupos; cuánto predice realmente la congruencia persona-ambiente la satisfacción y el rendimiento, ya que la relación hallada es modesta; y si conviene usar normas separadas por sexo o combinadas para no reforzar estereotipos sin ocultar diferencias.

Mito frecuente

Mito: «Un test vocacional dice para qué profesión vale una persona».

Realidad: los inventarios miden preferencias, no capacidades. Las escalas de Strong (1927) indican parecido con los gustos de profesionales satisfechos, no competencia, y el código de Holland (1959/1997) señala ambientes congruentes, cuya relación con la satisfacción es real pero modesta. Para orientar hay que integrar intereses, aptitudes, rendimiento, valores y oportunidades.

Conceptos clave

Concepto	Definición
Interés vocacional	Preferencia relativamente estable por actividades, ambientes de trabajo y ocupaciones
Intereses inventariados	Intereses obtenidos mediante un test, frente a los expresados y los manifiestos
RIASEC	Seis tipos de Holland: realista, investigador, artístico, social, emprendedor y convencional
Congruencia	Ajuste entre el tipo de la persona y el tipo del ambiente de trabajo
Consistencia	Proximidad en el hexágono de los dos primeros tipos del código de una persona
Diferenciación	Nitidez del perfil: distancia entre las puntuaciones más altas y las más bajas
Puntuación ipsativa	Puntuación relativa a las demás escalas de la misma persona; no permite comparar entre personas
Escala ocupacional	Escala de Strong formada por los ítems que diferencian a una profesión del grupo de referencia

Clave PIR

Prioridad media. Se pregunta qué enfoque representa cada autor (Holland tipológico, Kuder temático, Strong empírico), el orden del hexágono y qué tipos son opuestos, y la definición de congruencia, consistencia y diferenciación. Trampas típicas: confundir consistencia (dentro del código de la persona) con congruencia (persona-ambiente), creer que el Kuder es empírico o que sus puntuaciones permiten comparar a dos personas, y tomar como opuestos dos tipos que solo son alternos, como realista y artístico.

Autoevaluación

1. En el hexágono de Holland, ¿qué par de tipos es opuesto?
a) Realista y artístico
b) Investigador y emprendedor
c) Social y emprendedor

2. Una persona con código SA tiene un perfil de consistencia alta porque…
a) sus dos primeros tipos son adyacentes en el hexágono
b) su tipo coincide con el de su ambiente de trabajo
c) sus puntuaciones más altas y más bajas están muy separadas

3. ¿Qué consecuencia tiene el formato de tríadas de elección forzada del Kuder?
a) Permite comparar directamente el interés de dos personas en un área
b) Produce escalas independientes entre sí
c) Produce puntuaciones ipsativas, relativas a la propia persona

4. Las escalas ocupacionales del Strong se construyeron…
a) a partir de los seis tipos teóricos de Holland
b) comparando a profesionales satisfechos con una muestra de referencia
c) agrupando actividades por su contenido temático

5. El SDS se caracteriza sobre todo por…
a) aplicarse en formato de tríadas de elección forzada
b) basarse en escalas ocupacionales empíricas
c) ser autoaplicado y autocorregido por la propia persona

Soluciones

1 b. Los opuestos son R-S, I-E y A-C; realista y artístico son alternos, y social y emprendedor, adyacentes. **2 a.** La consistencia compara las letras del propio código; la opción b describe la congruencia y la c, la diferenciación. **3 c.** Preferir un área obliga a renunciar a otra, así que las escalas dependen entre sí y no admiten comparaciones entre personas. **4 b.** Es el método empírico de criterio externo, el mismo del MMPI. **5 c.** La persona responde, suma y obtiene su código RIASEC sin necesidad de un corrector.

Unidad 15 · Evaluación de actitudes

Objetivos: definir la actitud y sus componentes y describir las estrategias para medirla; explicar la construcción y la puntuación de las escalas Likert y Thurstone; describir el escalograma de Guttman y calcular su coeficiente de reproductibilidad; valorar el IAT y el debate sobre las medidas implícitas.

15.1 Concepto de actitud y estrategias de medida

Una **actitud** es una evaluación relativamente duradera, favorable o desfavorable, de un objeto. El objeto puede ser casi cualquier cosa: la energía nuclear, el teletrabajo, los turistas, la sanidad pública, una marca de refrescos o un vecino concreto. Las actitudes interesan porque resumen cómo valoramos el mundo y porque se supone que orientan la conducta.

El modelo clásico describe la actitud con **tres componentes** (Rosenberg y Hovland, 1960):

- **Cognitivo:** creencias sobre el objeto («los coches eléctricos contaminan menos»).
- **Afectivo:** sentimientos y emociones que despierta («me dan confianza»).
- **Conductual:** intenciones y tendencias de acción («me compraré uno cuando pueda»).

Los tres no siempre coinciden: alguien puede creer que el ejercicio es sano, sentir pereza ante el gimnasio y no ir nunca. En el estudio clásico de LaPiere (1934), muchos establecimientos que habían atendido sin problemas a una pareja de origen chino respondieron después por carta que no aceptarían a clientes de ese origen. Cuándo predice la actitud la conducta se estudia en Psicología Social; aquí interesa cómo se mide.

Estrategias de medida. Las actitudes no se observan directamente: se infieren de lo que la persona dice o hace. Las estrategias principales son:

Estrategia	Qué se registra	Ventaja	Limitación
Autoinforme (escalas)	Acuerdo con enunciados o valoraciones	Barato, rápido, aplicable a grupos grandes	Deseabilidad social; mide sobre todo lo que la persona piensa y declara
Observación de la conducta	Lo que la persona hace ante el objeto	No depende de lo que se declara	Costosa; la conducta tiene muchas causas además de la actitud
Registros psicofisiológicos	Activación ante el objeto	Difícil de controlar voluntariamente	Indica intensidad, no dirección (Unidad 1)
Medidas implícitas	Tiempos de reacción en tareas de clasificación	No preguntan directamente	Fiabilidad y validez discutidas (apartado 15.4)

En la práctica, casi todo lo publicado son **escalas de autoinforme**. Recogen lo que la persona cree y está dispuesta a contar, más que sus emociones o sus actos, y la deseabilidad social pesa mucho en temas sensibles, como los prejuicios (Evaluación Psicológica I y Unidad 9).

Dos escalas con enunciados casi idénticos pueden ser muy distintas según **cómo se construyeron**: cómo se eligieron los enunciados y cómo se combinan las respuestas. Hay tres procedimientos clásicos, asociados a Likert, Thurstone y Guttman (apartados 15.2 y 15.3). A ellos se suman el **diferencial semántico** de Osgood, que mide el significado connotativo de un objeto con pares de adjetivos opuestos y cuyo factor de evaluación funciona como medida de actitud (Unidad 2), y la **escala de distancia social** de Bogardus (1925).

La oferta de escalas es enorme y desigual, y muchas se diseñaron para un único estudio, así que antes de usar una conviene revisar cómo se construyó y qué fiabilidad y validez tiene. Un ejemplo: un ayuntamiento que quiere

conocer la actitud vecinal hacia los carriles bici obtendrá poca precisión con una sola pregunta («¿está a favor?») y bastante más con una escala de varios enunciados bien construida.

15.2 Escalas Likert y Thurstone

Escalas Likert. Rensis Likert (1932) propuso el método más usado hoy para construir escalas de actitud. La escala consta de varios enunciados, unos favorables y otros desfavorables al objeto, con un formato de respuesta graduado, típicamente de cinco puntos: «totalmente en desacuerdo», «en desacuerdo», «ni de acuerdo ni en desacuerdo», «de acuerdo» y «totalmente de acuerdo». La puntuación es **sumativa**: se suman las respuestas a todos los ítems, después de **invertir** las de los enunciados desfavorables, de modo que una puntuación alta siempre indique actitud favorable.

La construcción sigue unos pasos:

1. Se redacta un banco amplio de enunciados claramente favorables o desfavorables; los neutros se descartan porque no discriminan.
2. Se aplica a una muestra piloto.
3. Se hace un **análisis de ítems**: se conservan los que más correlacionan con la puntuación total o mejor separan a quienes puntúan alto y bajo.
4. Se comprueba la fiabilidad de la escala final.

Los ítems en ambos sentidos ayudan a controlar la **aquiescencia**, la tendencia a estar de acuerdo con todo.

Dos precisiones evitan errores frecuentes. Primera: estrictamente, una **escala Likert** es el conjunto de ítems sumados, no un ítem suelto con cinco opciones. Ese ítem aislado es un «ítem de tipo Likert». Segunda: la escala Likert no es lo mismo que el diferencial semántico. En el Likert se gradúa el acuerdo con un enunciado; en el diferencial semántico se sitúa un concepto entre dos adjetivos opuestos (Unidad 2).

Es fácil de construir, no necesita jueces y suele alcanzar buena fiabilidad con pocos ítems. Su limitación es teórica: las respuestas son **ordinales**, y sumarlas supone tratar como iguales las distancias entre categorías, un supuesto discutido (Psicometría).

Escalas Thurstone. Thurstone y Chave (1929) desarrollaron el primer método riguroso para medir actitudes, conocido como **método de los intervalos aparentemente iguales**. Su idea es asignar a cada enunciado un **valor escalar** que indique su posición en el continuo, de lo más desfavorable a lo más favorable.

1. Se redacta un banco amplio de enunciados que cubran todo el continuo, incluidos los moderados.
2. Un grupo numeroso de **jueces** clasifica cada enunciado en **11 categorías**, según lo favorable que lo considera, sin expresar su propia opinión.
3. Para cada enunciado se calcula la **mediana** de las valoraciones de los jueces, que es su **valor escalar**, y una medida de **dispersión**, que indica su **ambigüedad**.
4. Se eligen enunciados con valores repartidos por todo el continuo y poca dispersión; los ambiguos se eliminan.

En la aplicación, la persona marca los enunciados con los que está de acuerdo y su puntuación es la **mediana o la media de los valores escalares** de los aceptados. Aceptar «los carriles bici mejoran la ciudad» (valor alto) y «la bici tiene ventajas e inconvenientes» (valor medio) sitúa a alguien en una zona moderadamente favorable.

Rasgo	Likert	Thurstone
Quién sitúa los ítems	Nadie: se seleccionan por análisis de ítems	Un grupo de jueces
Ítems moderados	Se evitan	Se necesitan para cubrir el continuo
Respuesta	Grado de acuerdo con cada ítem	Acuerdo o desacuerdo

Rasgo	Likert	Thurstone
Puntuación	Suma de respuestas	Mediana o media de los valores escalares aceptados
Coste de construcción	Bajo	Alto

La principal crítica al método de Thurstone es su **coste**, y se comprobó además que la propia actitud de los jueces puede influir en cómo sitúan los enunciados. Hoy se usa poco, pero introdujo la idea de escalar los ítems antes de medir a las personas.

15.3 Escalas Guttman y otras técnicas

El escalograma de Guttman. Louis Guttman (1944) propuso un modelo más exigente: una escala **acumulativa**. Los ítems se ordenan por intensidad, de modo que aceptar un ítem implica aceptar todos los de menor intensidad. Dicho de otro modo, las respuestas de cada persona forman una escalera sin huecos: un «sí» después de un «no» rompe el patrón.

Un ejemplo con la actitud hacia el reciclaje:

1. «Reciclar es útil».
2. «Separo el vidrio y el papel».
3. «Separo todos los residuos de casa».
4. «Evito comprar productos con exceso de envase».
5. «Dedico parte de mi tiempo libre a campañas de reciclaje».

En una escala perfecta, basta con saber **cuántos** ítems acepta una persona para saber **cuáles** acepta. Quien acepta tres ha aceptado el 1, el 2 y el 3. La puntuación total permite reproducir todo el patrón de respuestas.

El coeficiente de reproductibilidad. Los datos reales nunca son perfectos. Se llama **error** a cada respuesta que habría que cambiar, como mínimo, para convertir el patrón de una persona en un patrón perfecto. El grado de ajuste se resume con el **coeficiente de reproductibilidad**:

Reproductibilidad = 1 − errores / (ítems × sujetos)

Por convención, se exige un valor de **0,90 o más** para considerar que el conjunto de ítems forma una escala acumulativa.



Figura 15.1. **Tres formas de construir una escala de actitud.** A la izquierda, un ítem Likert de cinco puntos; en el centro, tres enunciados Thurstone con su valor escalar; a la derecha, un escalograma de Guttman de 5 ítems y 6 sujetos con un patrón perfecto y un error, con reproductibilidad = 1 − 1/30 ≈ 0,97. Datos inventados. Elaboración propia.

Como muestra la figura 15.1, con 5 ítems y 6 sujetos hay 30 respuestas; si solo una se sale del patrón, la reproductibilidad es 1 − 1/30 ≈ 0,97, por encima del criterio de 0,90.

El escalograma garantiza que los ítems miden **una sola dimensión** y da a la puntuación total un significado preciso, pero con actitudes de muchas facetas es raro llegar a 0,90, y por eso se cita más de lo que se aplica. Su idea de ordenar ítems y personas en un mismo continuo es un antecedente determinista de la teoría de respuesta al ítem, que admite errores probabilísticos (Psicometría).

Rasgo	Likert	Thurstone	Guttman
Lógica	Sumativa	Intervalos aparentemente iguales	Acumulativa
Clave de la construcción	Análisis de ítems	Valores escalares de jueces	Escalograma
Indicador de calidad	Fiabilidad, correlación ítem-total	Dispersión (ambigüedad) de los ítems	Reproductibilidad ≥ 0,90

Otras técnicas.

- **Escala de distancia social de Bogardus (1925).** Pregunta hasta qué grado de cercanía se aceptaría a miembros de un grupo, desde excluirlos del país hasta aceptarlos como familia. Tiene lógica acumulativa: quien acepta a alguien como familiar suele aceptarlo como vecino.
- **Diferencial semántico** (Osgood, Suci y Tannenbaum, 1957). El factor de **evaluación** (bueno-malo, agradable-desagradable, útil-inútil) es una medida directa del componente evaluativo de la actitud (Unidad 2).
- **Preguntas abiertas**, que captan matices pero son difíciles de puntuar de forma fiable.

La elección depende del objetivo: para estudios con muchas personas suele bastar una escala Likert; para comprobar si unos ítems ordenan una actitud unidimensional, el escalograma es más informativo.

15.4 Medidas implícitas: el IAT y su debate

Las escalas preguntan a la persona qué piensa, y la respuesta pasa por su filtro consciente y por su deseo de quedar bien. Las **medidas implícitas** intentan evaluar las asociaciones evaluativas sin preguntar directamente, a partir de la rapidez con la que se realizan ciertas tareas. La más conocida es el **Test de Asociación Implícita** (IAT; Greenwald, McGhee y Schwartz, 1998).

Cómo funciona. La persona clasifica lo más rápido posible estímulos que aparecen en una pantalla pulsando dos teclas. Hay dos pares de categorías: un par de **conceptos** (por ejemplo, flores e insectos, uno de los ejemplos del trabajo original) y un par de **atributos** (agradable y desagradable). Tras unas fases de práctica, las categorías se combinan:

- En una fase, la misma tecla sirve para «flor» y «agradable», y la otra para «insecto» y «desagradable».
- En otra fase, se invierte la combinación: «flor» comparte tecla con «desagradable», e «insecto» con «agradable».

La lógica es que las tareas son más fáciles y rápidas cuando las categorías que comparten tecla están **asociadas en la memoria**. Si una persona responde claramente más rápido en la primera combinación, se infiere una asociación más fuerte entre flores y lo agradable que entre insectos y lo agradable. La **diferencia en tiempos de reacción** entre las dos combinaciones es la puntuación del IAT. El mismo procedimiento se ha aplicado a grupos sociales, marcas, alimentos o al autoconcepto.

Por qué interesó tanto. Prometía esquivar la deseabilidad social, porque es difícil controlar a voluntad tiempos de reacción de milisegundos, y acceder a asociaciones que la introspección no alcanza.

El debate. La investigación posterior ha matizado mucho esas expectativas:

- **Fiabilidad.** La fiabilidad test-retest es **baja** para un instrumento que pretende medir algo estable de una persona: la misma persona puede obtener resultados bastante distintos en dos aplicaciones.
- **Predicción de la conducta.** El metaanálisis de Oswald et al. (2013) halló una correlación de solo **r ≈ 0,15** entre las puntuaciones del IAT y criterios de discriminación étnica o racial, una capacidad predictiva débil.
- **Cambio.** Según el metaanálisis de Forscher et al. (2019), modificar las puntuaciones en medidas implícitas no se traduce necesariamente en cambios en la conducta.
- **Interpretación.** Se discute si mide una actitud personal, asociaciones culturales que la persona conoce pero no comparte o la familiaridad con los estímulos.

Uso responsable. De este debate se deriva una conclusión práctica clara. El IAT es una herramienta de **investigación** útil para estudiar procesos en grupos, pero **no** es un instrumento de diagnóstico individual: no permite afirmar que una persona concreta tiene prejuicios ni predecir cómo se comportará. Usarlo para seleccionar personal, para decidir sobre una persona o para «demostrar» el racismo oculto de alguien no tiene apoyo empírico.

Un caso: en un curso de formación, un participante obtiene en un IAT en línea una asociación negativa con un grupo y se angustia pensando que es «racista sin saberlo». Un resultado aislado y poco fiable no define su actitud ni predice su conducta: puede invitar a reflexionar, pero no es un diagnóstico.

Otras medidas implícitas, como el **priming evaluativo**, comparten buena parte de estas limitaciones. Las actitudes implícitas y el prejuicio se estudian en Psicología Social.

Consenso y debate

Consenso: las actitudes se miden sobre todo con escalas de autoinforme, y lo que distingue a cada escala es su método de construcción: sumativo (Likert, 1932), de intervalos aparentemente iguales (Thurstone y Chave, 1929) o acumulativo (Guttman, 1944), con una reproductibilidad mínima de 0,90. La escala Likert es la más usada por su sencillez y su buena fiabilidad. Las actitudes declaradas no siempre predicen la conducta.

Debate: qué mide realmente el IAT y para qué sirve, dada su baja fiabilidad test-retest y su débil relación con la conducta (Oswald et al., 2013; Forscher et al., 2019). También se discute si es legítimo tratar como intervalares las respuestas ordinales de las escalas Likert.

Mito frecuente

Mito: «El IAT revela los prejuicios ocultos de una persona y predice cómo se comportará».

Realidad: el IAT (Greenwald, McGhee y Schwartz, 1998) mide diferencias en tiempos de reacción con una fiabilidad test-retest baja, y su correlación con criterios de discriminación es débil, r ≈ 0,15 (Oswald et al., 2013). Es útil para investigar en grupos, pero no para diagnosticar a individuos ni para predecir su conducta.

Conceptos clave

Concepto	Definición
Actitud	Evaluación duradera, favorable o desfavorable, de un objeto (componentes cognitivo, afectivo y conductual)

Concepto	Definición
Escala Likert	Escala sumativa de ítems de acuerdo seleccionados por análisis de ítems (Likert, 1932)
Ítem invertido	Enunciado desfavorable cuya respuesta se recodifica; ayuda a controlar la aquiescencia
Valor escalar	Mediana de las valoraciones de los jueces sobre un enunciado en el método de Thurstone
Intervalos aparentemente iguales	Método de Thurstone y Chave (1929): jueces sitúan los enunciados en 11 categorías
Escala acumulativa	Escala en la que aceptar un ítem implica aceptar todos los de menor intensidad (Guttman, 1944)
Reproductibilidad	1 − errores / (ítems × sujetos); en Guttman se exige 0,90 o más
IAT	Medida implícita basada en tiempos de reacción al clasificar categorías combinadas (Greenwald et al., 1998)

Clave PIR

Prioridad media. Se pregunta qué método corresponde a cada autor (Likert sumativo, Thurstone con jueces e intervalos aparentemente iguales, Guttman acumulativo), cómo se obtiene el valor escalar y el cálculo de la reproductibilidad. Trampas típicas: confundir Thurstone con Guttman, llamar «escala Likert» a un único ítem, confundir el Likert con el diferencial semántico y presentar el IAT como un instrumento fiable de diagnóstico individual.

Autoevaluación

1. En el método de Thurstone y Chave (1929), el valor escalar de un enunciado es…
a) la mediana de las valoraciones de los jueces
b) su correlación con la puntuación total de la escala
c) la proporción de personas que lo aceptan

2. Una escala en la que aceptar un ítem implica aceptar todos los de menor intensidad es una escala…
a) sumativa de Likert
b) de intervalos aparentemente iguales
c) acumulativa de Guttman

3. Un escalograma con 4 ítems, 10 sujetos y 2 errores tiene una reproductibilidad de…
a) 0,80
b) 0,95
c) 0,98

4. ¿Qué función cumple incluir enunciados desfavorables en una escala Likert?
a) Calcular el valor escalar de cada enunciado
b) Ayudar a controlar la aquiescencia
c) Garantizar que la escala sea acumulativa

5. Según la evidencia disponible sobre el IAT, ¿qué afirmación es correcta?
a) Su fiabilidad test-retest es alta y permite diagnosticar prejuicios individuales
b) Predice la conducta mucho mejor que las medidas explícitas
c) Su relación con la conducta discriminatoria es débil, en torno a r ≈ 0,15

Soluciones

1 a. La mediana de los jueces sitúa el enunciado en el continuo, y la dispersión indica su ambigüedad. **2 c.** El escalograma es acumulativo; la b describe el método de Thurstone. **3 b.** 1 − 2/(4 × 10) = 1 − 0,05 = 0,95, por encima del criterio de 0,90. **4 b.** Quien está de acuerdo con todo queda en evidencia al aceptar enunciados contradictorios;

además, se invierten al puntuar. **5 c.** Oswald et al. (2013) hallaron una predicción débil, y su fiabilidad test-retest es baja.

Capítulo 6 · Evaluación de la salud y la calidad de vida

La psicología de la salud no se ocupa solo del malestar emocional: también evalúa cómo vive una persona su enfermedad, qué hábitos la protegen o la ponen en riesgo y con qué recursos hace frente al estrés. Este capítulo presenta los instrumentos más usados para medir la calidad de vida relacionada con la salud, la personalidad como factor de riesgo, el estilo de vida y las variables de estrés, afrontamiento, apoyo social y malestar emocional en pacientes con enfermedades físicas.

Unidad 16 · Evaluación en psicología de la salud

Objetivos: definir la calidad de vida relacionada con la salud y distinguir los instrumentos genéricos de los específicos; describir la estructura del SF-36, el SF-12, el EQ-5D y el WHOQOL-BREF; valorar la evidencia sobre los patrones de conducta tipo A, C y D y sus instrumentos; describir la evaluación del estilo de vida, del estadio de cambio y de la adherencia; conocer los instrumentos de estrés percibido, afrontamiento, apoyo social, ansiedad y depresión en contextos sanitarios.

16.1 Calidad de vida relacionada con la salud: SF-36, SF-12, EQ-5D y WHOQOL-BREF

Desde su Constitución de 1946, la Organización Mundial de la Salud entiende la salud como algo más que no estar enfermo: incluye el bienestar físico, mental y social. Por eso, para saber cómo está un paciente no bastan sus análisis. Dos personas con la misma artrosis de rodilla pueden vivirla de forma muy distinta: una sigue caminando a diario y la otra ha dejado de salir de casa.

La **calidad de vida relacionada con la salud (CVRS)** es la valoración que hace la propia persona de cómo su estado de salud afecta a su funcionamiento físico, emocional y social. Es una medida **subjetiva**: recoge la percepción del paciente, no la salud «objetiva», y complementa los indicadores clínicos sin sustituirlos. Se usa para describir el impacto de una enfermedad, comparar tratamientos, seguir la evolución de un paciente y planificar recursos.

Los instrumentos de CVRS se dividen en dos grandes grupos:

- **Genéricos**: sirven para cualquier población, sana o enferma, y permiten comparar grupos clínicos distintos entre sí y con la población general. Son el SF-36, el SF-12, el EQ-5D y el WHOQOL-BREF.
- **Específicos**: se diseñan para una enfermedad o un grupo concreto (cáncer, asma, diabetes). Son más sensibles a los cambios propios de esa enfermedad, pero no permiten comparar entre enfermedades.

Lo habitual es combinar un instrumento genérico con uno específico.

El SF-36 (Ware y Sherbourne, 1992) es el cuestionario genérico más extendido. Tiene 36 ítems agrupados en **8 escalas**: función física, rol físico, dolor corporal, salud general, vitalidad, función social, rol emocional y salud mental. Las escalas se combinan en **dos componentes sumario**, uno **físico** y otro **mental**. Cada escala se puntúa de forma que las puntuaciones más altas indican mejor estado de salud. La versión española de Alonso, Prieto y Antó (1995) mostró una consistencia interna entre 0,71 y 0,94 en casi todas las escalas, con una

excepción: la de Función Social, que solo alcanzó 0,45. Conviene recordar este dato al interpretar esa escala aislada.

Instrumento	Ítems	Estructura	Rasgo distintivo
SF-36	36	8 escalas y 2 componentes sumario (físico y mental)	El genérico de referencia
SF-12	12	Los 2 componentes sumario	Versión breve del SF-36 para estudios amplios
EQ-5D	5 + escala visual	5 dimensiones y escala analógico-visual	Muy breve; útil en economía de la salud
WHOQOL-BREF	26	4 dominios: físico, psicológico, relaciones sociales y ambiente	Desarrollado por la OMS; incluye el entorno

El SF-12 es una versión reducida del SF-36 que permite obtener los dos componentes sumario con solo 12 ítems. Es útil en encuestas de población y estudios con muchos participantes, a cambio de perder el detalle de las ocho escalas.

El EQ-5D, del grupo EuroQol, describe el estado de salud en **5 dimensiones** (movilidad, cuidado personal, actividades cotidianas, dolor o malestar y ansiedad o depresión) y añade una **escala analógico-visual** en la que la persona sitúa su salud de ese día entre el peor y el mejor estado imaginable. Su brevedad lo hace muy práctico en consultas y en estudios de coste-efectividad.

El WHOQOL-BREF, desarrollado por la OMS a partir de un instrumento más largo, tiene **26 ítems** y **4 dominios**: físico, psicológico, relaciones sociales y ambiente. Su particularidad es incluir el **entorno** (vivienda, seguridad, acceso a servicios) como parte de la calidad de vida.

El **dolor** se evalúa con escalas visuales analógicas (EVA), en las que el paciente marca su intensidad sobre una línea, o con instrumentos multidimensionales como el **cuestionario de dolor de McGill** o el **WHYMPI**, que recogen también sus cualidades y su interferencia en la vida diaria.

16.2 La personalidad como factor de riesgo: tipos A, C y D

El estudio sistemático de la personalidad como factor de riesgo empezó con dos cardiólogos, **Friedman y Rosenman**. Observaron que muchos de sus pacientes coronarios compartían un estilo de conducta que llamaron **patrón de conducta tipo A**: urgencia temporal e impaciencia, competitividad, implicación excesiva en el trabajo y **hostilidad**. Lo opuesto, un estilo más tranquilo y menos competitivo, se denominó tipo B.

Conviene subrayar que se habla de **patrón de conducta**, no de rasgo de personalidad en sentido estricto: se define por lo que la persona hace (hablar deprisa, interrumpir, irritarse en una cola) en situaciones que lo provocan.

La evidencia. El estudio **WCGS** (*Western Collaborative Group Study*) encontró una asociación entre el tipo A y la cardiopatía coronaria, y durante unos años el patrón se consideró un factor de riesgo independiente. Sin embargo, la asociación global **no se replicó** en el estudio **MRFIT**. Los análisis posteriores llevaron a una conclusión que hoy es de consenso: el componente que se asocia con el riesgo cardiovascular es la **hostilidad**, no el patrón completo. Ser rápido o ambicioso no parece dañino; vivir en un estado de desconfianza y enfado crónico, sí.

Instrumentos para el tipo A y la hostilidad:

- **Entrevista estructurada**: el método original. El entrevistador provoca deliberadamente al evaluado (por ejemplo, hablando despacio o interrumpiendo) y valora tanto el contenido de las respuestas como la forma: tono de voz, velocidad, gestos de impaciencia.
- **JAS** (*Jenkins Activity Survey*): autoinforme desarrollado en el marco del WCGS.

- **Escala tipo A de Framingham**: autoinforme breve que recoge competitividad, impaciencia y presión en el trabajo.
- **Escala de hostilidad de Cook-Medley**: formada por ítems del MMPI, evalúa sobre todo la hostilidad cínica.

El tipo D. Denollet propuso la **personalidad tipo D** (de *distressed*, «angustiado») como combinación de dos rasgos: **afectividad negativa** (tendencia a sentir preocupación, tristeza e irritación) e **inhibición social** (tendencia a no expresar esas emociones por miedo al rechazo). Se evalúa con la **DS14**, una escala de 14 ítems con una subescala para cada rasgo; se considera tipo D a quien puntúa alto en ambas. Los estudios iniciales en pacientes cardiacos hallaron un peor pronóstico, pero las **réplicas posteriores han sido más débiles**, y su valor predictivo sigue en debate.

El tipo C. Se propuso como un estilo asociado al cáncer: complacencia, poca asertividad y **supresión de las emociones negativas**, sobre todo de la ira. La hipótesis tuvo mucha difusión, pero la evidencia de que este estilo cause cáncer o acelere su evolución es **débil** (ver el mito de esta unidad). Una variable relacionada es la **alexitimia**: a la persona le cuesta reconocer qué siente y ponerle palabras. Su medida más usada es la **TAS-20** (Bagby, Parker y Taylor, 1994).

Patrón	Rasgos centrales	Enfermedad estudiada	Instrumento	Estado de la evidencia
Tipo A	Urgencia, competitividad, hostilidad	Cardiopatía coronaria	Entrevista estructurada, JAS	Solo la hostilidad mantiene apoyo
Tipo C	Complacencia, supresión emocional	Cáncer	Sin instrumento de referencia	Débil
Tipo D	Afectividad negativa e inhibición social	Pronóstico cardiaco	DS14	En debate

Si Andrés, tras un infarto, puntúa alto en la escala de Cook-Medley y en las dos subescalas de la DS14, esos datos no predicen con certeza su evolución, pero orientan la intervención hacia el manejo del enfado y la expresión emocional. Las teorías de rasgo y los modelos de enfermedad se estudian en Personalidad y Diferencias Individuales y en Psicología de la Salud.

16.3 Estilo de vida y prevención

Muchas enfermedades crónicas tienen detrás **conductas de salud** que se repiten a diario: qué se come, cuánto se camina, si se fuma o se bebe y cómo se duerme. El **estilo de vida** es el conjunto relativamente estable de esas conductas. Evaluarlo sirve para estimar riesgos, decidir qué cambiar primero y comprobar si una intervención preventiva funciona.

Métodos de evaluación. Se usan los mismos métodos generales que en cualquier evaluación, cuyas garantías se estudian en Evaluación Psicológica I:

- **Entrevista**, para conocer la historia de cada hábito y su función.
- **Autoinformes** específicos para cada conducta, como el **AUDIT** de la OMS para el consumo de alcohol, el **test de Fagerström** para la dependencia de la nicotina o el **IPAQ** para la actividad física.
- **Autorregistros**, en los que la persona anota cada cigarrillo, cada comida o cada paseo, con la situación en que ocurre.
- **Observación** y **medidas objetivas**, como podómetros, acelerómetros o marcadores biológicos.
- **Cuestionarios globales** de estilo de vida, que reúnen varias conductas en un solo perfil.

Los autoinformes tienden a infravalorar las conductas mal vistas, como beber, y a sobrevalorar las deseables, como el ejercicio. Los autorregistros son más precisos, pero exigen constancia y pueden modificar la conducta registrada (reactividad). Conviene combinar fuentes.

El estadio de cambio. Saber qué hace una persona no basta: hay que saber si está dispuesta a cambiar. El **modelo transteórico** de Prochaska y DiClemente (1983), que incorporó más tarde el estadio de preparación (Prochaska, DiClemente y Norcross, 1992), describe el cambio de conducta como un proceso en etapas:

Estadio	Situación de la persona	Ejemplo (tabaco)
Precontemplación	No se plantea cambiar en un futuro próximo	«Fumo y no tengo ningún problema»
Contemplación	Se plantea cambiar, pero aún no lo ha intentado	«Debería dejarlo este año»
Preparación	Tiene intención inmediata y da pequeños pasos	Ha pedido cita en la unidad de tabaquismo
Acción	Ha cambiado la conducta recientemente	Lleva dos meses sin fumar
Mantenimiento	Consolida el cambio y previene recaídas	Lleva más de un año sin fumar

El estadio se evalúa con preguntas breves sobre la intención y la conducta reciente, o con cuestionarios como la **URICA**. La utilidad práctica es clara: a una persona en precontemplación no le sirve un plan detallado para dejar de fumar; le sirve antes una intervención que aumente su motivación. La entrevista motivacional se trata en Evaluación Psicológica I.

Adherencia al tratamiento. Muchas intervenciones fracasan porque no se siguen. La **adherencia** es el grado en que la conducta del paciente coincide con las indicaciones acordadas con el profesional: tomar la medicación, seguir una dieta, acudir a las revisiones. Se evalúa con autoinformes y entrevistas, con recuentos de comprimidos, con registros de dispensación en la farmacia o con marcadores biológicos. Ningún método es perfecto: los pacientes tienden a declarar más adherencia de la real, y los recuentos no garantizan que el fármaco se haya tomado.

Locus de control de la salud. Otra variable relacionada con la prevención es la creencia sobre quién controla la propia salud: uno mismo, los profesionales o el azar. Quien atribuye su salud a la suerte tiende a implicarse menos en conductas preventivas. Se mide con escalas multidimensionales de locus de control de la salud.

Un ejemplo: Lucía tiene hipertensión. Su autorregistro muestra que apenas camina, y sus respuestas sobre la intención de cambio la sitúan en contemplación. La evaluación no solo describe sus hábitos: indica por dónde empezar.

16.4 Estrés, afrontamiento, apoyo social, ansiedad y depresión hospitalarias

Las variables de esta sección suelen organizarse en un modelo secuencial. Las **características personales** influyen en cómo se perciben las situaciones; la situación percibida como amenazante genera **estrés**; la persona responde con **estrategias de afrontamiento**; y el resultado se refleja en su **estado emocional** y su **salud**. El **apoyo social** actúa a lo largo de todo el proceso, amortiguando el impacto del estrés.

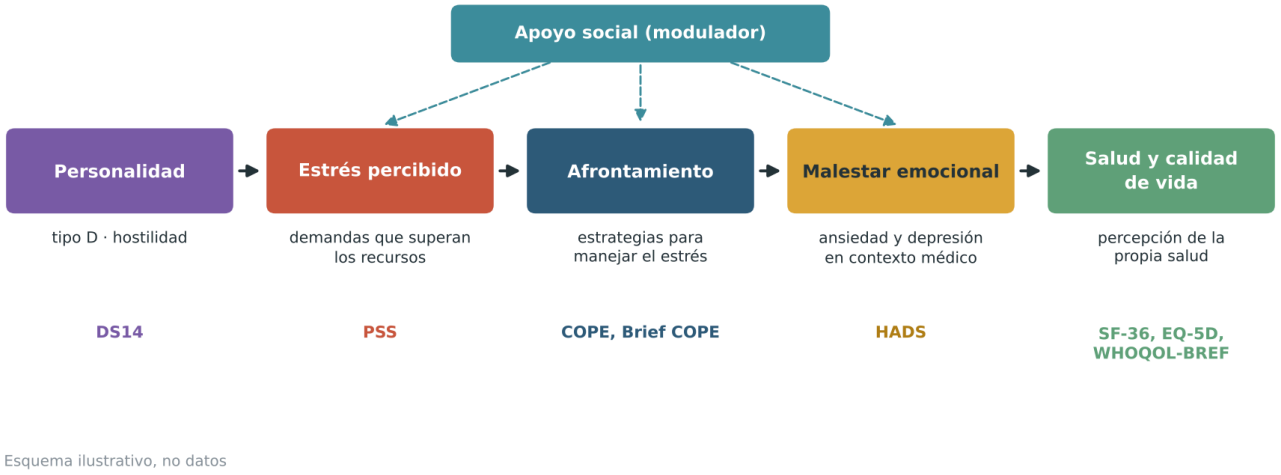


Figura 16.1. **Modelo de evaluación en psicología de la salud.** Secuencia personalidad → estrés percibido → afrontamiento → malestar emocional → salud y calidad de vida, con sus instrumentos (DS14; PSS; COPE y Brief COPE; HADS; SF-36, EQ-5D y WHOQOL-BREF) y el apoyo social como modulador de todo el proceso. Elaboración propia.

Como muestra la figura 16.1, cada caja del modelo tiene su instrumento de referencia.

Estrés percibido. La perspectiva actual, basada en el modelo transaccional de Lazarus y Folkman (1984), entiende el estrés como el resultado de la **valoración** que hace la persona: una situación es estresante cuando se percibe como amenazante y se juzga que los recursos propios no bastan. Por eso tiene sentido medir el estrés **percibido**, no solo los acontecimientos vividos. La **PSS** (*Perceived Stress Scale*; Cohen, Kamarck y Mermelstein, 1983) pregunta con qué frecuencia la persona ha sentido su vida como impredecible, incontrolable o sobrecargada durante el último mes. En la adaptación española de Remor (2006), con 440 participantes, la versión de 14 ítems obtuvo un α de 0,81 y la de 10 ítems, de 0,82.

Afrontamiento. El **afrontamiento** son los esfuerzos cognitivos y conductuales para manejar una situación estresante (Lazarus y Folkman, 1984). Se distinguen estrategias **centradas en el problema** (planificar, buscar información, actuar) y **centradas en la emoción** (buscar consuelo, reinterpretar, desahogarse), además de estrategias de evitación, como la negación. El **COPE** (Carver, Scheier y Weintraub, 1989) evalúa un amplio abanico de estrategias, y su versión abreviada, el **Brief COPE**, se usa mucho con pacientes por su brevedad. Ninguna estrategia es buena o mala en sí: centrarse en el problema ayuda cuando la situación es controlable, y aceptar o reinterpretar, cuando no lo es.

Apoyo social. Conviene distinguir el apoyo **estructural** (tamaño y frecuencia de contacto de la red) del **funcional** (ayuda emocional, material o informativa que se obtiene), y el apoyo **percibido** del **recibido**. El que más se relaciona con la salud es el percibido: sentir que habrá alguien disponible si se necesita. Se evalúa con cuestionarios como el de apoyo social del estudio MOS o el Duke-UNC.

Ansiedad y depresión en pacientes médicos. Evaluar el malestar emocional en una persona con una enfermedad física plantea un problema: síntomas como el cansancio, el insomnio o la pérdida de apetito pueden deberse a la propia enfermedad. La **HADS** (*Hospital Anxiety and Depression Scale*; Zigmond y Snaith, 1983) resuelve este problema **excluyendo los síntomas somáticos**. Tiene **14 ítems**, 7 de ansiedad y 7 de depresión, cada uno puntuado de 0 a 3. En la versión española, la consistencia interna es de aproximadamente 0,86 en cada subescala (Quintana et al., 2003). Es una herramienta de **cribado**: una puntuación alta indica que conviene una evaluación más completa, no establece un diagnóstico. Los criterios diagnósticos de los trastornos de ansiedad y depresivos se estudian en Psicopatología.

Un ejemplo: Rosa, en tratamiento con quimioterapia, está muy cansada, pero puntúa bajo en la subescala de depresión de la HADS porque esta no pregunta por el cansancio, sino, entre otras cosas, por la capacidad de disfrutar. Su malestar físico no se confunde con un trastorno del estado de ánimo.

Consenso y debate

Consenso: la calidad de vida relacionada con la salud es una medida de la percepción del paciente y complementa los indicadores clínicos. El SF-36 es el instrumento genérico de referencia, con buena consistencia interna en su versión española salvo en la escala de Función Social (Alonso, Prieto y Antó, 1995). Dentro del patrón tipo A, la hostilidad es el componente asociado al riesgo coronario; la asociación del patrón global, observada en el WCGS, no se replicó en el MRFIT. En pacientes con enfermedad física conviene usar instrumentos que no dependan de síntomas somáticos, como la HADS (Zigmond y Snaith, 1983).

Debate: el valor pronóstico de la personalidad tipo D, porque las réplicas han dado resultados más débiles que los estudios iniciales de Denollet.

Mito frecuente

Mito: «Las personas que reprimen sus emociones, la llamada personalidad tipo C, tienen más probabilidades de desarrollar cáncer».

Realidad: la evidencia que relaciona este estilo con la aparición o la evolución del cáncer es débil. Sucede algo parecido a lo que ocurrió con el tipo A: un patrón amplio, muy difundido, que no resistió los estudios de replicación, como el MRFIT frente al WCGS. Además, la idea tiene un coste: puede hacer que los pacientes se sientan responsables de su enfermedad por «no haber expresado» lo que sentían.

Conceptos clave

Concepto	Definición
Calidad de vida relacionada con la salud	Valoración subjetiva del impacto de la salud en el funcionamiento físico, emocional y social
Instrumento genérico	Medida de CVRS aplicable a cualquier población, que permite comparar enfermedades
SF-36	Cuestionario genérico de 36 ítems, 8 escalas y 2 componentes sumario (Ware y Sherbourne, 1992)
Patrón de conducta tipo A	Urgencia temporal, competitividad y hostilidad; solo la hostilidad mantiene apoyo como riesgo
Personalidad tipo D	Combinación de afectividad negativa e inhibición social, evaluada con la DS14 (Denollet)
Modelo transteórico	Describe el cambio de conducta en estadios, de la precontemplación al mantenimiento
Afrontamiento	Esfuerzos cognitivos y conductuales para manejar una situación estresante
HADS	Escala de 14 ítems de ansiedad y depresión sin síntomas somáticos (Zigmond y Snaith, 1983)

Clave PIR

Prioridad media. Se pregunta la estructura del SF-36 (8 escalas y 2 componentes sumario), qué rasgos definen los tipos A y D y qué instrumento corresponde a cada uno, por qué la HADS excluye los síntomas somáticos y en qué estadio del modelo transteórico se encuentra una persona a partir de un caso. Trampas típicas: creer que el SF-36 mide la salud objetiva, afirmar que el patrón tipo A completo es un factor de riesgo confirmado (lo es la hostilidad) y confundir contemplación con preparación.

Autoevaluación

1. El SF-36 se organiza en…
a) 5 dimensiones y una escala analógico-visual
b) 8 escalas y 2 componentes sumario
c) 4 dominios, entre ellos el de ambiente

2. La HADS excluye los síntomas somáticos porque…
a) estos síntomas tienen menor fiabilidad que los cognitivos
b) la escala se diseñó solo para población general sana
c) en pacientes médicos pueden deberse a la enfermedad física

3. Según la evidencia acumulada, el componente del patrón tipo A asociado al riesgo coronario es…
a) la hostilidad
b) la competitividad
c) la urgencia temporal

4. La DS14 evalúa la personalidad tipo D mediante dos subescalas:
a) afectividad negativa e inhibición social
b) hostilidad cínica y urgencia temporal
c) supresión de la ira y complacencia

5. Marta fuma y dice que debería dejarlo este año, pero todavía no ha hecho nada para conseguirlo. Según el modelo transteórico, está en…
a) precontemplación
b) contemplación
c) acción

Soluciones

1 b. Las 5 dimensiones con escala visual corresponden al EQ-5D y los 4 dominios, al WHOQOL-BREF. **2 c.** El cansancio o el insomnio pueden deberse a la enfermedad y no a un trastorno emocional. **3 a.** El patrón global no se replicó en el MRFIT; la hostilidad sí mantiene apoyo. **4 a.** Las otras opciones corresponden a los tipos A y C. **5 b.** Se plantea cambiar, pero sin intención inmediata ni pasos concretos, que definirían la preparación.

Apéndices

Estudios y datos clave

Estudio o instrumento	Dato o idea central	Unidad
National Research Council (2003)	El polígrafo discrimina por encima del azar en incidentes concretos, pero registra activación y no engaño; en cribados con tasa base baja genera muchos falsos positivos	1
Osgood, Suci y Tannenbaum (1957)	Diferencial semántico: tres factores del significado connotativo (evaluación, potencia y actividad)	2
Kelly (1955)	Técnica de rejilla: elementos × constructos bipolares, a partir de la teoría de los constructos personales	2
Rorschach (1921); Exner (1974); Meyer et al. (2011)	Diez láminas; Sistema Comprehensivo; R-PAS con variables elegidas por su apoyo empírico	3
Morgan y Murray (1935)	TAT: historias ante láminas, según el modelo de necesidades y presiones	3
Lilienfeld, Wood y Garb (2000)	Pocos índices del Rorschach y del TAT tienen apoyo; los signos gráficos casi ninguno	4
Mihura et al. (2013)	65 variables del Sistema Comprehensivo: r = 0,27 con criterios externos frente a 0,08 con autoinformes; 30 variables con buen apoyo	4
Spearman (1904); Thurstone (1938); Carroll (1993)	Factor g; aptitudes mentales primarias; modelo de tres estratos, base del CHC	5
Waterhouse (2006); Pashler et al. (2008)	Falta apoyo empírico para las inteligencias múltiples y para los estilos de aprendizaje	5
Binet y Simon (1905); Stern (1912); Terman (1916); Wechsler (1939)	Primera escala; cociente intelectual; Stanford-Binet; CI de desviación	6
Trahan et al. (2014)	Efecto Flynn: 285 estudios, ≈ 2,3 puntos de CI por década	6
Bratsberg y Rogeberg (2018)	Más de 730.000 reclutas noruegos: el efecto Flynn y su inversión desde la cohorte de 1975 tienen origen ambiental	6
Ritchie y Tucker-Drob (2018)	Cada año adicional de escolarización aporta entre 1 y 5 puntos de CI	6
WAIS-IV (España, 2012); WAIS-5 (EE. UU., 2024); WISC-V (España, 2015)	De 4 a 5 índices primarios: el Razonamiento Perceptivo se divide en Visoespacial y Razonamiento Fluido	7
Raven (1938)	Matrices progresivas: prototipo de inteligencia fluida y de g, con carga cultural reducida, no nula	8
Paulhus (1984)	Deseabilidad social: autoengaño y manejo de la impresión	9
Hathaway y McKinley (1943)	MMPI construido por el método empírico de criterio externo	10
MMPI-3 (2020; España, 2026)	335 ítems y 52 escalas	10

Estudio o instrumento	Dato o idea central	Unidad
Costa y McCrae (1992)	NEO-PI-R: 5 factores × 6 facetas, 240 ítems	11
Krueger et al. (2012)	PID-5: 220 ítems, 25 facetas y 5 dominios del modelo alternativo del DSM-5	11
Broca (1861); Wernicke (1874); Luria (1962)	Localización del lenguaje; sistemas funcionales y evaluación cualitativa	12
Peña-Casanova et al. (2009)	NEURONORMA: normas españolas conjuntas para mayores de 49 años, ajustadas por edad y escolaridad	12
Nasreddine et al. (2005)	MoCA frente a MMSE en el deterioro cognitivo leve: sensibilidad del 90 % frente al 18 %	13
Holland (1959/1997)	Seis tipos en un hexágono; congruencia, consistencia y diferenciación	14
Likert (1932); Thurstone y Chave (1929); Guttman (1944)	Escalas sumativas, de intervalos aparentemente iguales y acumulativas	15
Oswald et al. (2013)	El IAT predice la discriminación de forma débil (r ≈ 0,15)	15
Alonso, Prieto y Antó (1995)	Versión española del SF-36: 8 escalas y 2 componentes sumario	16
Remor (2006)	Versión española de la PSS: α ≈ 0,81–0,82	16

Mitos y correcciones

Mito	Corrección	Unidad
«El polígrafo detecta cuándo alguien miente»	Registra activación fisiológica, que no es específica del engaño (NRC, 2003)	1
«Las técnicas subjetivas son pura opinión y no pueden analizarse de forma cuantitativa»	El diferencial semántico y la rejilla admiten índices y análisis factoriales o de componentes	2
«El Rorschach no tiene ninguna validez»	Algunas variables, sobre todo las de distorsión perceptiva y pensamiento desorganizado, tienen validez aceptable (Mihura et al., 2013)	3
«Las técnicas proyectivas son tan fiables y válidas como los tests psicométricos»	La mayoría de sus índices carece de apoyo y de validez incremental (Lilienfeld et al., 2000)	4
«La teoría de las inteligencias múltiples está avalada empíricamente»	Las «inteligencias» académicas saturan en g (Visser, Ashton y Vernon, 2006) y faltan pruebas de su independencia (Waterhouse, 2006)	5
«El CI es inmutable»	Es estable, pero cambia con la escolarización, entre generaciones (efecto Flynn) y por el error de medida	6
«Las escalas de Wechsler se pueden aplicar en grupo»	Son de aplicación individual, como el Stanford-Binet y el K-BIT	7
«Las matrices de Raven son un test libre de cultura»	Reducen la carga cultural, pero no la eliminan	8

Mito	Corrección	Unidad
«Las escalas de validez detectan cuándo una persona miente»	Detectan patrones de respuesta atípicos, que hay que interpretar	9
«El MMPI se construyó mediante análisis factorial»	Se construyó por el método empírico de criterio externo	10
«El MBTI es un buen test de personalidad»	Dicotomiza dimensiones continuas, tiene baja estabilidad de tipo y poca validez predictiva	11
«Con la neuroimagen, la evaluación neuropsicológica ya no es necesaria»	La neuroimagen localiza lesiones; la evaluación describe qué funciones están alteradas y cómo afectan a la vida diaria	12
«Si el MMSE sale normal, se puede descartar el deterioro cognitivo»	Tiene efecto techo y poca sensibilidad para el deterioro leve	13
«Un test vocacional dice para qué profesión vale una persona»	Evalúa intereses, no aptitudes ni éxito futuro; orienta, no decide	14
«El IAT revela los prejuicios ocultos y predice la conducta»	Tiene baja fiabilidad test-retest y predice la conducta de forma débil	15
«La personalidad tipo C causa cáncer»	La evidencia es débil e inconsistente	16

Bibliografía

Manuales de referencia

- Cohen, R. J., Schneider, W. J. y Tobin, R. M. (2022). *Psychological testing and assessment* (10.ª ed.). McGraw-Hill.
- Fernández-Ballesteros, R. (dir.) (2011). *Evaluación psicológica: conceptos, métodos y estudio de casos* (2.ª ed.). Pirámide.
- Groth-Marnat, G. y Wright, A. J. (2016). *Handbook of psychological assessment* (6.ª ed.). Wiley.
- Lezak, M. D., Howieson, D. B., Bigler, E. D. y Tranel, D. (2012). *Neuropsychological assessment* (5.ª ed.). Oxford University Press.
- Schneider, W. J. y McGrew, K. S. (2018). The Cattell-Horn-Carroll theory of cognitive abilities. En D. P. Flanagan y E. M. McDonough (Eds.), *Contemporary intellectual assessment: Theories, tests, and issues* (4.ª ed., pp. 73–163). Guilford.

Manuales de los tests (adaptaciones españolas citadas)

- Ben-Porath, Y. S. y Tellegen, A. (2026). *MMPI-3. Inventario Multifásico de Personalidad de Minnesota-3* (P. Santamaría, adapt.). Hogrefe TEA Ediciones.
- Costa, P. T. y McCrae, R. R. (2008). *NEO PI-R. Inventario de Personalidad NEO Revisado* (3.ª ed.; A. Cordero, A. Pamos y N. Seisdedos, adapt.). TEA Ediciones.
- Morey, L. C. (2011). *PAI. Inventario de Evaluación de la Personalidad* (M. Ortiz-Tallo, P. Santamaría, V. Cardenal y M. P. Sánchez, adapt.). TEA Ediciones.
- Wechsler, D. (2012). *WAIS-IV. Escala de inteligencia de Wechsler para adultos-IV*. Pearson.
- Wechsler, D. (2015). *WISC-V. Escala de inteligencia de Wechsler para niños-V*. Pearson.

Artículos seleccionados

- Alonso, J., Prieto, L. y Antó, J. M. (1995). La versión española del SF-36 Health Survey (Cuestionario de Salud SF-36): un instrumento para la medida de los resultados clínicos. *Medicina Clínica, 104*(20), 771–776.
- Bratsberg, B. y Rogeberg, O. (2018). Flynn effect and its reversal are both environmentally caused. *Proceedings of the National Academy of Sciences, 115*(26), 6674–6678.
- Flynn, J. R. (1987). Massive IQ gains in 14 nations: What IQ tests really measure. *Psychological Bulletin, 101*(2), 171–191.
- Forscher, P. S., Lai, C. K., Axt, J. R., Ebersole, C. R., Herman, M., Devine, P. G. y Nosek, B. A. (2019). A meta-analysis of procedures to change implicit measures. *Journal of Personality and Social Psychology, 117*(3), 522–559.
- Greenwald, A. G., McGhee, D. E. y Schwartz, J. L. K. (1998). Measuring individual differences in implicit cognition: The implicit association test. *Journal of Personality and Social Psychology, 74*(6), 1464–1480.
- Krueger, R. F., Derringer, J., Markon, K. E., Watson, D. y Skodol, A. E. (2012). Initial construction of a maladaptive personality trait model and inventory for DSM-5. *Psychological Medicine, 42*(9), 1879–1890.
- Lilienfeld, S. O., Wood, J. M. y Garb, H. N. (2000). The scientific status of projective techniques. *Psychological Science in the Public Interest, 1*(2), 27–66.
- Mihura, J. L., Meyer, G. J., Dumitrascu, N. y Bombel, G. (2013). The validity of individual Rorschach variables: Systematic reviews and meta-analyses of the Comprehensive System. *Psychological Bulletin, 139*(3), 548–605.
- Muñiz, J., Hernández, A. y Fernández-Hermida, J. R. (2020). Utilización de los tests en España: el punto de vista de los psicólogos. *Papeles del Psicólogo, 41*(1), 1–15.
- Nasreddine, Z. S., Phillips, N. A., Bédirian, V., Charbonneau, S., Whitehead, V., Collin, I., Cummings, J. L. y Chertkow, H. (2005). The Montreal Cognitive Assessment, MoCA: A brief screening tool for mild cognitive impairment. *Journal of the American Geriatrics Society, 53*(4), 695–699.
- Oswald, F. L., Mitchell, G., Blanton, H., Jaccard, J. y Tetlock, P. E. (2013). Predicting ethnic and racial discrimination: A meta-analysis of IAT criterion studies. *Journal of Personality and Social Psychology, 105*(2), 171–192.
- Pashler, H., McDaniel, M., Rohrer, D. y Bjork, R. (2008). Learning styles: Concepts and evidence. *Psychological Science in the Public Interest, 9*(3), 105–119.
- Paulhus, D. L. (1984). Two-component models of socially desirable responding. *Journal of Personality and Social Psychology, 46*(3), 598–609.
- Peña-Casanova, J. et al. (2009). Spanish Multicenter Normative Studies (NEURONORMA Project): Methods and sample characteristics. *Archives of Clinical Neuropsychology, 24*(4), 307–319.
- Pittenger, D. J. (2005). Cautionary comments regarding the Myers-Briggs Type Indicator. *Consulting Psychology Journal: Practice and Research, 57*(3), 210–221.
- Quintana, J. M., Padierna, A., Esteban, C., Arostegui, I., Bilbao, A. y Ruiz, I. (2003). Evaluation of the psychometric characteristics of the Spanish version of the Hospital Anxiety and Depression Scale. *Acta Psychiatrica Scandinavica, 107*(3), 216–221.
- Remor, E. (2006). Psychometric properties of a European Spanish version of the Perceived Stress Scale (PSS). *The Spanish Journal of Psychology, 9*(1), 86–93.
- Ritchie, S. J. y Tucker-Drob, E. M. (2018). How much does education improve intelligence? A meta-analysis. *Psychological Science, 29*(8), 1358–1369.
- Trahan, L. H., Stuebing, K. K., Fletcher, J. M. y Hiscock, M. (2014). The Flynn effect: A meta-analysis. *Psychological Bulletin, 140*(5), 1332–1360.
- Visser, B. A., Ashton, M. C. y Vernon, P. A. (2006). Beyond g: Putting multiple intelligences theory to the test. *Intelligence, 34*(5), 487–502.

- Waterhouse, L. (2006). Multiple intelligences, the Mozart effect, and emotional intelligence: A critical review. *Educational Psychologist, 41*(4), 207–225.
- Zigmond, A. S. y Snaith, R. P. (1983). The Hospital Anxiety and Depression Scale. *Acta Psychiatrica Scandinavica, 67*(6), 361–370.

Documentos institucionales

- National Research Council (2003). *The polygraph and lie detection*. National Academies Press.

Créditos de las ilustraciones

Las figuras con gráficos, esquemas y tablas son de **elaboración propia** de SAIMAP. Las que llevan la indicación «Esquema ilustrativo, no datos» representan la forma general de un modelo o de un resultado y no datos reales. Los perfiles, ítems y puntuaciones de ejemplo están marcados como inventados. No se reproduce ningún ítem ni material protegido de los tests. Las cifras reales proceden de los estudios citados en el pie de cada figura.

Las fotografías y grabados históricos proceden de **Wikimedia Commons**. SAIMAP ha reunido algunos de ellos en láminas (figuras de las unidades 6 y 12) y los ha redimensionado; la fotografía de Phineas Gage se ha recortado. No se ha alterado su contenido. La imagen con licencia CC BY-SA se reutiliza bajo la misma licencia.

Figura	Archivo original (Wikimedia Commons)	Autor	Licencia
U1 · Cronoscopio de Hipp	Hipp Chronoscope, c. 1890, view 1 - Museum of Science and Industry (Chicago) - DSC06506.JPG	Daderot	CC0 1.0
U1 · Polígrafo Keeler	November 2016- Polygraph Machine - Jack Ruby.jpg	Federal Bureau of Investigation	Dominio público
U3 · Hermann Rorschach	Hermann Rorschach c.1910.JPG	Anónimo (hacia 1910)	Dominio público
U6 · Galton	Sir Francis Galton, circa 1890.jpg	Graham's Art Studios	Dominio público
U6 · Binet	Alfred Binet.jpg	Fotógrafo no identificado (siglo XIX)	Dominio público
U6 · Stern	WLStern.jpg	Autor desconocido (principios del siglo XX)	Dominio público
U6 · Terman	Lewis Madison Terman.jpg	Autor desconocido (1923)	Dominio público
U6 · Army Alpha	American soldiers taking a predecessor of the Army Alpha - November 1917.jpg	Departamento de Guerra de EE. UU.	Dominio público
U12 · Broca	Paul Broca 2.jpg	Autor desconocido	Dominio público
U12 · Cerebro de Leborgne	Cerveau de Louis Victor Leborgne dit Tantan 1.jpg	Selbymay	CC BY-SA 4.0
U12 · Wernicke	Carl Wernicke.JPG	Max Glauer (hacia 1900)	Dominio público
U12 · Phineas Gage (recortada)	Phineas Gage GageMillerPhoto2010-02-17 Unretouched Color Cropped.jpg	Autor desconocido	Dominio público

Figura	Archivo original (Wikimedia Commons)	Autor	Licencia
Resto de figuras	—	Elaboración propia (SAIMAP)	Libre uso educativo con atribución